Cvičenie: Kvadratické programovanie

Optimalizácia a optimálne riadenie

Problém:

Minimalizujte kvadratickú formu dvoch premenných:

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c$$

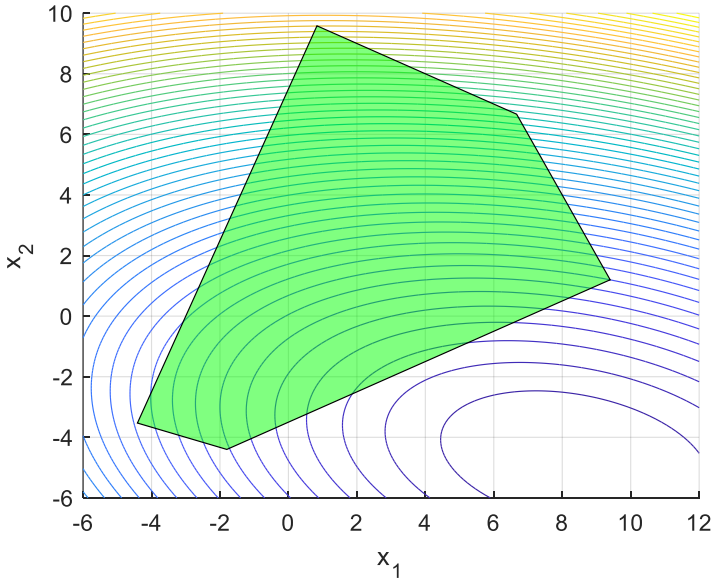
$$A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 3 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$

Uvažujte ohraničenia lineárnymi nerovnicami v tvare:

$$A_c x \leq b_c$$

$$A_c = \begin{pmatrix} 1 & -2 \\ -5 & 2 \\ 2 & 1 \\ 0.5 & 1 \\ -1 & -3 \end{pmatrix} b_c = \begin{pmatrix} 7 \\ 15 \\ 20 \\ 10 \\ 15 \end{pmatrix}$$

Ohraničenia predstavujú nasledovný polygón:



Karush–Kuhn–Tuckerove (KKT) podmienky pre kvadratické programovanie sú nasledovné:

$$\nabla_x L(x^*, \lambda^*) = Ax^* + b + {A_c}^T \lambda^* = \mathbf{0}$$

$$A_c x^* - b_c \leq \mathbf{0}$$

$$\lambda^* \geq \mathbf{0}$$

$$\mathrm{diag}(\lambda^*)(A_c x^* - b_c) = \mathbf{0}$$

- Spojený vektor hľadaných premenných $\theta \in \mathbb{R}^{n+p+p}$ bude

$$\theta = \begin{bmatrix} x \\ \lambda \\ s \end{bmatrix}$$

$x \in \mathbb{R}^n$ je vektor optimalizovaných premenných

$\lambda \in \mathbb{R}^p$ je vektor Lagrangeových multiplikátorov (pomocné premenné)

$s \in \mathbb{R}^p$ je vektor ktorý predstavuje mieru splnenia podmienok nerovníc

$$A_c x - b_c = -s$$

- Spojená funkcia reziduí bude $r(\theta) \in \mathbb{R}^{n+p+p}$

$$r(\theta) = \begin{bmatrix} r_1(\theta) \\ r_2(\theta) \\ r_3(\theta) \end{bmatrix} = \begin{bmatrix} Ax + b + {A_c}^T \lambda \\ A_c x - b_c + s \\ \mathrm{diag}(\lambda) s - \mu \mathbf{1} \end{bmatrix}$$

- Jakobián reziduí $\nabla r(\theta) \in \mathbb{R}^{n+p+p \times n+p+p}$ bude

$$\nabla r(\theta) = \begin{pmatrix} A & {A_c}^T & \mathbf{0} \\ A_c & \mathbf{0} & I \\ \mathbf{0} & \mathrm{diag}(s) & \mathrm{diag}(\lambda) \end{pmatrix}$$

- Cieľom je nájsť také θ^* že $r(\theta^*) = \mathbf{0}$ a teda všetky reziduá budú nulové
- Použijeme iteratívny algoritmus – Newtonovu metódu
- Krok $\Delta\theta_{k+1}$ nech spĺňa sústavu lineárnych rovníc

$$\nabla r(\theta_k) \Delta\theta_{k+1} = -r(\theta_k)$$

$$\begin{pmatrix} A & {A_c}^T & \mathbf{0} \\ A_c & \mathbf{0} & I \\ \mathbf{0} & \mathrm{diag}(s_k) & \mathrm{diag}(\lambda_k) \end{pmatrix} \begin{bmatrix} \Delta x_{k+1} \\ \Delta\lambda_{k+1} \\ \Delta s_{k+1} \end{bmatrix} = - \begin{bmatrix} Ax_k + b + {A_c}^T \lambda_k \\ A_c x_k - b_c + s_k \\ \mathrm{diag}(\lambda_k) s_k - \mu \mathbf{1} \end{bmatrix}$$

- Faktor μ môžeme zvoliť ako:

$$\mu = \frac{\lambda^T s}{2q}$$

- Nová aproximácia optima však musí spĺňať podmienky $\lambda_{k+1} \geq \mathbf{0}$, $s_{k+1} \geq \mathbf{0}$
- Definujme si preto skalár (tlmenie) $0 \leq \gamma \leq 1$ tak aby sme zabezpečili

$$\begin{pmatrix} \lambda_k + \gamma \Delta\lambda_{k+1} \\ s_k + \gamma \Delta s_{k+1} \end{pmatrix} \geq \mathbf{0}$$

- Odhad θ_{k+1} potom aktualizujeme ako

$$\theta_{k+1} = \theta_k + \gamma \Delta\theta_{k+1}$$

- Pokračujeme s novým KKT systémom až do splnenia podmienky (veľkosť rezidua)

$$\left(r(\theta_k)\right)^T r(\theta_k) < \epsilon$$

Úloha:

Použite skript *quadprog_scr*

Implementujte funkciu `optim_quadprog` (priečinok `optim_alg`):

```
function [x, x_log, s, lambda] = optim_quadprog(x_0, lambda_0, A, b, A_c, b_c,
eps, log)
```

Implementujte výpočet reziduí:

```
    r_1 = %TODO
    r_2 = %TODO
    r_3 = %TODO
```

Implementujte ukončovaciu podmienku:

```
if %TODO
        break;
end
```

Implementujte Jakobián a výpočet Newtonovho kroku:

```
   J=%TODO
   delta =%TODO
```

Implementujte výpočet aktualizácie riešenia

```
    theta=%TODO
```

Analyzujte a interpretujte „backstepping“ algoritmus:

```
if sum(theta(n_params+1:end) + delta(n_params+1:end) < 0)
        i = (1:length(theta)) > n_params & theta' + delta' < 0 & delta' < 0;
        gamma = 0.9 * min(-theta(i) ./ delta(i));
end
```

Analyzujte vplyv počiatočného odhadu optima na priebeh optimalizácie

Analyzujte vplyv počiatočného odhadu Lagrangeových multiplikátorov na priebeh optimalizácie

Riešenie:

