Účelové funkcie - skalárne funkcie viacerých premenných

Optimalizačná úloha

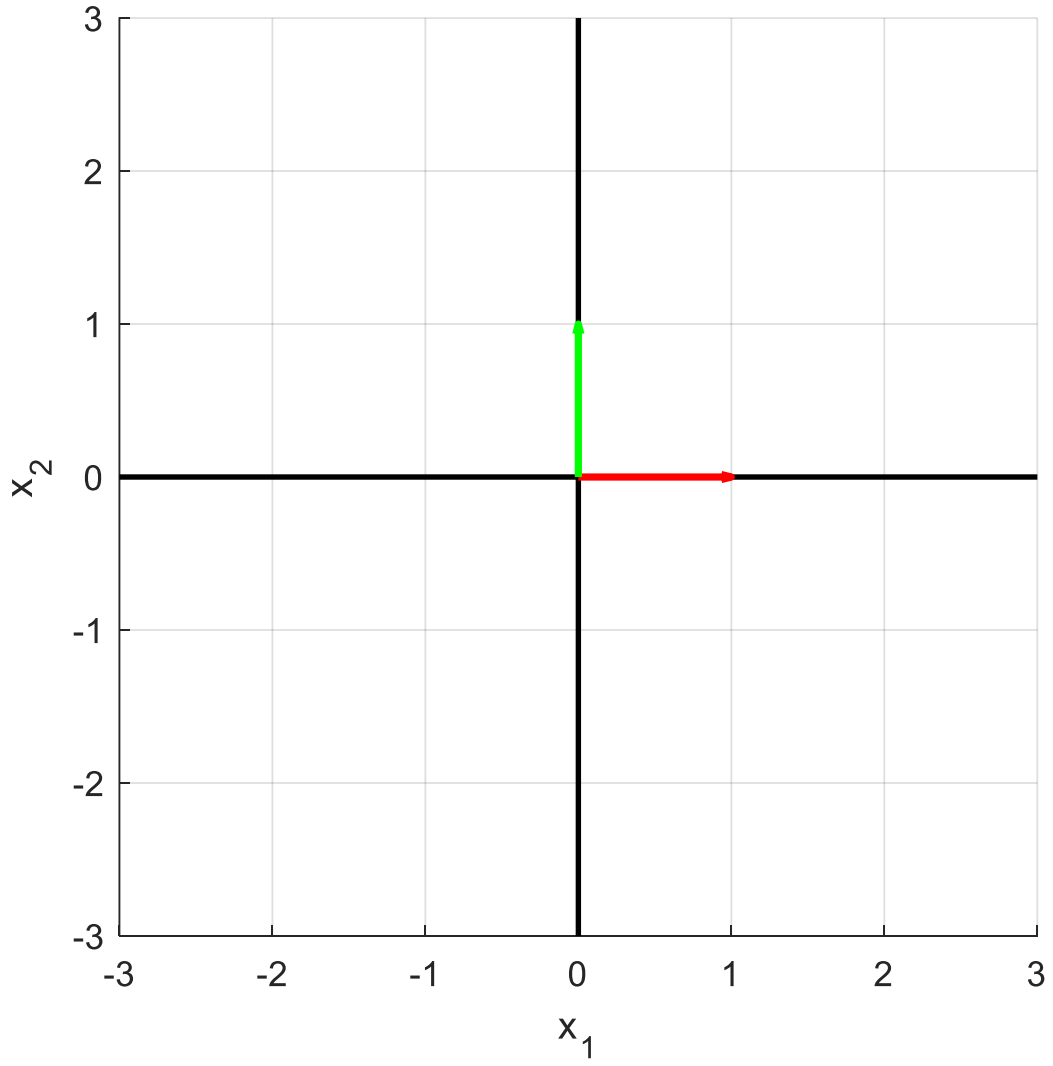
- Budeme uvažovať **skalárnu funkciu n premenných**
  - $J(x)$: $\mathbb{R}^n \to \mathbb{R}$ kde $x \in \mathbb{R}^n$ je vektor optimalizovaných premenných
  - **Premenné sú to čo môžeme ovplyvniť, zvoliť alebo zmeniť**
  - Skalárna funkcia znamená, že jej výstup/výsledok je reálne číslo

    $$J(x)\colon\ \mathbb{R}^n \to \mathbb{R}$$

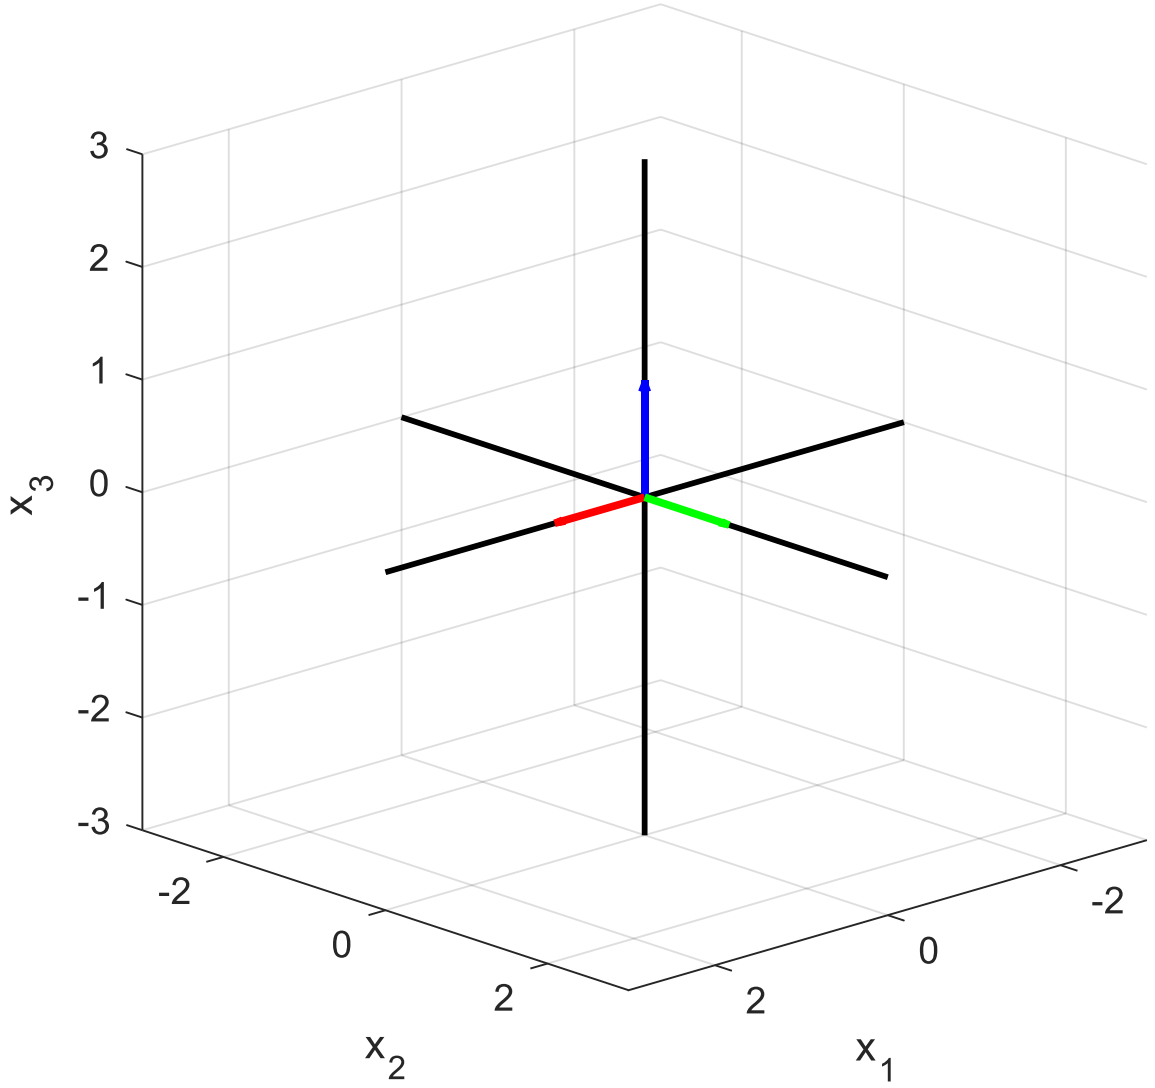
    znamená, že funkcia zobrazuje z $\mathbb{R}^n$ do $\mathbb{R}$
- Pohybujeme sa v n-rozmernom priestore reálnych čísel $\mathbb{R}^n$
- Každému bodu teda vieme priradiť jeho ohodnotenie účelovou funkciou

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix}$$

Priestor $\mathbb{R}^2$



Priestor $\mathbb{R}^3$



Optimalizačná úloha

- Funkcia $J(x)$ sa nazýva účelová, kriteriálna alebo fitness funkcia
- Účelová funkcia vyjadruje mieru našej „nespokojnosti“ s riešením
- Optimalizačná úloha kladie za cieľ nájsť minimum x^* funkcie $J(x)$ také že:

$$J(x^*) < J(x) \text{ pre všetky } x$$

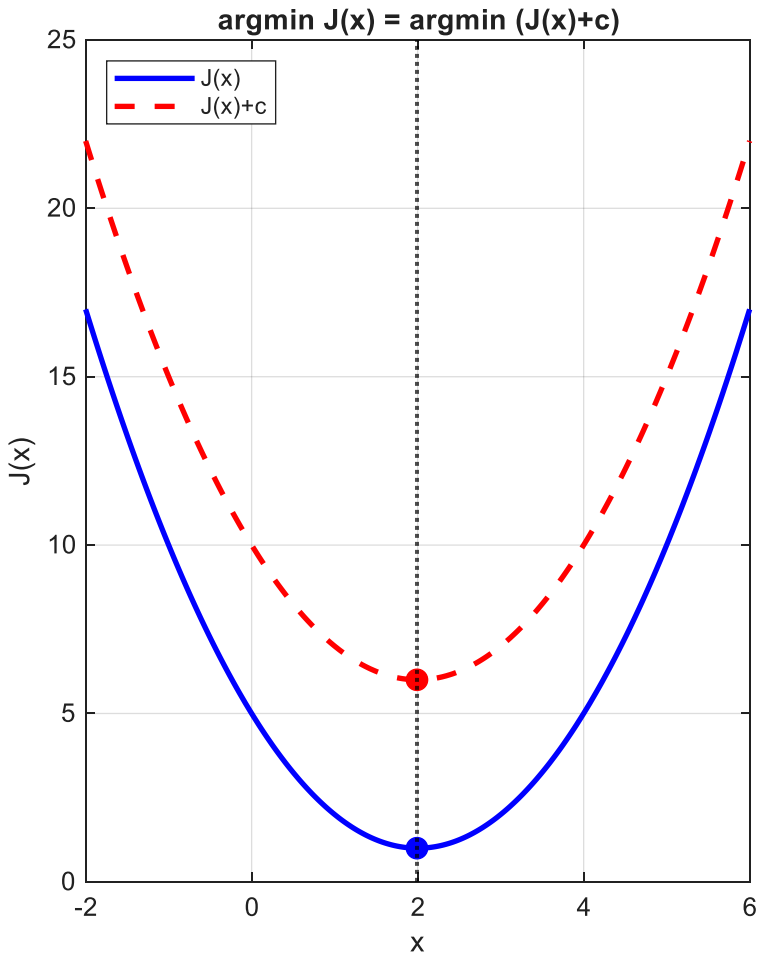
- Optimalizačnú úlohu značíme ako

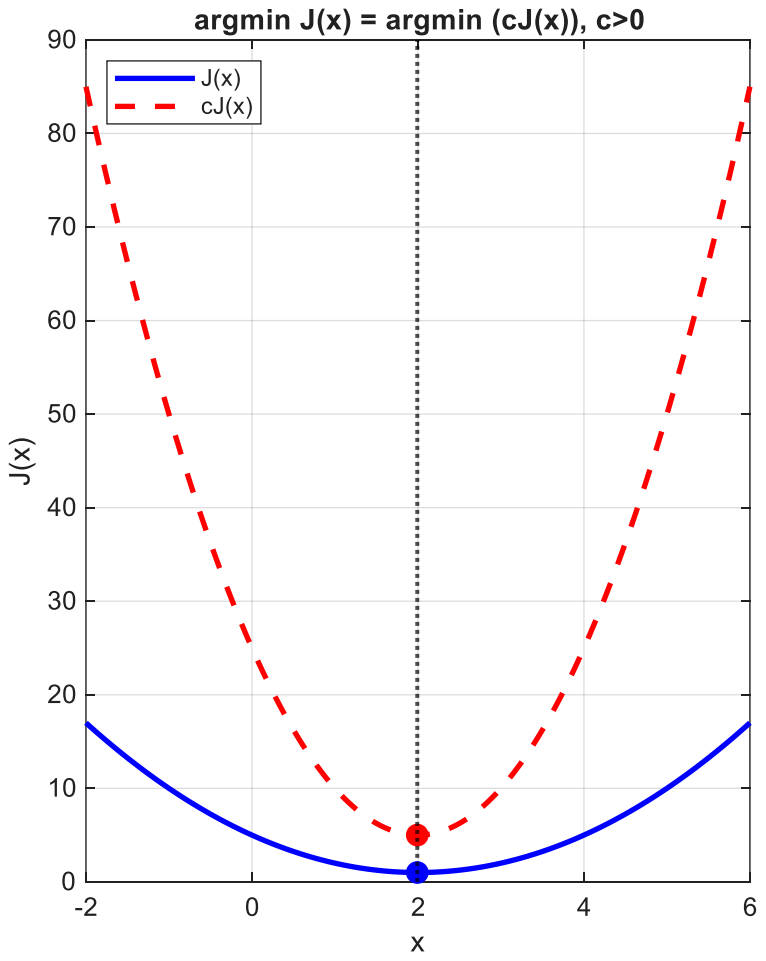
$$x^* = \arg\min_x J(x)$$

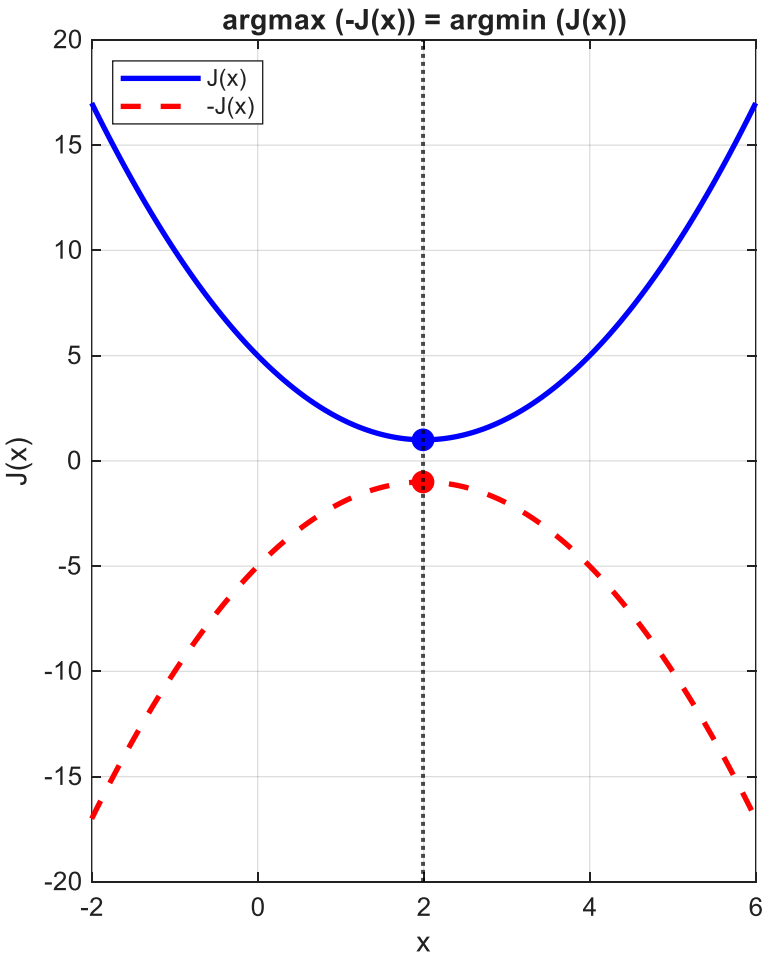
  teda hľadanie premenných (vektora) x, ktoré minimalizujú $J(x)$
- Cieľom nie je nájsť $J(x^*)$ ale x^*
- Platí nasledovné:

$$\arg\min_x J(x) = \arg\min_x \left(J(x) + c\right)$$
$$\arg\min_x J(x) = \arg\min_x \left(c \times J(x)\right)$$
$$\arg\max_x J(x) = \arg\min_x \left(-J(x)\right)$$

$$J(x) = (x-2)^2 + 1$$


argmin J(x) = argmin (J(x)+c)
J(x)
J(x)+c
J(x)
x


argmin J(x) = argmin (cJ(x)), c>0
J(x)
cJ(x)
J(x)
x


argmax (-J(x)) = argmin (J(x))
J(x)
-J(x)
J(x)
x

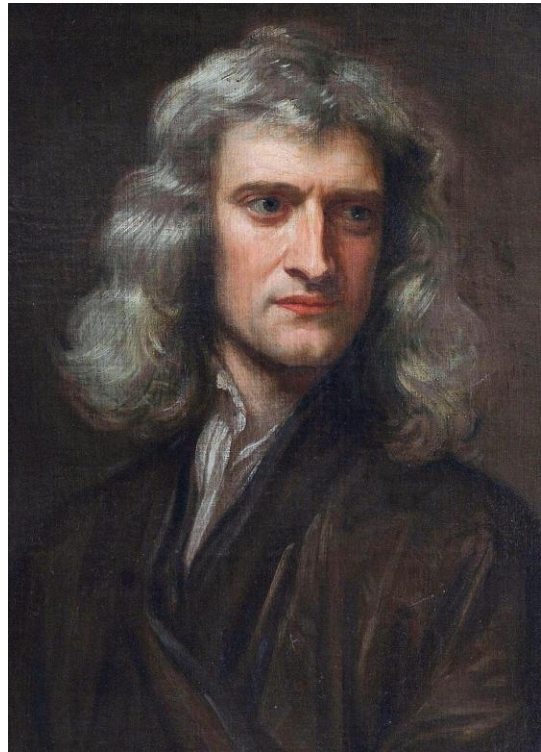
Derivácia skalárnej funkcie jednej premennej

- Majme funkciu jednej premennej $J(x)$: $\mathbb{R} \to \mathbb{R}$ kde $x \in \mathbb{R}$ je skalár
- Derivácia $\frac{\partial J(x)}{\partial x}$ vyjadruje mieru zmeny $J(x)$ pri veľmi malej zmene x
- Môžeme ju definovať ako limitu rozdielu (sprava alebo zľava):

$$\frac{\partial J(x)}{\partial x} = \lim_{\mathrm{d}x \to 0} \frac{J(x + \mathrm{d}x) - J(x)}{\mathrm{d}x} = \lim_{\mathrm{d}x \to 0} \frac{J(x) - J(x - \mathrm{d}x)}{\mathrm{d}x}$$

$\mathrm{d}x$ predstavuje nekonečne malú zmenu premennej-infinitezimálny počet (Newton a Leibniz)

- Deriváciu $\frac{\partial J(x)}{\partial x}$ môžeme interpretovať ako sklon dotyčnice (priamky) ku grafu funkcie v danom bode
  - Ak $\frac{\partial J(x)}{\partial x} > 0$ potom $J(x)$ s kladnou zmenou x rastie
  - Ak $\frac{\partial J(x)}{\partial x} < 0$ potom $J(x)$ s kladnou zmenou x klesá
  - Ak $\frac{\partial J(x)}{\partial x} = 0$ potom $J(x)$ sa nemení v okolí x



Druhá derivácia skalárnej funkcie jednej premennej

- Druhá derivácia $\frac{\partial^2 J(x)}{\partial x^2}$ vyjadruje mieru zmeny $\frac{\partial J(x)}{\partial x}$ pri veľmi malej zmene x
- Môžeme ju definovať ako limitu:

$$\frac{\partial^2 J(x)}{\partial x^2} = \frac{\partial}{\partial x}\left(\frac{\partial J(x)}{\partial x}\right) = \lim_{\mathrm{d}x \to 0} \frac{\frac{J(x+\mathrm{d}x)-J(x)}{\mathrm{d}x} - \frac{J(x)-J(x-\mathrm{d}x)}{\mathrm{d}x}}{\mathrm{d}x}$$

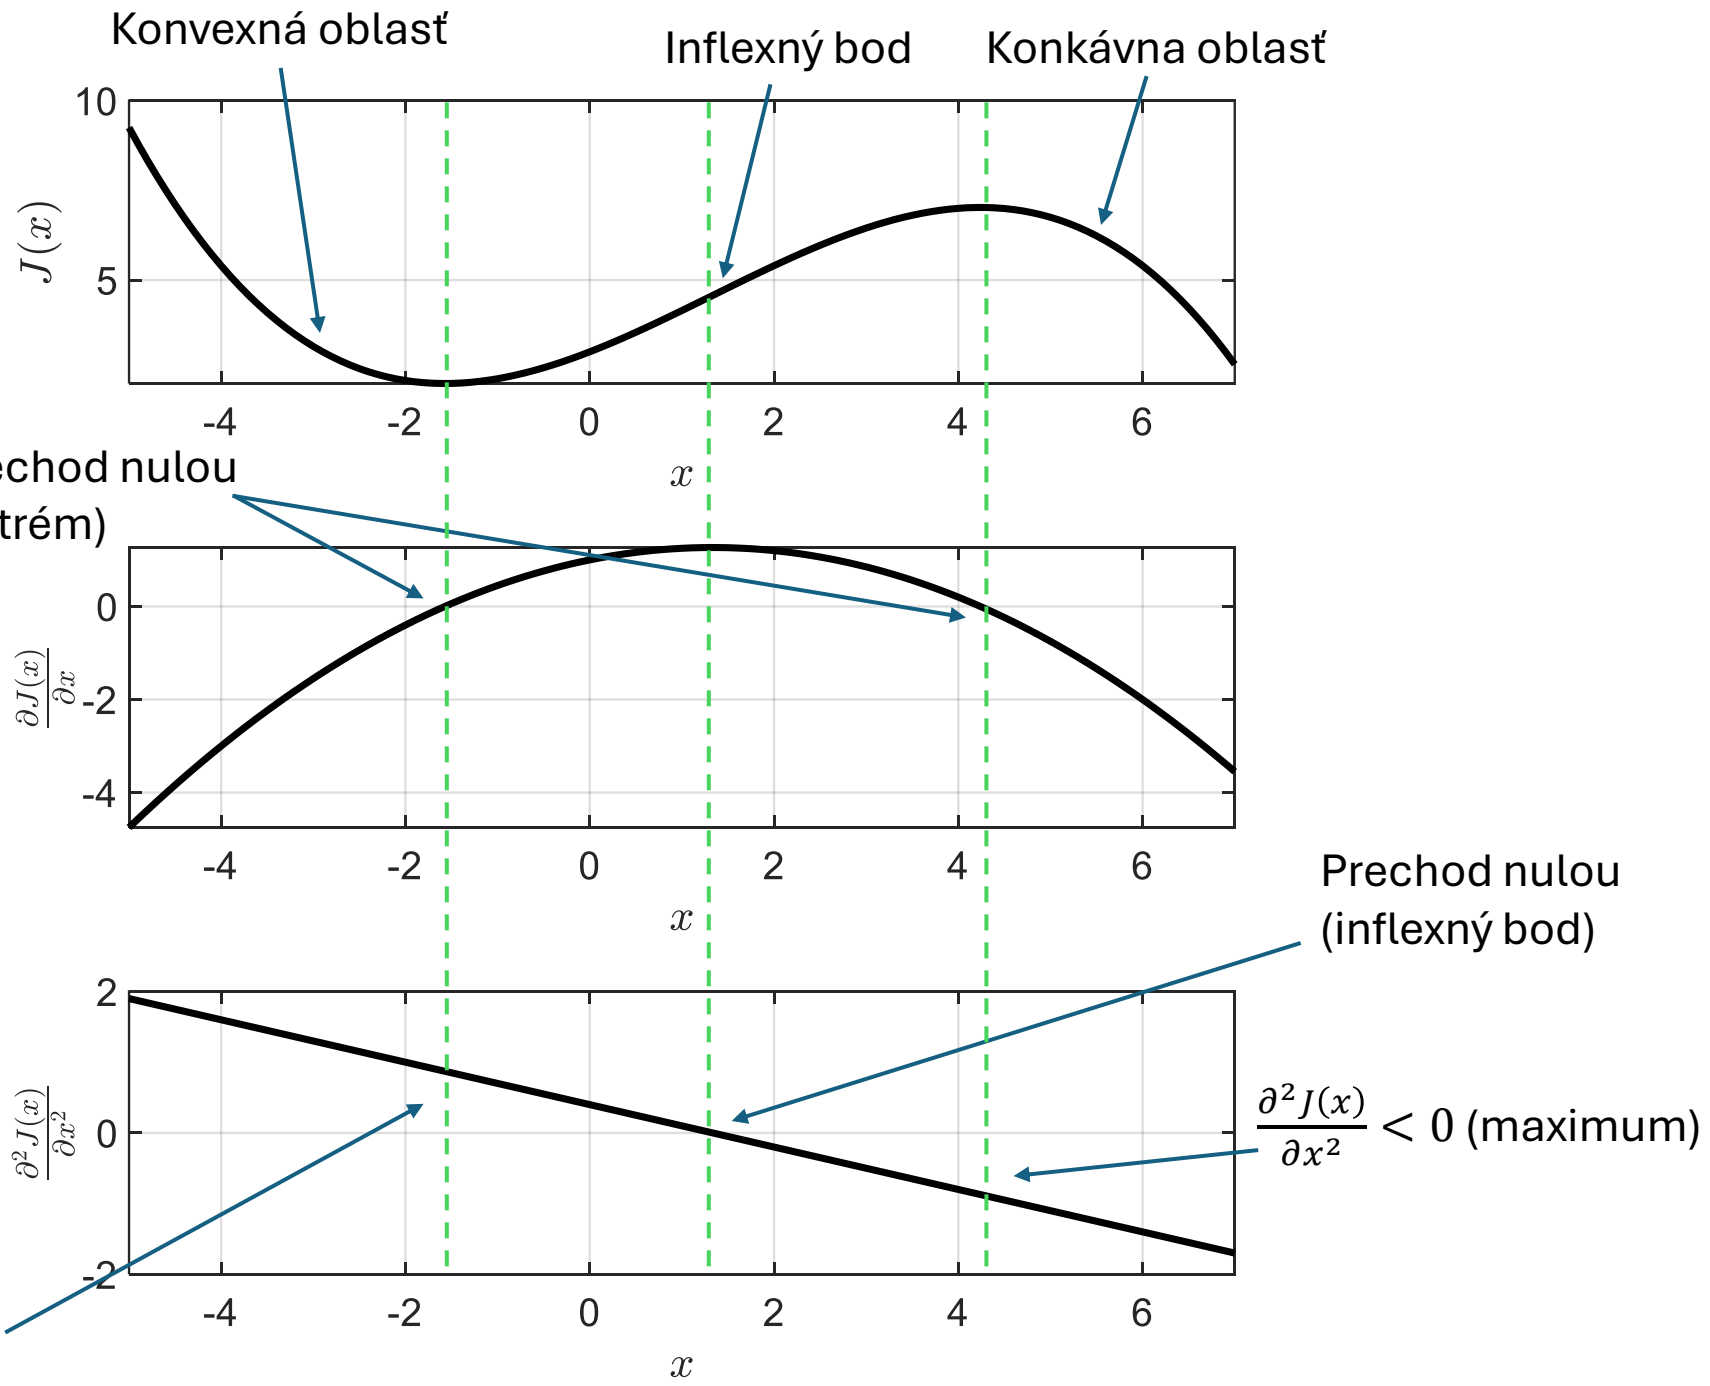
$$\frac{\partial^2 J(x)}{\partial x^2} = \lim_{\mathrm{d}x \to 0} \frac{J(x+\mathrm{d}x)+J(x-\mathrm{d}x)-2J(x)}{\mathrm{d}x^2}$$

- Definícia druhej derivácie využíva tri nekonečne blízke body x, $x+\mathrm{d}x$, $x-\mathrm{d}x$
  - Ak $\frac{\partial^2 J(x)}{\partial x^2} > 0$ potom $J(x)$ je v okolí x konvexná (graf sa ohýba nahor)
  - Ak $\frac{\partial^2 J(x)}{\partial x^2} < 0$ potom $J(x)$ je v okolí x konkávna (graf sa ohýba nadol)
  - Ak $\frac{\partial^2 J(x)}{\partial x^2} = 0$ potom $J(x)$ sa v okolí x dá dobre aproximovať priamkou a má inflexný bod (mení sa z konvexnej na konkávnu alebo naopak)

$$J(x) = -0.05\,x^3 + 0.2\,x^2 + x + 3$$

$$\frac{\partial J(x)}{\partial x} = -0.15\,x^2 + 0.4\,x + 1$$

$$\frac{\partial^2 J(x)}{\partial x^2} = -0.3\,x + 0.4$$



Základné objekty lineárnej algebry

- Sme v priestore reálnych čísel $\mathbb{R}$
- Maticu s m riadkami a n stĺpcami budeme označovať ako

$$A \in \mathbb{R}^{m \times n}$$

  - Prvok na i-tom riadku a j-tom stĺpci budeme označovať a_{ij}
  - Matica A potom bude mať štruktúru

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

- Ak transponujeme maticu $A \in \mathbb{R}^{m \times n}$ tak $A^T \in \mathbb{R}^{n \times m}$
- Ak platí, že $A = A^T$ a teda $a_{ij} = a_{ji}$ tak maticu nazývame symetrická
- Ak máme vektor $v \in \mathbb{R}^n$ tak operáciu $Av \in \mathbb{R}^n$ nazývame lineárna transformácia a matica A je lineárny operátor

Základné objekty lineárnej algebry

- Vektor s n prvkami (dĺžky n) budeme označovať ako

$$b \in \mathbb{R}^n$$

- Prvok na i-tej pozícii budeme označovať b_i
- Vektor má vždy stĺpcovú štruktúru

$$b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

- Ak použijeme transpozíciu b^T tak hovoríme o riadkovom vektore

$$b^T = (b_1 \quad b_2 \quad \cdots \quad b_n)$$

- Nulový vektor označujeme tučným písmom

$$\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Základné typy maticových výrazov

- Skalárny súčin $b^T x$ (dot product)

$$b^T x = \begin{pmatrix} b_1 & b_2 & \cdots & b_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \sum_{i=1}^{n} b_i x_i = b \cdot x$$

- V prípade že x je premenná, tak $b^T x$ je lineárna funkcia
  - Platí že

$$b^T x = x^T b$$

  - Ak je skalárny súčin $b^T x = 0$, tak vektory b, x nazývame vzájomne ortogonálne (kolmé)
- Suma druhých mocnín $e^T e$ (veľkosť/norma vektora (ℓ_2 norma))

$$e^T e = \begin{pmatrix} e_1 & e_2 & \cdots & e_n \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = \sum_{i=1}^{n} {e_i}^2 = \|e\|^2 \geq 0$$

- Outer product (matica) $xb^T \in \mathbb{R}^{m \times n}$

$$xb^T = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{pmatrix} \begin{pmatrix} b_1 & b_2 & \cdots & b_n \end{pmatrix} = \begin{pmatrix} x_1 b_1 & x_1 b_2 & \cdots & x_1 b_n \\ x_2 b_1 & x_2 b_2 & \cdots & x_2 b_n \\ \vdots & \vdots & \ddots & \vdots \\ x_m b_1 & x_m b_2 & \cdots & x_m b_n \end{pmatrix}$$

Parciálne derivácie a gradient funkcie viacerých premenných

- Parciálna derivácia $\frac{\partial J(x)}{\partial x_i}$ znamená derivovať funkciu $J(x)$ podľa i-tej premennej x_i
- Gradient – vektor prvých parciálnych derivácii podľa jednotlivých premenných

$$\nabla J(x) = \begin{pmatrix} \frac{\partial J(x)}{\partial x_1} \\ \frac{\partial J(x)}{\partial x_2} \\ \vdots \\ \frac{\partial J(x)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} \lim_{\mathrm{d}x_1 \to 0} \frac{J(x + \mathrm{d}x_1) - J(x)}{\mathrm{d}x_1} \\ \lim_{\mathrm{d}x_2 \to 0} \frac{J(x + \mathrm{d}x_2) - J(x)}{\mathrm{d}x_2} \\ \vdots \\ \lim_{\mathrm{d}x_n \to 0} \frac{J(x + \mathrm{d}x_n) - J(x)}{\mathrm{d}x_n} \end{pmatrix}$$

- Gradient je vlastne vektorová funkcia $\nabla J(x)$: $\mathbb{R}^n \to \mathbb{R}^n$
  - Každému bodu x v priestore $\mathbb{R}^n$ priradí vektor $\mathbb{R}^n$
- Zovšeobecnenie derivácie pre funkcie viacerých premenných
- Gradient udáva ako sa zmení hodnota funkcie $J(x)$ pri zmene jednotlivých premenných
  - Ak $\frac{\partial J(x)}{\partial x_i} > 0$ potom $J(x)$ s kladnou zmenou x_i rastie
  - Ak $\frac{\partial J(x)}{\partial x_i} < 0$ potom $J(x)$ so kladnou zmenou x_i klesá
  - Ak $\frac{\partial J(x)}{\partial x_i} = 0$ potom $J(x)$ sa so zmenou x_i nemení

Príklad

- Uvažujme funkciu

$$J(x_1, x_2) = x_1 e^{2x_2} + \sin(x_1).$$

- 1. Určíme parciálnu deriváciu podľa x_1:
  - Pri derivovaní podľa x_1 považujeme x_2 za konštantu:

$$\frac{\partial J}{\partial x_1} = e^{2x_2} + \cos(x_1)$$

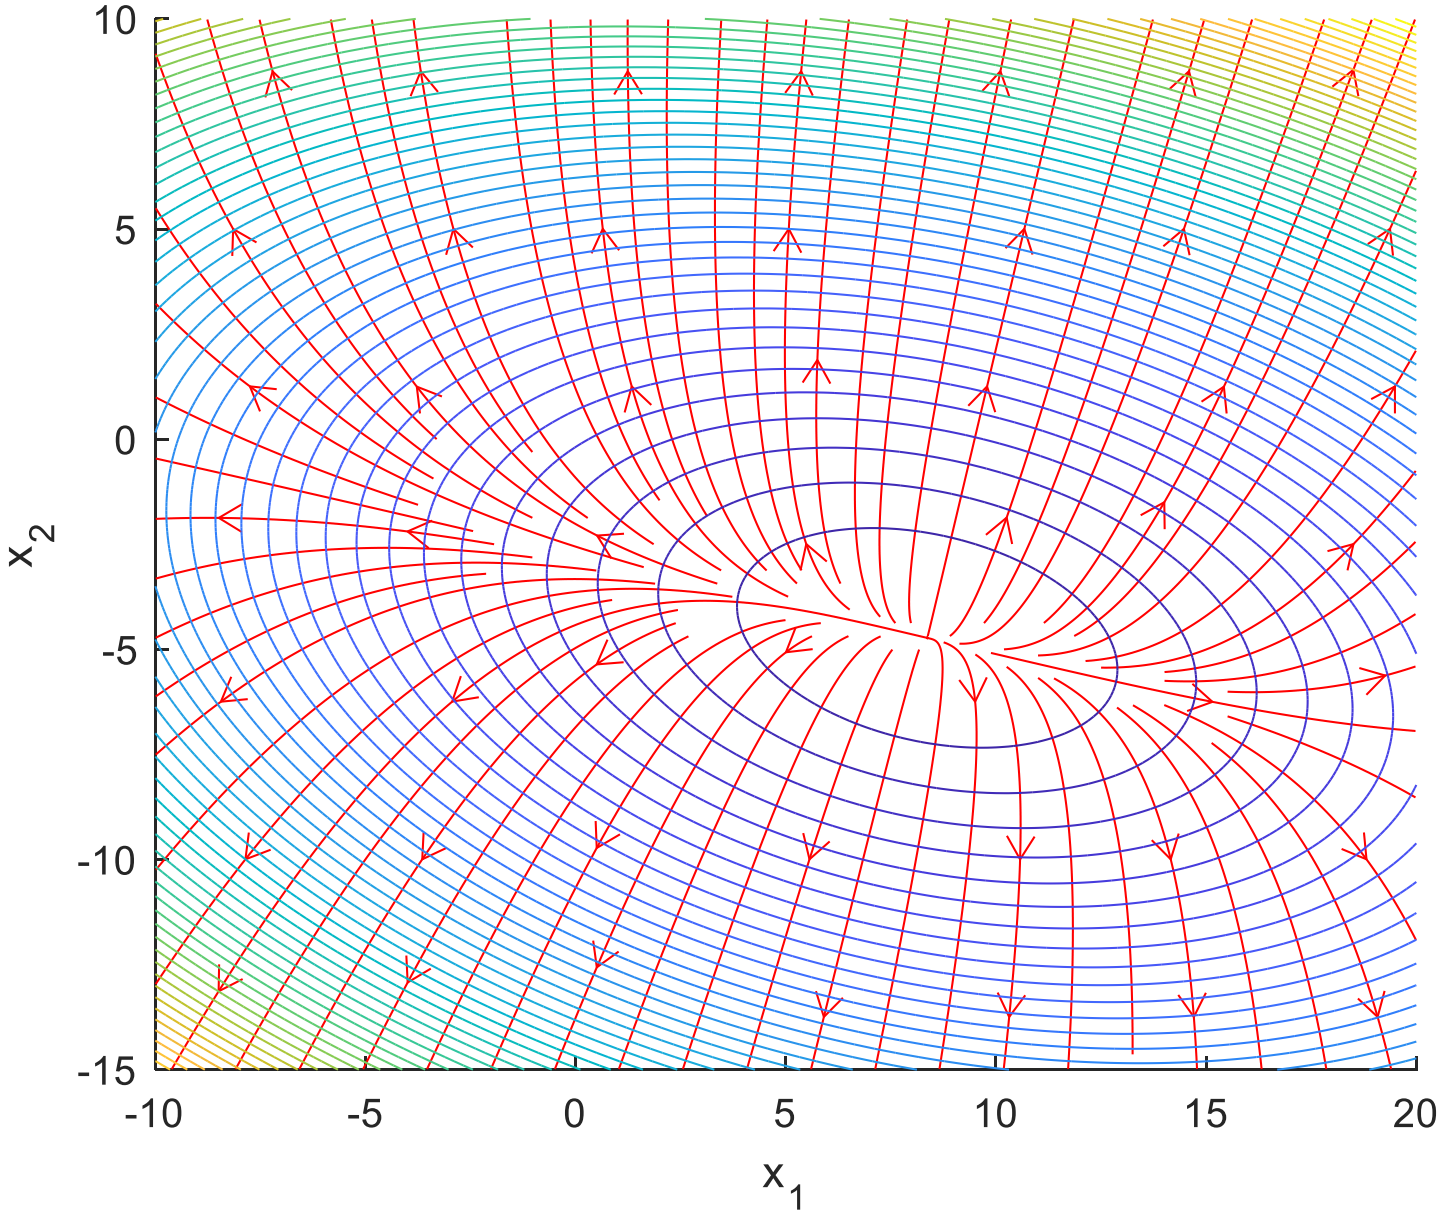
- 2. Určíme parciálnu deriváciu podľa x_2:
  - Pri derivovaní podľa x_2 považujeme x_1 za konštantu:

$$\frac{\partial J}{\partial x_2} = 2x_1 e^{2x_2}$$

- 3. Zostavíme gradient:

$$\nabla J(x) = \begin{bmatrix} e^{2x_2} + \cos(x_1) \\ 2x_1 e^{2x_2} \end{bmatrix}$$

Gradient vytvára vektorové pole (každému bodu v priestore priradí vektor)



Derivácia v smere a význam gradientu



- Gradient nie je ekvivalentný k derivácii funkcie, pretože **derivácia je skalár a gradient je vektor**
- Derivácia funkcie $J(x)$ v smere vektora $s \in \mathbb{R}^n$ je daná ako skalárny súčin

$$s^T \nabla J(x) = (s_1 \quad s_2 \quad \cdots \quad s_n) \begin{pmatrix} \frac{\partial J(x)}{\partial x_1} \\ \frac{\partial J(x)}{\partial x_2} \\ \vdots \\ \frac{\partial J(x)}{\partial x_n} \end{pmatrix} = s_1 \frac{\partial J(x)}{\partial x_1} + s_2 \frac{\partial J(x)}{\partial x_2} + \cdots s_n \frac{\partial J(x)}{\partial x_n} = \sum_{i=1}^{n} s_i \frac{\partial J(x)}{\partial x_i}$$

- Definuje ako sa zmení účelová funkcia $J(x)$ ak sa hýbeme po priamke v smere s
- Skalárny súčin $s^T \nabla J(x)$ je najväčší ak sú vektory rovnobežné (uhol medzi nimi je nulový)
- Ak sa hýbeme v priamo smere gradientu $s = \nabla J(x)$ potom derivácia je najväčšia možná a kladná

$$s^T \nabla J(x) = \nabla J(x)^T \nabla J(x) = \sum_{i=1}^{n} \left(\frac{\partial J(x)}{\partial x_i} \right)^2$$

- Gradient $\nabla J(x)$ je preto vektor, ktorý určuje **smer najväčšieho rastu** funkcie
- Antigradient $s = -\nabla J(x)$ určuje **smer najväčšieho poklesu** funkcie
- Takýto smerový vektor spĺňa $s^T \nabla J(x) = -\nabla J(x)^T \nabla J(x)$
- Derivácia v tomto smere je záporná a najmenšia možná

Izolínie (izoplochy) funkcie

- Izolínie (vrstevnice) alebo izoplochy sú krivky alebo plochy v priestore premenných, na ktorých má funkcia konštantnú hodnotu

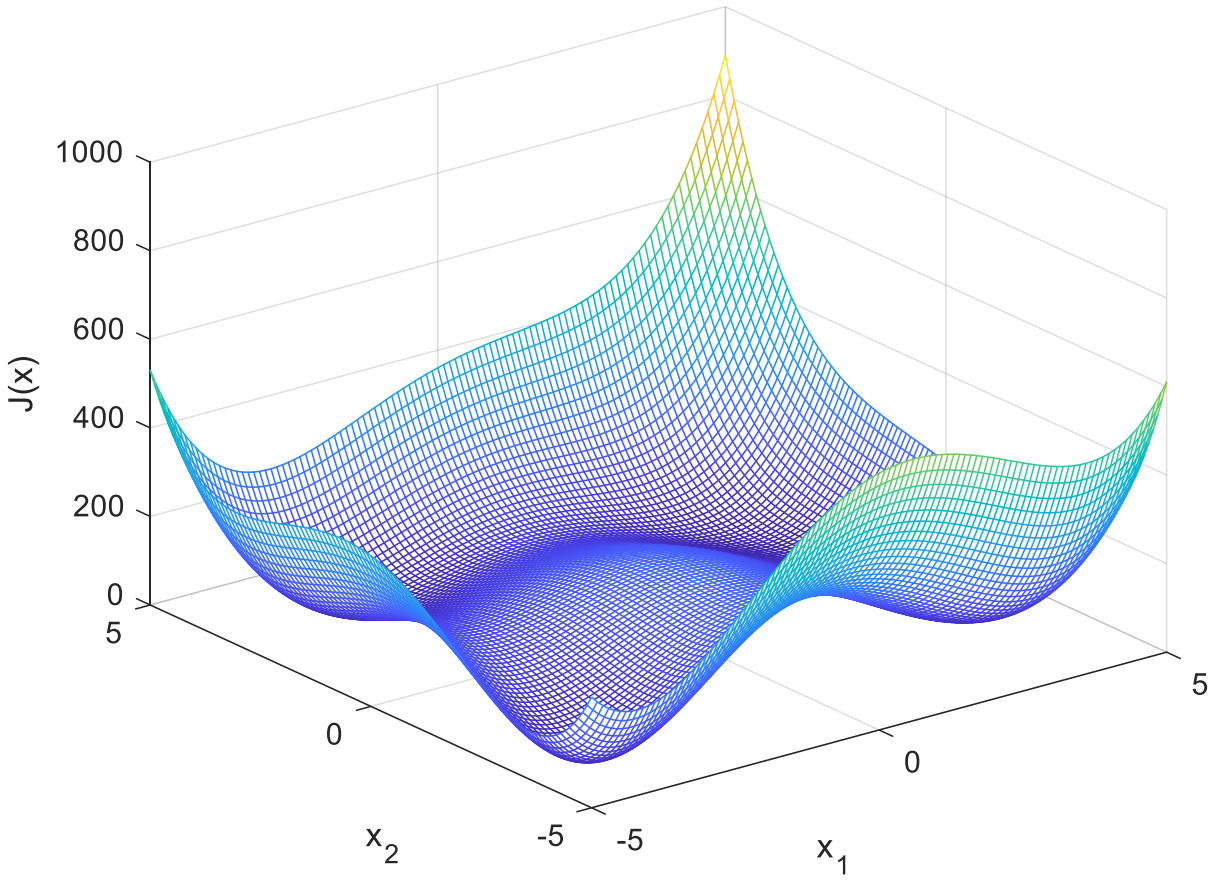
$$J(x) = q$$

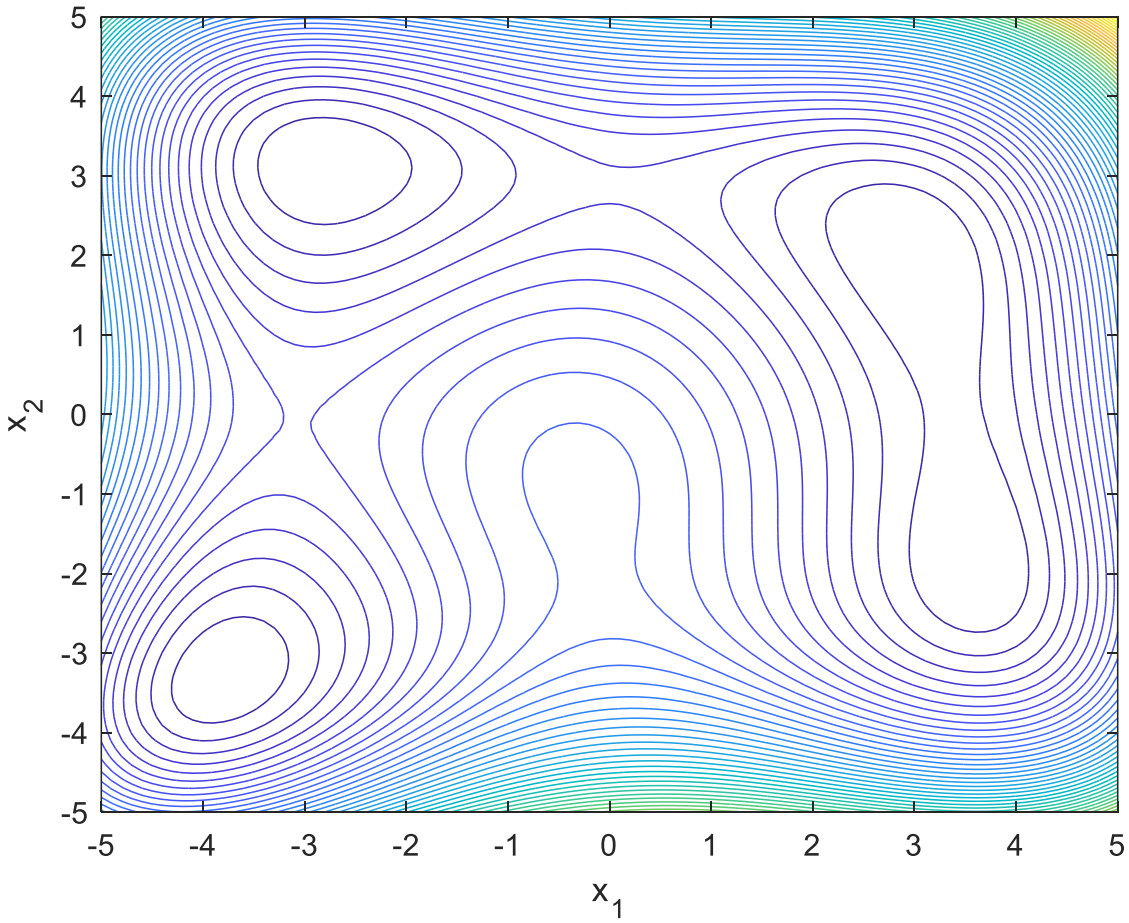
- Funkcia $J(x)$ si zachováva hodnotu v smere s ktorý je kolmý na gradient $\nabla J(x)$
  - Takýto smerový vektor spĺňa (derivácia v smere je nula)

$$s^T \nabla J(x) = 0$$

  - Vektory s a $\nabla J(x)$ sa potom označujú ako ortogonálne (vzájomne kolmé)
  - Smer s kolmý na gradient ukazuje smer izolínii/izoplôch

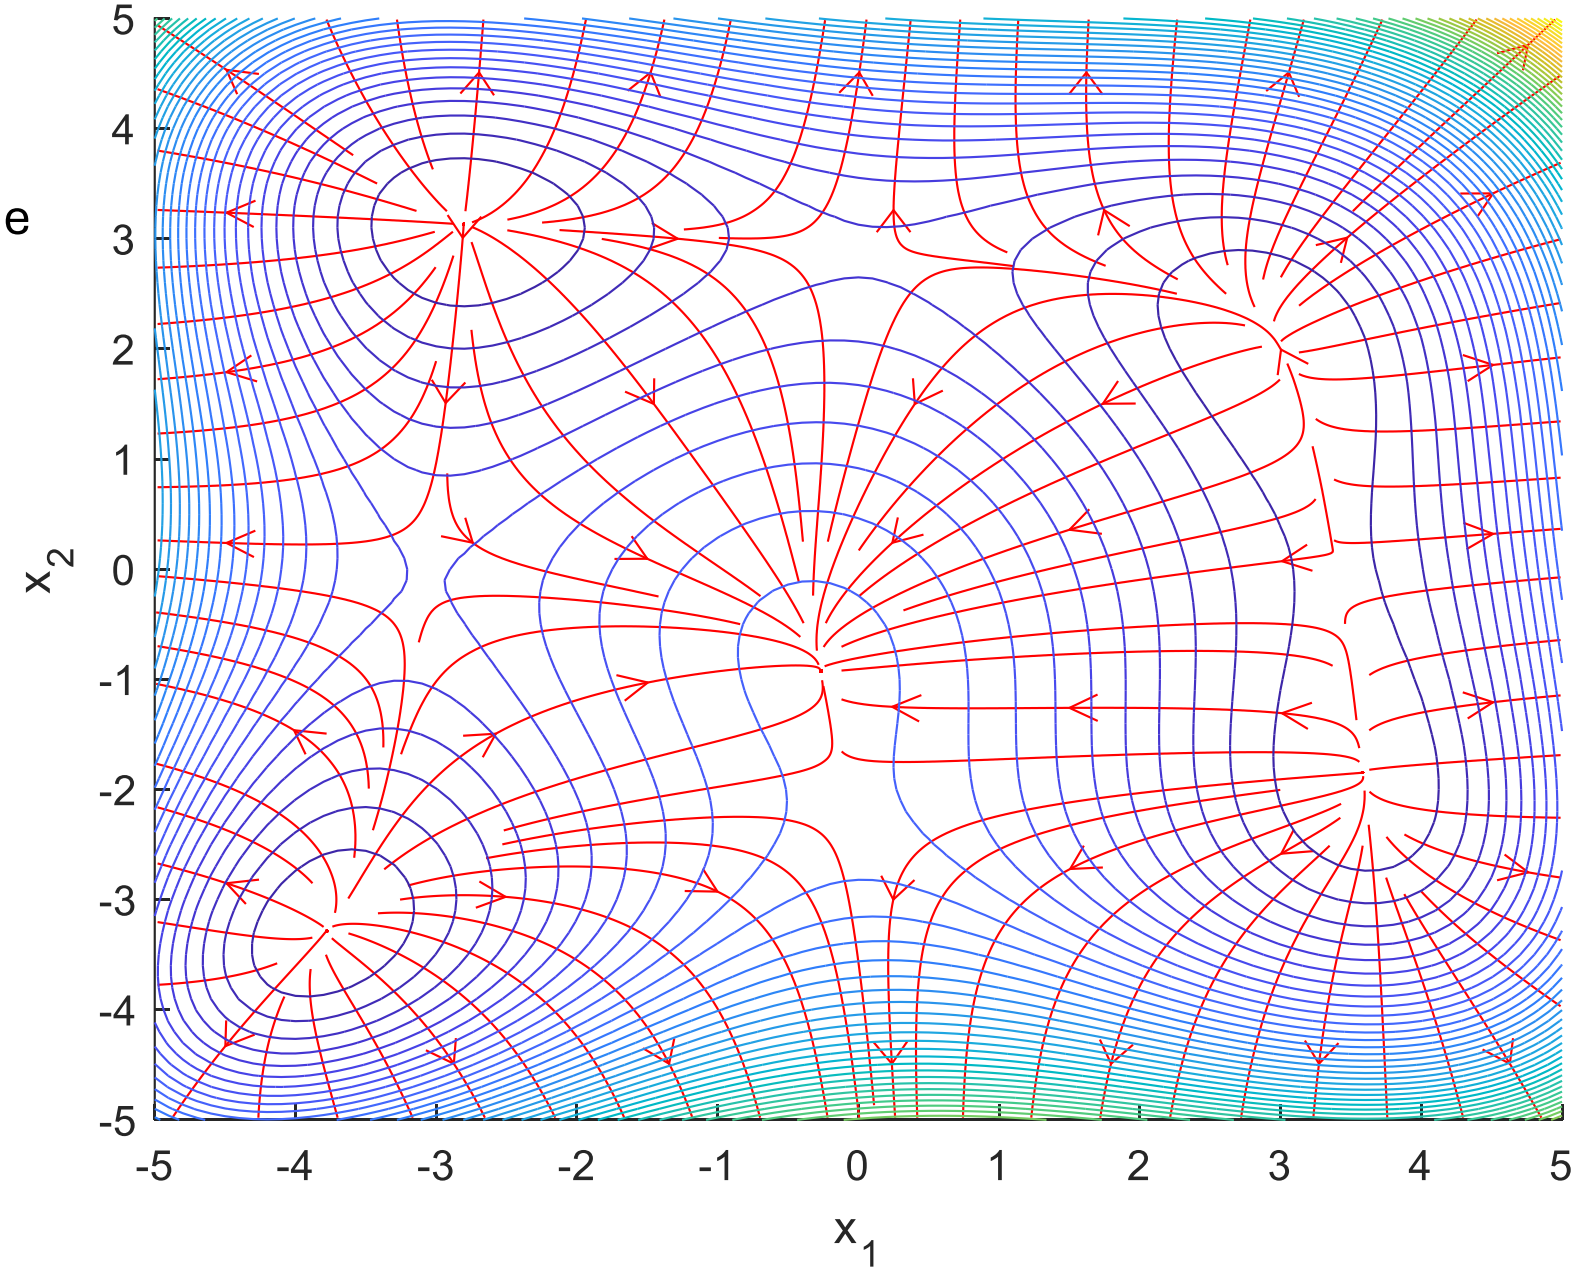
$$J(x) = \left({x_1}^2 + x_2 - 11\right)^2 + \left(x_1 + {x_2}^2 - 7\right)^2$$





$$J(x) = \left({x_1}^2 + x_2 - 11\right)^2 + \left(x_1 + {x_2}^2 - 7\right)^2$$

Gradienty sú kolmé na izolínie



Kvadratická forma



- **Zovšeobecnenie kvadratickej funkcie** pre viac premenných
- Špeciálny druh polynómu druhého stupňa zapísaný pomocou matíc a vektorov

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c$$

$J(x) \in \mathbb{R}$ (skalár), $A \in \mathbb{R}^{n \times n}$ (matica), $b \in \mathbb{R}^n$ (vektor), $c \in \mathbb{R}$ (skalár)

- Matica A tvorí kvadratický člen a ovplyvňuje tvar (zakryvenie) funkcie
- Vektor b tvorí lineárny člen a posúva funkciu vzhľadom na premenné
- Skalár c je absolútny člen, ktorý len posúva funkčnú hodnotu

- Typicky predpokladáme, že A je **symetrická matica** $A = A^T$
- Ak A nie je symetrická $A \neq A^T$
  - Potom platí $x^T Ax = \left(x^T Ax\right)^T = x^T A^T x = x^T \left(\frac{A+A^T}{2}\right) x$
  - Ak je matica A v kvadratickej forme $x^T Ax$, tak nezáleží na tom či je symetrická lebo vo výraze $x^T Ax$ sa správa ako symetrická

Kvadratický člen $x^T Ax$

$$x^T Ax = (x_1 \quad x_2 \quad \cdots \quad x_n)\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{12} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{nn} \end{pmatrix}\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

$$x^T Ax = \sum_{i=1}^{n}\sum_{j=1}^{n} x_i x_j a_{ij} = {x_1}^2 a_{11} + x_1 x_2 a_{12} + x_1 x_3 a_{13} \ldots + x_2 x_1 a_{12} + {x_2}^2 a_{22} + x_2 x_3 a_{23} \ldots x_3 x_1 a_{13} + x_3 x_2 a_{23} + {x_3}^2 a_{33}$$

- Členy $x_i x_j a_{ij}$ a $x_j x_i a_{ji}$ sú rovnaké kvôli symetrii A, preto

$$x^T Ax = \sum_{i=1}^{n} {x_i}^2 a_{ii} + \sum_{i=1}^{n}\sum_{j=1}^{n} x_i x_j a_{ij} = \sum_{i=1}^{n} {x_i}^2 a_{ii} + 2\sum_{i=1}^{n}\sum_{j=i}^{n} x_i x_j a_{ij}$$

- Kvadratické členy ${x_i}^2 a_{ii}$ obsahujú diagonálne prvky A
- Zmiešané súčiny $x_i x_j a_{ij}$ obsahujú mimodiagonálne prvky A

Čo je to definitnosť matice ?



- Ako interpretovať definitnosť matice ?
  - Pre kladne definitnú maticu $A \succ 0$ bude pre ľubovoľný vektor x platiť $x^T Ax \geq 0$
  - Pre záporne definitnú maticu $A \prec 0$ bude pre ľubovoľný vektor x platiť $x^T Ax \leq 0$
  - Pre indefinitnú maticu A bude výraz $x^T Ax$ môcť byť kladný alebo záporný podľa toho aké prvky obsahuje x
- Definitnosť matice súvisí s jej **vlastnými číslami**
  - Ak sú všetky vlastné čísla kladné tak matica je kladne definitná
  - Ak sú všetky vlastné čísla záporné tak matica je záporne definitná
  - Ak sú vlastné čísla kladné aj záporné tak matica je indefinitná

Rozklad symetrickej matice na vlastné čísla

- Majme symetrickú maticu $A \in \mathbb{R}^{n \times n}$, $A = A^T$
- Túto maticu možno rozložiť (diagonalizovať) ako

$$A = Q\Lambda Q^T = Q\Lambda Q^{-1}$$

$Q \in \mathbb{R}^{n \times n}$ je matica vlastných vektorov, ktorá spĺňa $Q^T = Q^{-1}$ a teda $Q^T Q = I$ (je ortogonálna)

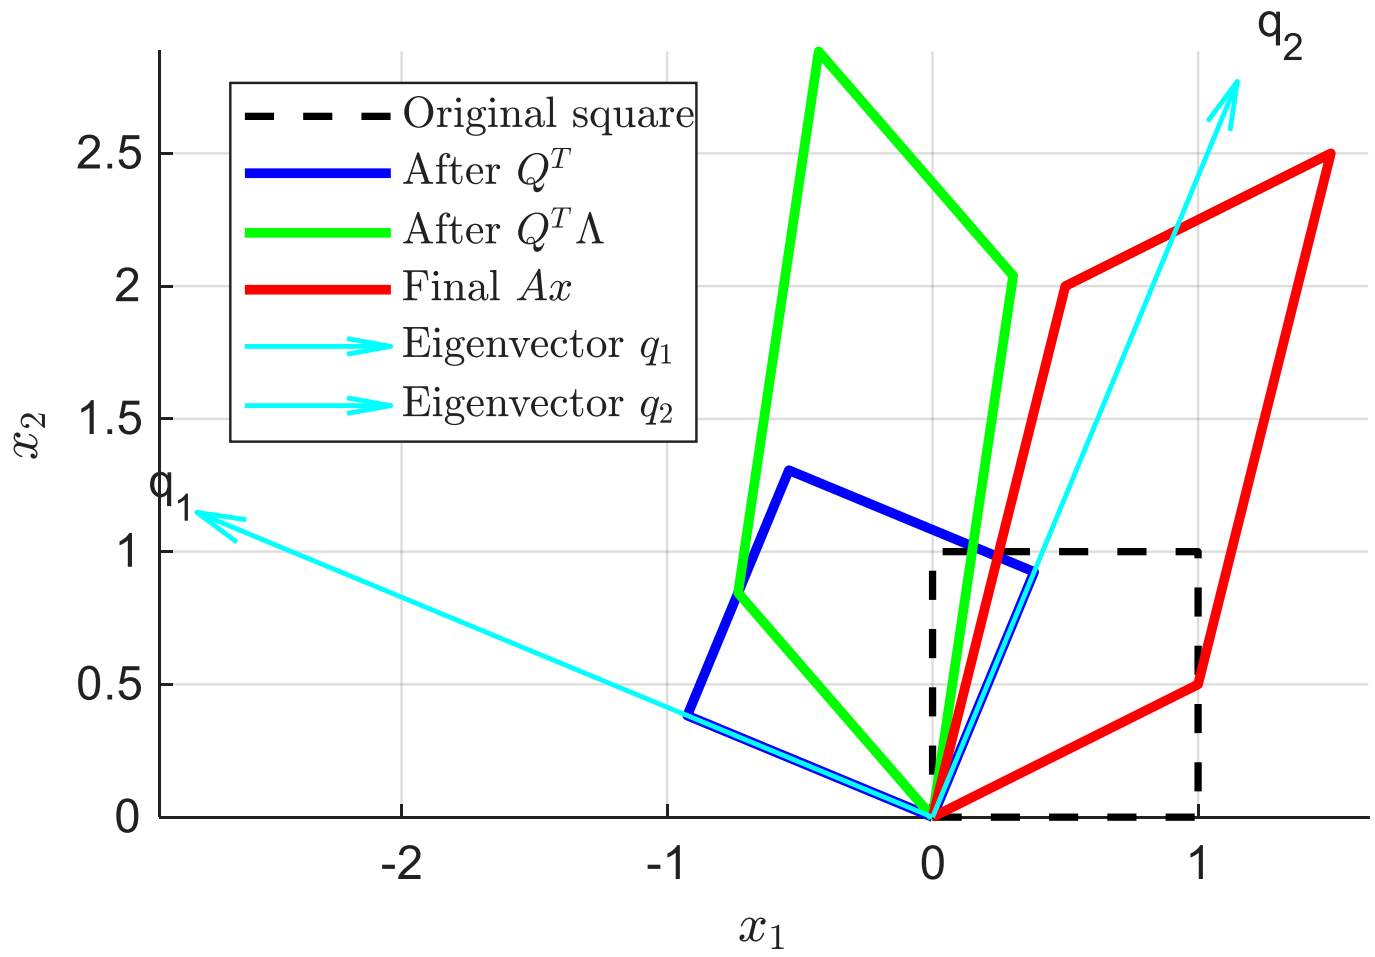
$\Lambda \in \mathbb{R}^{n \times n}$ je diagonálna matica vlastných čísel

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}$$

- Rozklad matice na vlastné čísla predstavuje tri jednoduché geometrické operácie pri transformácii vektora x ako Ax:
  - otočenie súradnicového systému (Q^T),
  - nezávislé škálovanie v smeroch vlastných vektorov (Λ),
  - otočenie späť (Q).

$$\begin{pmatrix} 1 & 0.5 \\ 0.5 & 2 \end{pmatrix} = \begin{pmatrix} -0.9239 & 0.3827 \\ 0.3827 & 0.9239 \end{pmatrix} \begin{pmatrix} 0.7929 & 0 \\ 0 & 2.2071 \end{pmatrix} \begin{pmatrix} -0.9239 & 0.3827 \\ 0.3827 & 0.9239 \end{pmatrix}$$

$$A = Q\Lambda Q^T$$



Prečo môžeme vykonať takýto rozklad?

- Definícia vlastného vektora q_i a vlastného čísla λ_i je nasledovná rovnosť

$$Aq_i = \lambda_i q_i$$

- Zostavme maticu Q z vlastných vektorov:

$$Q = [q_1 \quad q_2 \quad \dots \quad q_n]$$

- Predpokladajme, že matica A má aspoň dva vlastné vektory potom sústavu rovníc z prevej rovnice ide prepísať takto:

$$A[q_1 \quad q_2 \quad \dots \quad q_n] = [\lambda_1 q_1 \quad \lambda_2 q_2 \quad \dots \quad \lambda_n q_n]$$

- Alebo kompaktnejšie:

$$AQ = [\lambda_1 q_1 \quad \lambda_2 q_2 \quad \dots \quad \lambda_n q_n] = [q_1 \quad q_2 \quad \dots \quad q_n] \begin{pmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{pmatrix} = Q\Lambda$$

kde

$$\Lambda = \begin{pmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{pmatrix}$$

- Rovnicu $AQ = Q\Lambda$ vieme prepísať nasledovne:

$$A = Q\Lambda Q^{-1}$$

- Za predpokladu, že Q je ortogonálna matica ($Q^T = Q^{-1}$) získame

$$A = Q\Lambda Q^T$$

- Prečo je Q ortogonálna matica ($Q^T = Q^{-1}$) ak $A = A^T$ je symetrická ?

Ak $A = A^T$ tak potom aj $Q\Lambda Q^{-1} = (Q\Lambda Q^{-1})^T = {Q^{-1}}^T \Lambda^T Q^T = {Q^{-1}}^T \Lambda Q^T$ a teda $Q^{-1} = Q^T$

Rozklad matice na vlastné čísla a definitnosť

- Uvažujme rozklad $A = Q^T \Lambda Q$ v kvadratickom člene $x^T Ax$

$$x^T Ax = x^T Q \Lambda Q^T x$$

- Ak vektor Qx označíme ako $z = Q^T x$ potom

$$x^T Ax = x^T Q \Lambda Q^T x = z^T \Lambda z$$

$$(z_1 \quad z_2 \quad \cdots \quad z_n) \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} = \sum_{i=1}^{n} \lambda_i {z_i}^2$$

- Potom $z^T \Lambda z > 0$ a $x^T Ax > 0$ iba ak všetky $\lambda_i > 0$
- Výraz $x^T Ax$ je vždy kladný ak sú všetky vlastné čísla A kladné (A je kladne definitná)

Druhé parciálne derivácie a Hessián



- Druhá parciálna derivácia $J(x)$ podľa i-tej a j-tej premennej sa označuje

$$\frac{\partial^2 J(x)}{\partial x_i \partial x_j}$$

- Hessián je matica druhých parciálnych derivácii - maticová funkcia $\nabla^2 J(x)$: $\mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$

$$\nabla^2 J(x) = \begin{pmatrix} \frac{\partial^2 J(x)}{\partial {x_1}^2} & \frac{\partial^2 J(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 J(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 J(x)}{\partial x_1 \partial x_2} & \frac{\partial^2 J(x)}{\partial {x_2}^2} & \cdots & \frac{\partial^2 J(x)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 J(x)}{\partial x_1 \partial x_n} & \frac{\partial^2 J(x)}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 J(x)}{\partial {x_n}^2} \end{pmatrix}$$

- Pri spojitých funkciách, ktoré majú spojité $\frac{\partial^2 J(x)}{\partial x_i \partial x_j}$ na poradí derivovania nezáleží, preto

$$\frac{\partial^2 J(x)}{\partial x_i \partial x_j} = \frac{\partial^2 J(x)}{\partial x_j \partial x_i}$$

- Hessián je **symetrický**

$$\nabla^2 J(x) = \left(\nabla^2 J(x)\right)^T$$

Stacionárne body a podmienky extrému

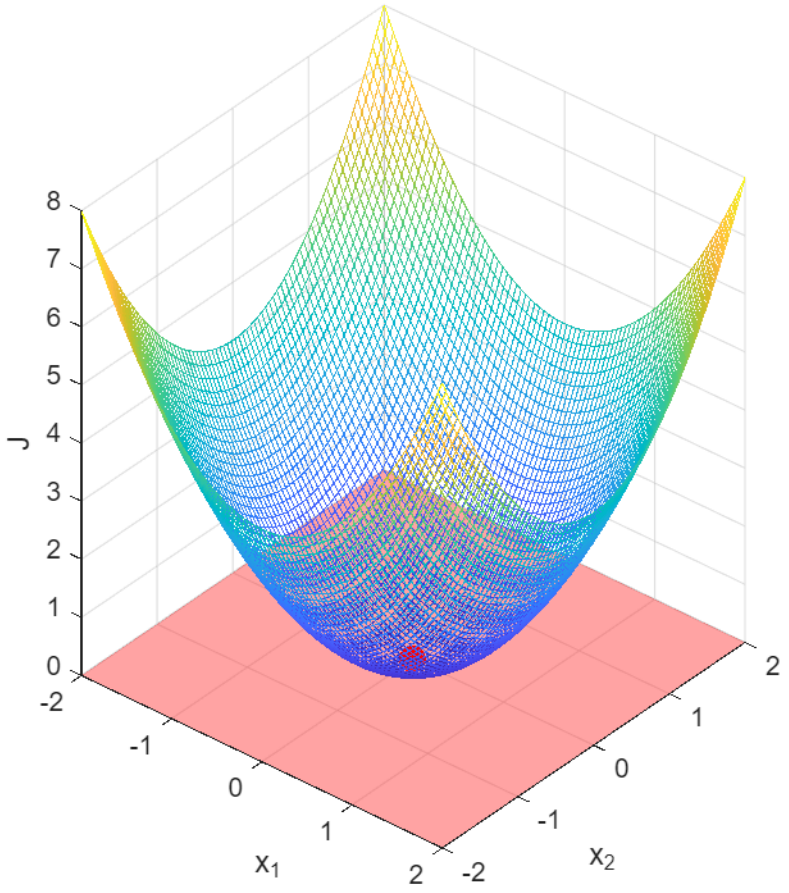


- Stacionárny bod účelovej funkcie - gradient rovný nulovému vektoru

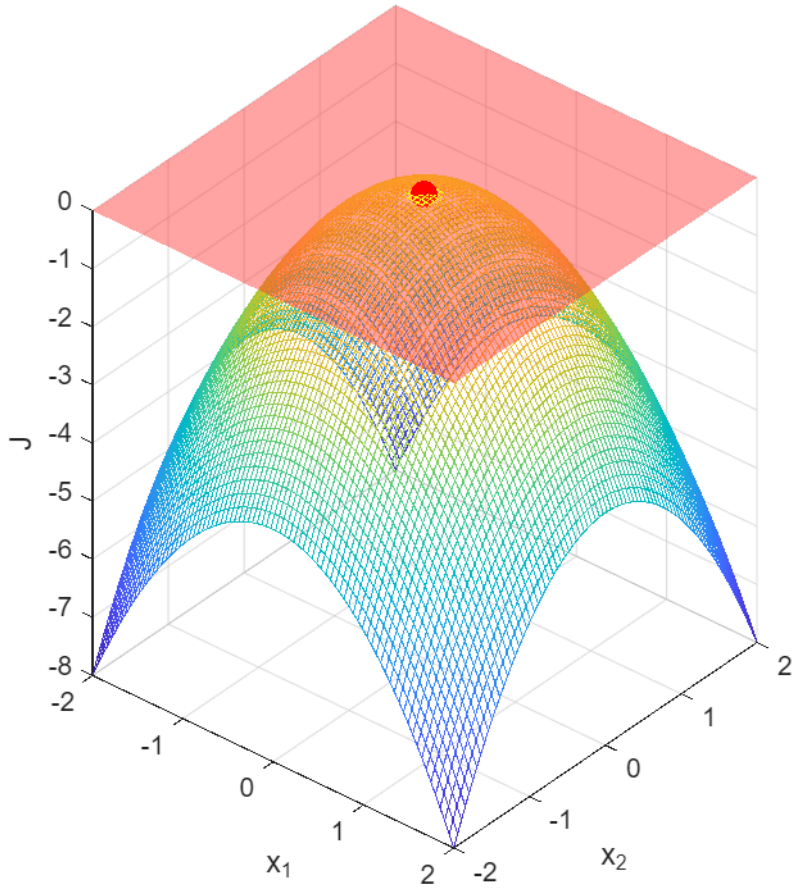
$$\nabla J(x^*) = \mathbf{0}$$

- **Nevyhnutná podmienka pre extrém** účelovej funkcie
- Typy stacionárnych bodov na základe vlastností Hessiánu v bode x^* (**postačujúce podmienky pre extrém**)
  - Ak gradient $\nabla J(x^*) = \mathbf{0}$ a Hessián $\nabla^2 J(x^*) \succ 0$ (**kladne definitný**), funkcia má v bode x^* **minimum a je lokálne konvexná**
  - Ak gradient $\nabla J(x^*) = \mathbf{0}$ a Hessián $\nabla^2 J(x^*) \prec 0$ (**záporne definitný**), funkcia má v bode x^* **maximum a je lokálne konkávna**
  - Ak neplatí ani jedno, $\nabla^2 J(x^*)$ (**indefinitný**), funkcia má v bode x^* **sedlo**
- Ak existuje iba jediné (unikátne) x^* spĺňajúce postačujúce podmienky pre extrém, problém je potom **unimodálny** a x^* je **globálnym extrémom**
- V opačnom prípade je problém multimodálny a extrém je lokálny

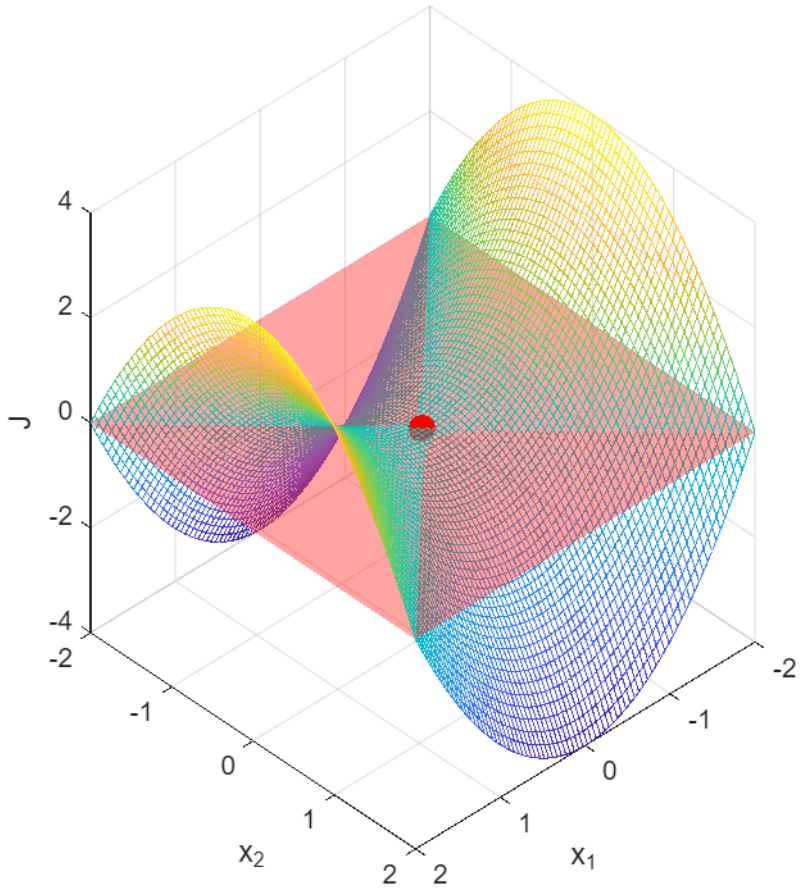
$\nabla J(x^*) = \mathbf{0}$ a $\nabla^2 J(x^*) \succ 0$



$\nabla J(x^*) = \mathbf{0}$ a $\nabla^2 J(x^*) \prec 0$



$\nabla J(x^*) = \mathbf{0}$



Dôkaz - Taylorov rozvoj funkcie viacerých premenných

- Funkciu $J(x)$ vieme aproximovať v okolí bodu x_0 ako kvadratickú formu s využitím Taylorovho rozvoja

$$J\ (x) \cong J(x_0) + (x - x_0)^T \nabla J(x_0) + \frac{1}{2}(x - x_0)^T \nabla^2 J(x_0)(x - x_0)$$

kde $\nabla J(x_0)$ je gradient v bode x_0 a $\nabla^2 J(x_0)$ je Hessián v bode x_0

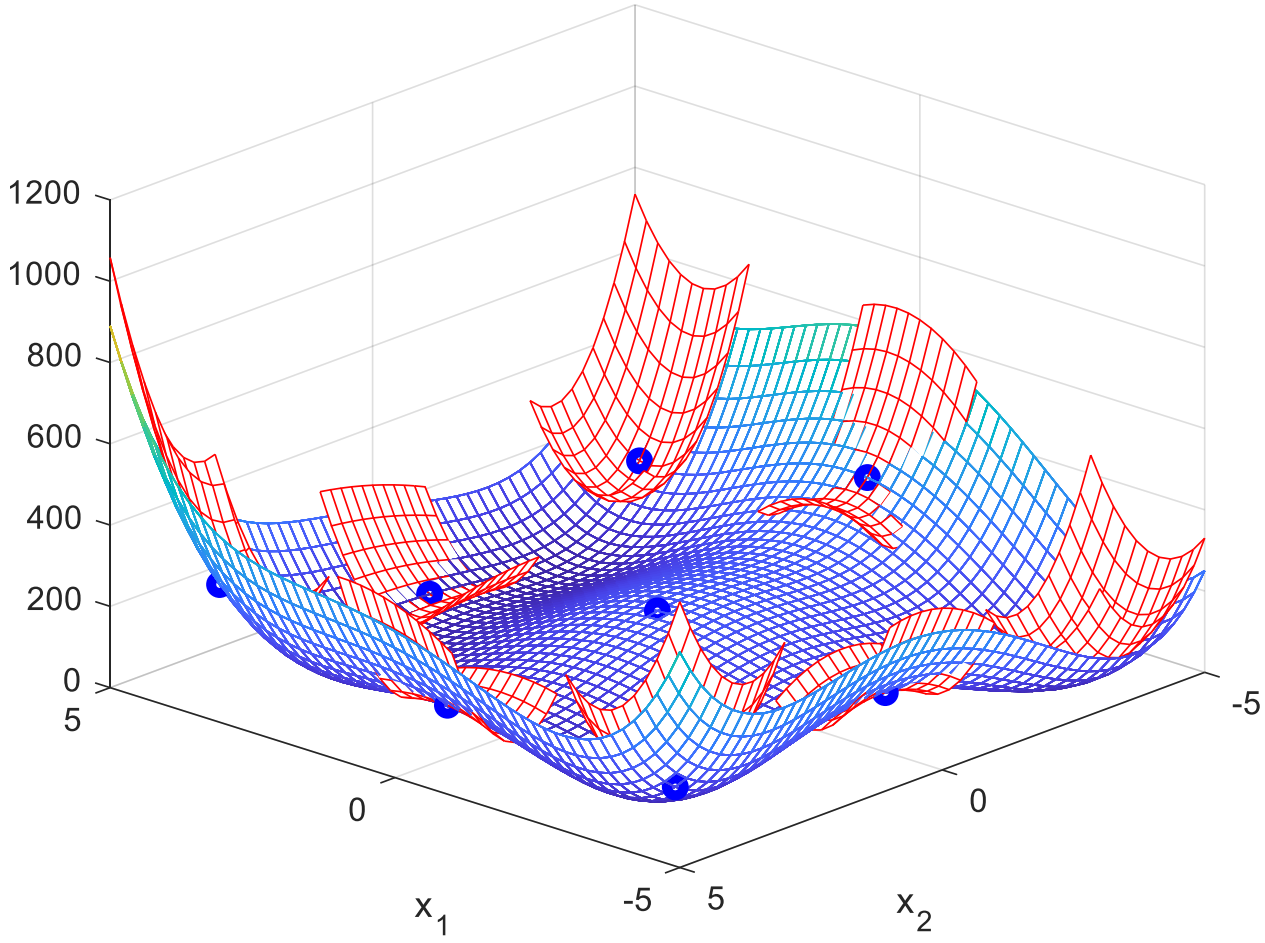
- Gradient $\nabla J(x_0)$ tak tvorí lineárny člen, Hessián $\nabla^2 J(x_0)$ tvorí kvadratický člen a funkčná hodnota $J(x_0)$ je absolútny člen
- V okolí stacionárneho bodu x^* platí $\nabla J(x^*) = \mathbf{0}$ (nulový gradient) pričom získame aproximáciu

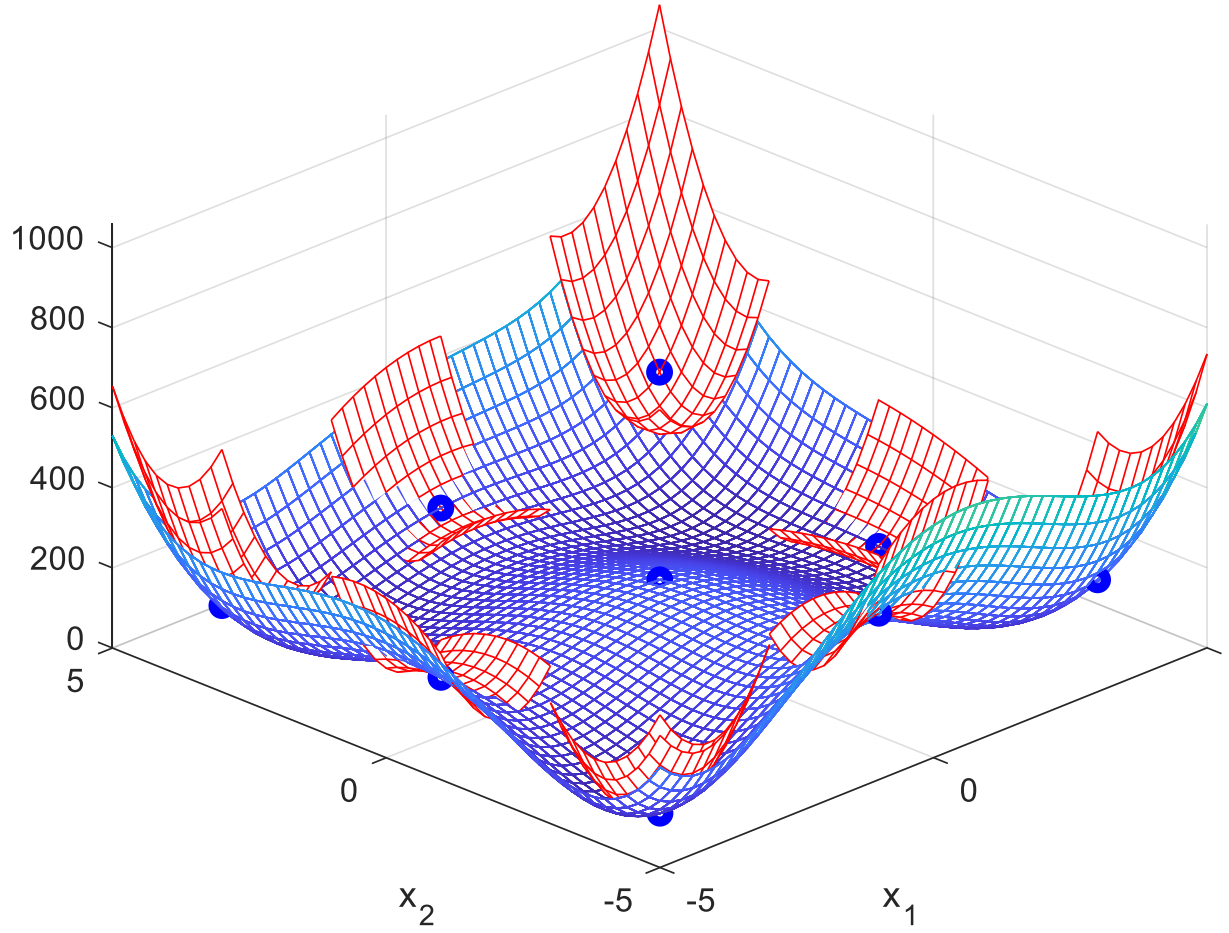
$$J\ (x) \cong J(x^*) + \frac{1}{2}(x - x^*)^T \nabla^2 J(x^*)(x - x^*)$$

- Z tejto aproximácie vyplýva že:
  - Ak $\nabla^2 J(x^*) \succ 0$ (kladne definitný) výraz $(x - x^*)^T \nabla^2 J(x^*)(x - x^*) \geq 0$ je vždy kladný a funkcia má v bode x^* lokálne minimum $J(x^*)$
  - Ak $\nabla^2 J(x^*) \prec 0$ (záporne definitný) výraz $(x - x^*)^T \nabla^2 J(x^*)(x - x^*) \leq 0$ je vždy záporný a funkcia má v bode x^* lokálne maximum $J(x^*)$

$$J(x) = \left({x_1}^2 + x_2 - 11\right)^2 + \left(x_1 + {x_2}^2 - 7\right)^2$$

Lokálna aproximácia funkcie kvadratickou formou
(Taylorov rozvoj v okolí daného bodu)





Maticová analýza – gradienty funkcii obsahujúcich maticové výrazy

- Funkcie obsahujúce maticové a vektorové výrazy môžeme derivovať
- Majme skalárnu funkciu n premenných $f(x)$: $\mathbb{R}^n \to \mathbb{R}$
- Ak $f(x) = b^T x$ alebo $f(x) = x^T b$ (lineárna funkcia)
  - Gradient $\nabla f(x) = b$
- Ak $f(x) = x^T A x$ (kvadratická funkcia)
  - Gradient $\nabla f(x) = \left(A + A^T\right)x = 2Ax$
- Ak $f(x) = c$ (konštantná funkcia)
  - Gradient $\nabla f(x) = \mathbf{0}$

Vlastnosti kvadratickej formy



- Gradient $\nabla J(x)$ kvadratickej formy bude

$$\nabla J(x) = \nabla\left(\frac{1}{2}x^T Ax + b^T x + c\right) = Ax + b$$

  - Lineárny voči x
- Hessián

$$\nabla^2 J(x) = \nabla(Ax + b) = A$$

  - Konštantný
- Podmienka optimálnosti (stacionárny bod – nulový gradient)

$$\nabla J(x^*) = Ax^* + b = \mathbf{0}$$

- **Stacionárny bod x^* spĺňa sústavu lineárnych rovníc**

$$Ax^* = -b$$
$$x^* = -A^{-1}b$$

  - Je jediným (unikátnym) riešením
  - Kvadratická forma môže mať preto iba jeden extrém
- Stacionárny bod môže byť maximum, minimum alebo sedlo podľa definitnosti A

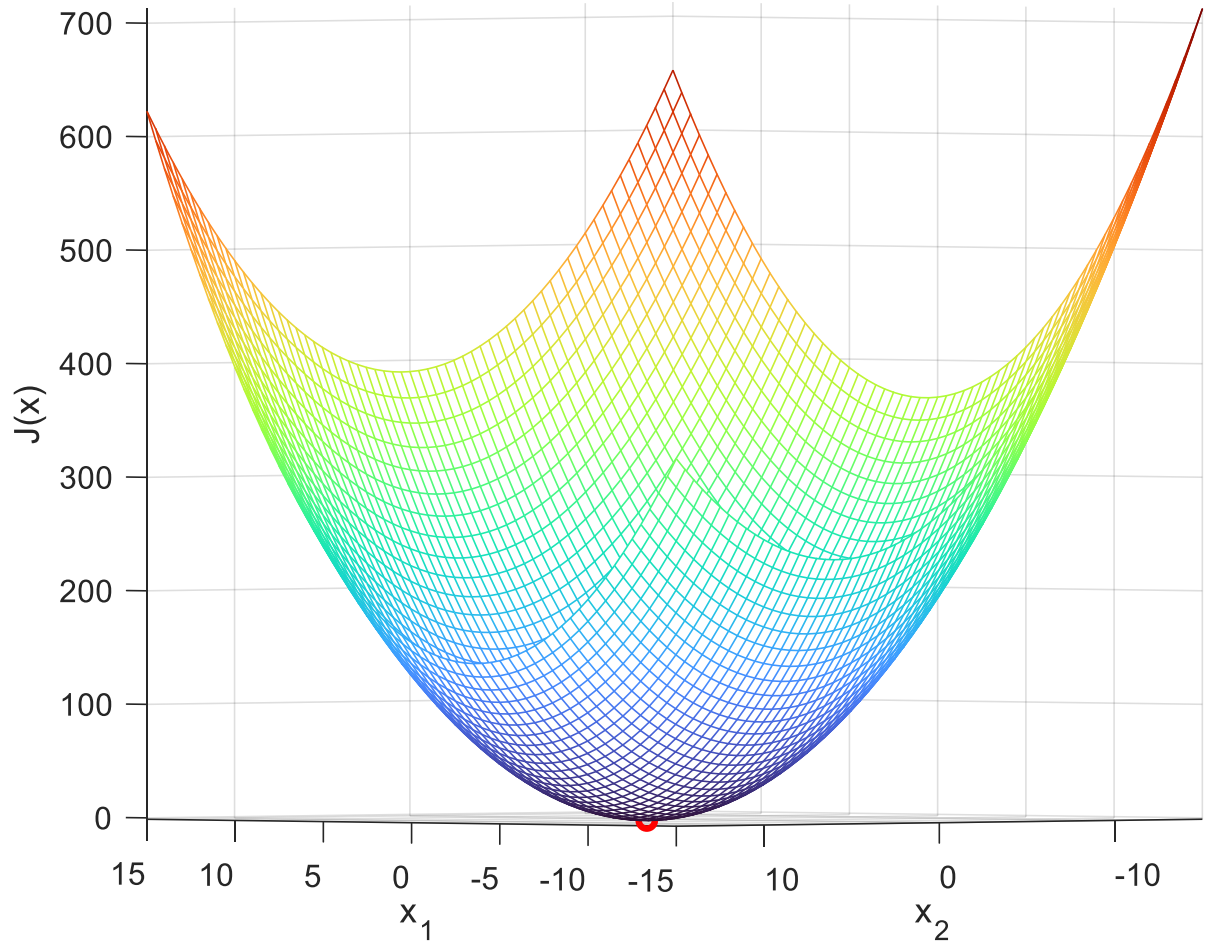
Typy stacionárnych bodov kvadratických foriem na základe definitnosti matice A

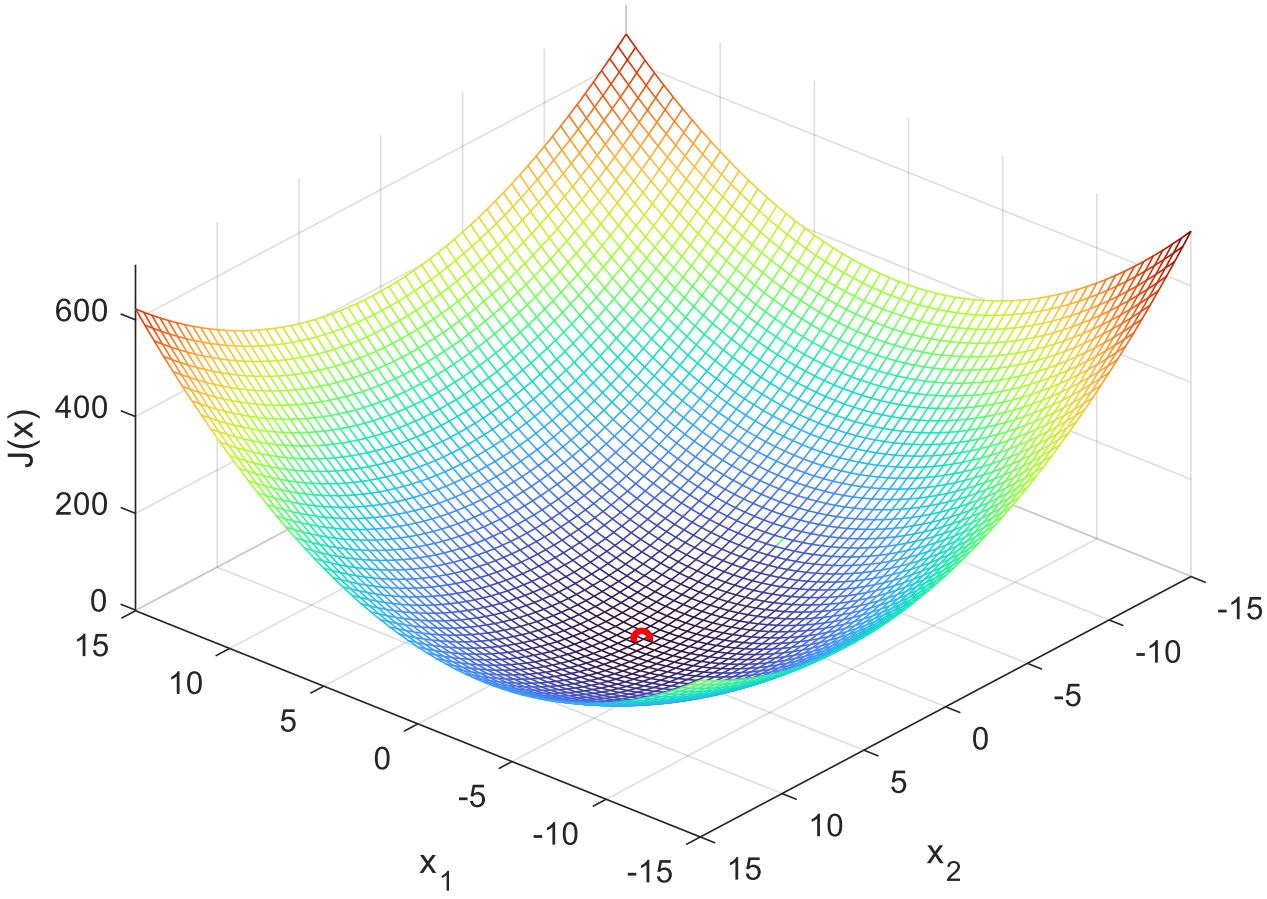


- Ak $Ax^* = -b$ a $A \succ 0$ (**kladne definitná**)
  - kvadratická forma je konvexná funkcia
  - v bode x^* je globálne **minimum**
- Ak $Ax^* = -b$ a $A \prec 0$ (**záporne definitná**)
  - kvadratická forma je konkávna funkcia
  - v bode x^* je globálne **maximum**
- Ak neplatí ani jedno, A je (**indefinitná**)
  - kvadratická forma má v bode x^* **sedlo**

$$A = \begin{pmatrix} 2.8 & 0.4 \\ 0.4 & 2.2 \end{pmatrix}, b = \begin{pmatrix} 4 \\ -7 \end{pmatrix}, c = 15$$

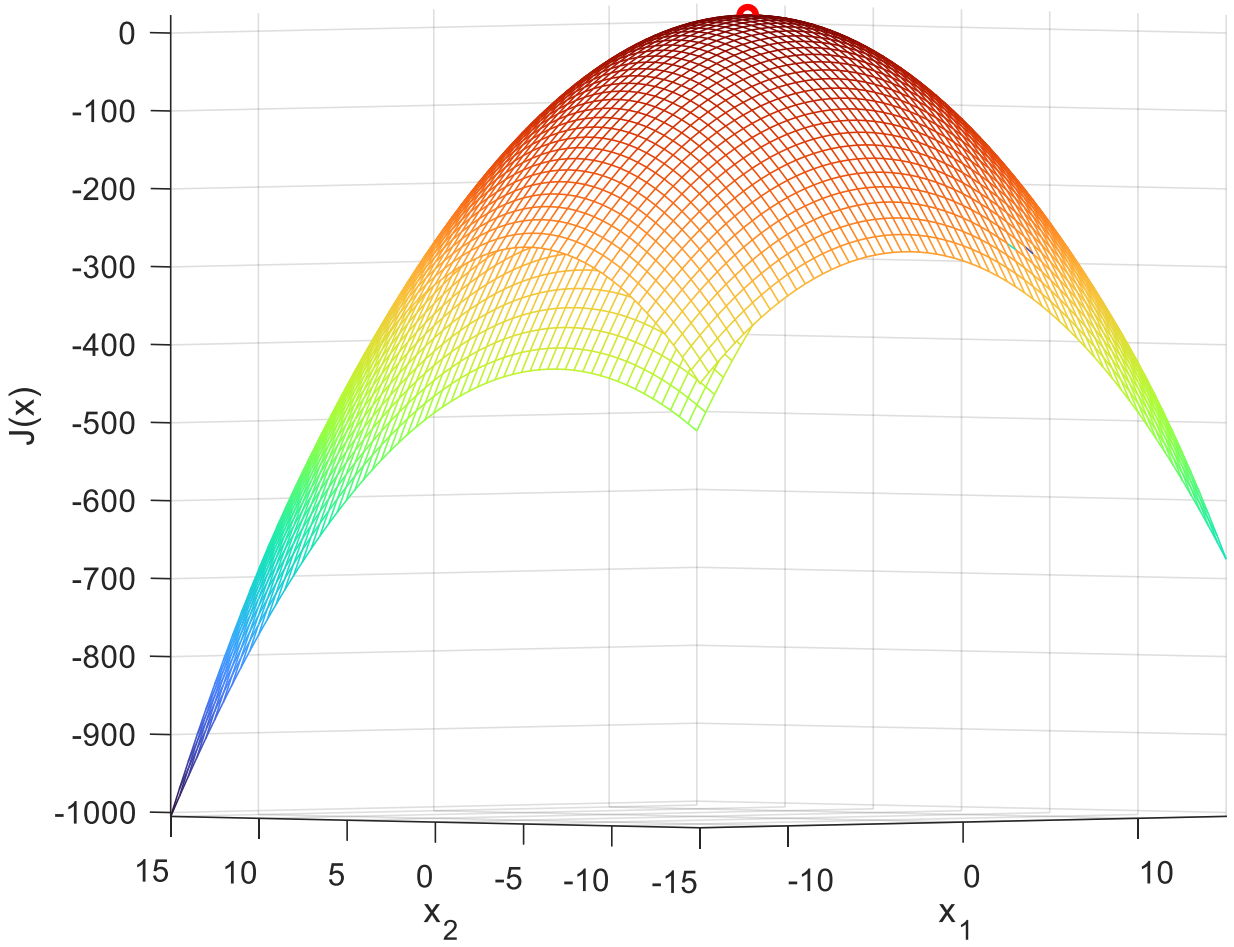
$$\Lambda = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$$

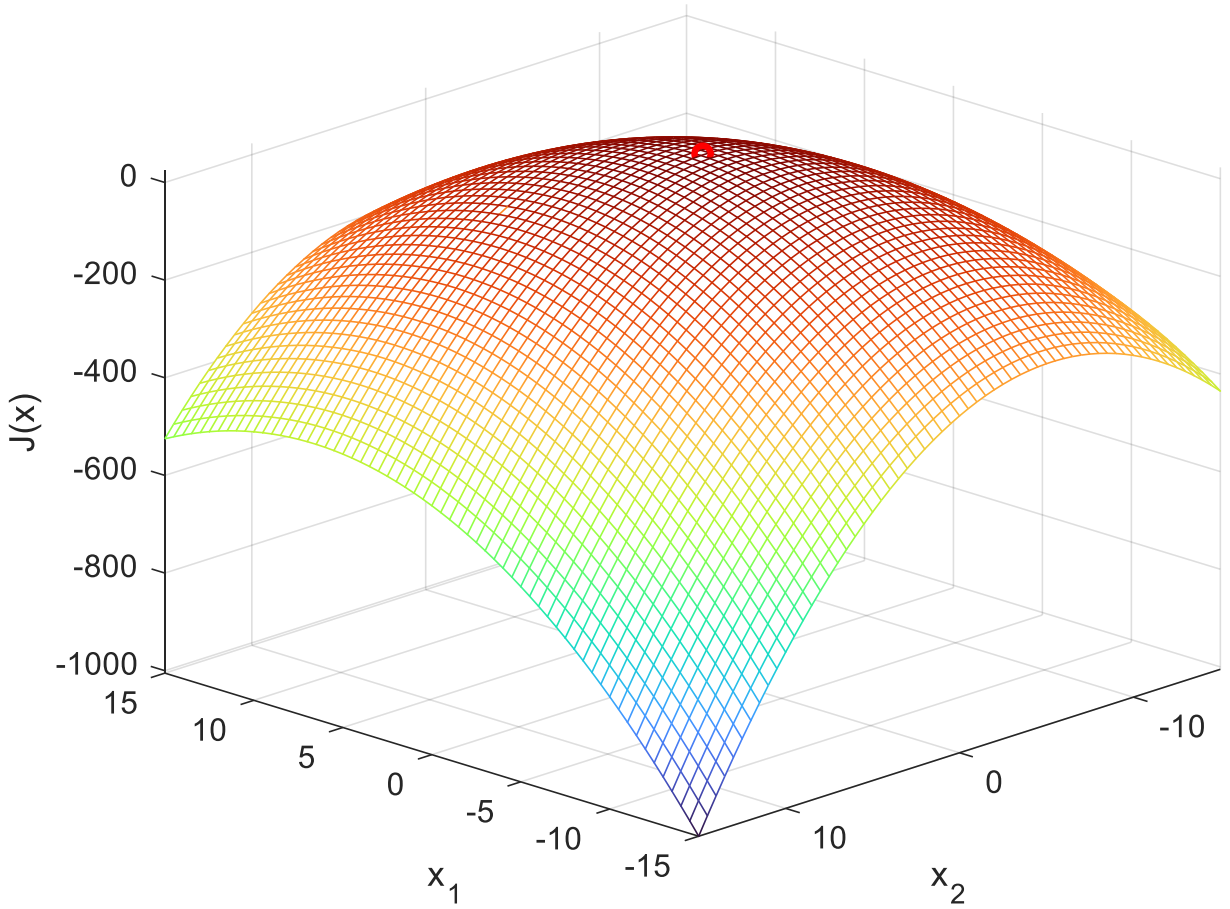




$$A = \begin{pmatrix} -2.4 & 0.8 \\ 0.8 & -3.6 \end{pmatrix}, b = \begin{pmatrix} 4 \\ -7 \end{pmatrix}, c = 15$$

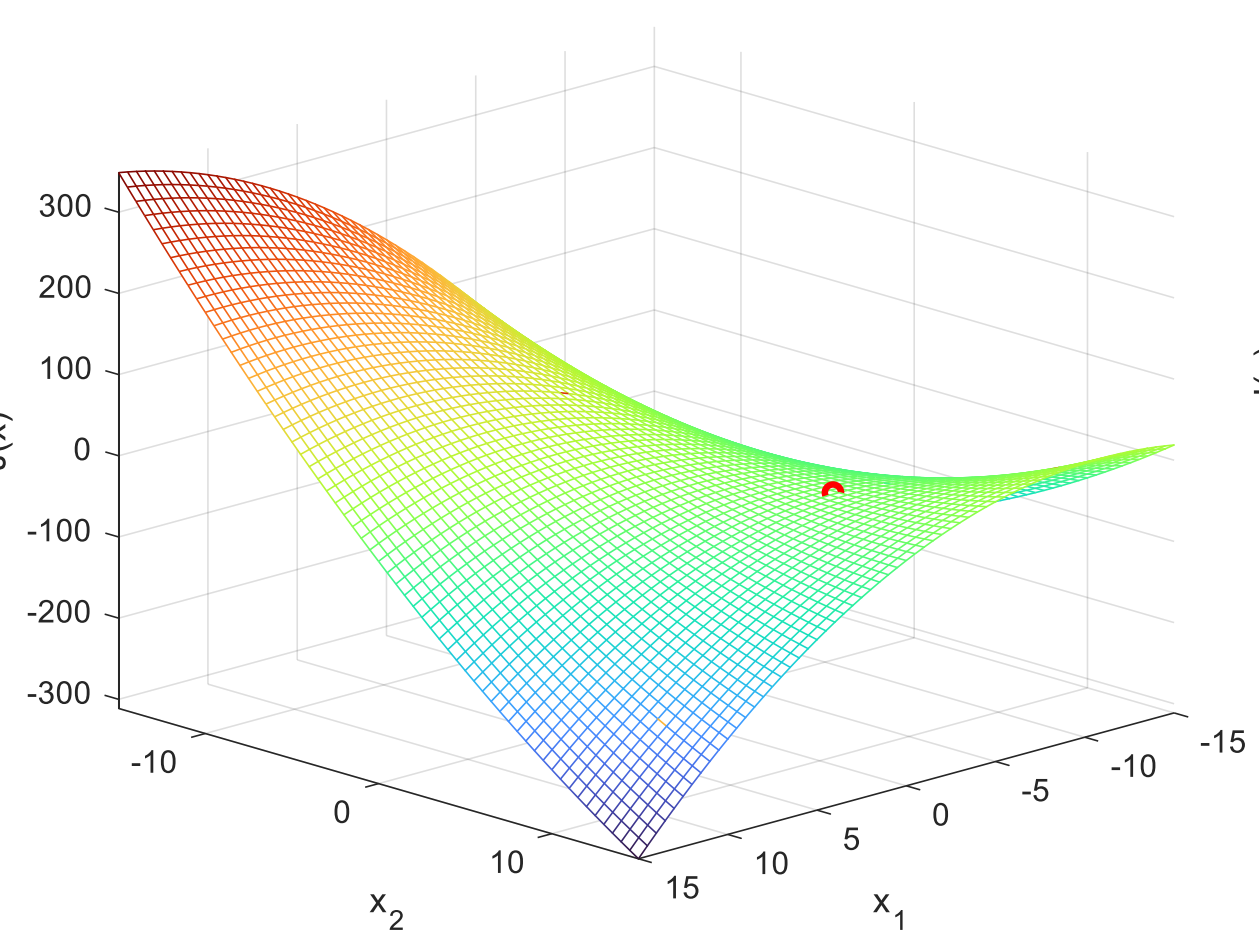
$$\Lambda = \begin{pmatrix} -4 & 0 \\ 0 & -2 \end{pmatrix}$$

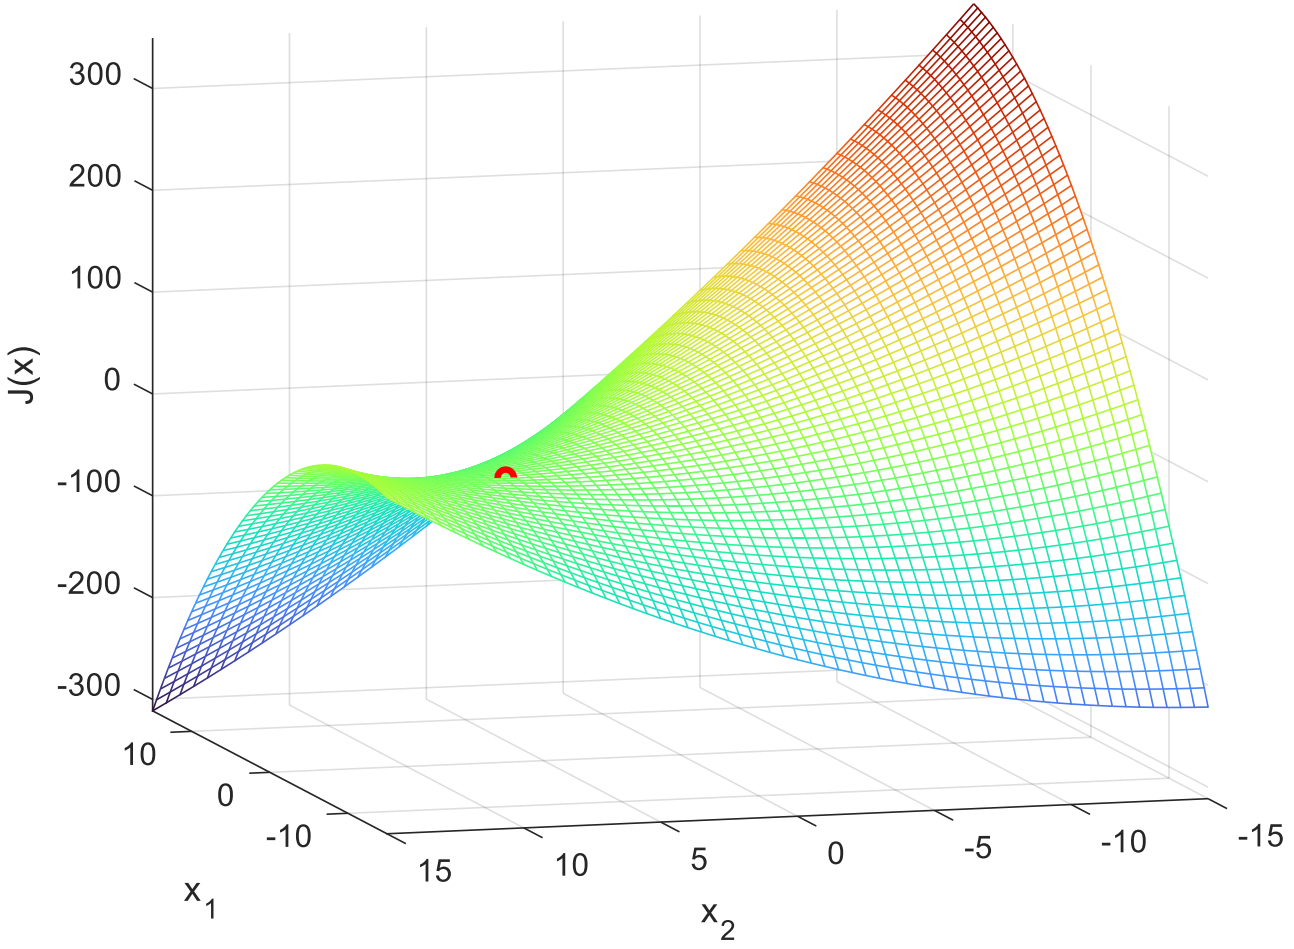




$$A = \begin{pmatrix} -1 & -1 \\ -1 & -0.5 \end{pmatrix}, b = \begin{pmatrix} 4 \\ -7 \end{pmatrix}, c = 15$$

$$\Lambda = \begin{pmatrix} 1 & 0 \\ 0 & -1.5 \end{pmatrix}$$



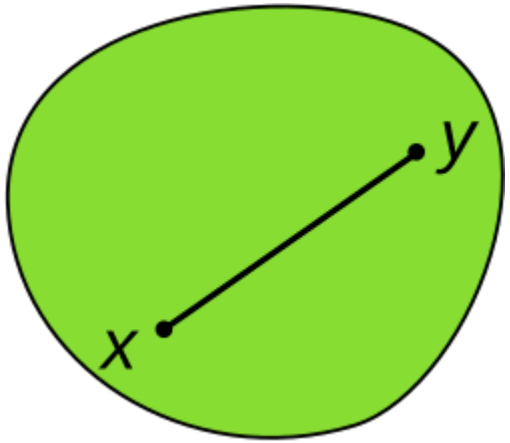


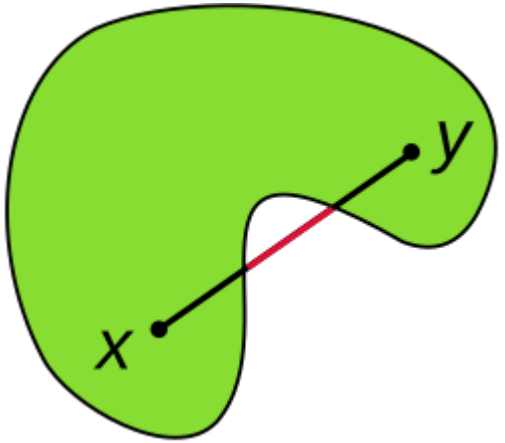
Konvexná funkcia

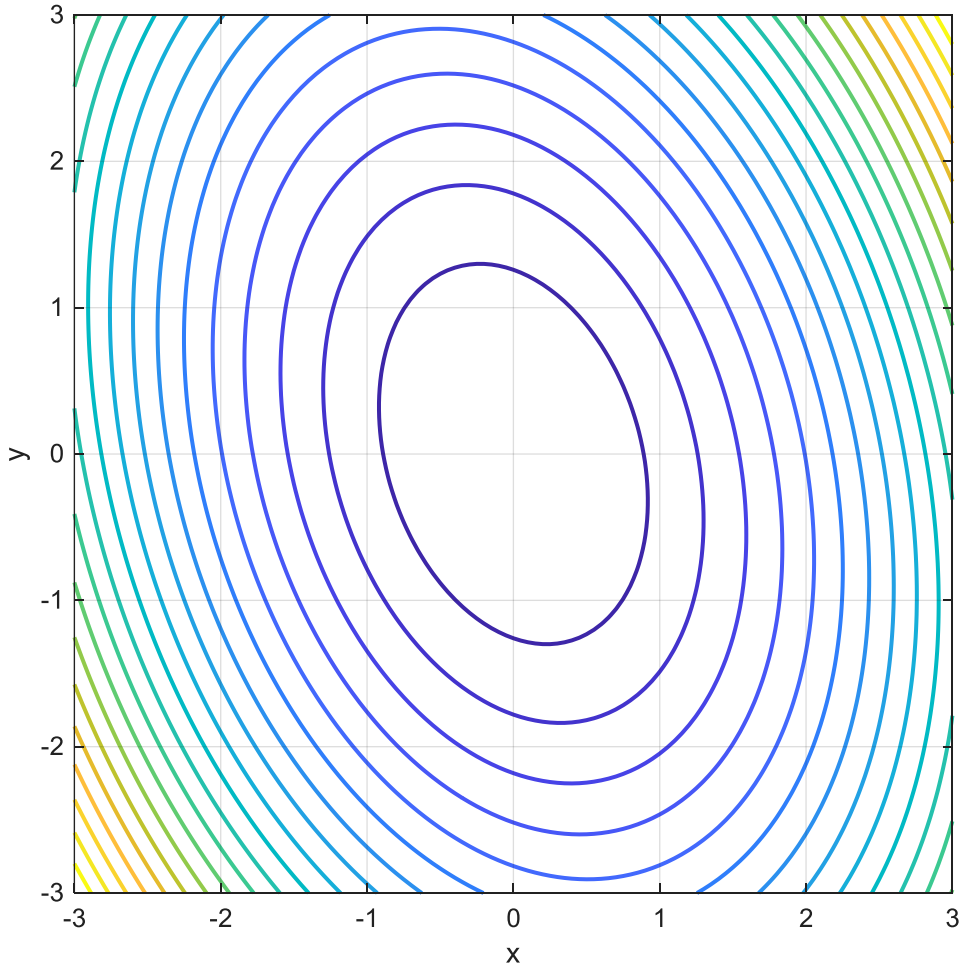
- Pre konvexnú funkciu $J(x)$: $\mathbb{R}^n \rightarrow \mathbb{R}$ na celom jej definičnom obore platí že jej Hessián je kladne definitný

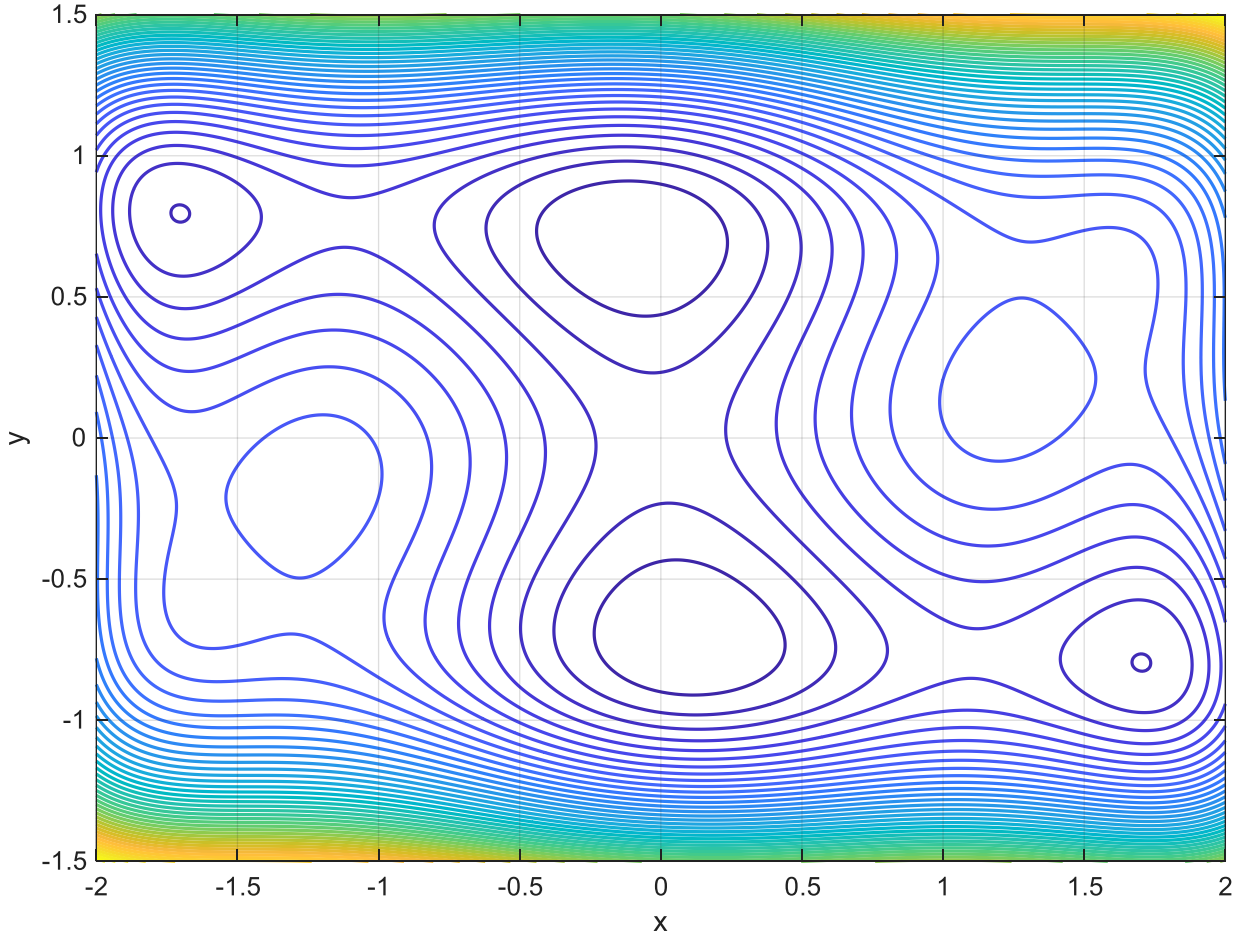
$$\nabla^2 J(x) \succ 0$$
$$\forall x \in \mathbb{R}^n$$

- Dôsledkom toho je že funkcia $J(x)$ môže mať maximálne jedno minimum
- Lokálne minimum spĺňajúce $\nabla J(x^*) = \mathbf{0}$ je preto automaticky globálnym minimom
- Izolínie funkcie tvoria množinu bodov, ktoré spĺňaju x: $J(x) = q$
- Konvexné teleso je množina, ktorá obsahuje celú úsečku spájajúcu ľubovoľné dva svoje body.
- Napríklad kvadratická forma $J(x) = \frac{1}{2} x^T A x + b^T x + c$ je kovexná ak $A \succ 0$






3
2
1
0
-1
-2
-3
y
-3
-2
-1
0
1
2
3
x


1.5
1
0.5
0
-0.5
-1
-1.5
y
-2
-1.5
-1
-0.5
0
0.5
1
1.5
2
x

Vektorová funkcia a jej Jakobián



- Uvažujme teraz vektorovú funkciu

$$g(x): \mathbb{R}^n \rightarrow \mathbb{R}^p$$

- Jej vstupom je vektor $\mathbb{R}^n$ a výstupom je ďalší vektor $\mathbb{R}^p$

$$g(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_p(x) \end{pmatrix}$$

- Jakobián $\nabla g\ (x)$: $\mathbb{R}^n \rightarrow \mathbb{R}^{p \times n}$ vektorovej funkcie $g(x)$ predstavuje maticu transponovaných gradientov (prvých derivácii) jednotlivých čiastkových funkcii $g_i(x)$

$$\nabla g(x) = \begin{pmatrix} (\nabla g_1(x))^T \\ (\nabla g_2(x))^T \\ \vdots \\ (\nabla g_p(x))^T \end{pmatrix} = \begin{pmatrix} \frac{\partial g_1(x)}{\partial x_1} & \frac{\partial g_1(x)}{\partial x_2} & \cdots & \frac{\partial g_1(x)}{\partial x_n} \\ \frac{\partial g_2(x)}{\partial x_1} & \frac{\partial g_2(x)}{\partial x_2} & \cdots & \frac{\partial g_2(x)}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_p(x)}{\partial x_1} & \frac{\partial g_p(x)}{\partial x_2} & \cdots & \frac{\partial g_p(x)}{\partial x_n} \end{pmatrix}$$

- Jakobián nie je Hessián !
- V prípadne skalárnej funkcie je Jakobián ekvivalentný transponovanému gradientu
- Hessián je Jakobián gradientu !

Užitočné pravidlá lineárnej algebry

- Pravidlo o transpozícii násobenia

$$(ABC)^T = C^T B^T A^T$$

- Násobenie inverznou maticou

$$A^{-1}A = AA^{-1} = I$$

- Násobenie jednotkovou maticou

$$AI = IA = A$$

Gradienty zložitejších funkcii

- Ak $f(x) = g(x) + h(x)$ kde $g(x)$: $\mathbb{R}^n \to \mathbb{R}$, $h(x)$: $\mathbb{R}^n \to \mathbb{R}$
  - Gradient $\nabla f(x) = \nabla g(x) + \nabla h(x)$
- Ak $f(x) = g(x)h(x)$ kde $g(x)$: $\mathbb{R}^n \to \mathbb{R}$, $h(x)$: $\mathbb{R}^n \to \mathbb{R}$
  - Gradient $\nabla f(x) = h\,\nabla g(x) + g\,\nabla h(x)$
- Ak $f(x) = g(h(x))$ (zložená funkcia) kde $g(y)$: $\mathbb{R}^n \to \mathbb{R}$, $h(x)$: $\mathbb{R}^m \to \mathbb{R}^n$ potom gradient $\nabla f(x)$ bude

$$\nabla f(x) = \left(\nabla_h(x)\right)^T \nabla g(y)$$

  Kde $\nabla_h(x) \in \mathbb{R}^{n \times m}$ je Jakobián $h(x)$, $\nabla g(y) \in \mathbb{R}^n$ je gradient $g(y)$

- Reťazové pravidlo (chain rule)

$$\frac{\partial f(x_1, x_1, \dots x_n)}{\partial z} = \frac{\partial x_1}{\partial z}\frac{\partial f(x_1, x_1, \dots x_n)}{\partial x_1} + \frac{\partial x_2}{\partial z}\frac{\partial f(x_1, x_1, \dots x_n)}{\partial x_2} + \frac{\partial x_n}{\partial z}\frac{\partial f(x_1, x_1, \dots x_n)}{\partial x_n}$$

- Reťazové pravidlo (maticový zápis)

$$\nabla_z f(x, y) = (\nabla_x^z)^T \nabla_x f(x, y) + \left(\nabla_y^z\right)^T \nabla_y f(x, y)$$

  - $\nabla_x^z \in \mathbb{R}^{n_x \times n_z}$ je Jakobián x podľa z
  - $\nabla_y^z \in \mathbb{R}^{n_y \times n_z}$ je Jakobián y podľa z
  - $\nabla_x f(x, y) \in \mathbb{R}^{n_x}$ je gradient
  - $\nabla_y f(x, y) \in \mathbb{R}^{n_y}$ je gradient

Analytická optimalizácia

- Vychádza z analytického vyjadrenia účelovej funkcie $J(x)$ a jej gradientu $\nabla J(x)$
- Účelová funkcia často nemusí byť vôbec vyjadriteľná analyticky vzhľadom na premenné x
  - Príkladom môžu byť integrálne účelové funkcie
- Nájdenie gradientu navyše nemusí byť jednoduché
- Podmienka optimálnosti $\nabla J(x^*) = \mathbf{0}$ sa musí dať riešiť analyticky
- Definitnosť Hessiánu $\nabla^2 J(x^*) \succ 0$ sa musí dať overiť
- Analytická optimalizácia v praxi skoro nikdy nie je možná !

Príklad

- Majme kvadratickú účelovú funkciu dvoch premenných

$$J(x_1, x_2) = x_1^2 + x_2^2 - 4x_1 + 6x_2$$

- Nájdime prvé parciálne derivácie (gradient)

$$\frac{\partial J(x_1, x_2)}{\partial x_1} = 2x_1 - 4$$

$$\frac{\partial J(x_1, x_2)}{\partial x_2} = 2x_2 + 6$$

- Podmienka stacionárnosti $\frac{\partial J(x_1,x_2)}{\partial x_1} = \frac{\partial J(x_1,x_2)}{\partial x_2} = 0$ vedie na

$$2x_1 - 4 = 0 \Rightarrow 2x_1 = 4 \Rightarrow x_1 = 2$$

$$2x_2 + 6 \Rightarrow 2x_2 = -6 \Rightarrow x_2 = -3$$

- Nájdime druhé parciálne derivácie (Hessián)

$$\frac{\partial^2 J(x_1, x_2)}{\partial {x_1}^2} = 2$$

$$\frac{\partial^2 J(x_1, x_2)}{\partial {x_2}^2} = 2$$

$$\frac{\partial^2 J(x_1, x_2)}{\partial x_1 \partial x_2} = 0$$

$$\nabla^2 J(x) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \succ 0$$

- Nájdený stacionárny bod je teda minimum

Príklad

- Majme účelovú funkciu jednej premennej

$$J(x) = -5e^{-(x-2)^2}$$

- Nájdime prvú deriváciu

$$\frac{\partial J(x)}{\partial x} = 10(x-2)e^{-(x-2)^2}$$

- Podmienka stacionárnosti $\frac{\partial J(x)}{\partial x} = 0$ vedie na

$$-10(x-2)e^{-(x-2)^2} = 0 \Rightarrow x - 2 = 0 \Rightarrow x = 2$$

- Nájdime druhú deriváciu

$$\frac{\partial^2 J(x)}{\partial x^2} = \left(-20(x-2)^2 + 10\right)e^{-(x-2)^2}$$

$$\left.\frac{\partial^2 J(x)}{\partial x^2}\right|_{x=2} = 10e^0 = 1 > 0$$

- Nájdený stacionárny bod je teda minimum

$$J(x) = -5e^{-(x-2)^2}$$

