Gradientné metódy

Numerická optimalizácia

- Využíva iteračné metódy (algoritmy) na numerické nájdenie optima
- Snaží sa nájsť čo najpresnejšiu **aproximáciu** optima
- Postupné spresňovanie riešenia medzi iteráciami
- Minimálna hodnota účelovej funkcie sa hľadá „posúvaním“ sa v každom kroku
- Iterácie sa opakujú pokiaľ sa nedosiahne požadovaná tolerancia
  - Stagnácia poklesu účelovej funkcie
  - Veľkosť gradientu poklesne pod požadovanú hodnotu
- Numerické overenie splnenia postačujúcich podmienok extrému
  - Stacionárnosť (veľkosť gradientu blízka nule)
  - Definitnosť Hessiánu (numerický výpočet jeho vlastných čísel)



Gradientné optimalizačné metódy

- Využívajú znalosť gradientu optimalizačného problému
  - Gradient musíme odvodiť/nájsť
  - V každej iterácii musíme vypočítať hodnotu gradientu
- **Základný princíp**
  - Chceme aby účelová funkcia postupne klesala
  - Gradient $\nabla J(x)$ v danom bode určuje lokálny smer najstrmšieho nárastu funkcie
  - Musíme sa pohybovať proti gradientu
  - Antigradient $-\nabla J(x)$ v danom bode určuje lokálny smer najstrmšieho poklesu funkcie



Algoritmus všeobecnej gradientnej metódy

- V každom kroku sa vypočíta nový bod (aproximácia optima)
- Nový bod počítame rekurzívne ako

$$x(k+1) = x(k) - \gamma \nabla J\big(x(k)\big)$$

kde $\nabla J\big(x(k)\big)$ je gradient v $x(k)$ a $\gamma > 0$ je relatívna veľkosť kroku

- Smer je vždy určený antigradientom funkcie
- Relatívna veľkosť kroku γ môže byť fixná alebo variabilná
  - Malý krok – pomalá konvergencia
  - Veľký krok – oscilácie okolo optima a riziko nestability
- Algoritmus ukončujeme ak je splnená podmienka (veľkosť gradientu)

$$\Big(\nabla J\big(x(k)\big)\Big)^T \nabla J\big(x(k)\big) < \epsilon$$

Stabilita (konvergencia) gradientovej metódy pre kvadratickú formu

- Uvažujme krok gradientovej metódy

$$x(k+1) = x(k) - \gamma \nabla J\big(x(k)\big)$$

- Pričom gradient $\nabla J\big(x(k)\big)$ pre kvadratickú formu bude

$$\nabla J\big(x(k)\big) = Ax(k) + b$$

- Dosadíme a získame

$$x(k+1) = x(k) - \gamma(Ax(k) + b)$$
$$x(k+1) = (I - \gamma A)x(k) - \gamma b$$

- Získavame tak diferenčnú rovnicu diskrétneho systému v stavovom opise
- Riešenie bude stabilné ak vlastné čísla matice $(I - \gamma A)$ budú v jednotkovej kružnici
  - Pre malé γ je preto táto podmienka ľahko splnená
  - Pre veľké γ hrozí nestabilita (divergencia)

Prečo musia vlastné čísla tohto systému ležať vnútri jednotkovej kružnice?

- Nech máme **diskrétny dynamický systém** bez vstupu:

$$x(k+1) = Ax(k)$$

- Cieľ: zistiť **kedy je systém asymptoticky stabilný**, teda:

$$\lim_{n\to\infty} x(k+n) = 0;\ \forall x(k)$$

- Z hore uvedenej rekurzívnej rovnice môžeme získať explicitný vzťah:

$$x(k+2) = Ax(k+1)$$
$$x(k+2) = AAx(k)$$
$$x(k+n) = A^n x(k)$$

- Predpokladajme, že A je diagonalizovateľná:

$$x(k+n) = Q\Lambda Q^{-1} Q\Lambda Q^{-1} \dots Q\Lambda Q^{-1} x(k)$$
$$x(k+n) = Q\Lambda^n Q^{-1} x(k)$$

- Matica Λ je diagonálna s vlastnými číslami λ_i na diagonále:

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) \implies \Lambda^k = \mathrm{diag}\left(\lambda_1^k, \lambda_2^k, \dots, \lambda_n^k\right)$$

- Čo sa stane s λ^k keď $k \to \infty$?
- Nech $\lambda \in \mathbb{C}$, potom pre ľubovoľné komplexné číslo platí:

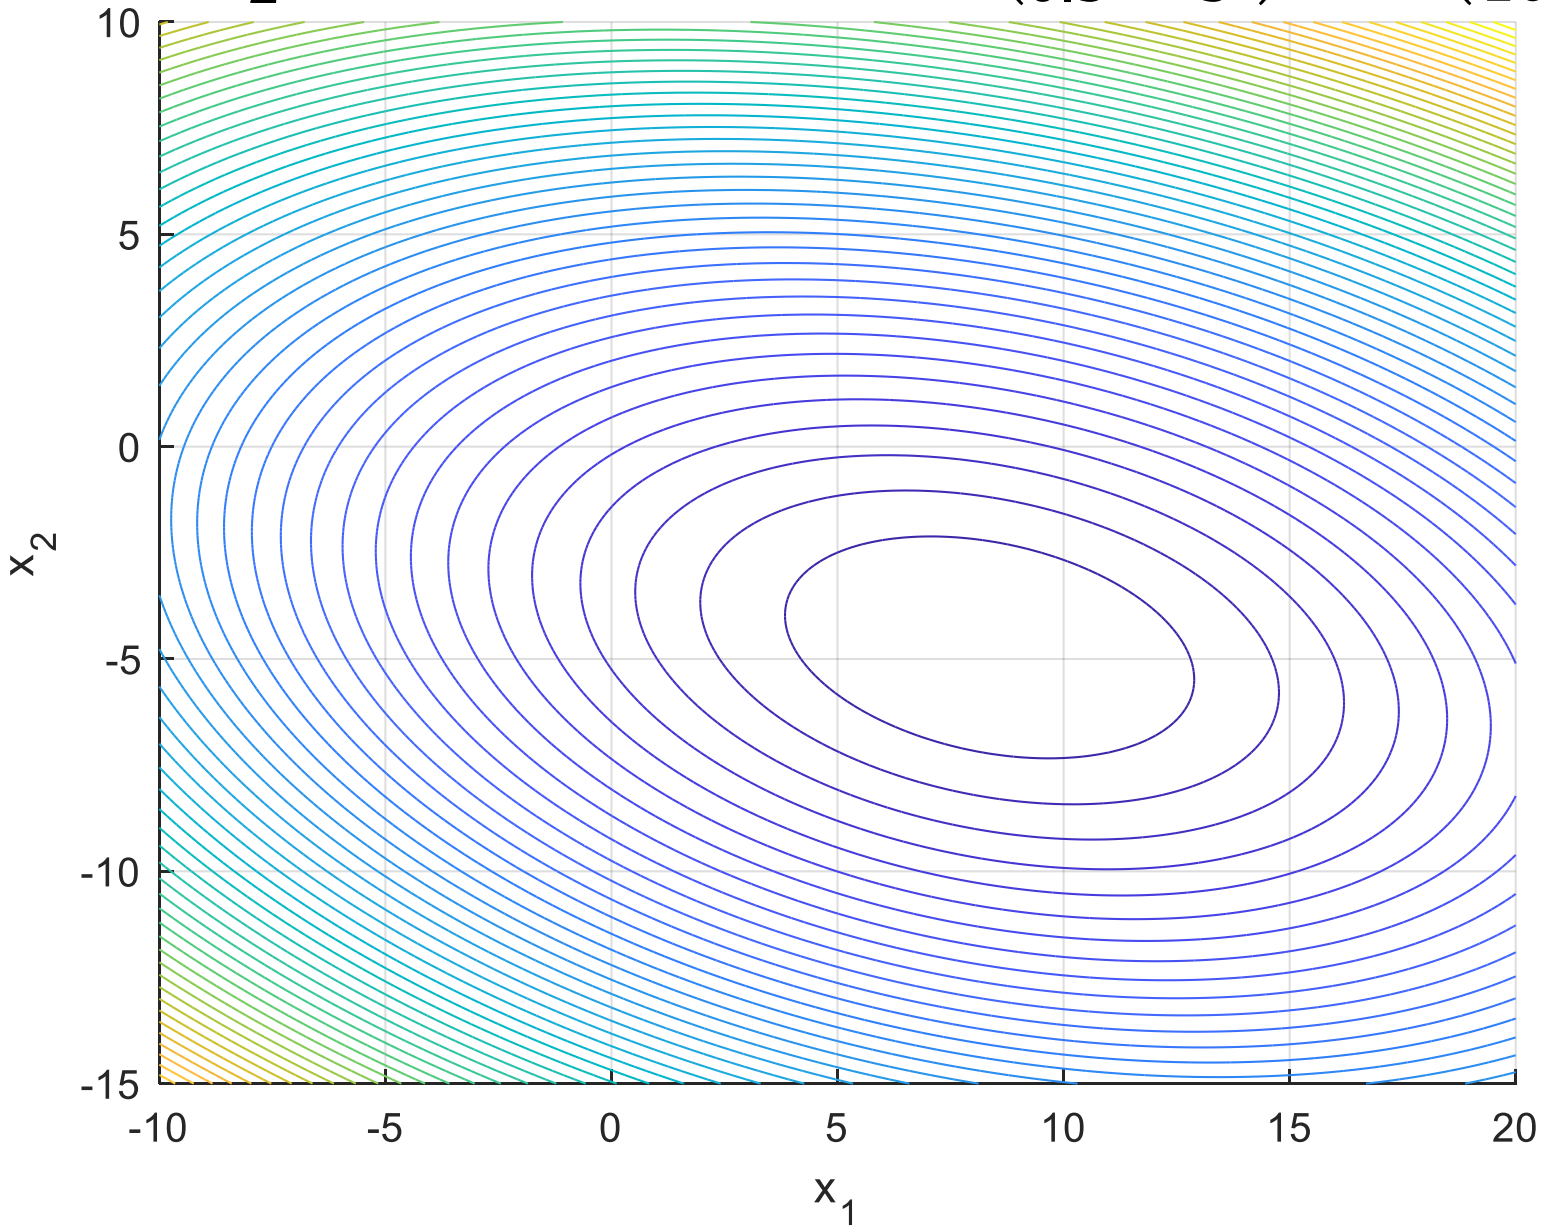
$$\lambda = re^{j\theta}, \text{kde } r = |\lambda| \text{ je magnitúda}$$

- Potom teda platí:

$$\lambda^k = \left(re^{j\theta}\right)^k = r^k e^{jk\theta}$$

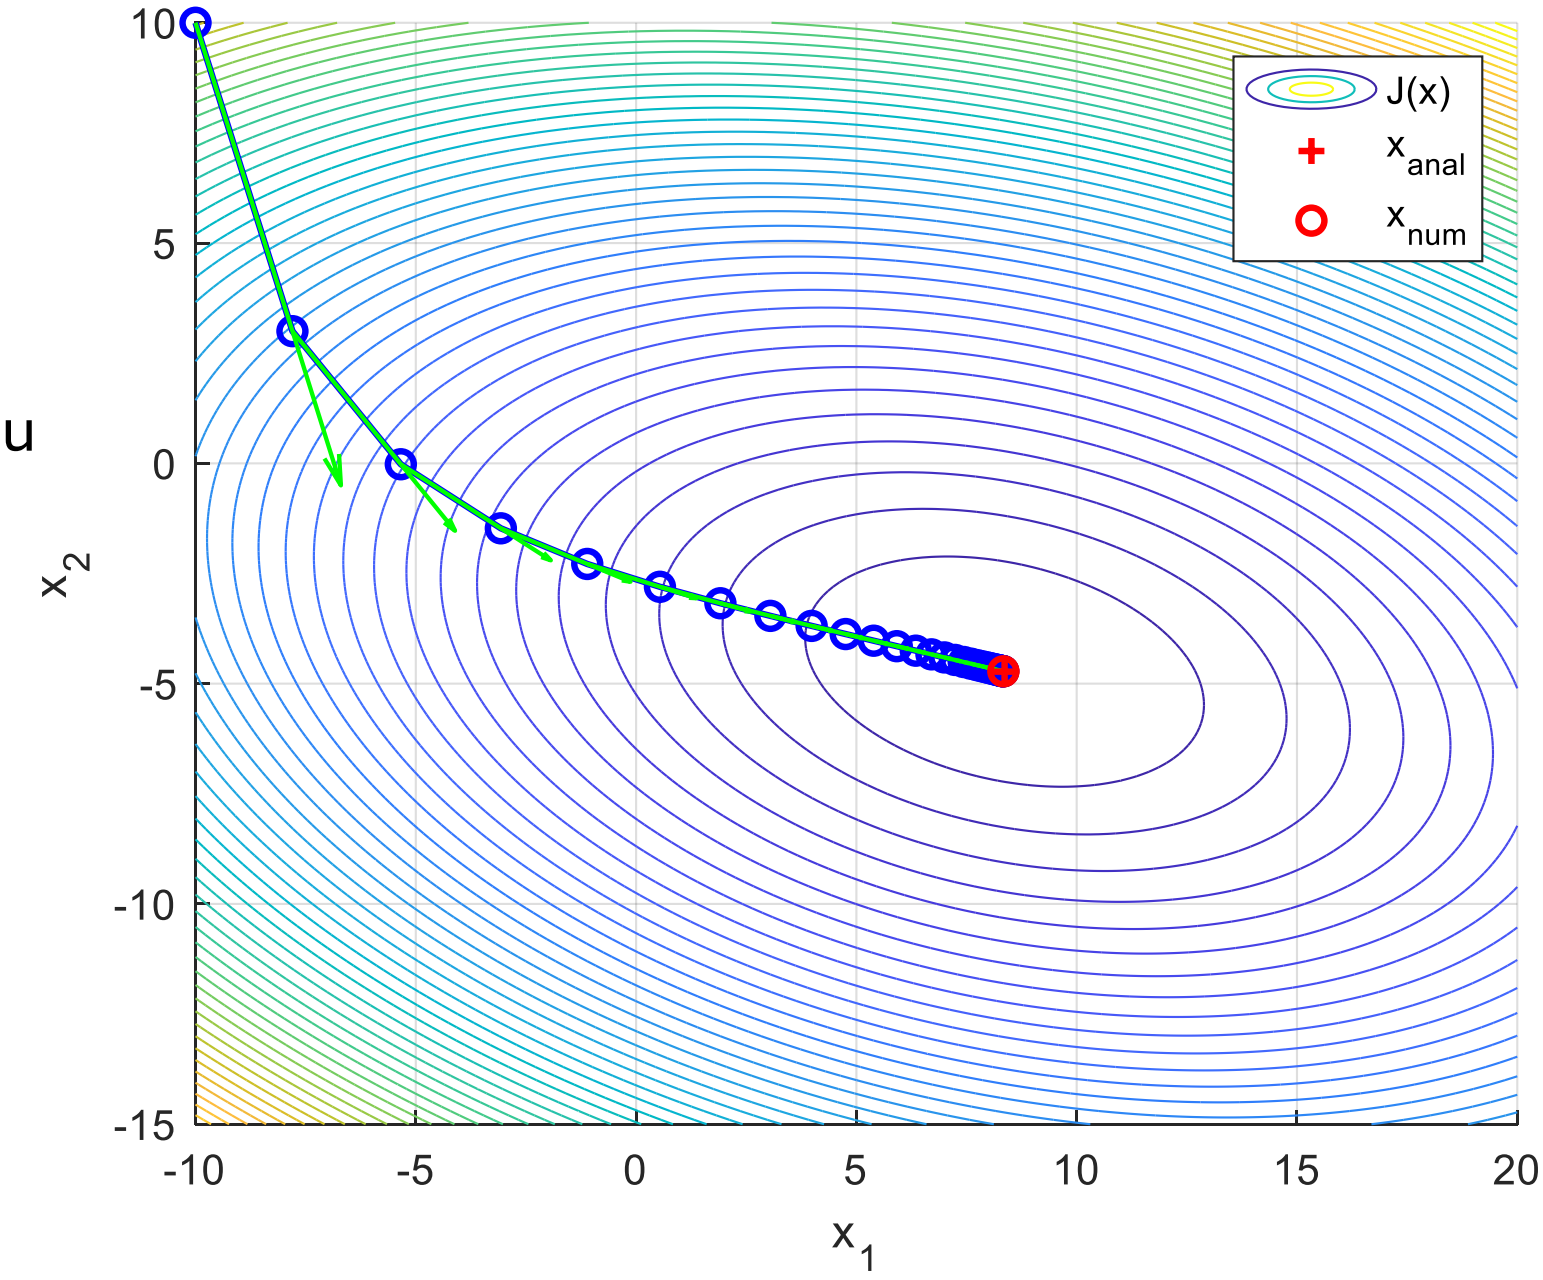
- r^k určuje rast alebo útlm
- $e^{jk\theta}$ predstavuje iba rotáciu v komplexnej rovine – neovplyvňuje veľkosť (modul)

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c, \qquad A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 3 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$



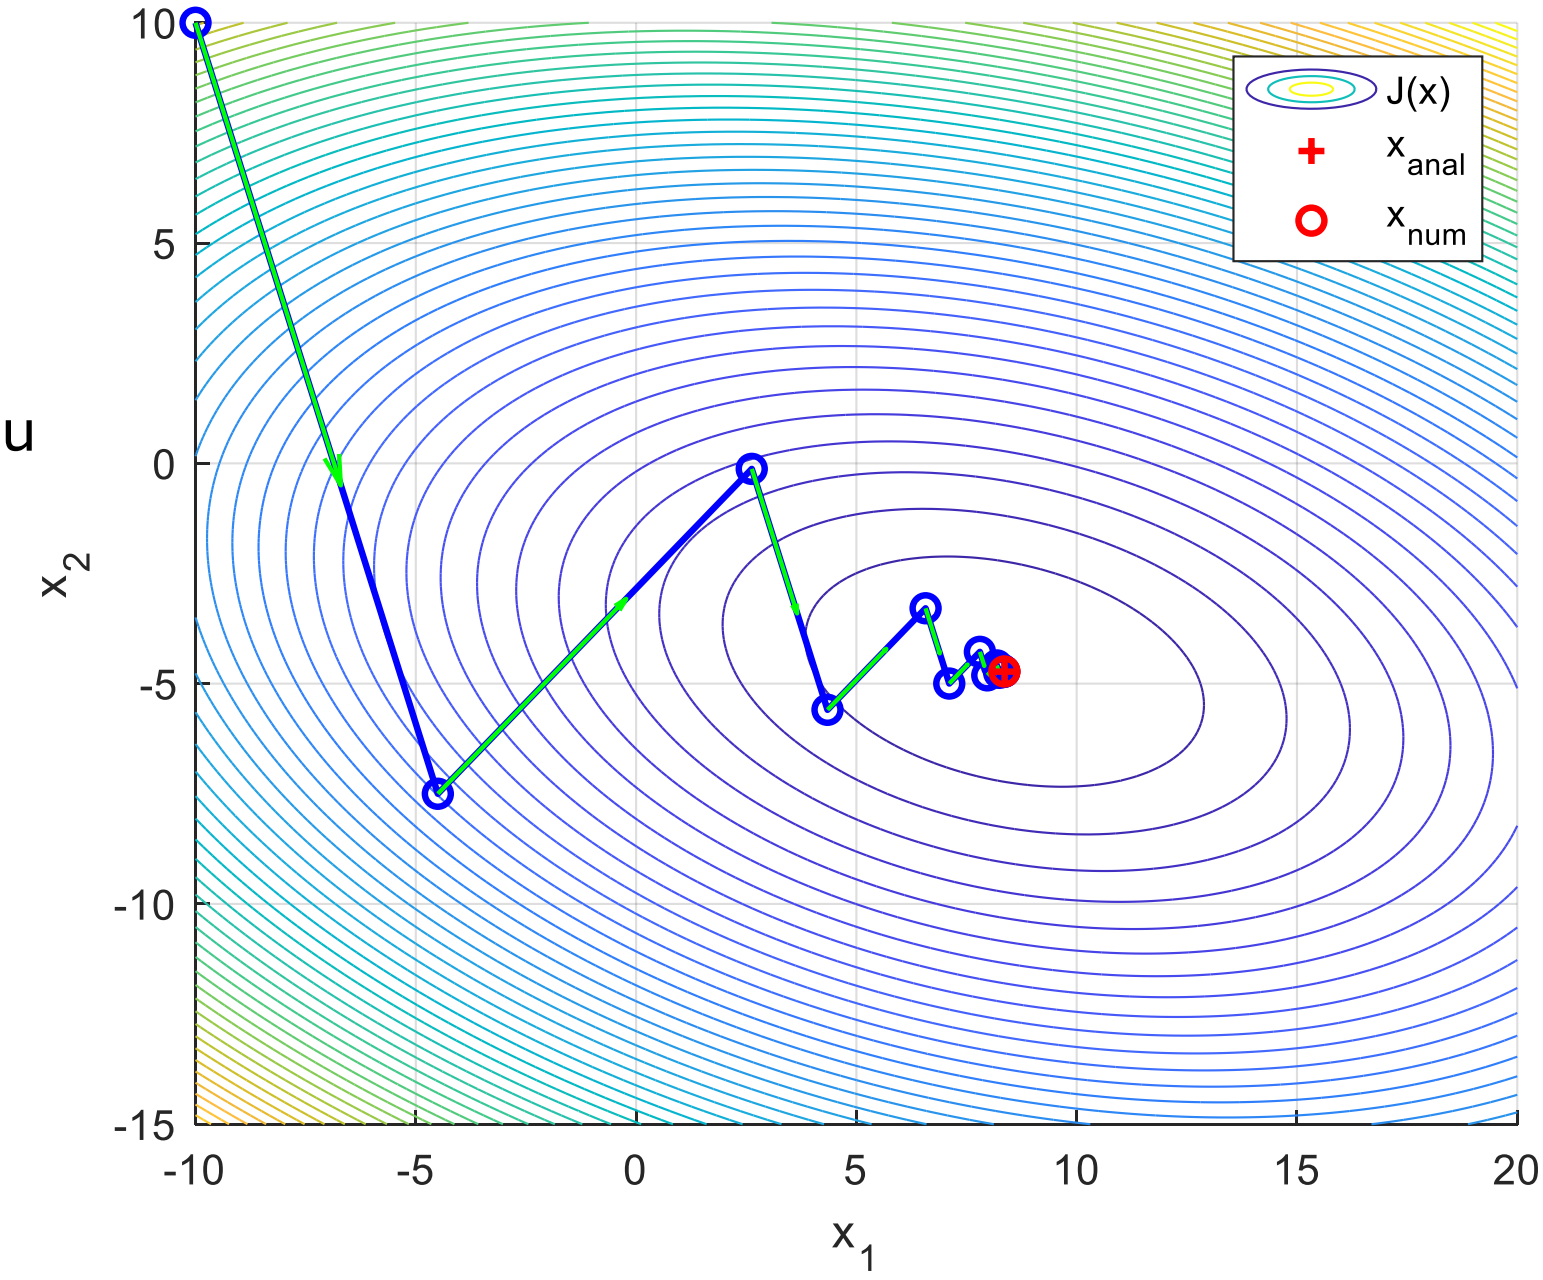
$\gamma = 0.2$

Stabilný algoritmus s pomalou konvergenciou



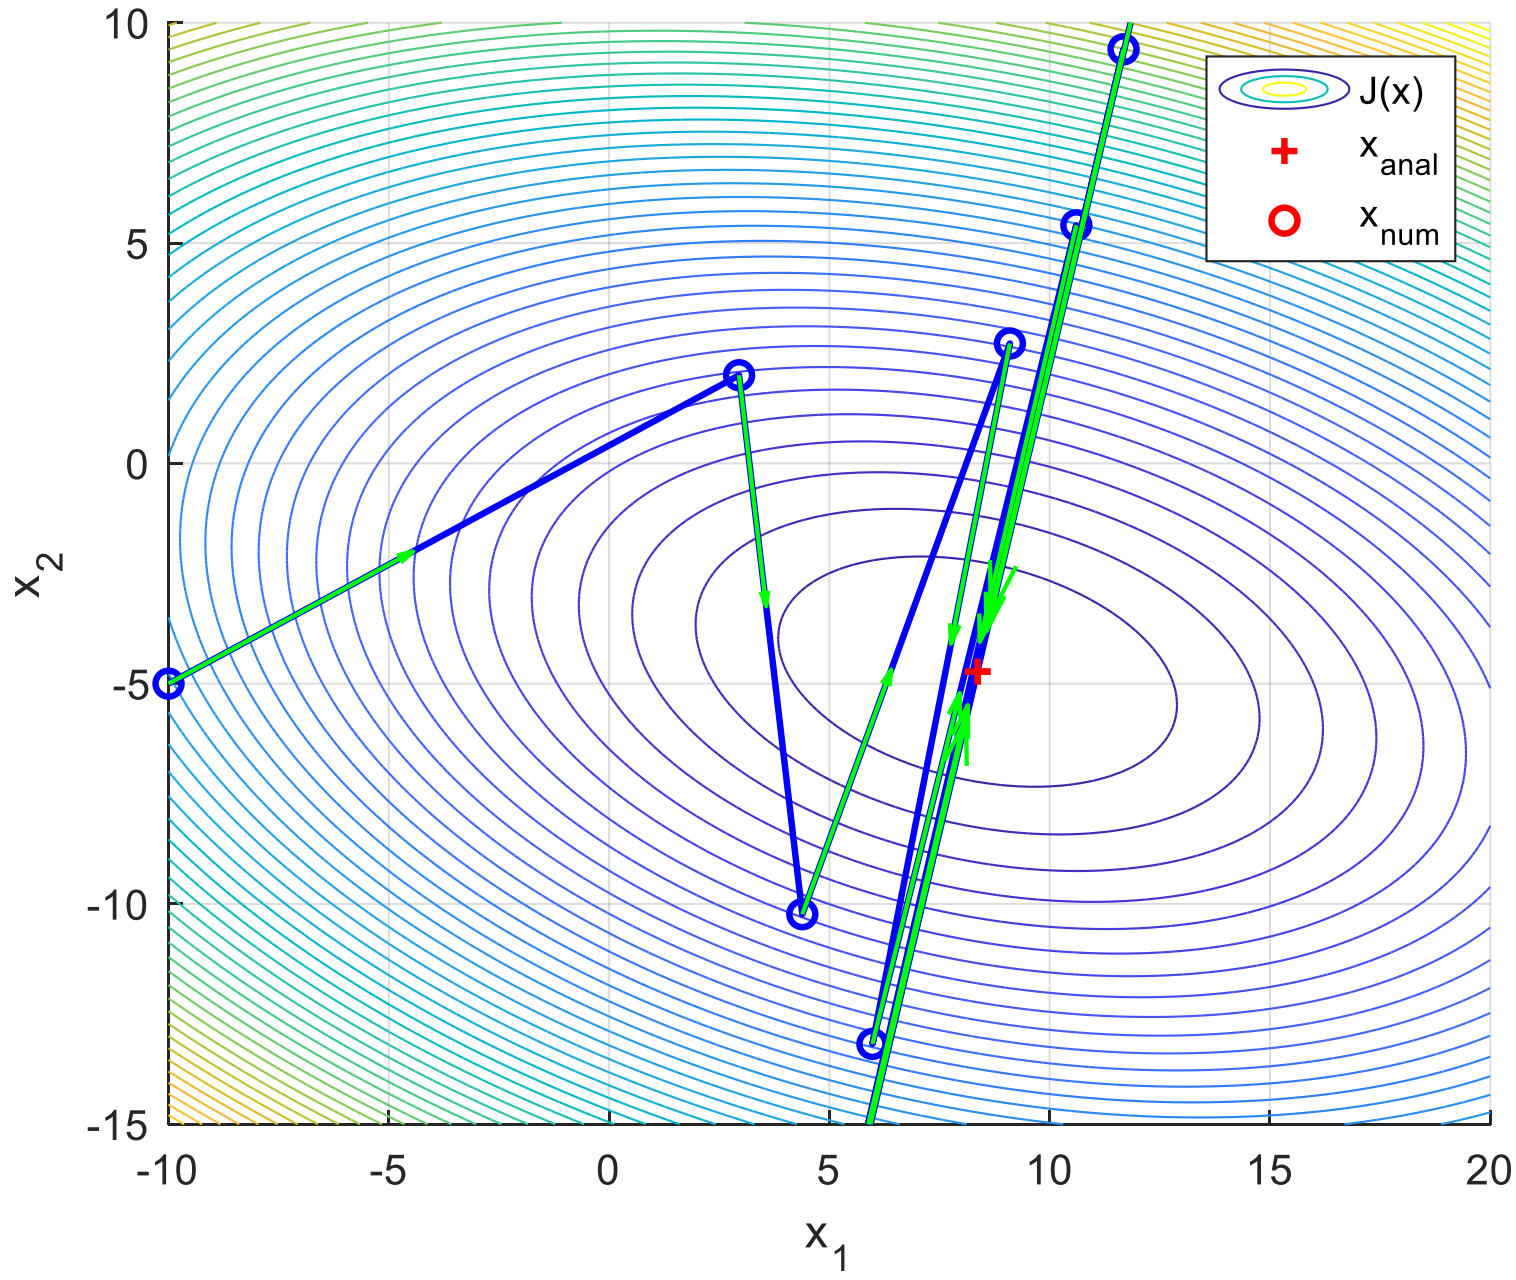
$\gamma = 0.5$

Stabilný algoritmus s oscilujúcou konvergenciou



$\gamma = 0.7$

Nestabilita algoritmu



Gradientová metóda s optimálnou dĺžkou kroku



- Nový bod počítame rekurzívne ako

$$x(k+1) = x(k) - \gamma(k)\nabla J\big(x(k)\big)$$

- **V smere antigradientu sa dá ísť pokiaľ sa funkčné hodnoty na priamke $\boldsymbol{x(k) - \gamma(k)\nabla J\big(x(k)\big)}$ vzhľadom na $\boldsymbol{\gamma(k)}$ zmenšujú**
- Musíme nájsť relatívnu veľkosť kroku $\gamma(k)$ takú že:

$$\gamma(k) = \arg\min_{\gamma(k)} J\left(x(k) - \gamma(k)\nabla J\big(x(k)\big)\right)$$

- V každom kroku riešime **jednorozmernú optimalizáciu $\boldsymbol{\gamma(k)}$**
- Gradienty v po sebe idúcich krokoch sú navzájom kolmé
- Optimálnu veľkosť kroku $\gamma(k)$ môžeme voliť s využitím gradientu $\nabla J\big(x(k)\big)$ a Hessiánu $\nabla^2 J\big(x(k)\big)$ ako

$$\gamma(k) = \frac{\nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T \nabla^2 J\big(x(k)\big) \nabla J\big(x(k)\big)}$$

Optimálna veľkosť kroku $\gamma(k)$ (odvodenie)

- Do kvadratickej formy dosadím krok gradientovej metódy

$$J\big(x(k+1)\big) = \frac{1}{2}\Big(x(k) - \gamma(k)\nabla J\big(x(k)\big)\Big)^T A\left(x(k) - \gamma(k)\nabla J\big(x(k)\big)\right) + b^T\left(x(k) - \gamma(k)\nabla J\big(x(k)\big)\right) + c$$

- Derivujem podľa $\gamma(k)$

$$\frac{\partial J(x)}{\partial \gamma(k)} = -b^T\nabla J\big(x(k)\big) + \gamma(k)\left(\nabla J\big(x(k)\big)\right)^T A\,\nabla J\big(x(k)\big) - x(k)^T A\,\nabla J\big(x(k)\big)$$

- Deriváciu položím rovnú nule $\frac{\partial J(x)}{\partial \gamma(k)} = 0$

$$\gamma(k)\nabla J\big(x(k)\big)^T A\nabla J\big(x(k)\big) = b^T\nabla J\big(x(k)\big) + x(k)^T A\nabla J\big(x(k)\big)$$

$$\gamma(k)\nabla J\big(x(k)\big)^T A\nabla J\big(x(k)\big) = \big(b^T + x(k)^T A\big)\nabla J\big(x(k)\big)$$

$$\gamma(k) = \frac{\big(b^T + x(k)^T A\big)\nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A\nabla J\big(x(k)\big)}$$

- Pretože $\big(b^T + x(k)^T A\big) = \left(\nabla J\big(x(k)\big)\right)^T$, potom pre $\gamma(k)$ získavam

$$\gamma(k) = \frac{\nabla J\big(x(k)\big)^T\nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A\nabla J\big(x(k)\big)}$$

Kolmosť dvoch po sebe idúcich gradientov

- Gradient v aktuálnom kroku je

$$\nabla J\big(x(k)\big) = Ax(k) + b$$

- Nový odhad bude

$$x(k+1) = x(k) - \frac{\nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A \nabla J\big(x(k)\big)} \nabla J\big(x(k)\big)$$

- Gradient v novom kroku bude

$$\nabla J\big(x(k+1)\big) = Ax(k+1) + b$$

$$\nabla J\big(x(k+1)\big) = A\left(x(k) - \frac{\nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A \nabla J\big(x(k)\big)} \nabla J\big(x(k)\big)\right) + b$$

$$\nabla J\big(x(k+1)\big) = \nabla J\big(x(k)\big) - \frac{\nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A \nabla J\big(x(k)\big)} A\, \nabla J\big(x(k)\big)$$

- Analyzujme teraz skalárny súčin medzi $\nabla J\big(x(k)\big)$ a $\nabla J\big(x(k+1)\big)$ pre overenie kolmosti

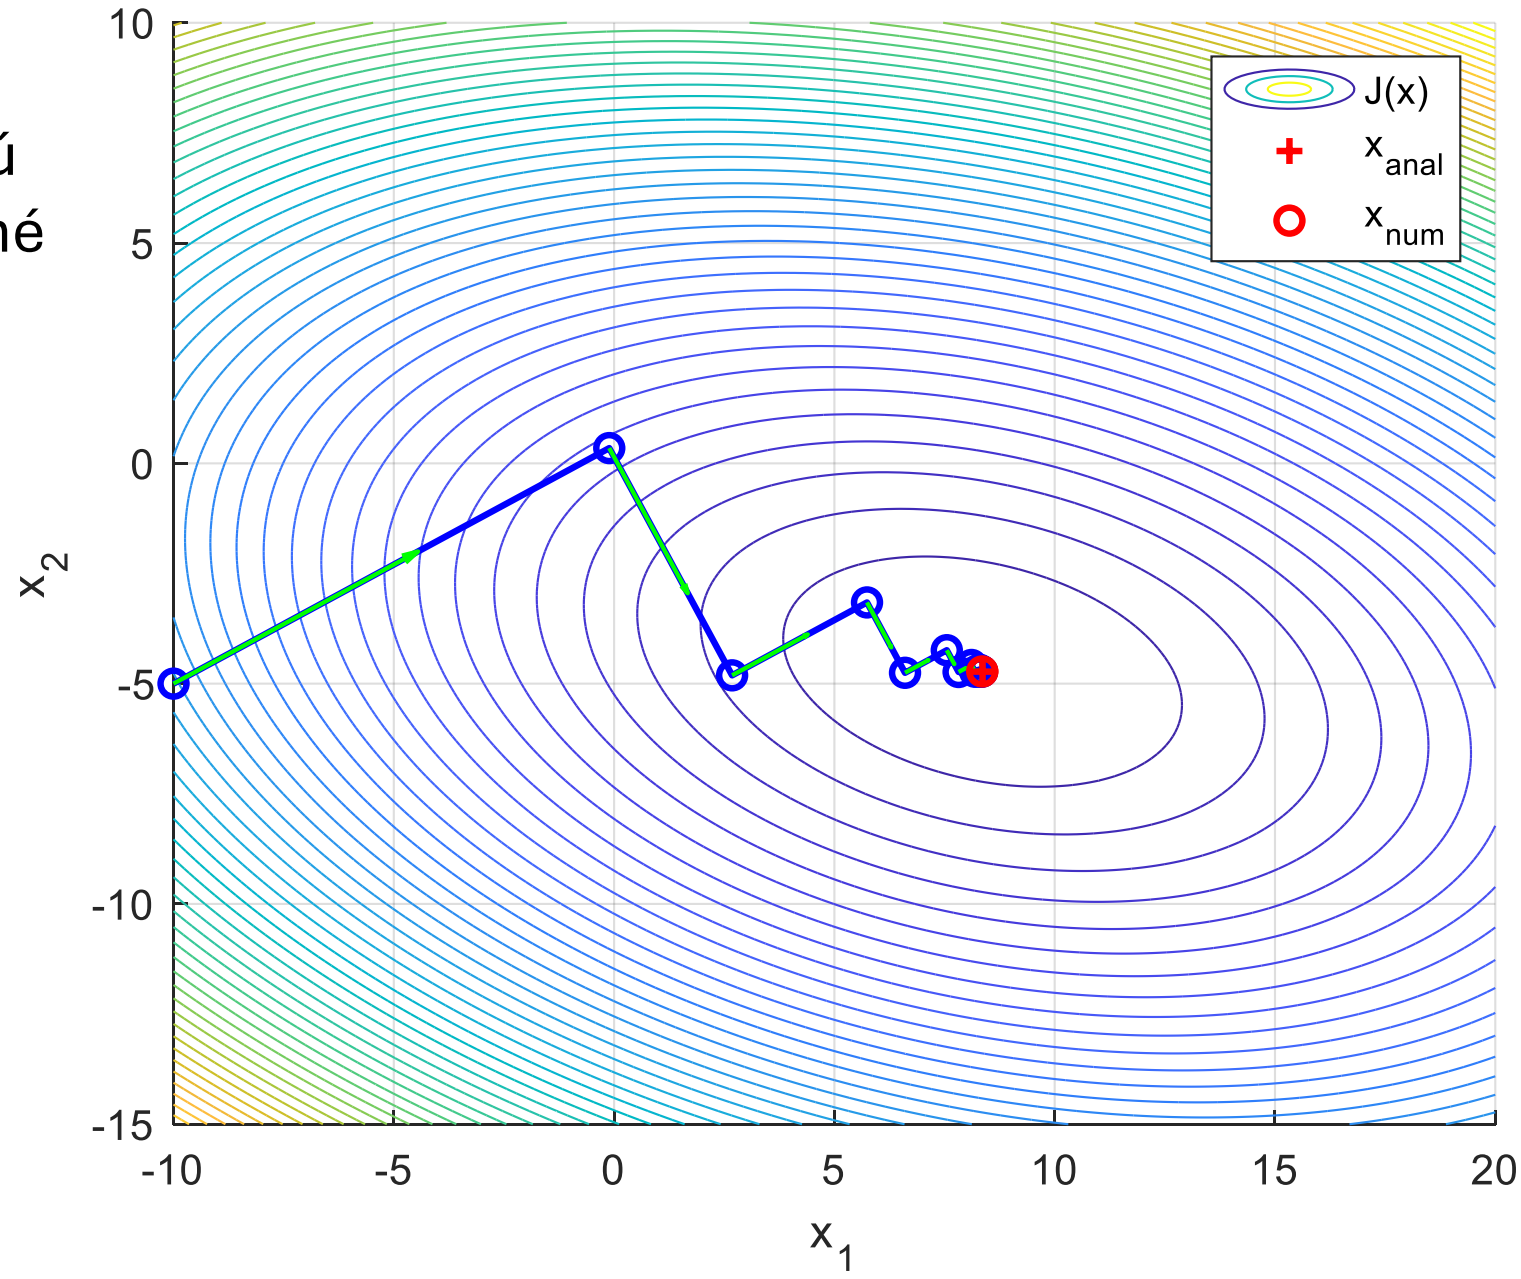
$$\nabla J\big(x(k+1)\big)^T \nabla J\big(x(k)\big) = \nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big) - \nabla J\big(x(k)\big)^T \frac{\nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A \nabla J\big(x(k)\big)} A\, \nabla J\big(x(k)\big)$$

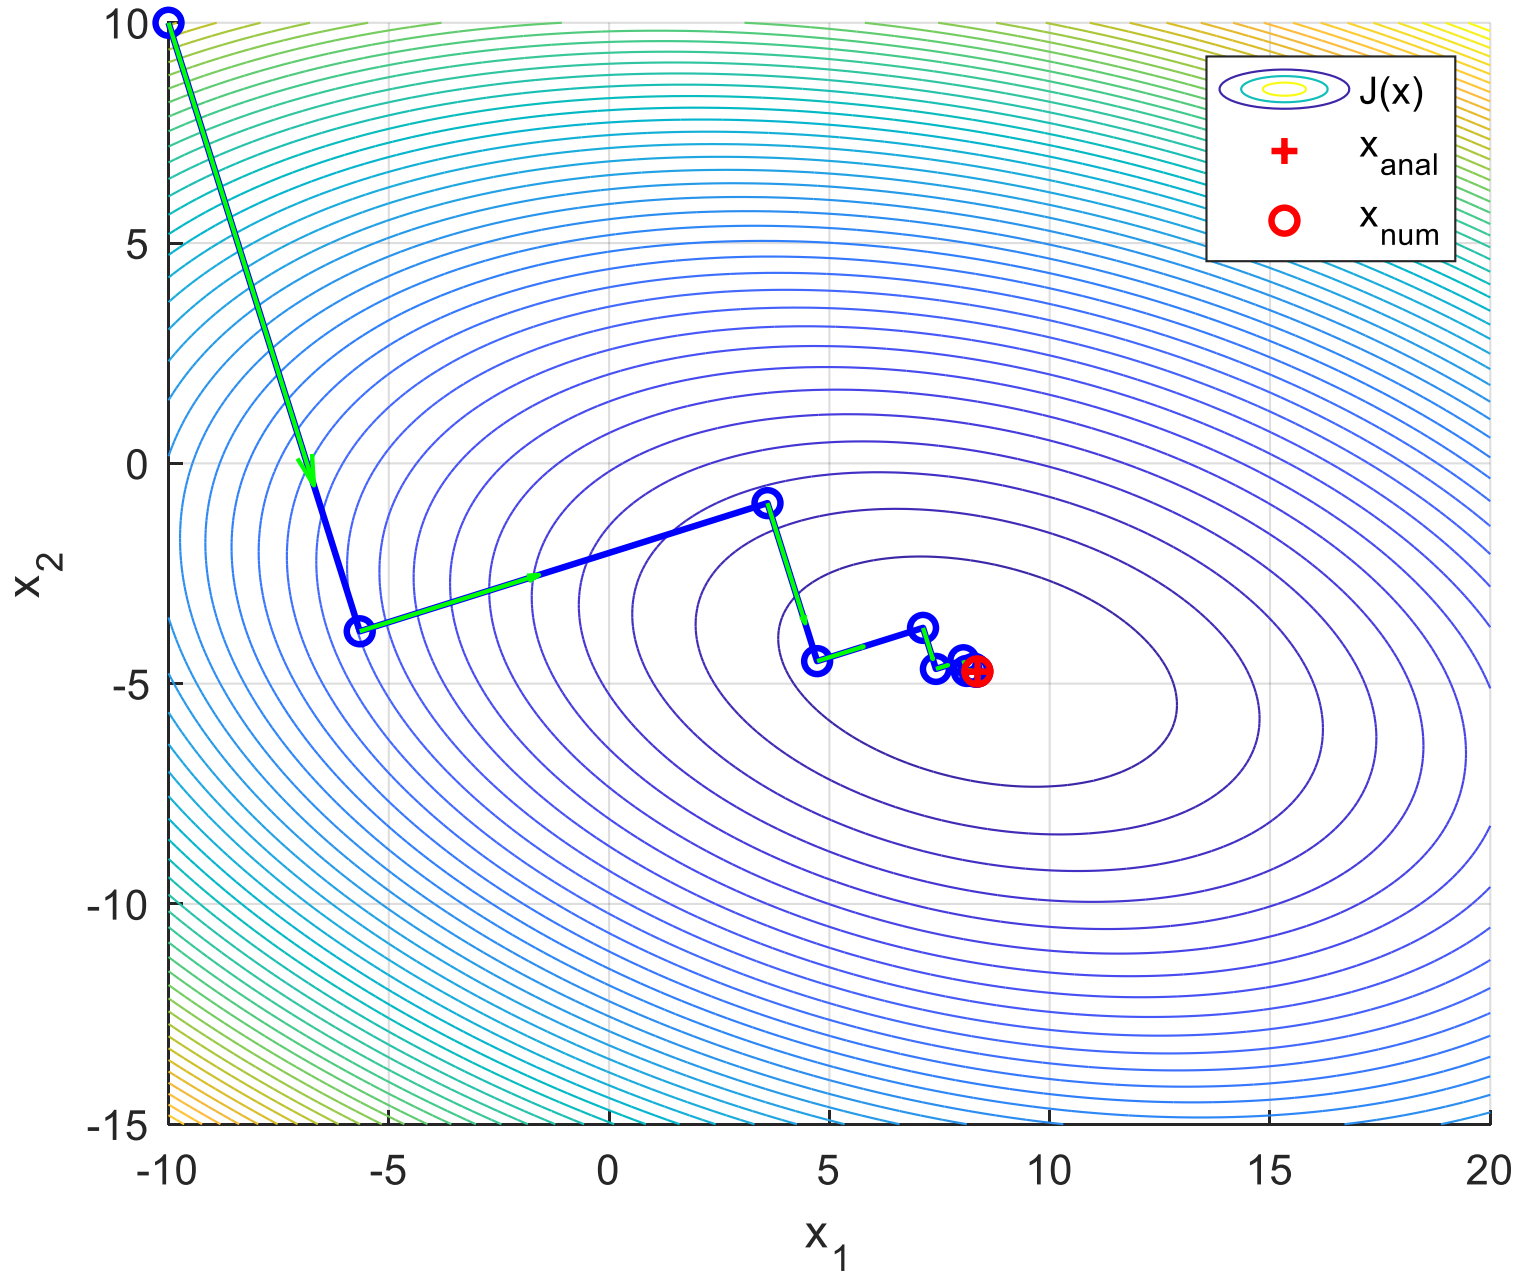
$$\nabla J\big(x(k+1)\big)^T \nabla J\big(x(k)\big) = \nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big) - \frac{\nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big)}{\nabla J\big(x(k)\big)^T A \nabla J\big(x(k)\big)} \nabla J\big(x(k)\big)^T A\, \nabla J\big(x(k)\big)$$

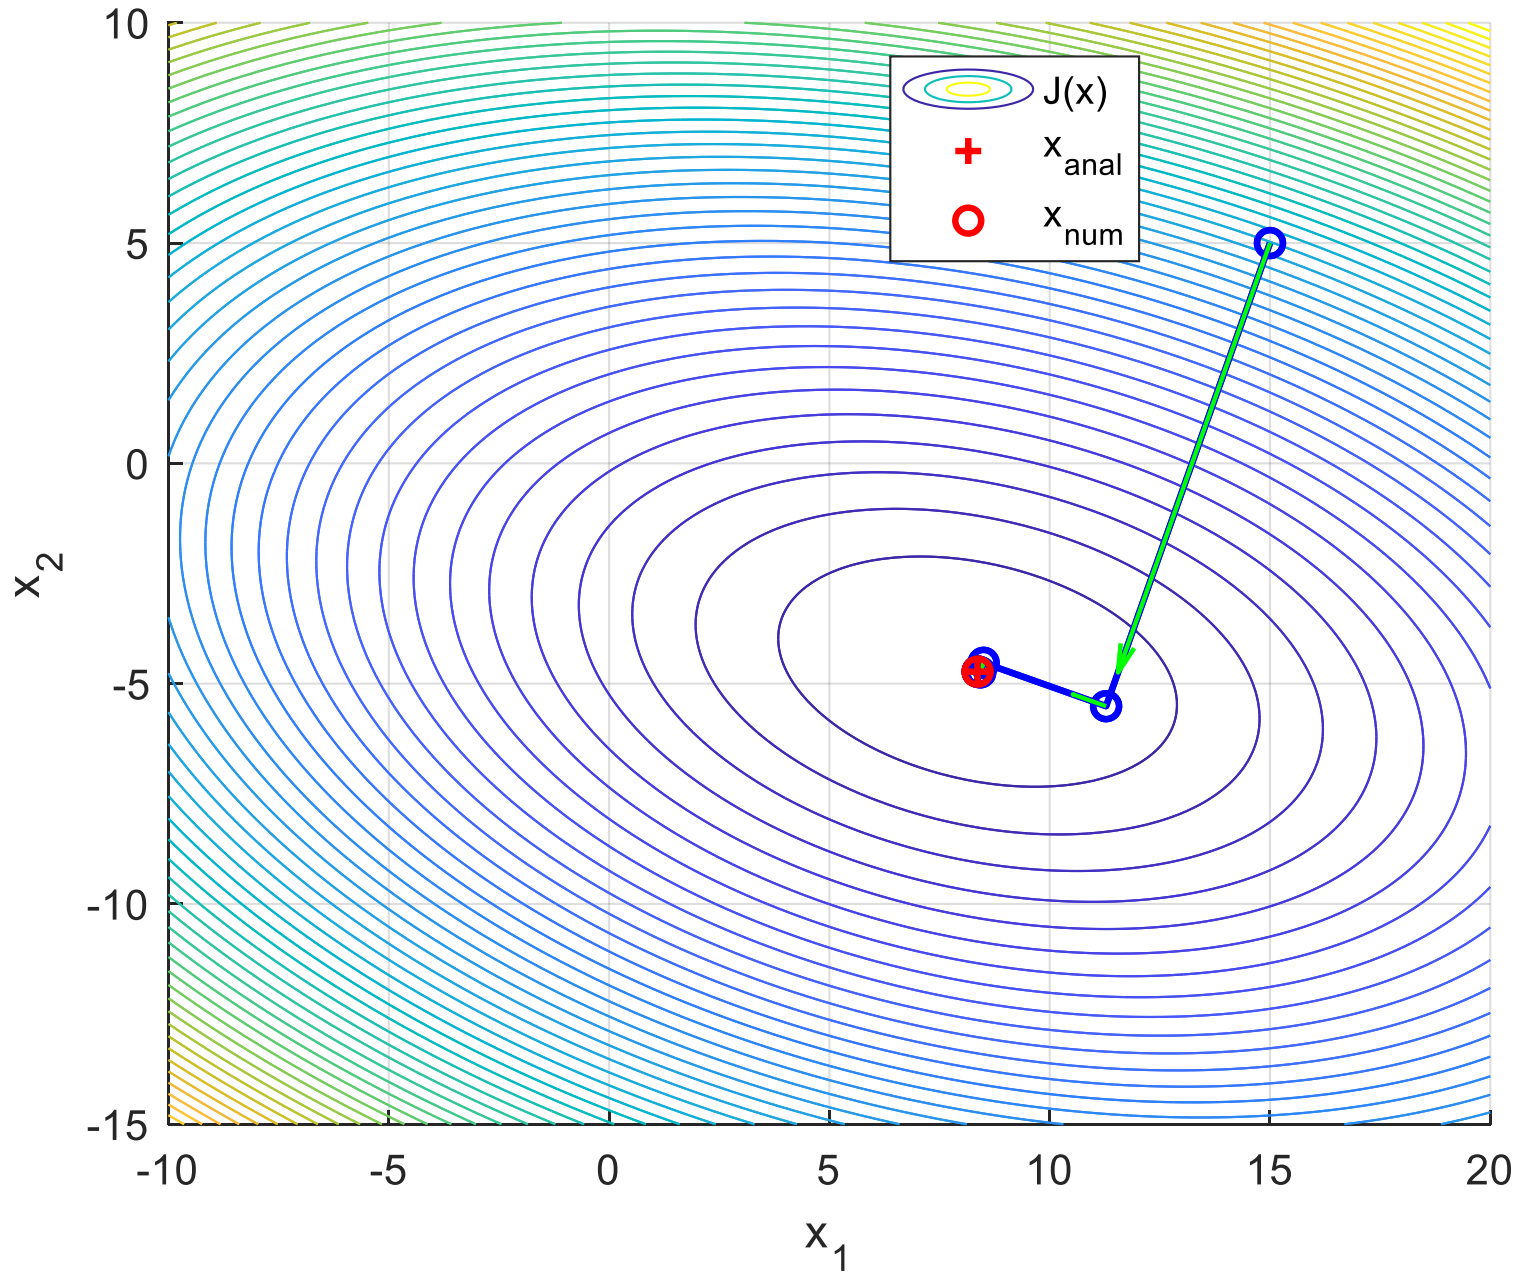
$$\nabla J\big(x(k+1)\big)^T \nabla J\big(x(k)\big) = \nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big) - \nabla J\big(x(k)\big)^T \nabla J\big(x(k)\big) = 0$$

- Po sebe idúce gradienty sú teda ortogonálne (kolmé)

Smery (gradienty) sú na seba kolmé




J(x)
x anal
x num
10
5
0
-5
-10
-15
-10
-5
0
5
10
15
20
x 2
x 1


J(x)
x anal
x num
10
5
0
-5
-10
-15
-10
-5
0
5
10
15
20
x 2
x 1

$$J(x) = \left({x_1}^2 + x_2 - 11\right)^2 + \left(x_1 + {x_2}^2 - 7\right)^2$$

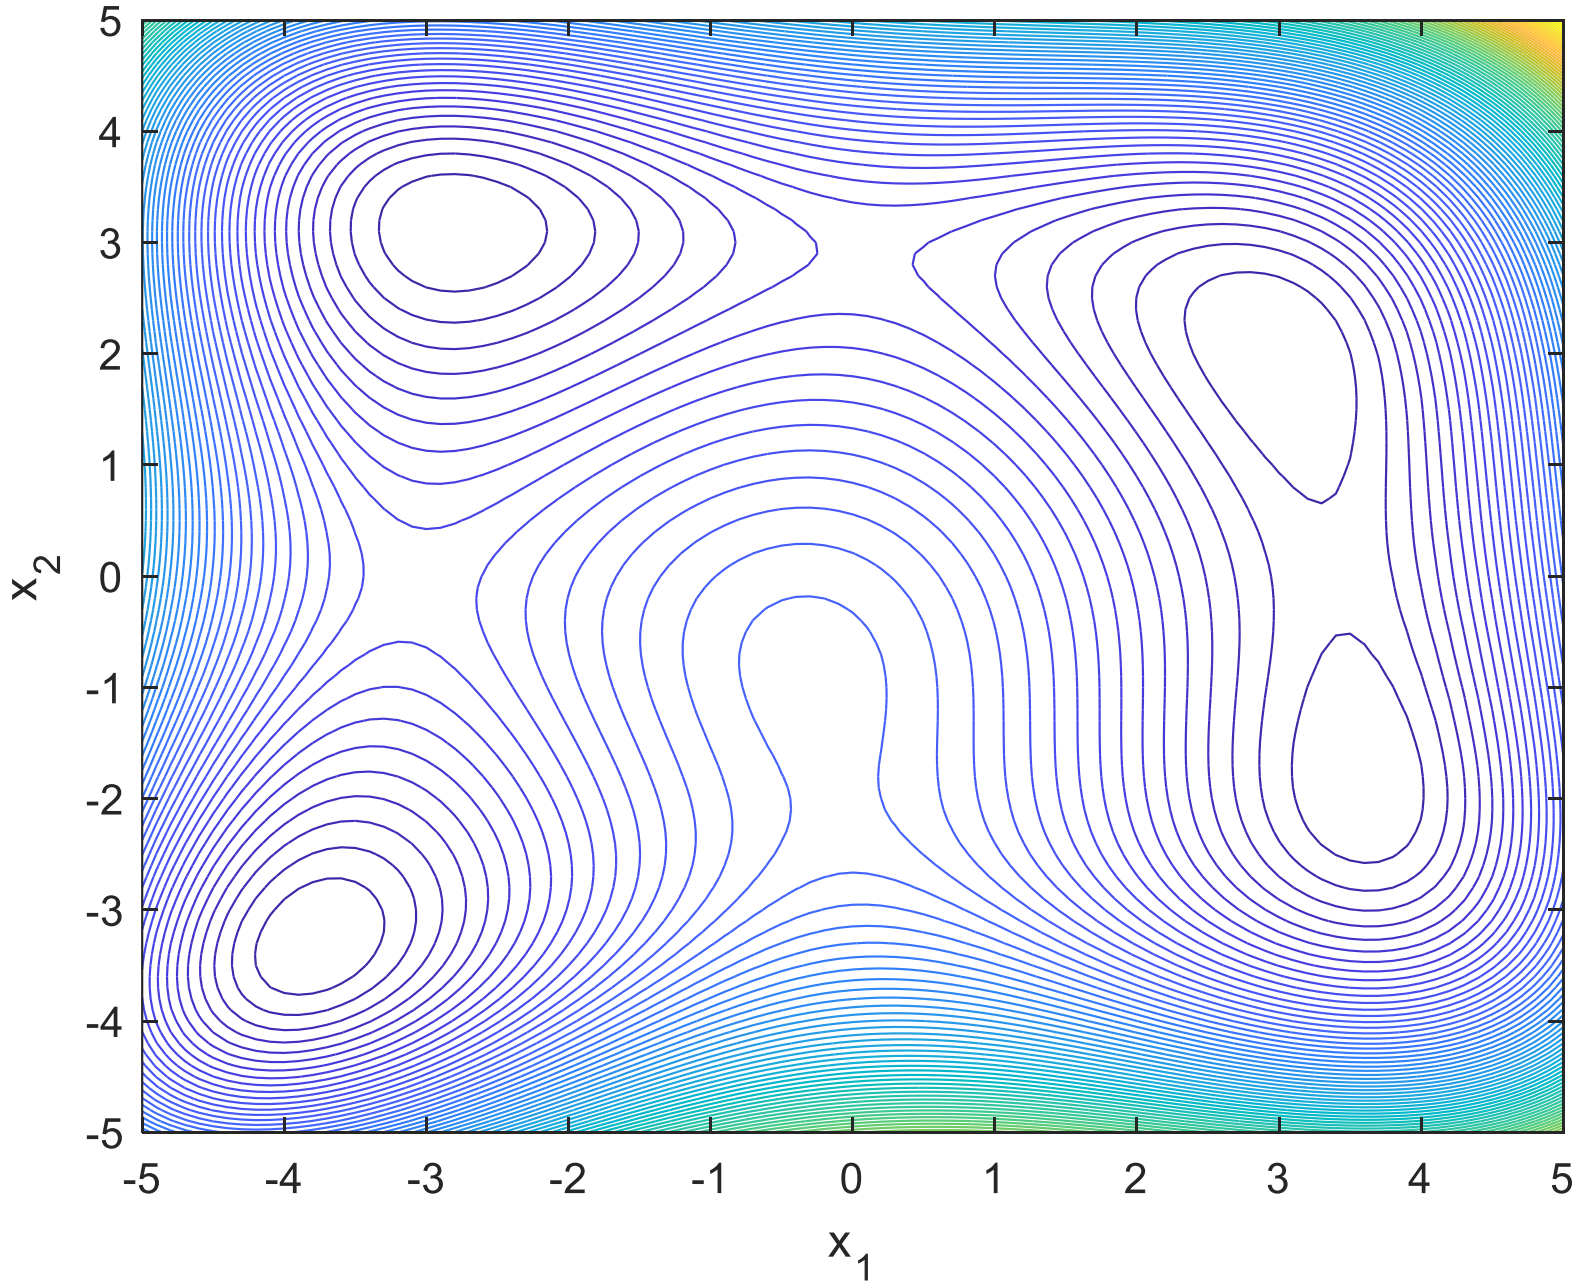
$$\frac{\partial J(x)}{\partial x_1} = 4x_1\left({x_1}^2 + x_2 - 11\right) + 2\left(x_1 + {x_2}^2 - 7\right)$$

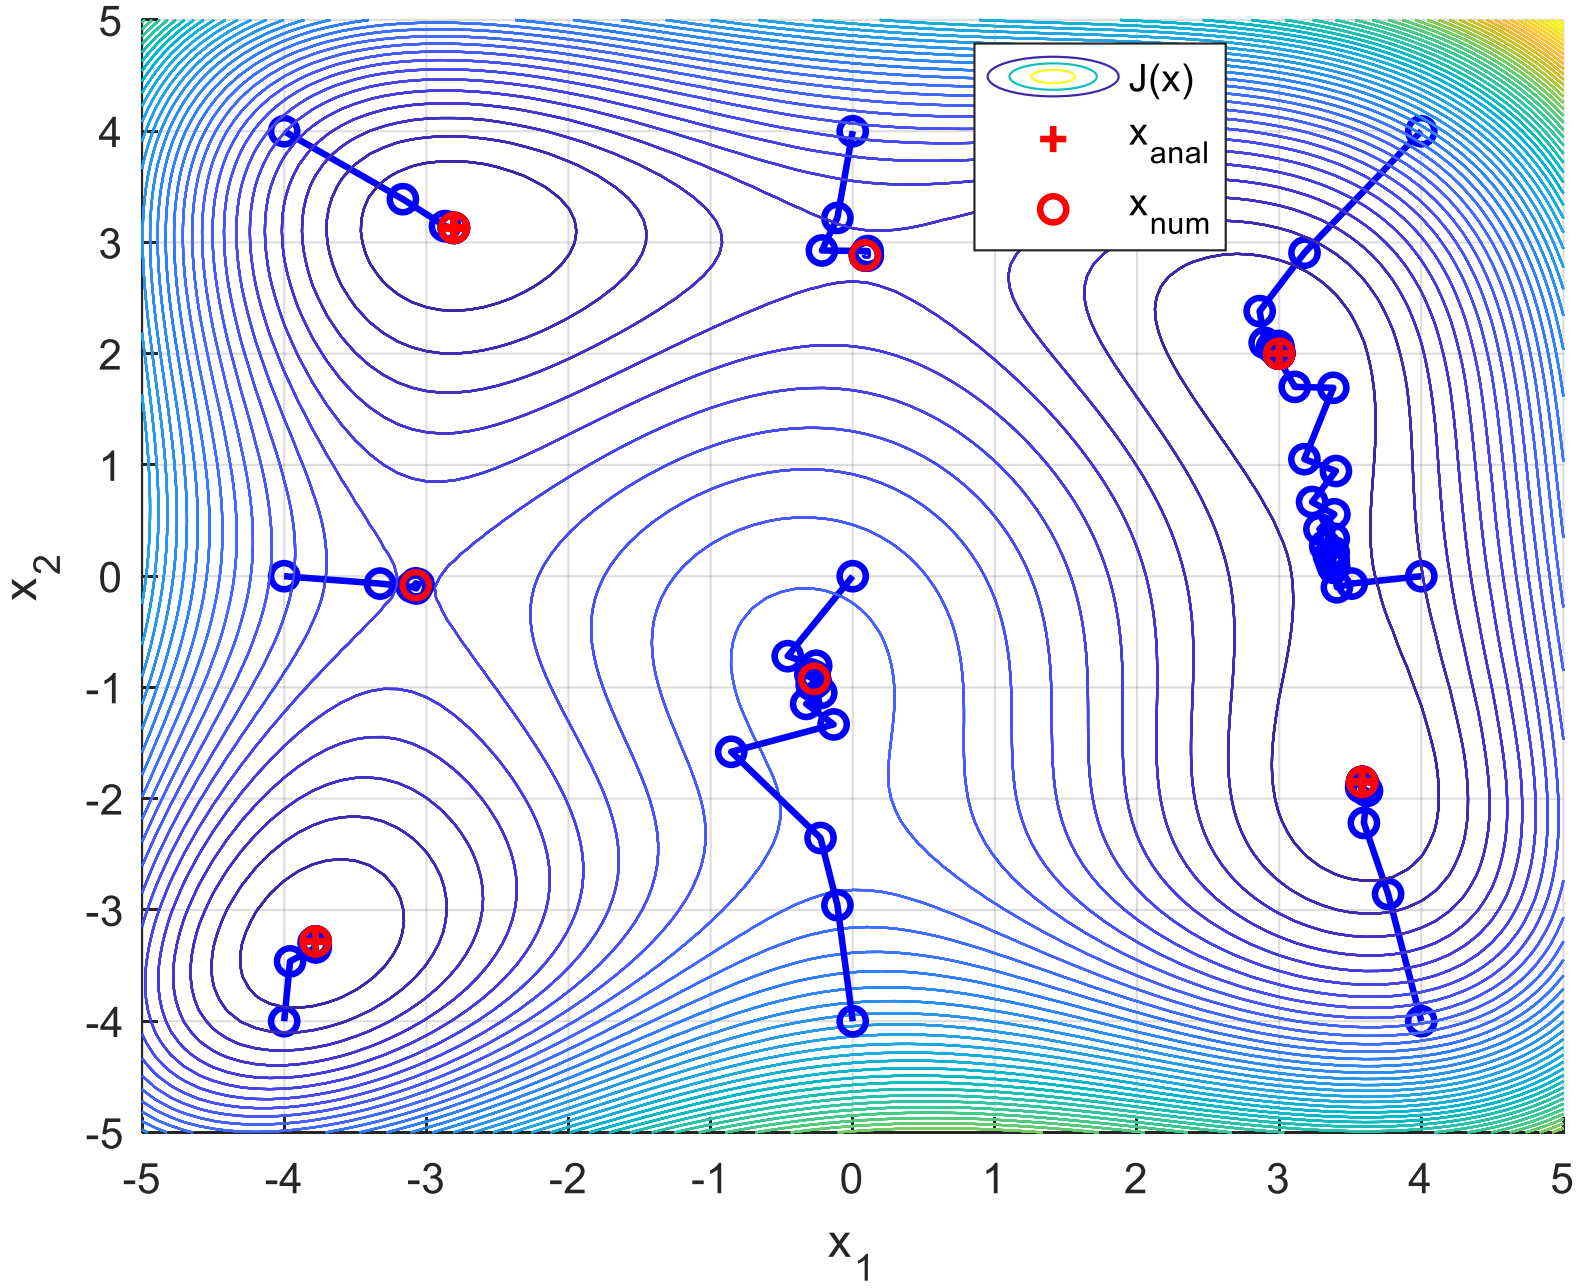
$$\frac{\partial J(x)}{\partial x_2} = 2\left({x_1}^2 + x_2 - 11\right) + 4x_2\left(x_1 + {x_2}^2 - 7\right)$$

$$\frac{\partial^2 J(x)}{\partial {x_1}^2} = 12{x_1}^2 + 4x_2 - 42$$

$$\frac{\partial^2 J(x)}{\partial {x_2}^2} = 2 + 4\left(x_1 + {x_2}^2 - 7\right) + 8{x_2}^2 = 12{x_2}^2 + 4x_1 - 26$$

$$\frac{\partial^2 J(x)}{\partial x_1 \partial x_2} = 4x_1 + 4x_2$$


5
4
3
2
1
0
-1
-2
-3
-4
-5
x2
-5
-4
-3
-2
-1
0
1
2
3
4
5
x1


J(x)
x anal
x num
x 1
x 2
5
4
3
2
1
0
-1
-2
-3
-4
-5
-5
-4
-3
-2
-1
0
1
2
3
4
5

Newtonova-Raphsonova metóda pre riešenie rovníc

- Newtonova-Raphsonova metóda nie je pôvodne výlučne optimalizačný algoritmus
- Je primárne efektívnou numerickou metódou na riešenie sústav nelineárnych algebrických rovníc
- Uvažujme všeobecnú nelineárnu vektorovú funkciu (n premenných)
$$f(x)\colon \mathbb{R}^n \to \mathbb{R}^n$$
- Cieľom je nájsť nulové body tejto funkcie (riešenia algebrických rovníc) také že
$$f(x^*) = \mathbf{0}$$
- Newtonova-Raphsonova metóda využíva Jakobián $\nabla f(x)\colon\ \mathbb{R}^n \to \mathbb{R}^{n\times n}$ na aktualizáciu odhadu
- Vychádza z linearizácie funkcie $f(x)$ v okolí bodu $x(k)$
- Prvé dva členy Taylorovho rozvoja budú
$$f(x) \cong f\big(x(k)\big) + \nabla f\big(x(k)\big)\big(x - x(k)\big)$$
- Ak má nový bod $x(k+1)$ spĺňať $f\big(x(k+1)\big) = \mathbf{0}$ potom
$$f\big(x(k+1)\big) = f\big(x(k)\big) + \nabla f\big(x(k)\big)\big(x(k+1) - x(k)\big) = \mathbf{0}$$
$$\nabla f\ \big(x(k)\big)\big(x(k+1) - x(k)\big) = -f\big(x(k)\big)$$
- Nový bod preto počítame rekurzívne ako
$$x(k+1) = x(k) - [\nabla f(x)]^{-1} f\big(x(k)\big)$$

Newtonova-Raphsonova metóda pri optimalizácii



- Vychádza z aproximovateľnosti účelovej funkcie kvadratickou formou (lineárny gradient)
- Využíva gradient $\nabla J(x)$ aj Hessián $\nabla^2 J(x)$ problému
- Hľadá riešenie sústavy rovníc (podmienka stacionárneho bodu)

$$\nabla J(x^*) = \mathbf{0}$$

- Nový bod počítame rekurzívne ako

$$x(k+1) = x(k) - \left[\nabla^2 J\big(x(k)\big)\right]^{-1} \nabla J\big(x(k)\big)$$

kde $\left[\nabla^2 J\big(x(k)\big)\right]^{-1}$ je inverzná Hesseho matica

- Krok a smer sú zviazané a určené gradientom aj Hessiánom
- Hessián určuje krok a zároveň vychyľuje smer daný gradientom
- Hľadá iba stacionárne body (môže nájsť aj maximum alebo sedlo)
- Veľmi rýchla konvergencia
- Algoritmus ukončujeme ak je splnená podmienka (veľkosť gradientu)

$$\Big(\nabla J\big(x(k)\big)\Big)^T \nabla J\big(x(k)\big) < \epsilon$$

Newtonova-Raphsonova metóda

- **Nie je nutné explicitne určiť inverznú Hesseho maticu**
  - **Postačuje vyriešiť sústavu lineárnych rovníc pre získanie kroku** $x(k+1)-x(k)$

$$\nabla^2 J\big(x(k)\big)\big(x(k+1)-x(k)\big) = -\nabla J\big(x(k)\big)$$

- V prípade minimalizácie kvadratickej formy konverguje v jednom kroku

$$x(1) = x(0) - A^{-1}(Ax(0)+b) = x(0) - x(0) - A^{-1}b = -A^{-1}b$$

- Výhody:
  - Veľmi rýchla konvergencia ak je tvar účelovej funkcie podobný kvadratickej forme
  - Pri voľbe kroku zohľadňuje tvar účelovej funkcie
- Nevýhody:
  - Citlivá na voľbu východiskového bodu $x(0)$
  - Môže skonvergovať do maxima alebo sedlového bodu
  - Vyžaduje Hessián problému
  - Vyžaduje vyriešiť sústavu n lineárnych rovníc v každom kroku

Regularizácia (tlmenie)



- Pri optimalizácii sa môžeme stretnúť s problémom, že Hessián $\nabla^2 J\big(x(k)\big)$ je singulárny alebo zle podmienený
  - aspoň jedno vlastné číslo $\nabla^2 J\big(x(k)\big)$ je veľmi malé = malý determinant
- V takom prípade Newtonov krok nemusí byť definovaný alebo vedie k nestabilite (príliš veľká zmena optimalizovaných parametrov v rámci kroku)
- Hessián upravíme regularizáciou

$$\nabla^2 J\big(x(k)\big) \leftarrow \nabla^2 J\big(x(k)\big) + \lambda I$$

  - Levenberg-Marquardtova regularizácia kde $\lambda > 0$
  - Pre veľké λ sa metóda správa podobne ako gradientná
  - Pre malé λ sa blíži k pôvodnému Newtonovmu kroku
- Všeobecná regularizácia uvažuje kladne definitnú maticu $\Lambda \in \mathbb{R}^{n\times n}$

$$\nabla^2 J\big(x(k)\big) \leftarrow \nabla^2 J\big(x(k)\big) + \Lambda$$

- Nový bod počítame rekurzívne ako

$$x(k+1) = x(k) - \left[\nabla^2 J\big(x(k)\big) + \Lambda\right]^{-1} \nabla J\big(x(k)\big)$$

- Regularizácia neovplyvňuje výsledok optimalizácie ale jej priebeh/stabilitu (spomaľuje konvergenciu)

Intuitívne vysvetlenie Newtonovej metódy

- Majme funkciu jednej premennej $J(x)$: $\mathbb{R} \to \mathbb{R}$, jej prvú deriváciu $\frac{\partial J(x)}{\partial x}$ a druhú deriváciu $\frac{\partial^2 J(x)}{\partial x^2}$
- Hľadáme stacionárne body ktoré spĺňajú $\frac{\partial J(x^*)}{\partial x} = 0$
- Ak $\frac{\partial J(x(k))}{\partial x} > 0$ chceme sa pohnúť tak aby sa $\frac{\partial J(x(k))}{\partial x}$ zmenšilo- proti smeru derivácie $\frac{\partial^2 J(x)}{\partial x^2}$
- Ak $\frac{\partial J(x(k))}{\partial x} < 0$ chceme sa pohnúť tak aby sa $\frac{\partial J(x(k))}{\partial x}$ zväčšilo- v smere derivácie $\frac{\partial^2 J(x)}{\partial x^2}$
- Ak je $\frac{\partial^2 J(x(k))}{\partial x^2}$ malá, tak zmena x má malý vplyv na $\frac{\partial J(x(k))}{\partial x}$ a musíme sa preto hýbať viac
- Ak je $\frac{\partial^2 J(x(k))}{\partial x^2}$ veľká, tak zmena x má veľký vplyv na $\frac{\partial J(x(k))}{\partial x}$ a musíme sa preto hýbať menej
- Znamienka $\frac{\partial J(x(k))}{\partial x}$ a $\frac{\partial^2 J(x(k))}{\partial x^2}$ preto vplývajú na smer pohybu
- Krok spĺňa uvedené podmienky ak

$$x(k+1) = x(k) - \frac{\frac{\partial J(x(k))}{\partial x}}{\frac{\partial^2 J(x(k))}{\partial x^2}}$$

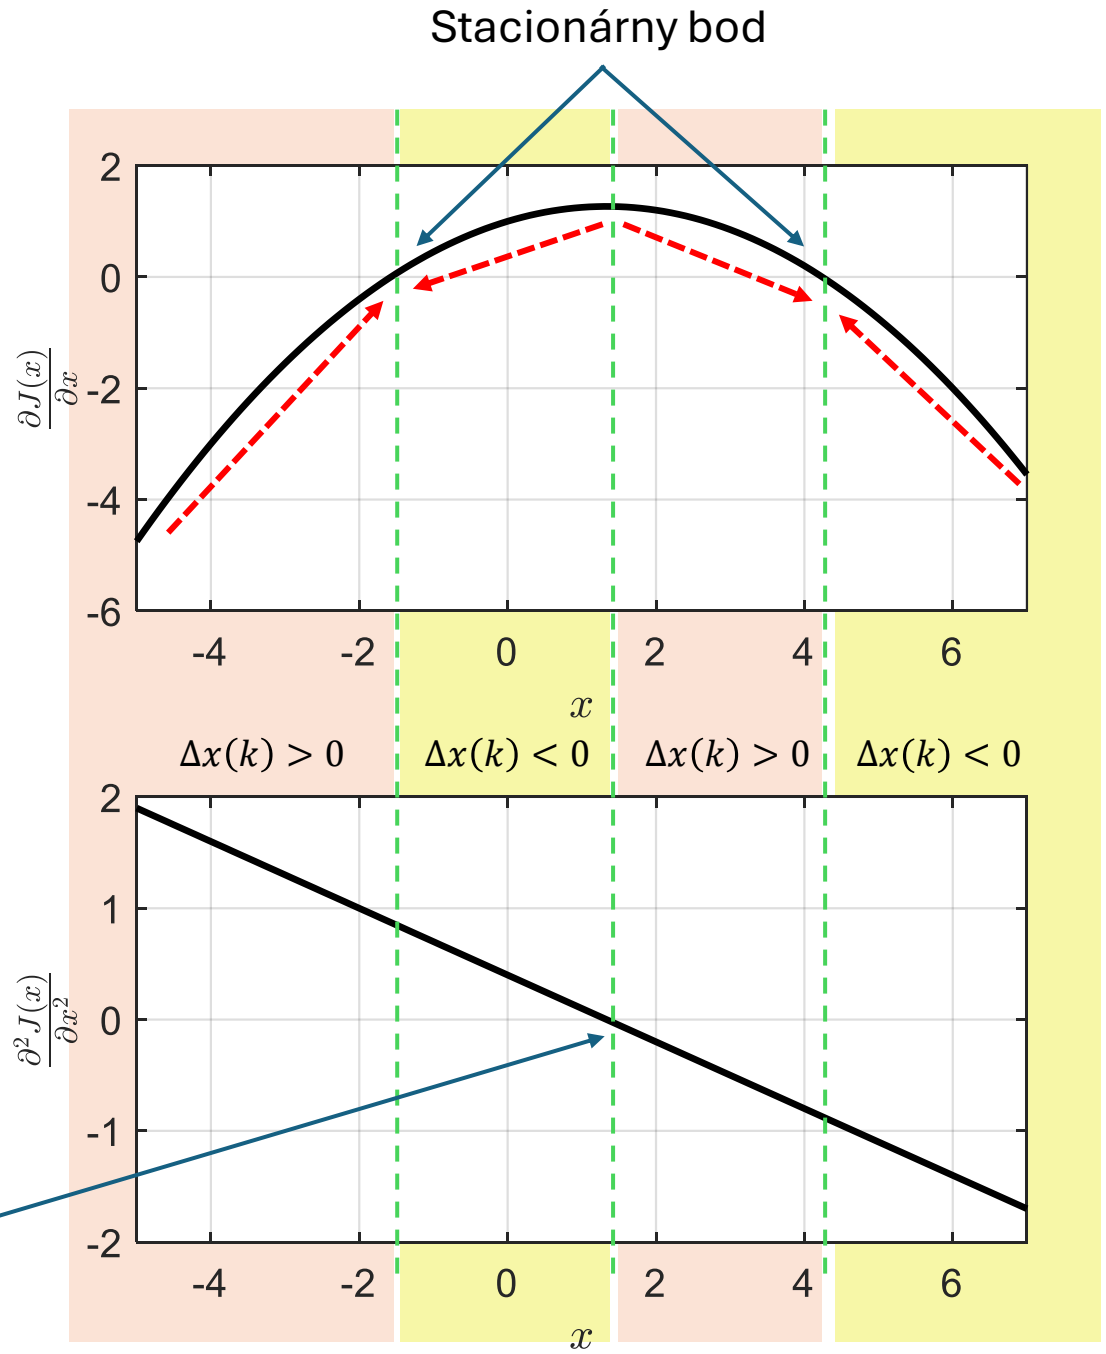
$$J(x) = -0.05\,x^3 + 0.2\,x^2 + x + 3$$

$$\frac{\partial J(x)}{\partial x} = -0.15\,x^2 + 0.4\,x + 1$$

$$\frac{\partial^2 J(x)}{\partial x^2} = -0.3\,x + 0.4$$

Krok je daný ako:

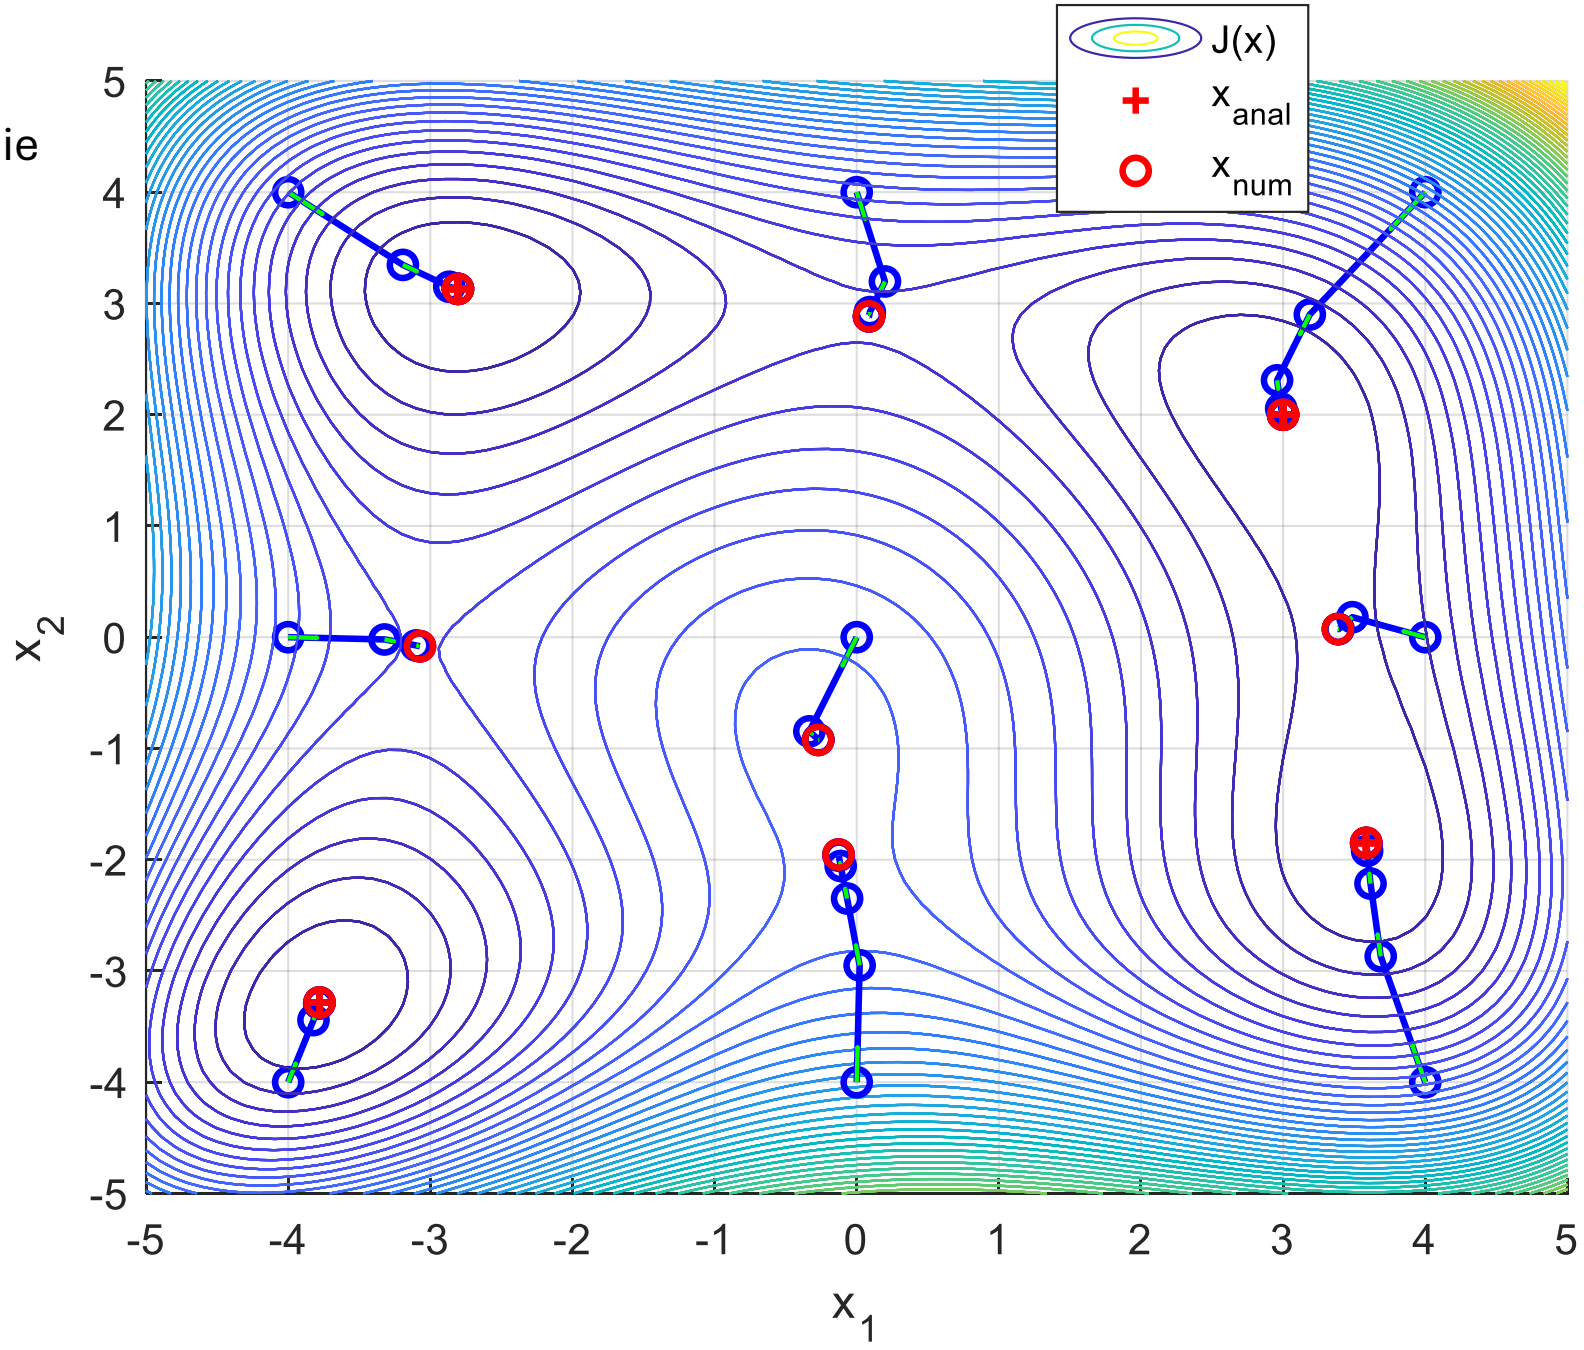
$$\Delta x(k) = x(k+1) - x(k) = -\frac{\frac{\partial J(x(k))}{\partial x}}{\frac{\partial^2 J(x(k))}{\partial x^2}}$$



$\frac{\partial^2 J(x(k))}{\partial x^2}$ mení znamienko

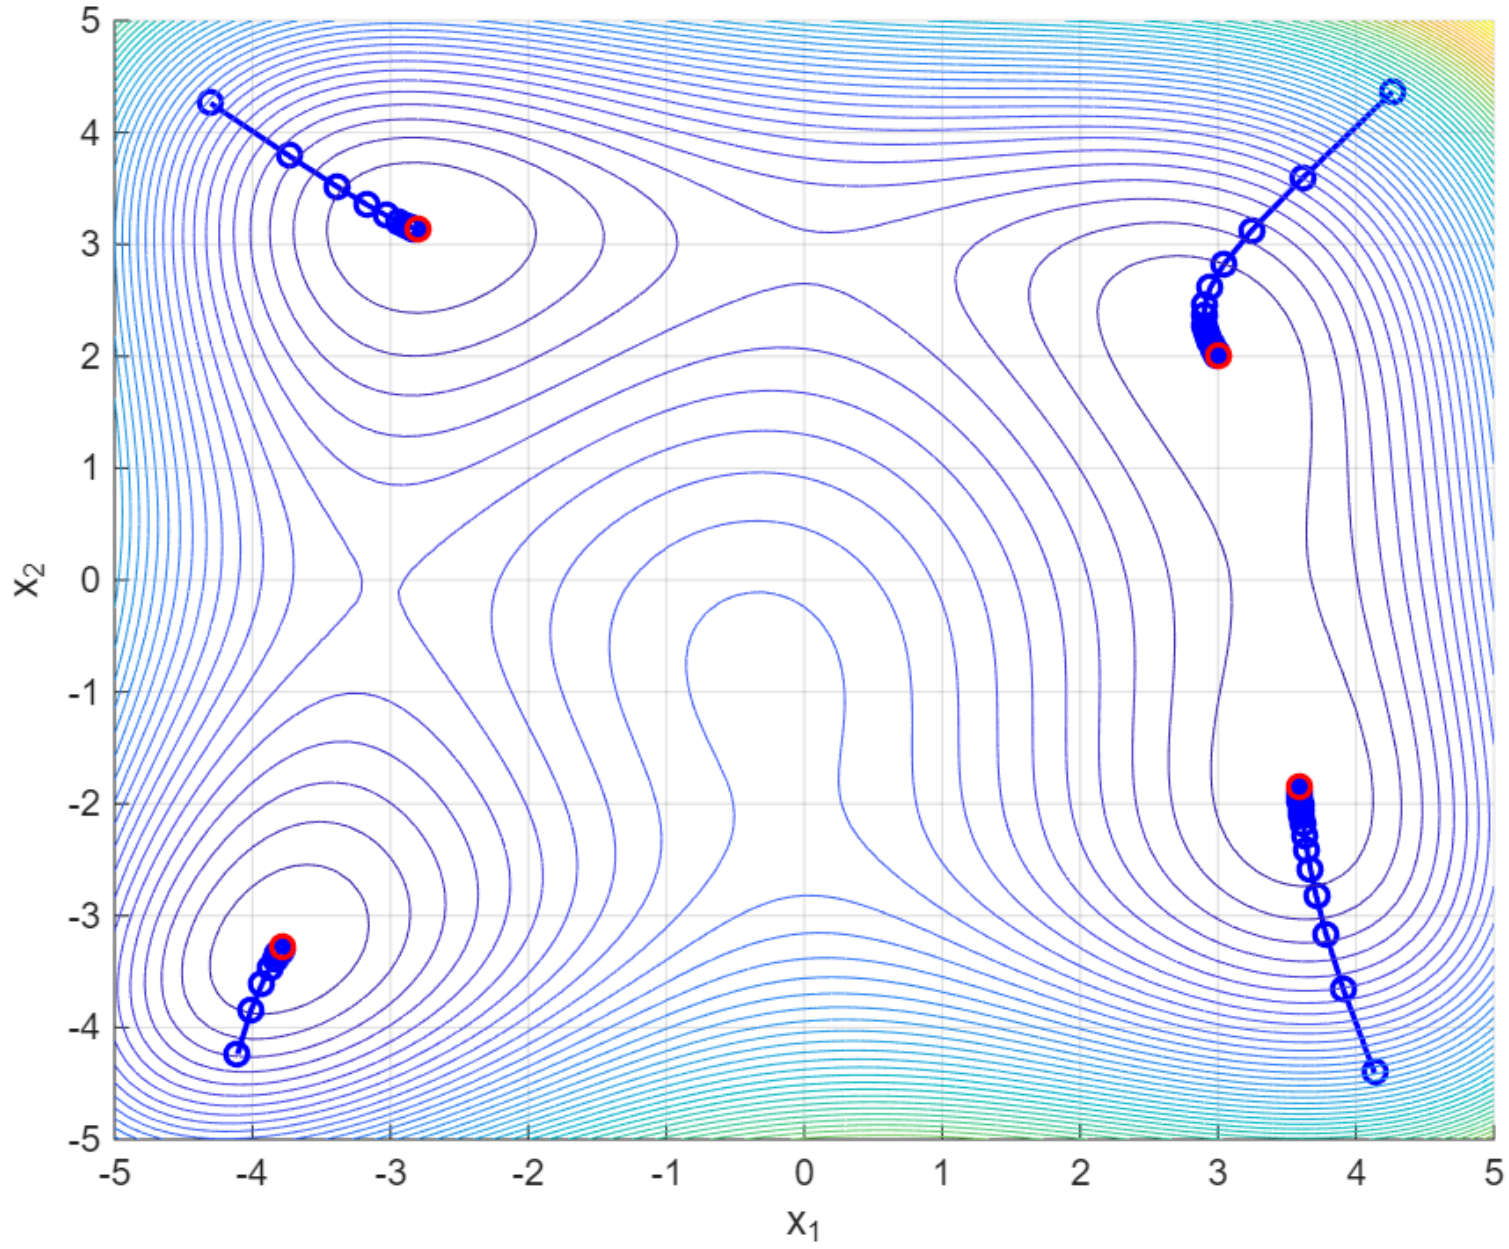
Bez regularizácie

$$\Lambda = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$



S regularizáciou

$$\Lambda = \begin{pmatrix} 100 & 0 \\ 0 & 100 \end{pmatrix}$$



Aproximácia gradientu a Hessiánu

- V prípade väčšiny inžinierskych optimalizačných úloh nie je možné analyticky nájsť gradient a Hessián príslušnej účelovej funkcie
- Tento problém vzniká hlavne ak neexistuje ani priamy analytický vzťah medzi účelovou funkciou a optimalizovanými premennými (napríklad integrálne účelové funkcie)
- Typicky máme k dispozícii iba hodnotu samotnej účelovej funkcie
- Účelová funkcia sa často tiež určuje numericky
  - numerické riešenie nelineárnych diferenciálnych rovníc
  - numerická integrácia
  - zložité počítačové simulácie fyzikálnych procesov
- Ako použiť gradientné metódy ak nepoznáme gradient a Hessián ?
- Riešenie je lokálna aproximácia gradientu a Hessiánu na základe skúmania vlastností účelovej funkcie v okolí daného bodu

Aproximácia gradientu

- Uvažujme skúmaný bod x_0 a účelovú funkciu $J(x)$
- Gradient účelovej funkcie v tomto bode môžeme odhadnúť ako diferenciu

$$\nabla J(x) = \begin{pmatrix} \frac{\partial J(x)}{\partial x_1} \\ \frac{\partial J(x)}{\partial x_2} \\ \vdots \\ \frac{\partial J(x)}{\partial x_n} \end{pmatrix} \cong \begin{pmatrix} \frac{J(x_0 + h_1 e_1) - J(x_0 - h_1 e_1)}{2h_1} \\ \frac{J(x_0 + h_2 e_2) - J(x_0 - h_2 e_2)}{2h_2} \\ \vdots \\ \frac{J(x_0 + h_n e_n) - J(x_0 - h_n e_n)}{2h_n} \end{pmatrix}$$

kde h_i je veľkosť daného okolia e_i sú štandardné bázové (jednotkové) vektory v smere i-tej súradnice

$$(e_1 \quad e_2 \quad \cdots \quad e_n) = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

- Pre odhad gradientu je preto potrebných ďalších $2n$ vyhodnotení účelovej funkcie

Apoximácia Hessiánu

- Uvažujme skúmaný bod x_0 a účelovú funkciu $J(x)$
- Hessián účelovej funkcie v tomto bode môžeme odhadnúť ako druhú diferenciu

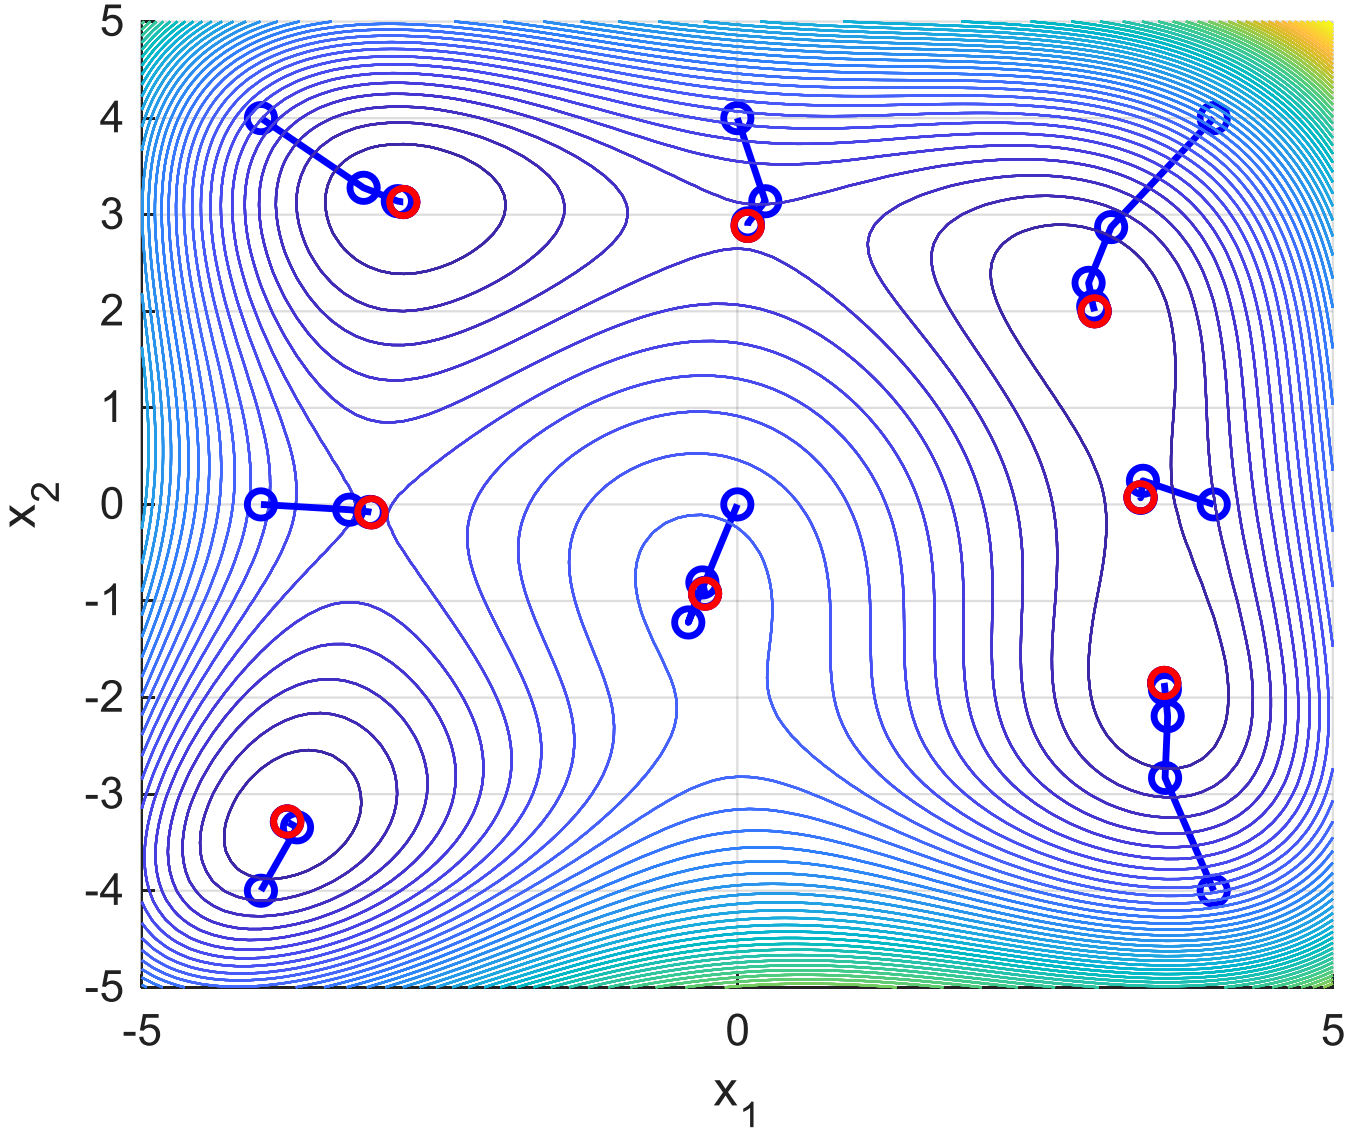
$$\frac{\partial^2 J(x)}{\partial x_i \partial x_j} \cong \frac{J(x_0 + h_i e_i + h_j e_j) - J(x_0 + h_i e_i - h_j e_j) - J(x_0 - h_i e_i + h_j e_j) + J(x_0 - h_i e_i - h_j e_j)}{4 h_i h_j}$$

kde h_i je veľkosť daného okolia e_i sú štandardné bázové (jednotkové) vektory v smere i-tej súradnice

$$(e_1 \quad e_2 \quad \cdots \quad e_n) = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

- Pre odhad Hessiánu je preto potrebných ďalších $4\frac{n(n+1)}{2}$ vyhodnotení účelovej funkcie
- Vektor veľkosti okolia h je možné voliť adaptívne na základe kroku gradientnej/Newtonovej metódy

$$h = \alpha |x(k+1) - x(k)|$$


5
4
3
2
1
0
-1
-2
-3
-4
-5
x2
-5
0
5
x1