Optimálny odhad stavu a Kalmanov filter



Diskrétny stochastický lineárny model

- Uvažujme stochastický lineárny diskrétny model v stavovom opise
- Rozšírenie deterministického modelu, ktoré zohľadňuje náhodné (stochastické) nemerateľné vplyvy (poruchy)
- Umožňuje modelovanie neurčitostí v dynamike systému a v meraniach výstupov
- Stochastický systém znamená, že podlieha:
  - Procesnému šumu $w(k)$ (vplyv náhodných zložiek na vývoj stavu)
  - Šumu merania $v(k)$ (vplyv náhodných zložiek na meranie výstupu)
- Diferenčná (state-transition) rovnica bude

$$x(k+1) = Ax(k) + Bu(k) + \boxed{w(k)}$$

- Rovnica merania výstupov (observation) bude

$$y(k) = Cx(k) + \boxed{v(k)}$$

- Tento model bude mať n stavov, r vstupov a m výstupov
- Stavový vektor $x(k) \in \mathbb{R}^n$, matica $A \in \mathbb{R}^{n\times n}$, matica $B \in \mathbb{R}^{n\times r}$ a vektor vstupov $u(k) \in \mathbb{R}^r$ budú:

$$x(k) = \begin{pmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_n(k) \end{pmatrix}, A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}, u(k) = \begin{pmatrix} u_1(k) \\ u_2(k) \\ \vdots \\ u_r(k) \end{pmatrix}, B = \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1r} \\ b_{21} & b_{22} & \cdots & b_{2r} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nr} \end{pmatrix},$$

- Výstupný vektor $y(k) \in \mathbb{R}^m$ a matica $C \in \mathbb{R}^{m\times n}$ budú

$$y(k) = \begin{pmatrix} y_1(k) \\ y_2(k) \\ \vdots \\ y_m(k) \end{pmatrix}, C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mn} \end{pmatrix},$$

- Vektor procesného šumu $w(k) \in \mathbb{R}^n$, a vektor šumu merania $v(k) \in \mathbb{R}^m$ budú:

$$w(k) = \begin{pmatrix} w_1(k) \\ w_2(k) \\ \vdots \\ w_n(k) \end{pmatrix}, v(k) = \begin{pmatrix} v_1(k) \\ v_2(k) \\ \vdots \\ v_m(k) \end{pmatrix}$$



Čo je procesný šum ?

- Neistota v správaní systému, ktorá vzniká priamo v dynamike systému
- Náhodná zložka, ktorá priamo ovplyvňuje dynamiku (vývoj) stavu systému
- Môžeme ho chápať ako poruchu s náhodným charakterom
- Procesný šum je vždy nemerateľný a nedokážeme ho predikovať
- Predstavuje rôzne nepredvídateľné vonkajšie faktory (vplyvy okolia, neistoty vo vstupoch) alebo vnútorné faktory (neistoty v modelovaní)

Príklady procesného šumu

1. Riadenie teploty v peci (priemyselná výroba):

- Zmeny v okolitých podmienkach: Ak sa napríklad teplota okolitého vzduchu zvýši alebo zníži, môže to ovplyvniť tepelné straty z pece a zmeniť podmienky vo vnútri pece.
- Náhodné zmeny v činnosti vykurovacieho systému: Degradácia vykurovacieho telesa spôsobí zmeny v generovaní a odovzdávaní tepla. Prechodové odpory kontaktov.
- Náhodné fluktuácie vo vlastnostiach vstupného materiálu: Typ materiálu v peci (merná tepelná kapacita), jeho hmotnosť a počiatočná (vstupná) teplota môžu byť veľmi variabilné.

Príklady procesného šumu

2. Riadenie letovej trajektórie dronov (kvadrokoptér) v reálnych podmienkach letu:

- Náhodné zmeny v rýchlosti vetra a hustote vzduchu, môžu ovplyvniť pohyb dronu. Turbulencia vzduchu – malé, náhodné víry alebo prudké zmeny smeru prúdenia vzduchu.
- Prechodné zmeny v batérii: Kolísanie výkonu batérie alebo problémy s napájaním (prechodové odpory).
- Nerovnomerné zaťaženie dronu – posun ťažiska, pridanie užitočnej záťaže (náklad).
- Prehriatie motorov – teplota ovplyvňuje parametre pohonu (odpor vinutia), čo môže spôsobiť odchýlky medzi modelom a realitou.
- Štrukturálne deformácie rámu – napr. v dôsledku silového preťaženia (zrýchlenia), mikro-nárazov alebo vibrácií.

Príklady procesného šumu

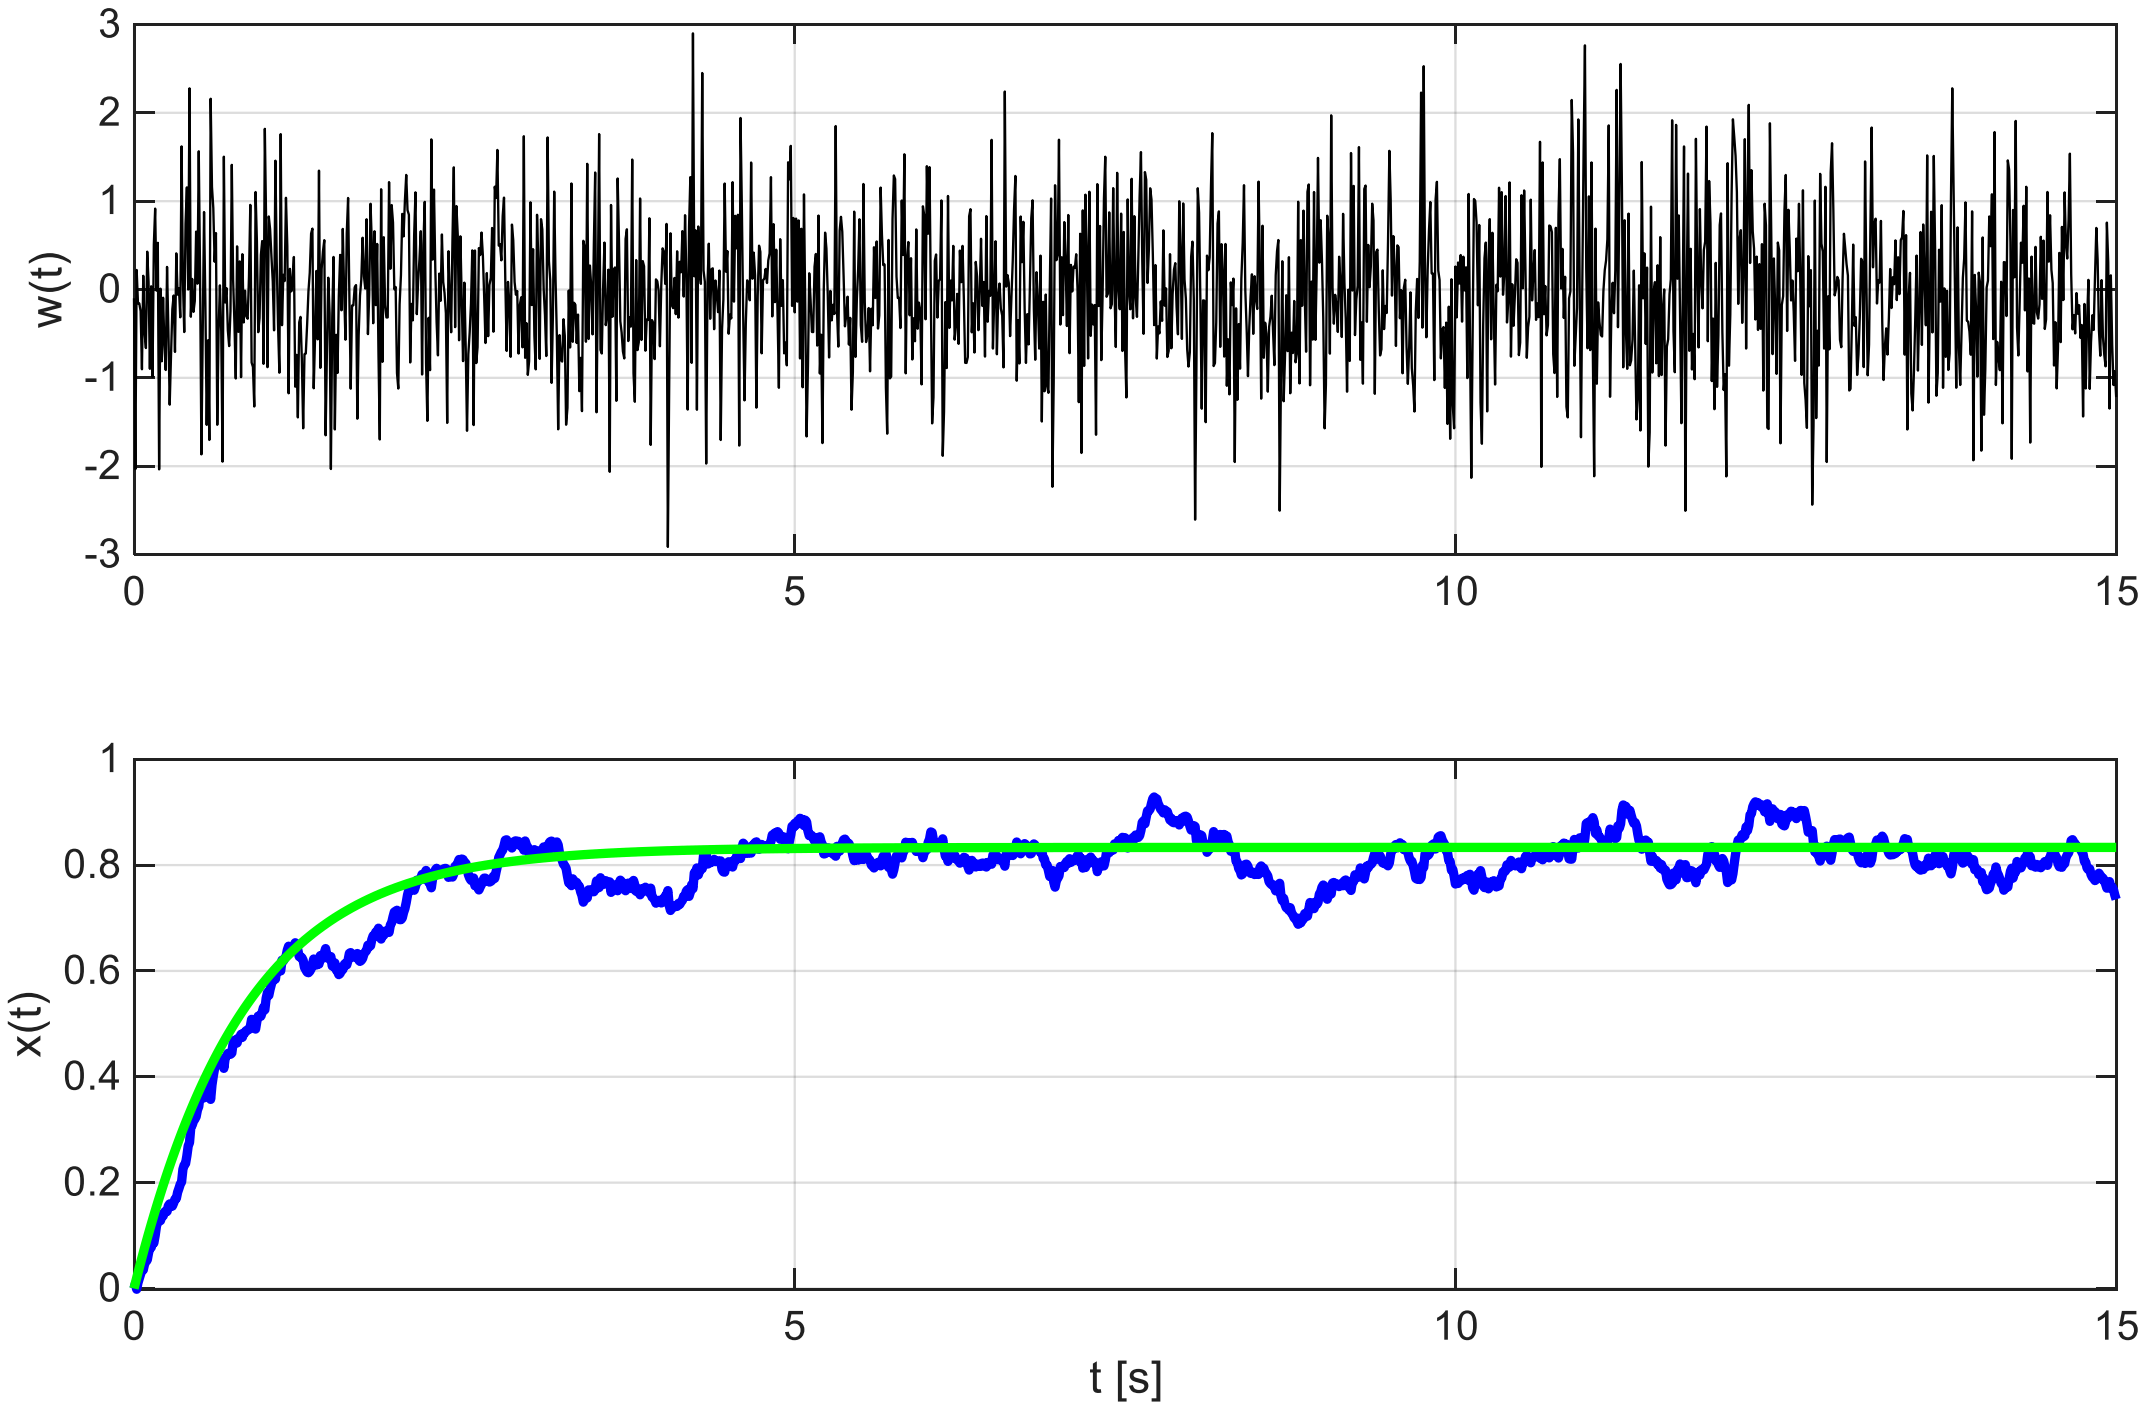
3. Modelovanie a riadenie dynamiky elektrizačnej sústavy:

- Neistoty v spotrebe: Spotreba energie je ovplyvnená mnohými náhodnými faktormi, ako je počet zapnutých spotrebičov v domácnostiach a podnikoch.
- Neistoty v dodávke z obnoviteľných zdrojov: Energia zo slnka alebo vetra má do určitej miery náhodný charakter, čo spôsobuje variabilitu vo výrobe energie. Fluktuácia výkonu solárnych panelov – závisí od oblačnosti. Náhodné zmeny výkonu veterných elektrární – vietor je ťažko predikovateľný.

Príklady procesného šumu

4. Robotické manipulátory, priemyselná robotika technologické procesy:

- Mechanické vibrácie z okolia – napr. pri robotoch na linkách - môže spôsobiť chyby v senzorike alebo mikroposuny
- Drobné kolízie alebo mikro-posuny pri kontakte s objektom
- Neistota v polohe objektu pri uchopení – kvôli sklzu alebo dynamike
- Mechanické vôle alebo deformácie konštrukcie robota pri zaťažení
- Kolísanie teploty mení sa rozťažnosť materiálov - drift polohy nástroja
- Tepelné deformácie materiálu počas zvárania
- Zmeny svetelných podmienok pre kamery - narušené strojové videnie
- Náhodné fluktuácie vo vlastnostiach vstupného materiálu

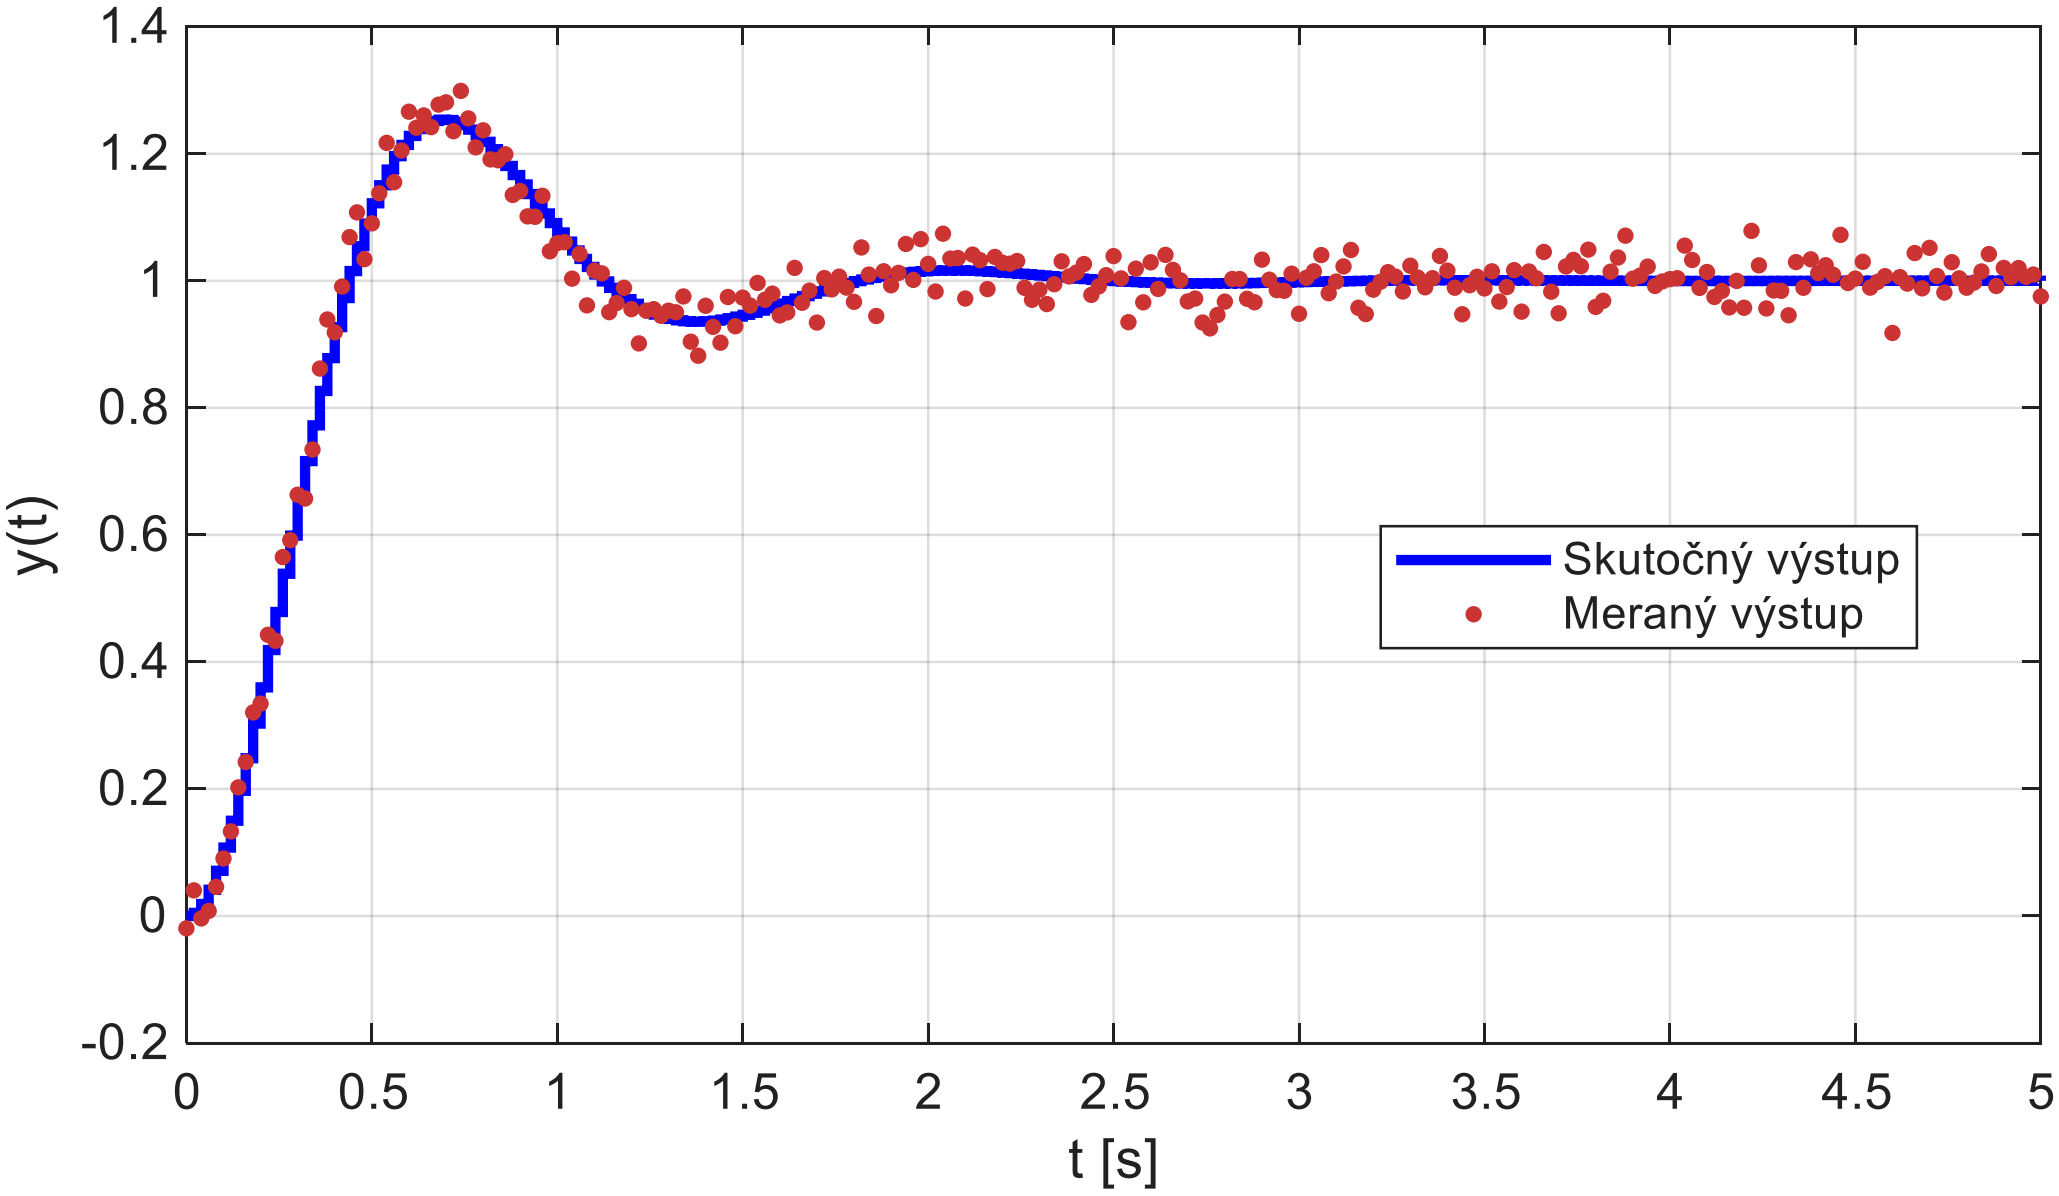

w(t)
3
2
1
0
-1
-2
-3
0
5
10
15
x(t)
1
0.8
0.6
0.4
0.2
0
0
5
10
15
t [s]

Čo je šum merania ?

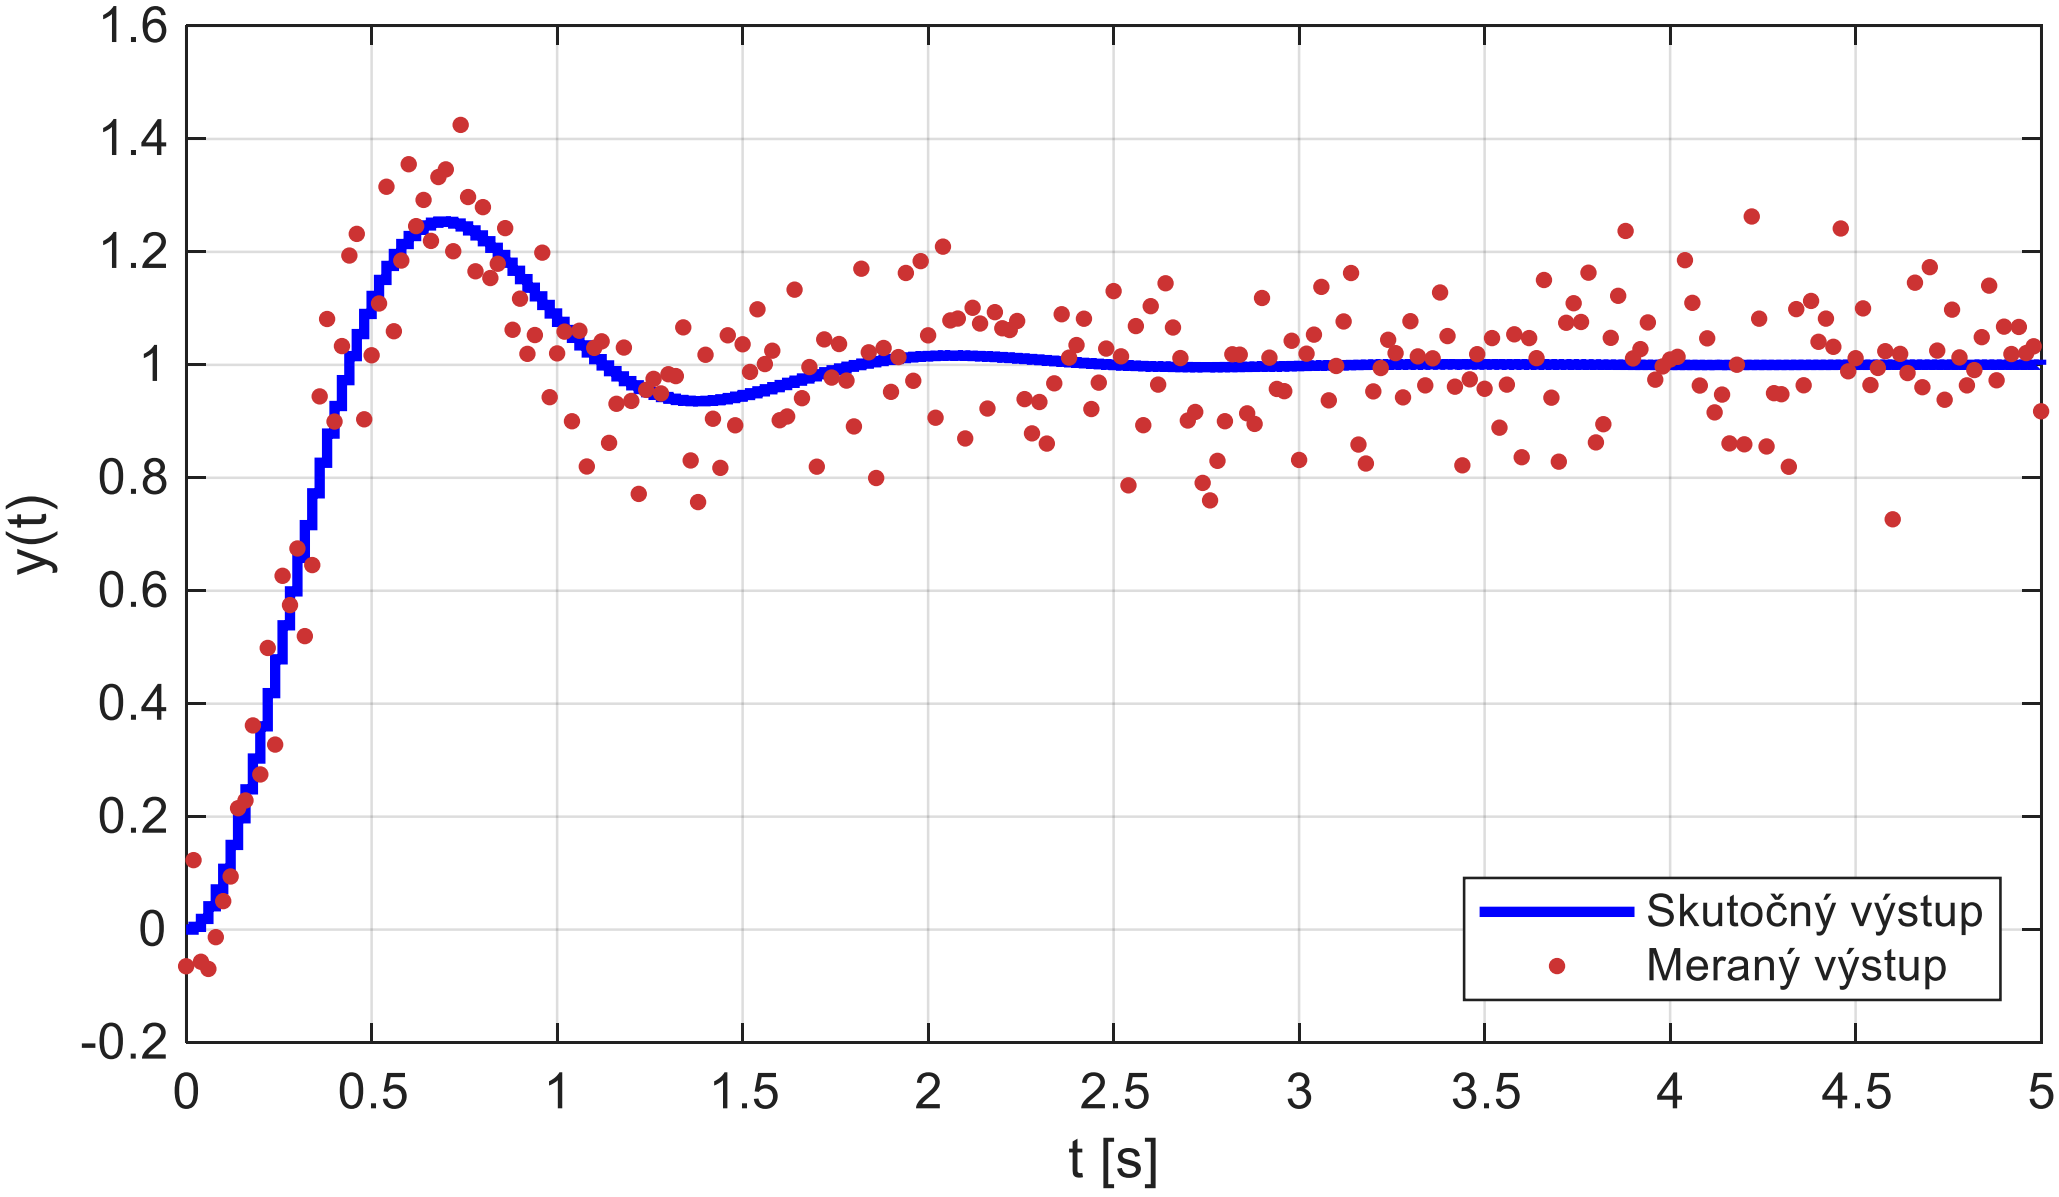


- Nepresnosť v údajoch, ktoré získavame zo senzorov/snímačov
- Náhodná zložka, ktorá ovplyvňuje meranie výstupu ale neovplyvňuje dynamiku (vývoj) stavu systému
- Môžeme ho chápať ako rozdiel medzi meraním a skutočnou hodnotou
- Šum merania je vždy nemerateľný a nedokážeme ho predikovať
- Predstavuje chybu spôsobenú samotným procesom merania
- Štatistické vlastnosti šumu merania vieme určiť z charakteristík snímačov alebo experimentálne

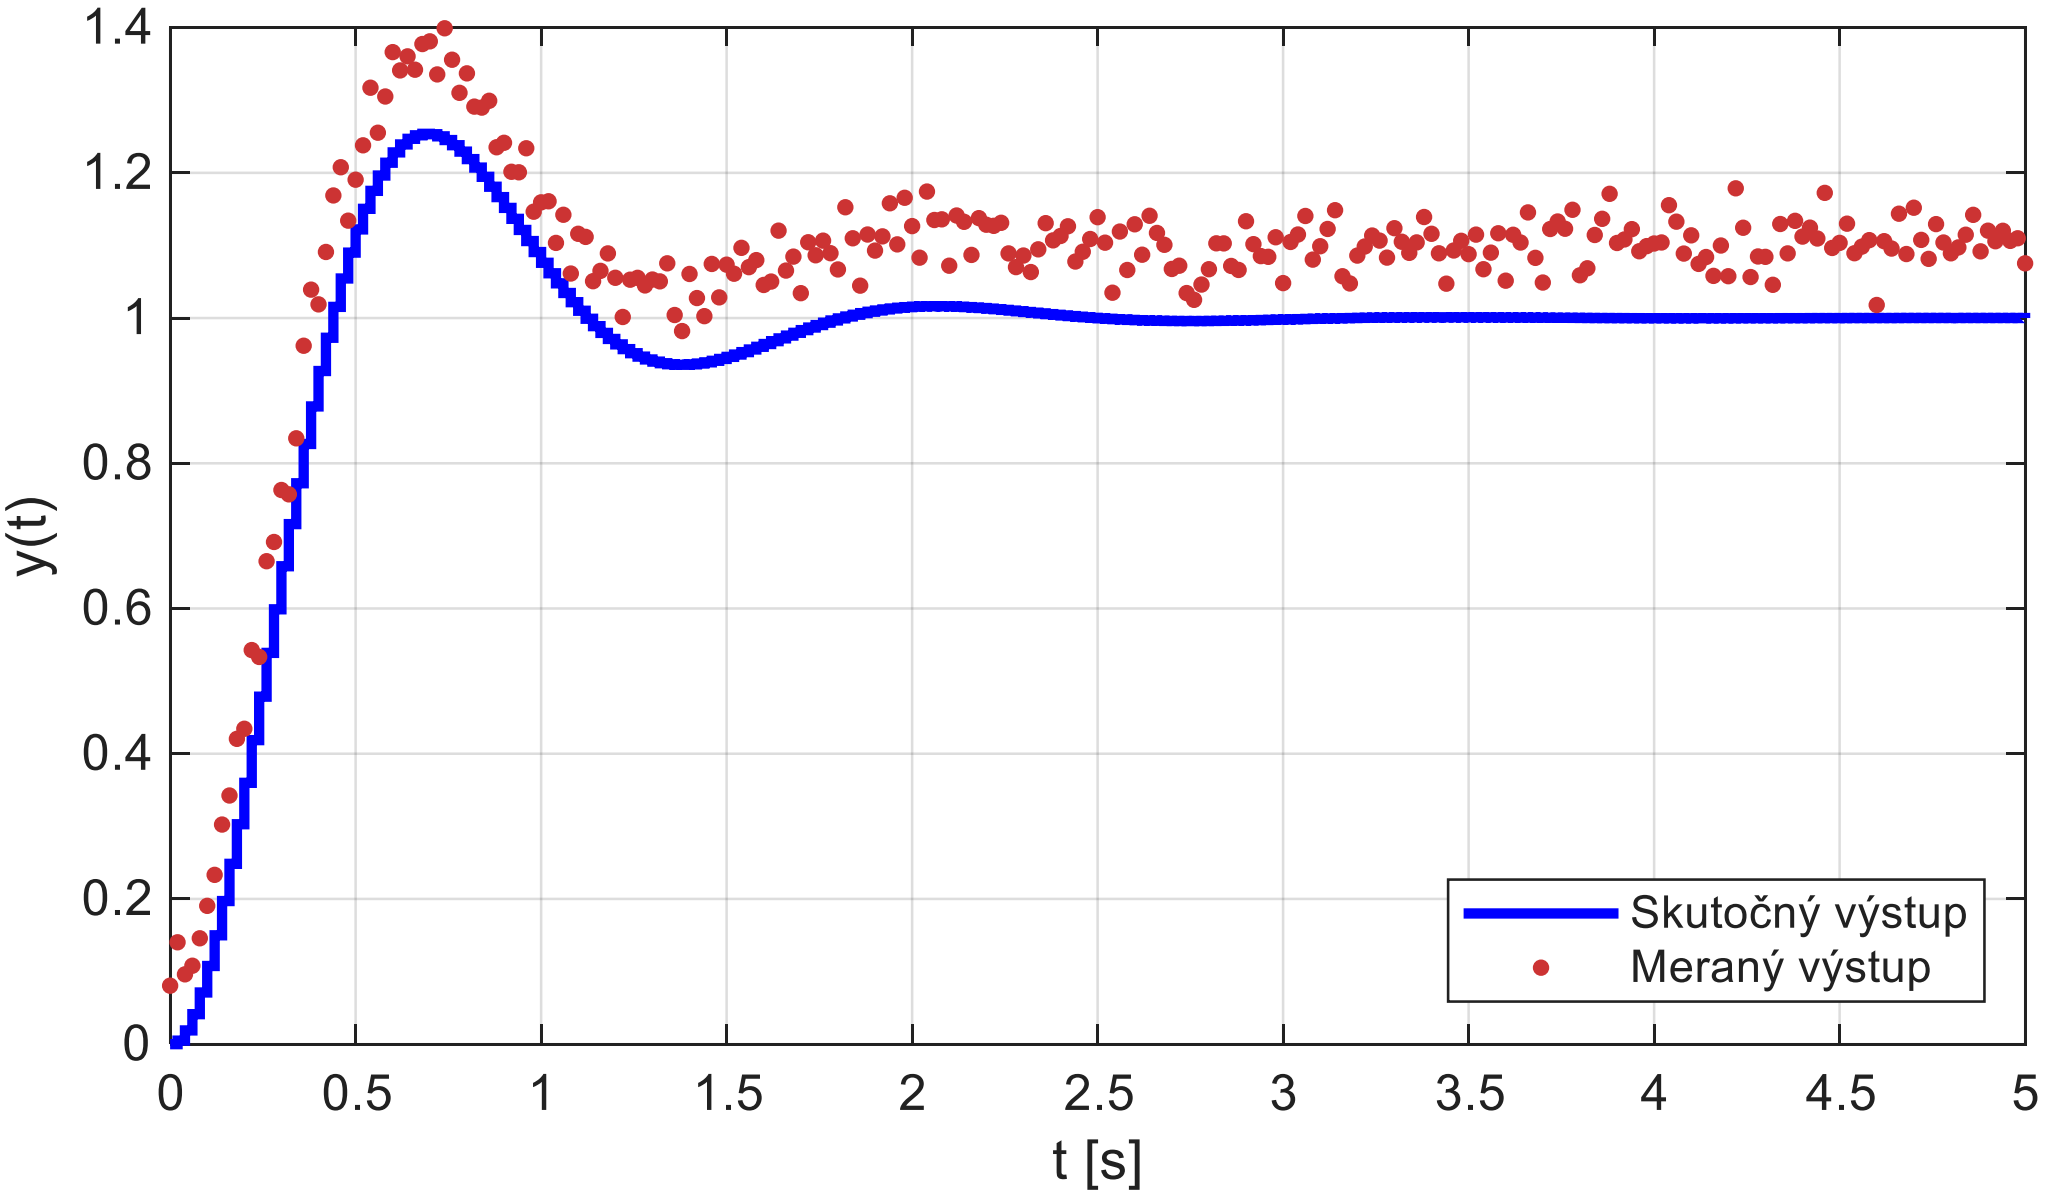
Nevychýlené meranie



Nevychýlené meranie s väčšou neistotou (väčší rozptyl šumu)



Vychýlené meranie



Príklady šumu merania

- Snímanie teploty (termistor, termočlánok) - elektromagnetické rušenie, elektronický šum A/D prevodníkov, kvantizačný šum
- Tepelný (Johnsonov) šum - vzniká v odporových prvkoch. Je to biely šum, ktorého amplitúda rastie s teplotou
- Meranie prúdu pretekajúceho motorom - elektromagnetické rušenie z motora (iskrenie komutátora) a frekvenčných meničov
- Akcelerometer – mechanické vibrácie
- Magnetometer (kompas) rušenie z kovových konštrukcií, motorov
- Ultrazvukový senzor - odrazy od hrán, šikmé plochy
- Lidar – odrazy, prach, para, priehľadné/skosené objekty

Expectancy operátor (operátor očakávanej hodnoty)

- Je štatistický operátor aplikovaný na náhodné premenné
- Predstavuje operátor očakávanej (strednej) hodnoty náhodnej premennej

$$E\{X\}$$

- Pravidlá pre prácu s expectancy operátorom:

$$E\{X + Y\} = E\{X\} + E\{Y\}$$
$$E\{XY\} \neq E\{X\}E\{Y\}$$

- Pre deterministickú premennú Q platí

$$E\{Q\} = Q$$

- Pre náhodnú premennú X, konštantnú maticu A a vektor b platí

$$E\{AX + b\} = AE\{X\} + \ b$$

- Používa sa pri definícii strednej hodnoty a kovariančnej matice

Štatistické vlastnosti procesného šumu a šumu merania

- Procesný šum $w(k)$ a šum merania $v(k)$ sú náhodné vektory, ktoré modelujeme ako stochastické procesy (vyvíjajú sa v čase)
- Predpokladáme, že sa riadia normálnym (Gaussovým) rozdelením pravdepodobnosti
- Ich stredná hodnota je nulová

$$E\{w(k)\} = \mathbf{0}$$
$$E\{v(k)\} = \mathbf{0}$$

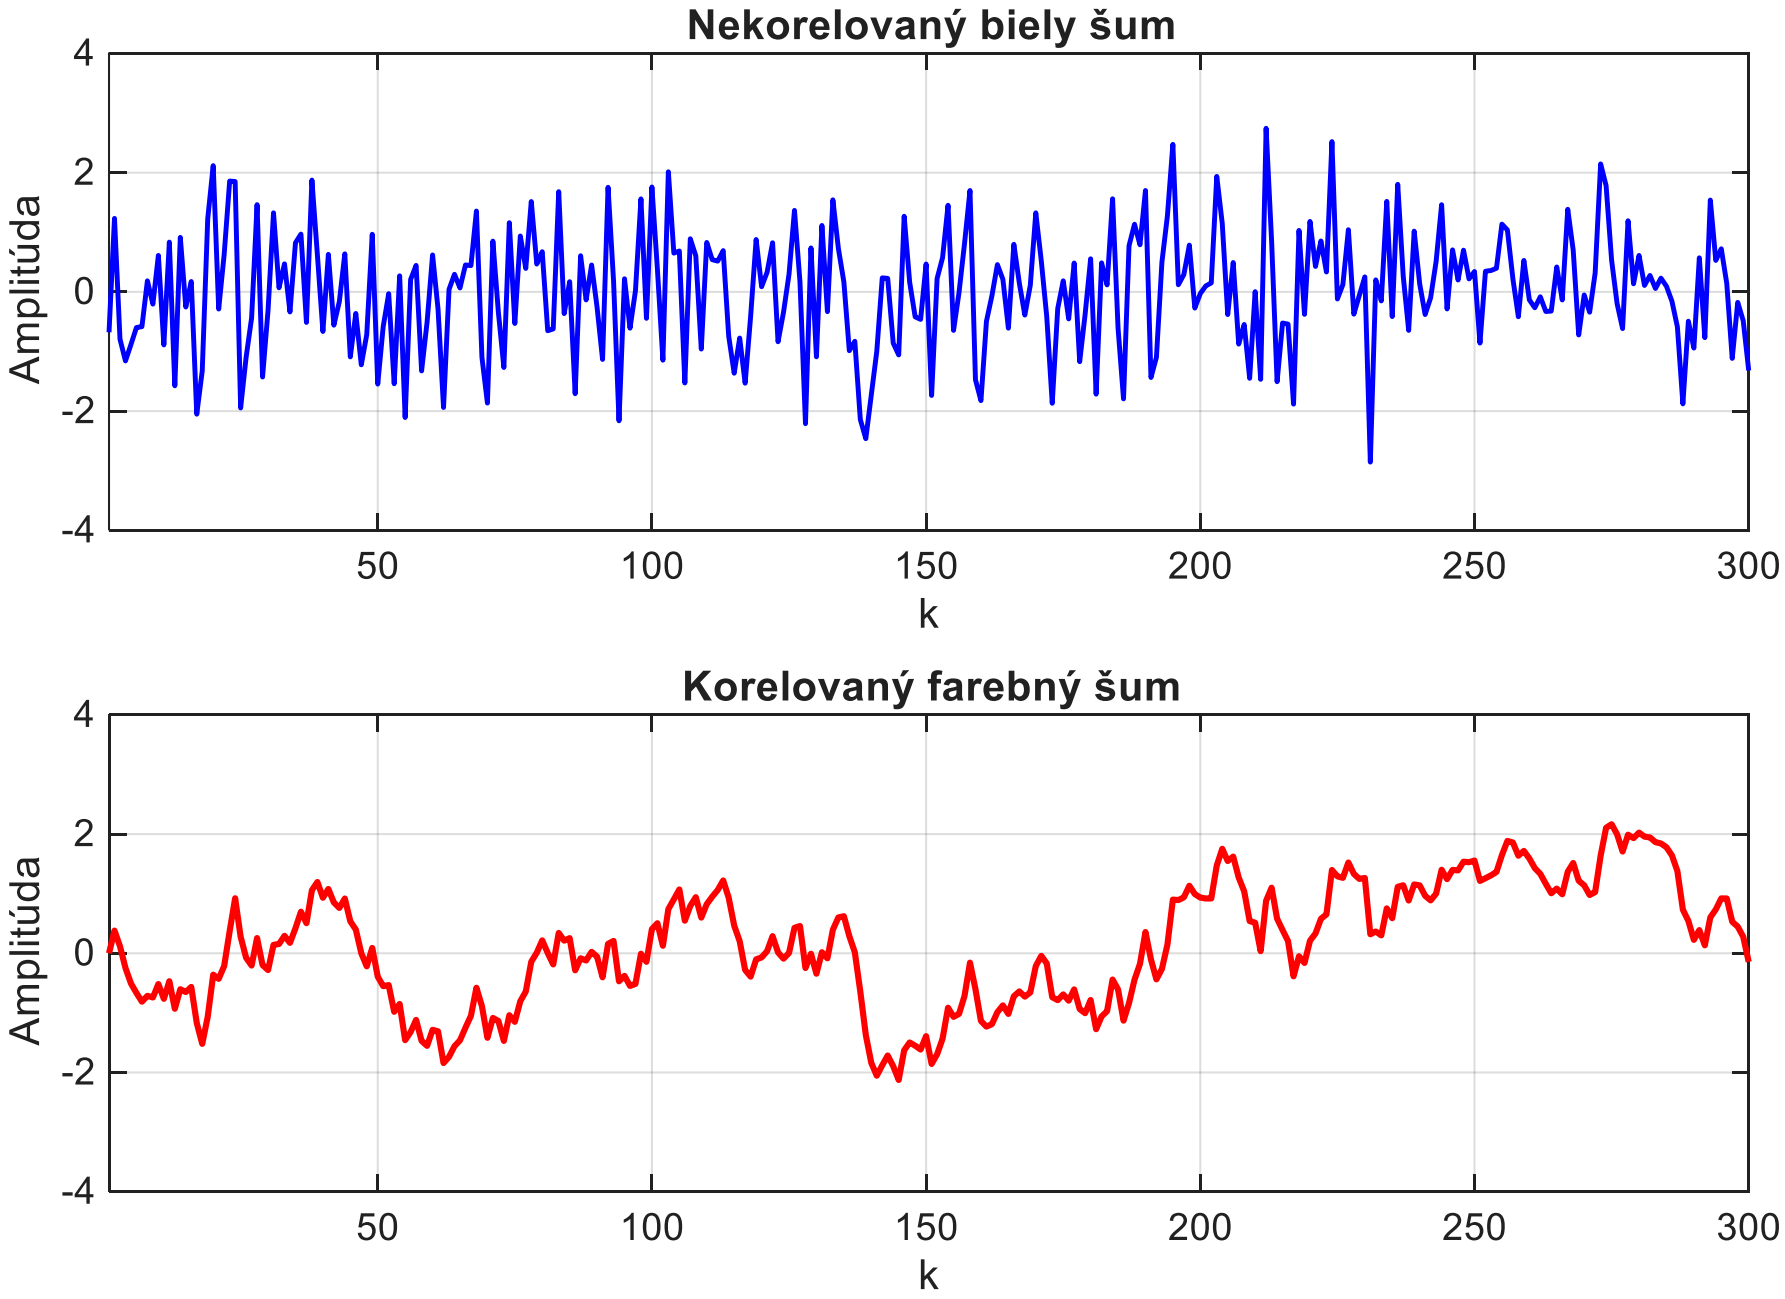
  - Ich priemerný (dlhodobý) vplyv na systém je preto nulový
- Tieto procesy nie sú korelované v čase (biely šum)

$$E\{w(k)w(k+i)^T\} = \mathbf{0}$$
$$E\{v(k)v(k+1)^T\} = \mathbf{0}$$

  - Ich jednotlivé časové inštancie spolu štatisticky nesúvisia
  - $w(k)$ je štatisticky nezávislé od $w(k-1)$
- Okrem toho sú tiež $v(k)$ a $w(k)$ vzájomne nekorelované

$$E\{v(k)w(k)^T\} = \mathbf{0}$$

  - Procesný šum $w(k)$ a šum merania $v(k)$ spolu štatisticky nesúvisia
  - $w(k)$ je štatisticky nezávislý od $v(k)$


Nekorelovaný biely šum
Amplitúda
4
2
0
-2
-4
50
100
150
200
250
300
k
Korelovaný farebný šum
Amplitúda
4
2
0
-2
-4
50
100
150
200
250
300
k

Kovariančné matice procesného šumu a šumu merania



- Štatistické vlastnosti $w(k)$ a $v(k)$ sú dané ich kovariančnými maticami

$$Q = \mathrm{cov}(w(k), w(k)) = E\{w(k)w(k)^T\}$$
$$R = \mathrm{cov}(v(k), v(k)) = E\{v(k)v(k)^T\}$$

$Q \in \mathbb{R}^{n\times n}$ je symetrická $(Q = Q^T)$ kladne definitná matica $(Q \succ 0)$

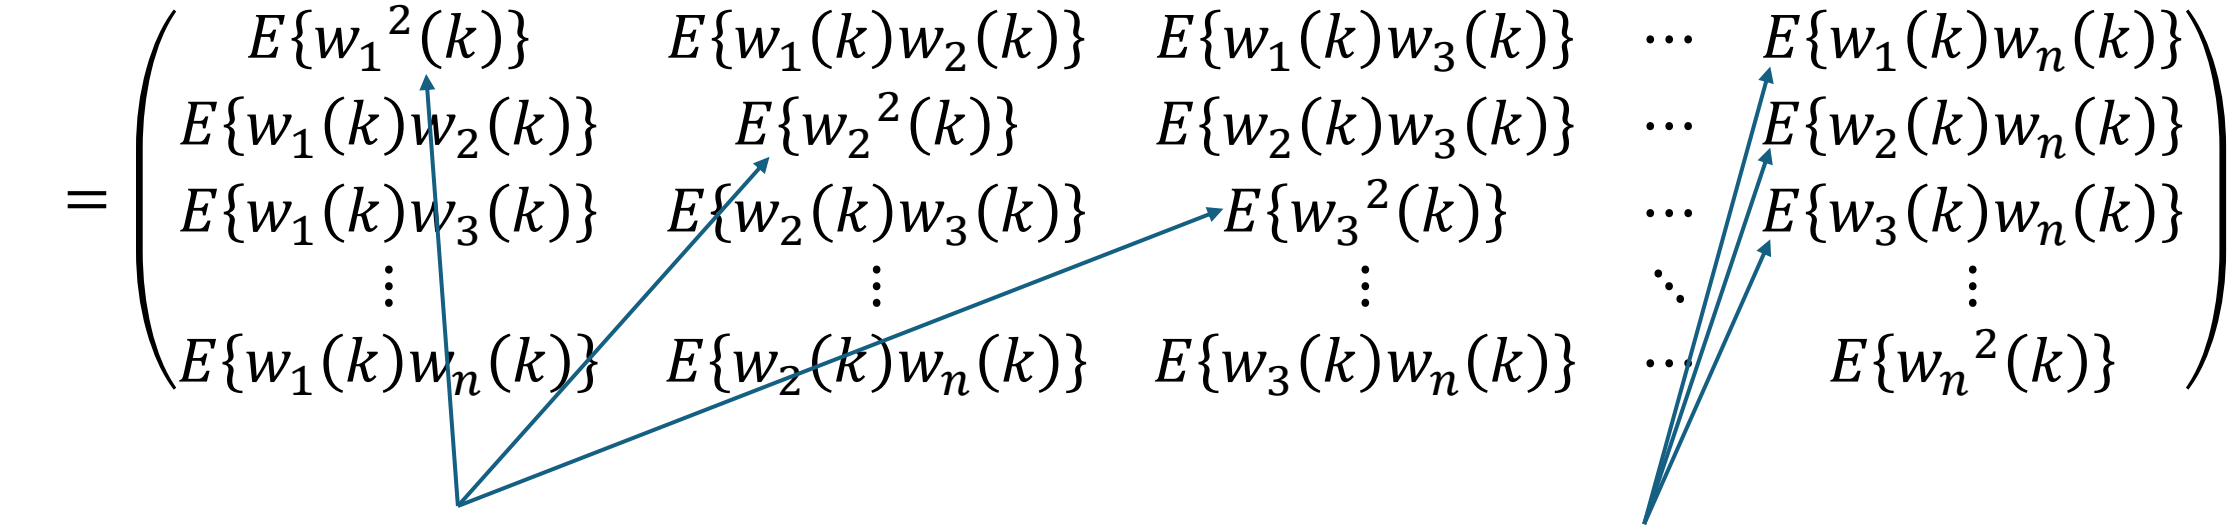
$R \in \mathbb{R}^{m\times m}$ je symetrická $(R = R^T)$ kladne definitná matica $(R \succ 0)$

- Pre viacero náhodných premenných nám poskytuje informácie o vzájomných štatistických závislostiach medzi nimi
- Variancia je ukazovateľ toho, ako veľmi sa jednotlivé hodnoty náhodnej premennej odchyľujú od svojej priemernej hodnoty
- Kovariancia je ukazovateľ toho, ako sa dve náhodné premenné menia spolu — teda či majú tendenciu rásť alebo klesať spoločne, alebo sa menia nezávisle
  - Ak je kovariancia kladná, znamená to, že premenné majú tendenciu rásť alebo klesať spolu
  - Ak je kovariancia záporná, znamená to, že keď jedna premenná rastie, druhá klesá
  - Ak je kovariancia blízka nule, znamená to, že medzi premennými neexistuje významná štatistická závislosť

Význam kovariančných matíc

$$Q = E\{w(k)w(k)^T\} = E\left\{\begin{pmatrix} w_1(k) \\ w_2(k) \\ w_3(k) \\ \vdots \\ w_n(k) \end{pmatrix} (w_1(k) \quad w_2(k) \quad w_3(k) \quad \cdots \quad w_n(k))\right\}$$

$$= \begin{pmatrix} E\{w_1{}^2(k)\} & E\{w_1(k)w_2(k)\} & E\{w_1(k)w_3(k)\} & \cdots & E\{w_1(k)w_n(k)\} \\ E\{w_1(k)w_2(k)\} & E\{w_2{}^2(k)\} & E\{w_2(k)w_3(k)\} & \cdots & E\{w_2(k)w_n(k)\} \\ E\{w_1(k)w_3(k)\} & E\{w_2(k)w_3(k)\} & E\{w_3{}^2(k)\} & \cdots & E\{w_3(k)w_n(k)\} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ E\{w_1(k)w_n(k)\} & E\{w_2(k)w_n(k)\} & E\{w_3(k)w_n(k)\} & \cdots & E\{w_n{}^2(k)\} \end{pmatrix}$$

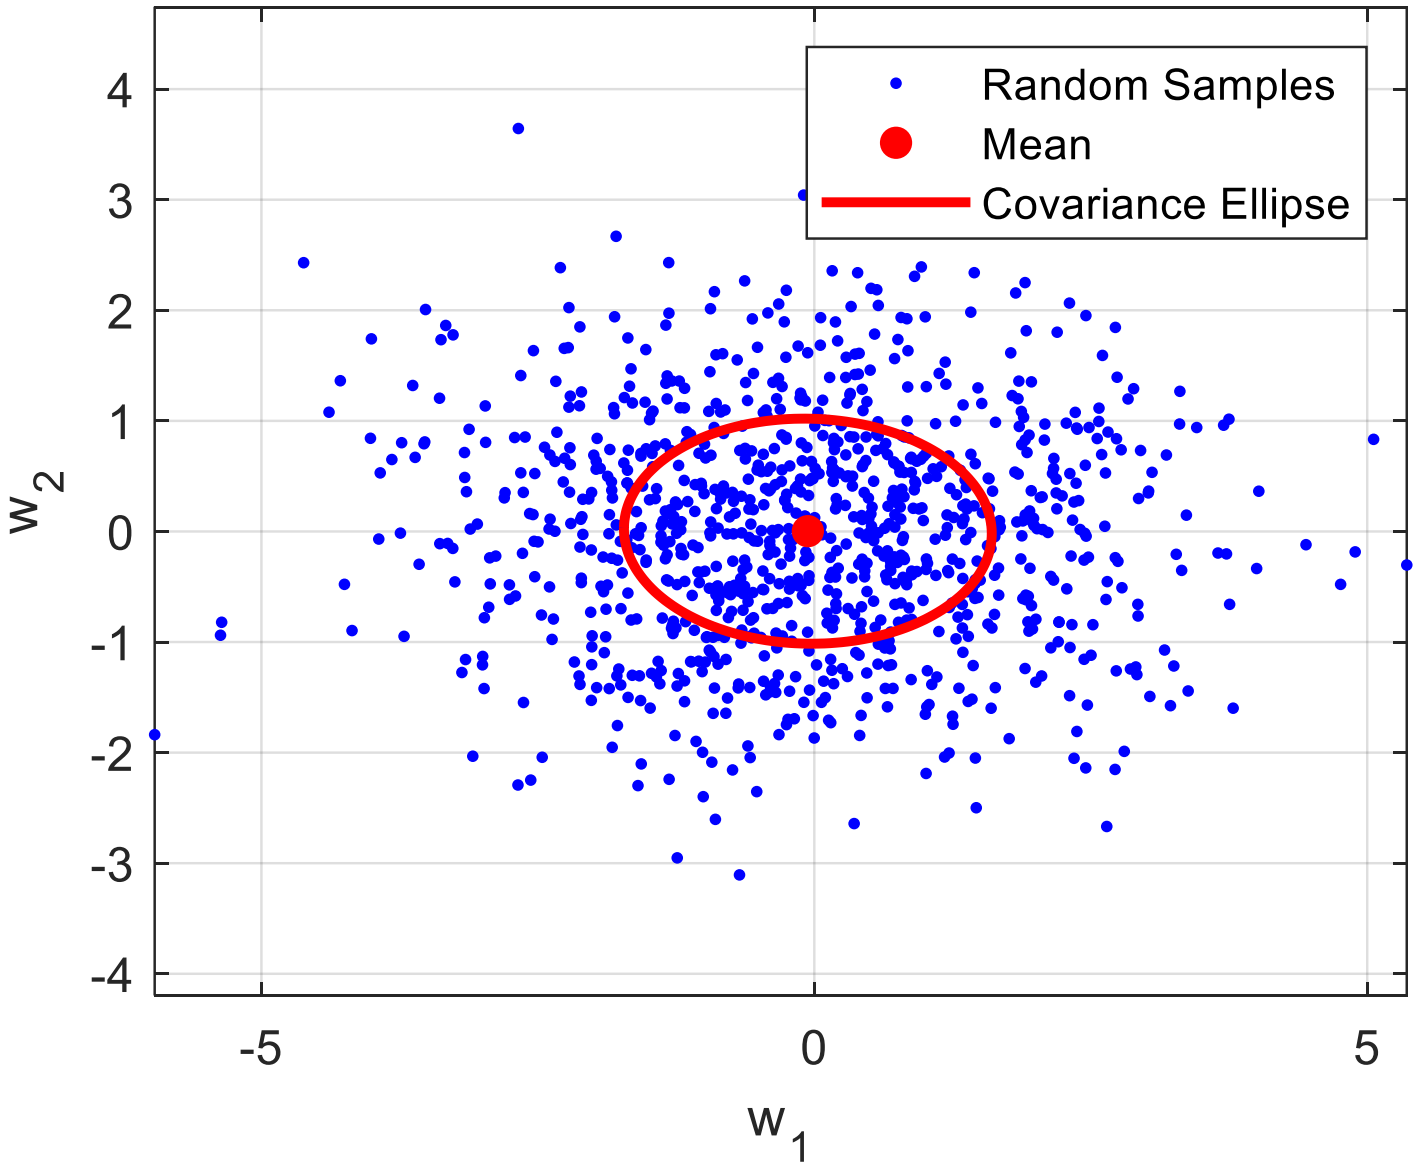


Na diagonále sú rozptyly (variancie) jednotlivých prvkov náhodného vektora

Mimo diagonálne prvky predstavujú kovariancie medzi prvkami náhodného vektora

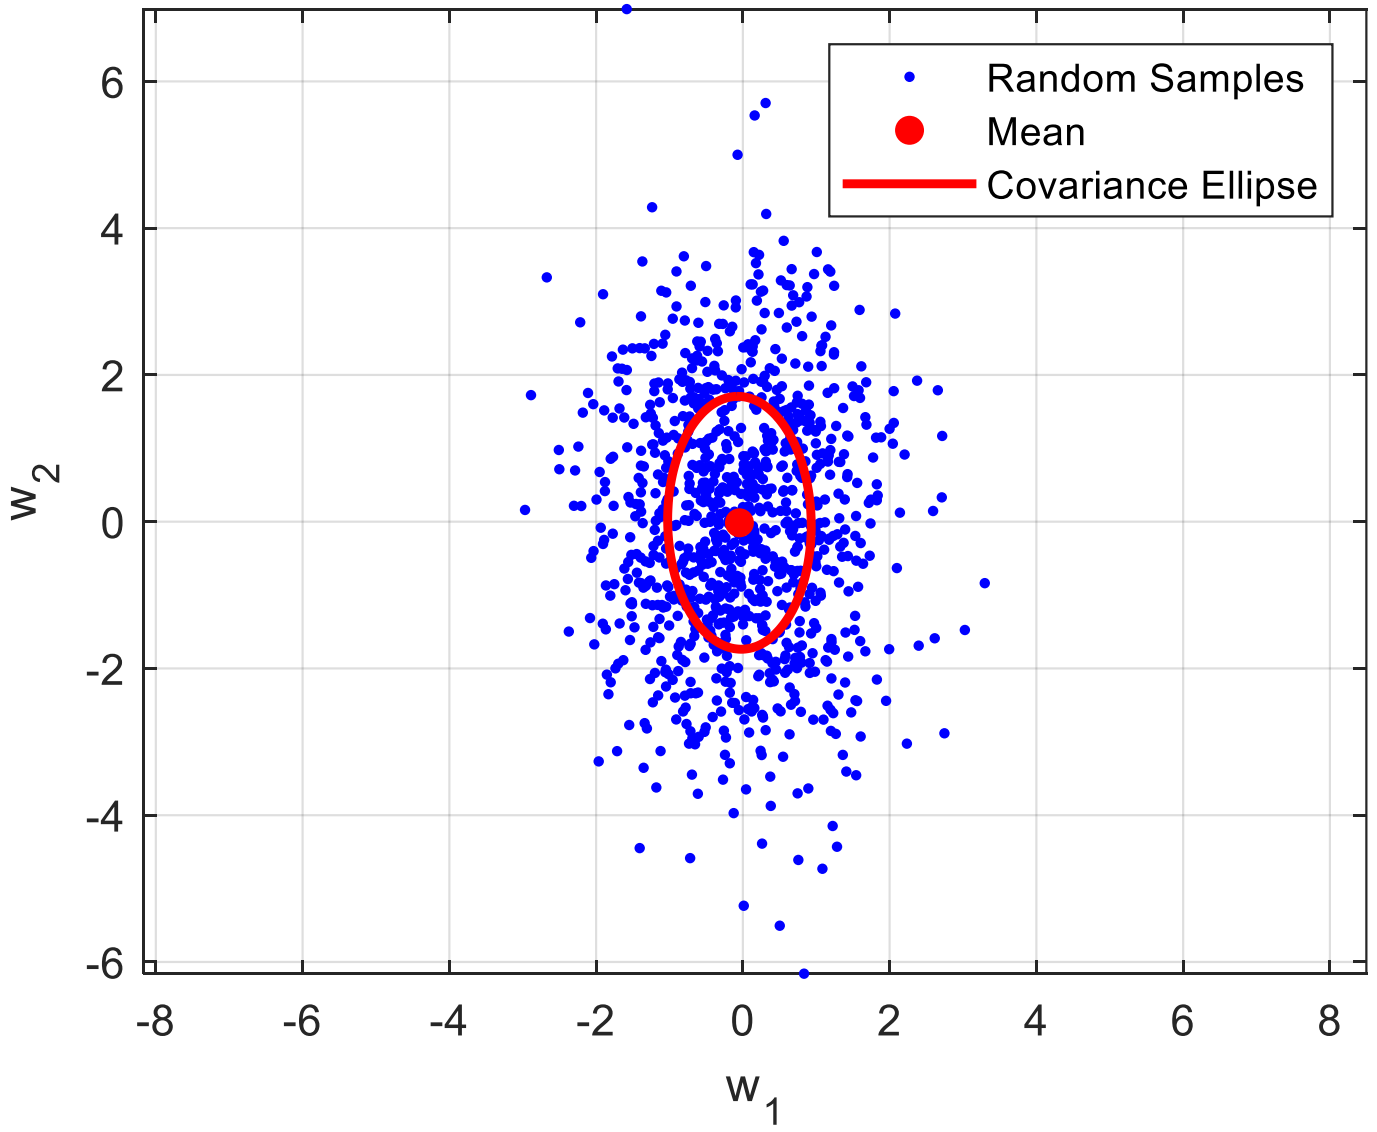
$$Q = E\{w(k)w(k)^T\} = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$

$$E\{w(k)\} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$



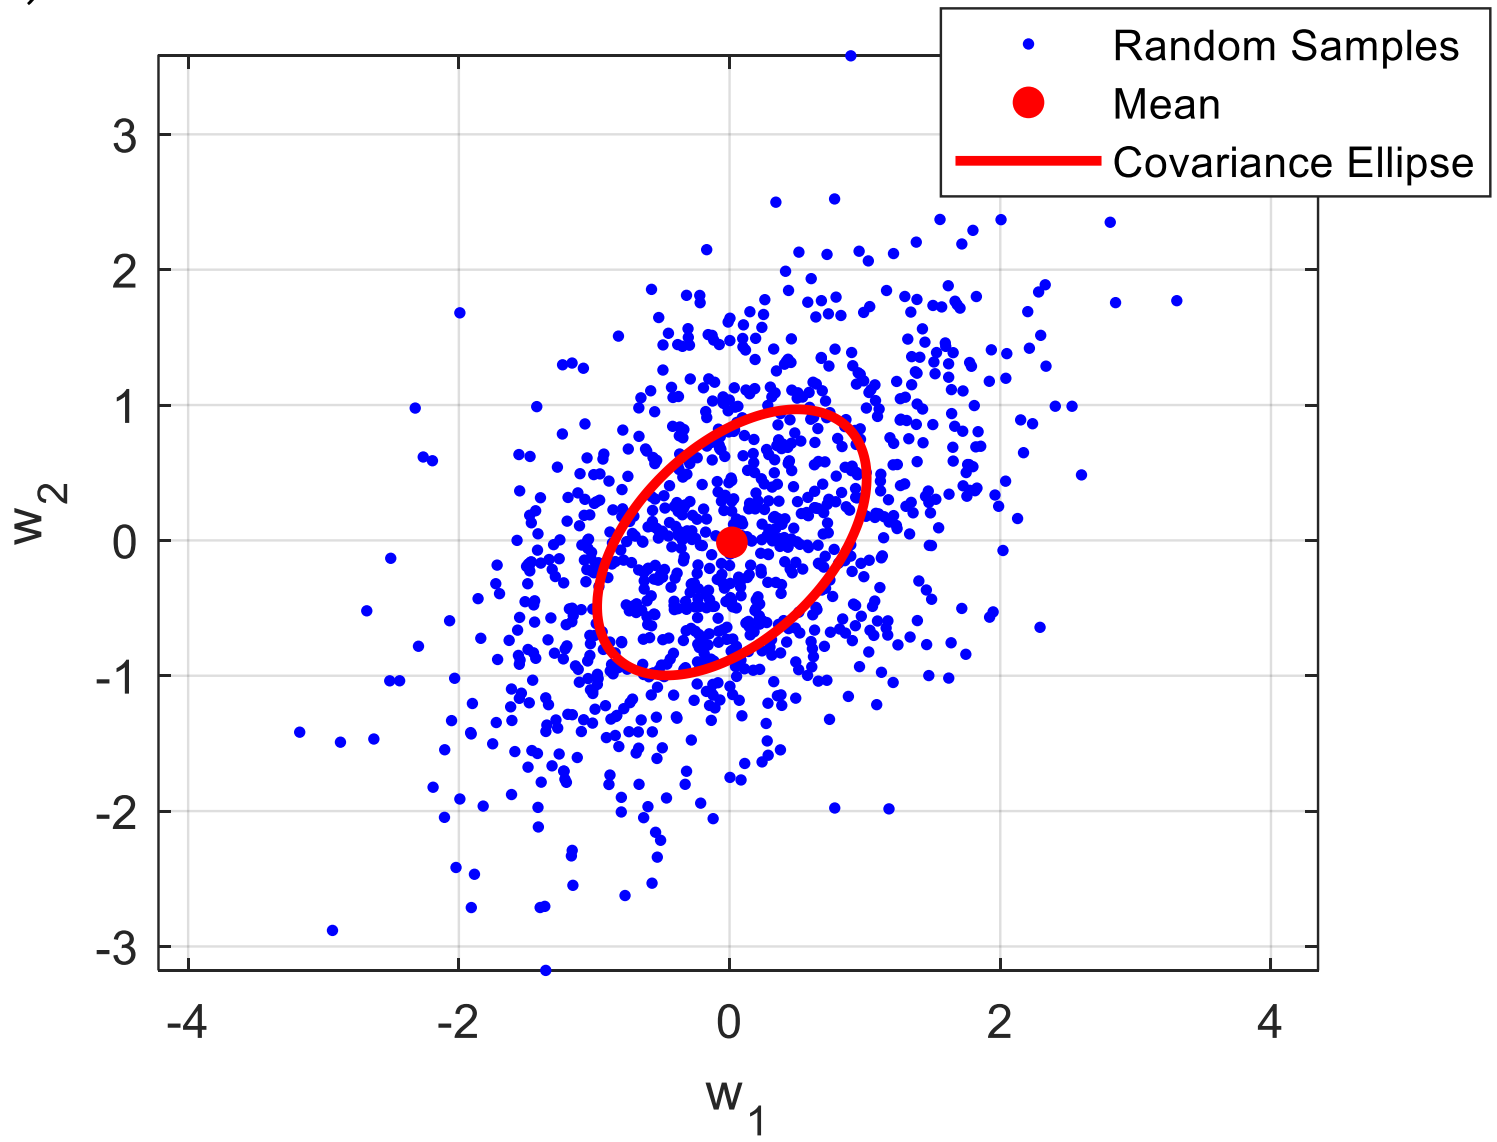
$$Q = E\{w(k)w(k)^T\} = \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}$$

$$E\{w(k)\} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$



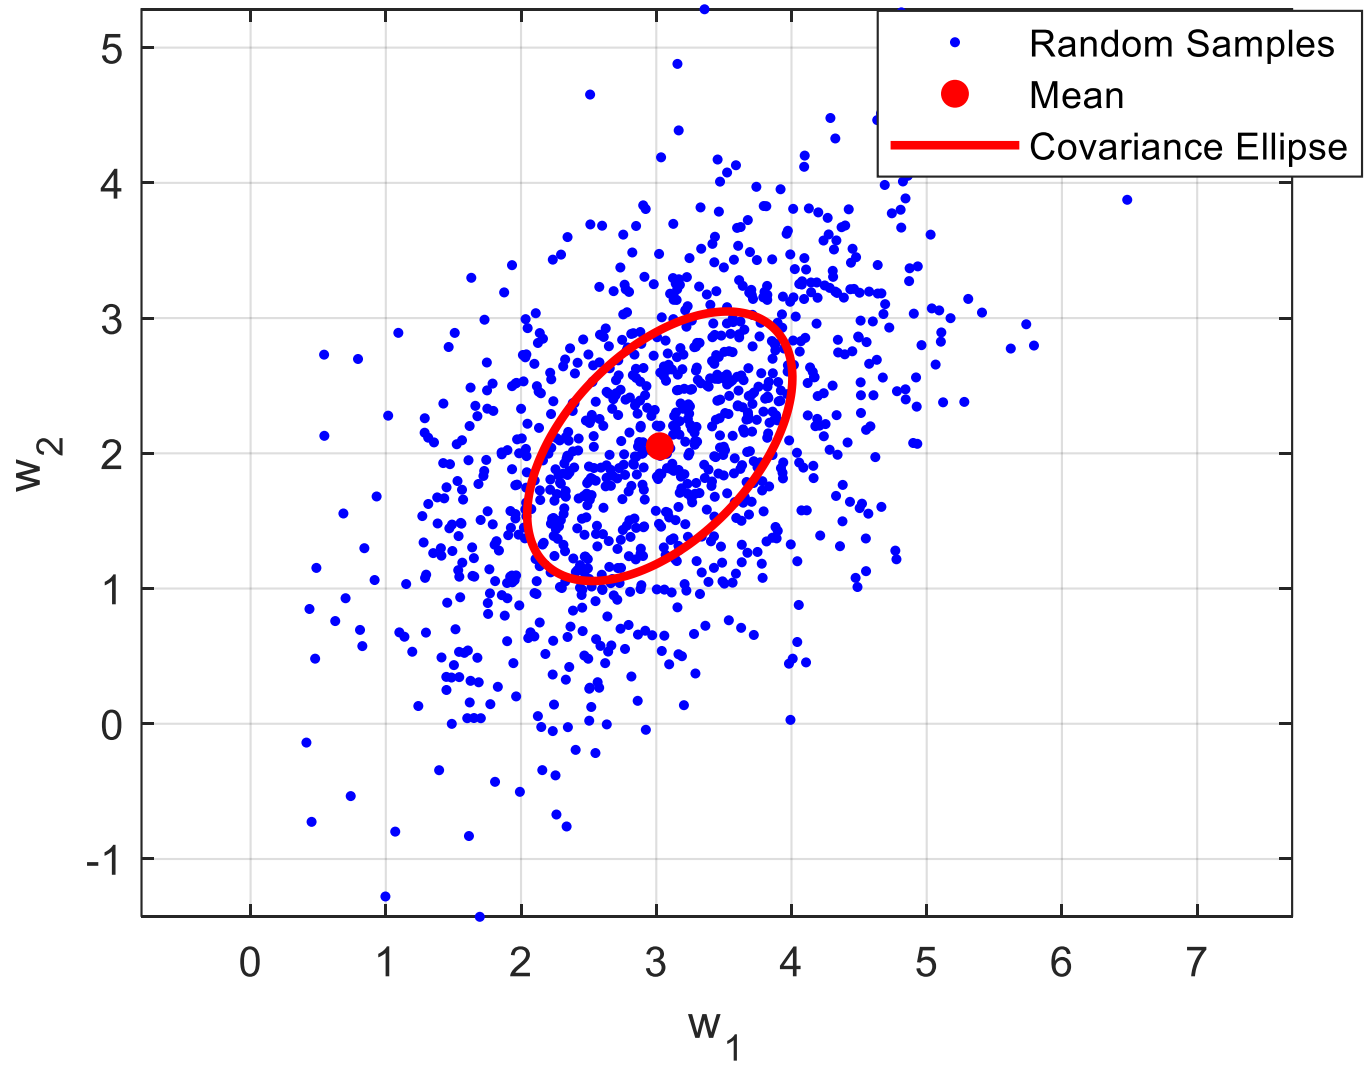
$$Q = E\{w(k)w(k)^T\} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$$

$$E\{w(k)\} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$



$$Q = E\{w(k)w(k)^T\} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$$

$$E\{w(k)\} = \begin{pmatrix} 3 \\ 2 \end{pmatrix}$$



Odhad stavu systému



- Úplný stavový vektor systému $x(k)$ je v realite len málokedy merateľný
  - Niektoré veličiny sú nedostupné pre praktické meranie (nemáme k nim priamy prístup) alebo pre ne neexistujú vhodné snímače
  - Merania stavov sú navyše nepresné (zaťažené šumom)
- Typicky máme k dispozícii len merania niektorých stavových veličín $m < n$
- Stavový vektor je preto potrebné odhadnúť (zrekonštruovať) na základe:
  - Modelu systému
  - Informácii o vstupoch
  - Meraní výstupov
- Načo je dobré odhadovať stavový vektor ?
  - Mnohé riadiace stratégie potrebujú celý stavový vektor (LQ, MPC)
  - Aj keď máme merania potrebných veličín, tie sú často zašumené. Odhad stavu šum vyhladzuje (filtruje) a poskytuje presnejšiu informáciu
  - Odhad stavu umožňuje spojiť informácie z rôznych senzorov (sensor fusion) do jednej presnejšej informácie

Odhad stavu a Kalmanov filter



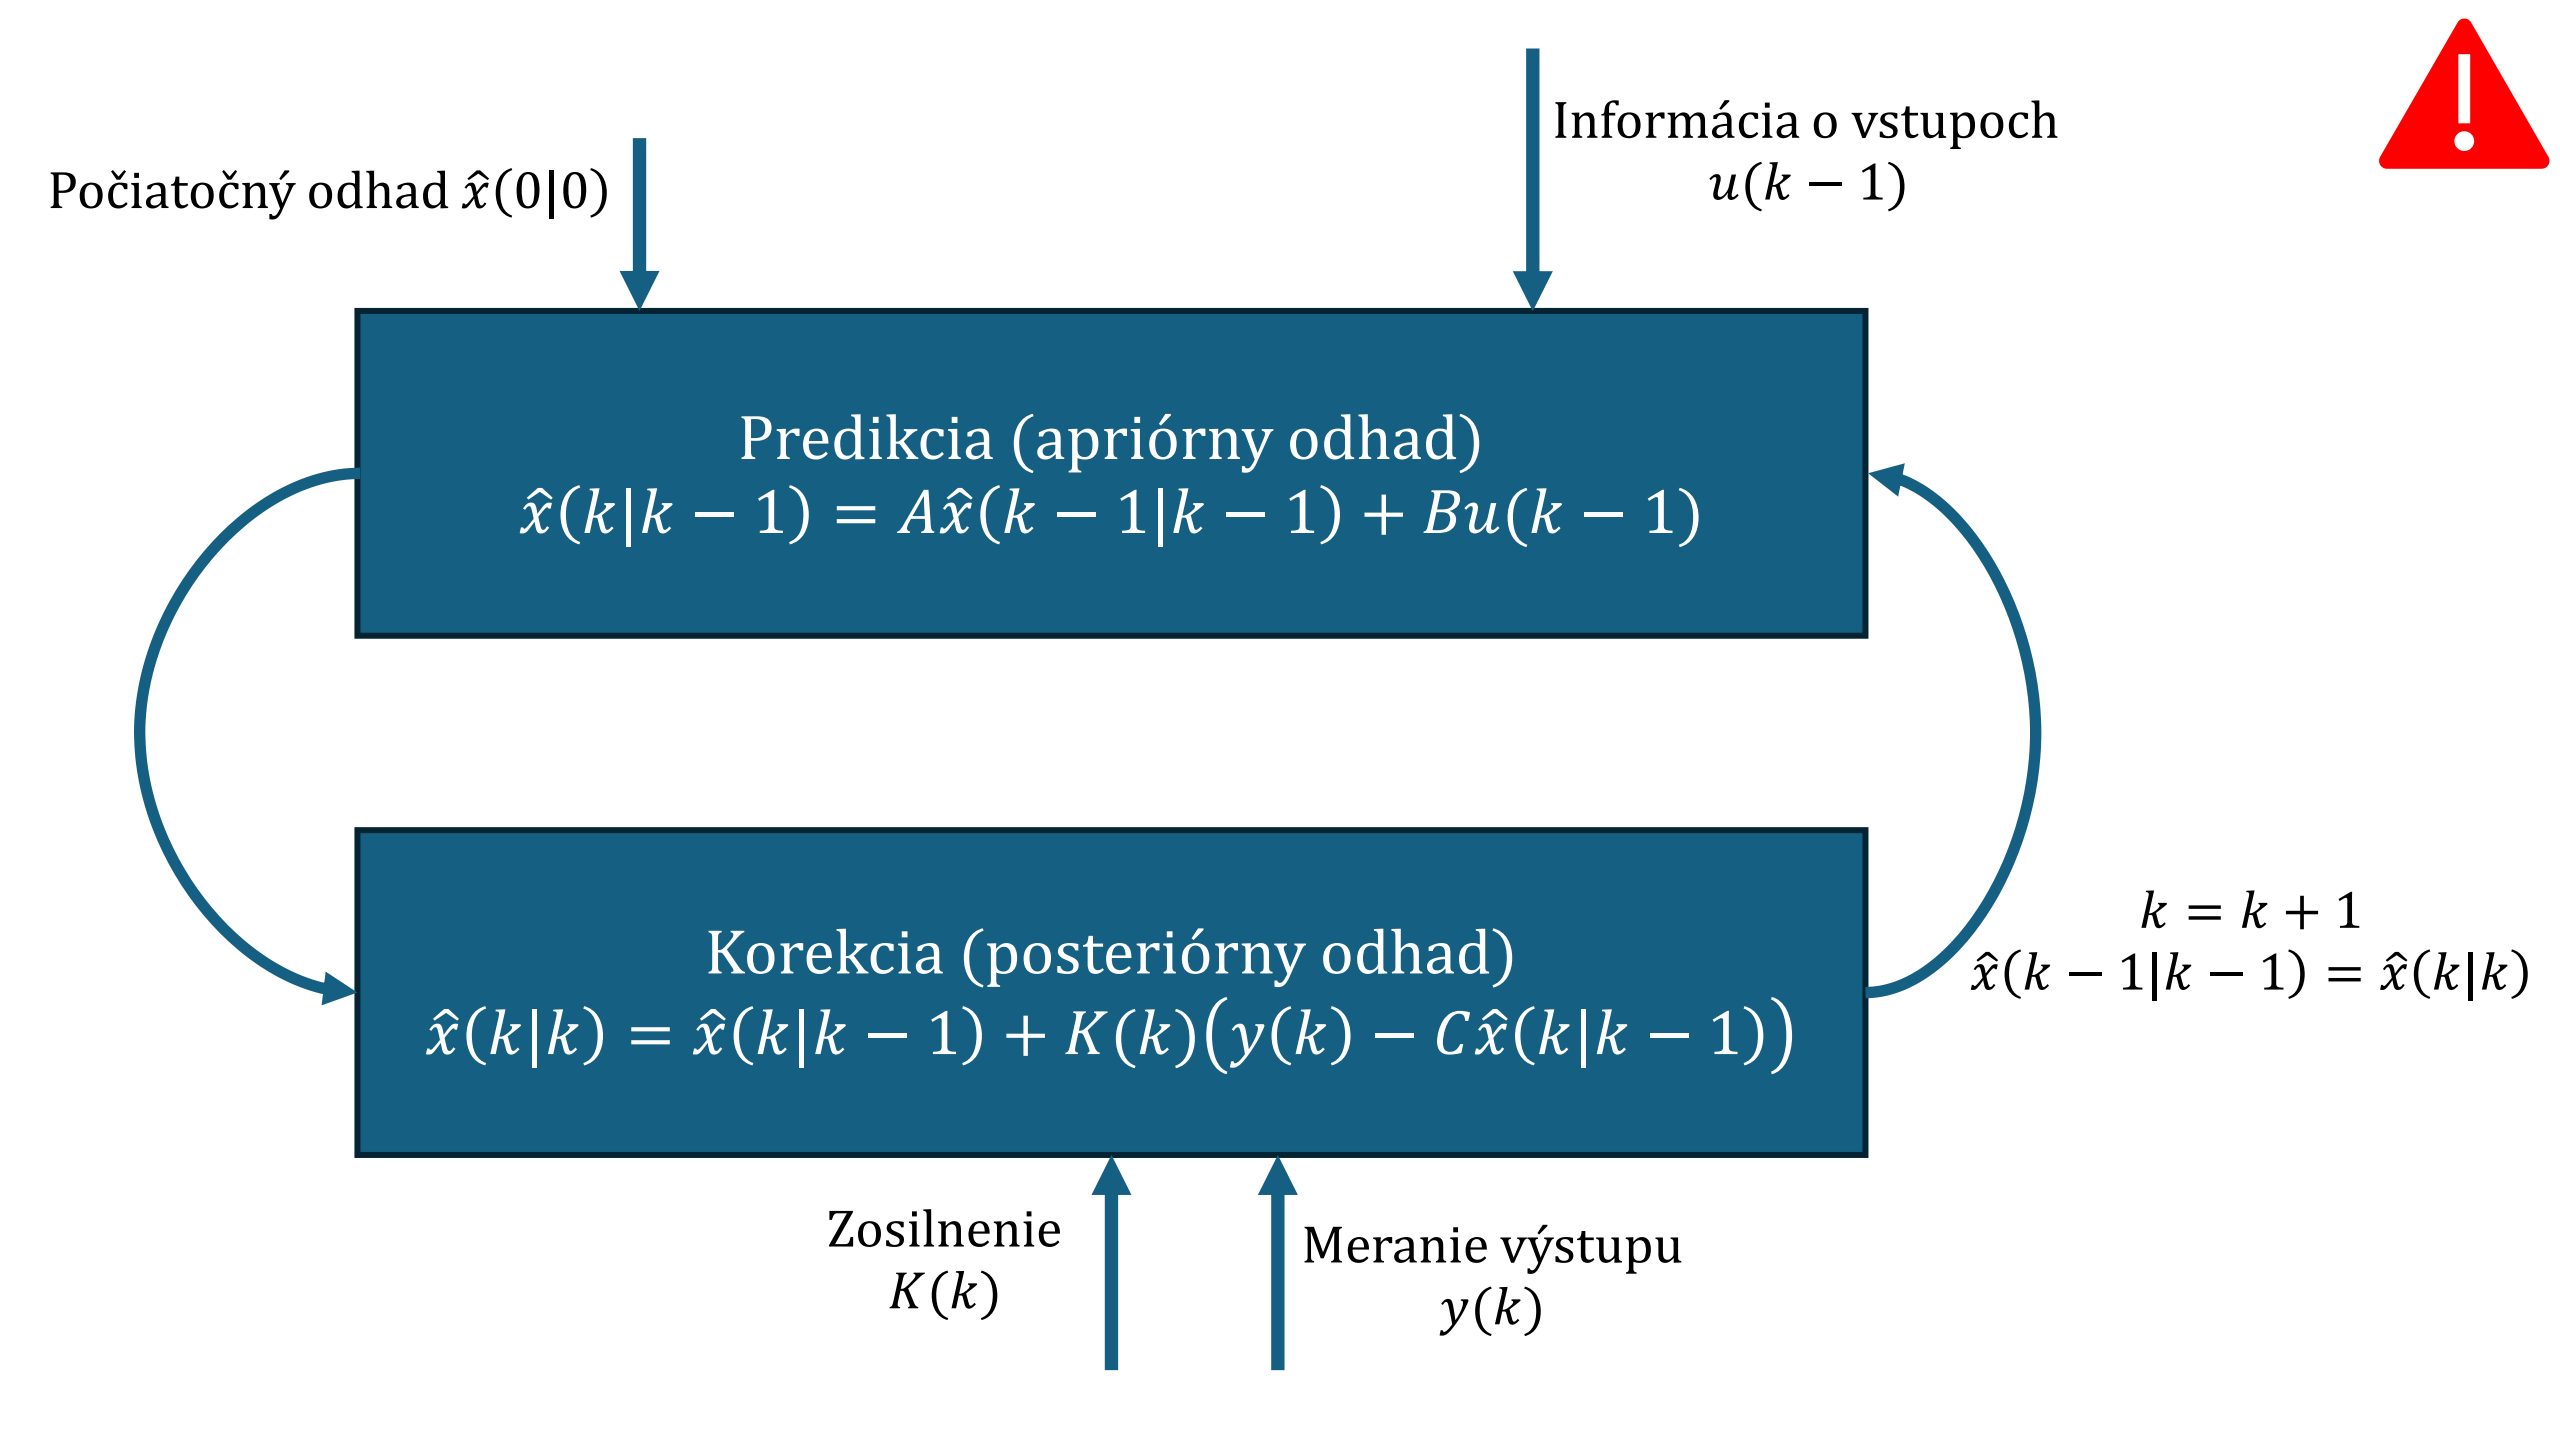
- Kalmanov filter je rekurzívny algoritmus pre odhad stavu (state estimator)
  - Využíva odhad stavu z predchádzajúceho kroku pre výpočet nového odhadu stavu
- Kombinuje model systému a reálne merania výstupu tak, aby čo najpresnejšie odhadol skutočný stav systému
- Odhad stavového vektora označíme $\hat{x}(k) \in \mathbb{R}^n$
- Budeme odlišovať dve fázy (kroky) odhadu stavu:
  - Predikcia, ktorá poskytne takzvaný apriórny odhad stavu $\hat{x}(k|k-1)$
  - Korekcia meraním, ktorá poskytne takzvaný posteriórny odhad stavu $\hat{x}(k|k)$
- Predikcia nech je daná diferenčnou rovnicou

$$\hat{x}(k|k-1) = A\hat{x}(k-1|k-1) + Bu(k-1)$$

- Korekcia nech je daná diferenčnou rovnicou

$$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)\big(y(k) - C\hat{x}(k|k-1)\big)$$

  - Člen $y(k) - C\hat{x}(k|k-1)$ je výstupná chyba predikcie vzhľadom na meranie $y(k)$
  - $K(k) \in \mathbb{R}^{n\times r}$ je premenlivá matica Kalmanovho zosilnenia (je predmetom návrhu)


Počiatočný odhad $\hat{x}(0|0)$
Informácia o vstupoch
$u(k-1)$
Predikcia (apriórny odhad)
$\hat{x}(k|k-1) = A\hat{x}(k-1|k-1) + Bu(k-1)$
Korekcia (posteriórny odhad)
$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)\big(y(k) - C\hat{x}(k|k-1)\big)$
$k = k+1$
$\hat{x}(k-1|k-1) = \hat{x}(k|k)$
Zosilnenie
$K(k)$
Meranie výstupu
$y(k)$

Chyba odhadu stavu a jej kovariančná matica

- Chyba (reziduum) odhadu stavu nech bude definovaná ako
  - Apriórna chyba (chyba predikovaného stavu)
$$e(k|k-1) = x(k) - \hat{x}(k|k-1)$$
  - Posteriórna chyba (chyba korigovaného stavu)
$$e(k|k) = x(k) - \hat{x}(k|k)$$
- Kovariančná matica apriórnej chyby odhadu stavu potom bude
$$P(k|k-1) = E\{e(k|k-1)e(k|k-1)^T\}$$
- Kovariančná matica posteriórnej chyby odhadu stavu potom bude
$$P(k|k) = E\{e(k|k)e(k|k)^T\}$$
- Diagonála kovariančnej matice $P(k|k)$ obsahuje rozptyly chyby $e(k|k)$ a teda hovorí o neistote (nepresnosti) odhadovaného stavu $\hat{x}(k|k)$
- Algoritmus odhadu stavu s optimálnym $K(k)$ bude minimalizovať rozptyly chyby $e(k|k)$

Vývoj chyby odhadu stavu (rekurzívne rovnice)

- Dynamika apriórnej chyby odhadu bude:

$$e(k|k-1) = x(k) - \hat{x}(k|k-1)$$

  - Dosadíme $x(k)$ a $\hat{x}(k|k)$

$$e(k|k-1) = Ax(k-1) + Bu(k-1) + w(k-1) - A\hat{x}(k-1|k-1) - Bu(k-1)$$

$$e(k|k-1) = A\big(x(k-1) - \hat{x}(k-1|k-1)\big) + w(k-1)$$

  - Potom $x(k-1) - \hat{x}(k-1|k-1) = e(k-1|k-1)$

$$e(k|k-1) = Ae(k-1|k-1) + w(k-1)$$

Vývoj chyby odhadu stavu (rekurzívne rovnice)

- Dynamika posteriórnej chyby odhadu bude

$$e(k|k) = x(k) - \hat{x}(k|k)$$

  - Dosadíme $\hat{x}(k|k)$

$$e(k|k) = x(k) - \hat{x}(k|k-1) - K(k)\big(y(k) - C\hat{x}(k|k-1)\big)$$

  - Potom $x(k) - \hat{x}(k|k-1) = e(k|k-1)$

$$e(k|k) = e(k|k-1) - K(k)\big(y(k) - C\hat{x}(k|k-1)\big)$$

  - Dosadíme $y(k)$

$$e(k|k) = e(k|k-1) - K(k)\big(Cx(k) + v(k) - C\hat{x}(k|k-1)\big)$$

  - Potom $x(k) - \hat{x}(k|k-1) = e(k|k-1)$

$$e(k|k) = (I - K(k)C)e(k|k-1) - K(k)v(k)$$

Dynamika kovariančnej matice apriórnej chyby odhadu stavu

- Odvodili sme rekurzívnu rovnicu pre apriórnu chybu odhadu stavu ako

$$e(k|k-1) = Ae(k-1|k-1) + w(k-1)$$

- Potom kovariančná matica $P(k|k-1)$ bude

$$P(k|k-1) = E\{e(k|k-1)e(k|k-1)^T\}$$

  - Dosadíme $e(k|k-1)$

$$P(k|k-1) = E\left\{\left(Ae(k-1|k-1) + w(k-1)\right)\left(Ae(k-1|k-1) + w(k-1)\right)^T\right\}$$

  - Roznásobíme

$$\begin{aligned} &P(k|k-1) \\ &= E\{Ae(k-1|k-1)e(k-1|k-1)^T A^T + w(k-1)w(k-1)^T \\ &+ 2Ae(k-1|k-1)w(k-1)^T\} \end{aligned}$$

  - Keďže $E\{w(k)w(k)^T\} = Q$ pričom platí že $e(k|k)$ a $w(k)$ sú nekorelované a teda $E\{e(k|k)w(k)^T\} = \mathbf{0}$, potom

$$P(k|k-1) = A\,E\{e(k-1|k-1)e(k-1|k-1)^T\}\,A^T + Q$$

  - Uvažujeme $E\{e(k|k)e(k|k)^T\} = P(k|k)$ a získame rekurzívnu rovnicu

$$P(k|k-1) = AP(k-1|k-1)A^T + Q$$

Dynamika kovariančnej matice posteriórnej chyby odhadu stavu

- Odvodili sme rekurzívnu rovnicu pre posteriórnu chybu odhadu stavu ako

$$e(k|k) = (I - K(k)C)e(k|k-1) - K(k)v(k)$$

- Potom kovariančná matica $P(k|k)$ bude

$$P(k|k) = E\{e(k|k)e(k|k)^T\}$$

- Dosadíme $e(k|k)$

$$P(k|k) = E\left\{\left((I - K(k)C)e(k|k-1) - K(k)v(k)\right)\left((I - K(k)C)e(k|k-1) - K(k)v(k)\right)^T\right\}$$

- Roznásobíme

$$P(k|k) = E\left\{(I - K(k)C)e(k|k-1)e(k|k-1)^T\left((I - K(k)C)\right)^T\right\} + E\{K(k)v(k)v^T(k)K^T(k)\} - E\left\{2(I - K(k)C)e(k|k-1)\left(K(k)v(k)\right)^T\right\}$$

Dynamika kovariančnej matice posteriórnej chyby odhadu stavu

- Keďže platí že $e(k|k-1)$ a $v(k)$ sú nekorelované a teda $E\{e(k|k-1)v(k)^T\} = \mathbf{0}$, potom

$$P(k|k)$$
$$= (I - K(k)C)E\{e(k|k-1)e(k|k-1)^T\}\big((I - K(k)C)\big)^T + K(k)E\{v(k)v^T(k)\}K(k)^T$$

- Dosadíme $E\{v(k)v(k)^T\} = R$ a $E\{e(k|k-1)e(k|k-1)^T\} = P(k|k-1)$

$$P(k|k) = (I - K(k)C)P(k|k-1)\big((I - K(k)C)\big)^T + K(k)RK(k)^T$$

- Nakoniec môžeme dosadiť $P(k|k-1) = AP(k-1|k-1)A^T + Q$ a získame rekurzívnu rovnicu

$$P(k|k) = (I - K(k)C)\big(AP(k-1|k-1)A^T + Q\big)\big((I - K(k)C)\big)^T + K(k)RK(k)^T$$

Stopa kovariančnej matice $P(k|k)$



- Stopa matice $\mathrm{tr}\big(P(k|k)\big)$ je skalár (jedno číslo)
- Predstavuje súčet všetkých prvkov na diagonále

$$\mathrm{tr}\big(P(k|k)\big) = \sum_{i=1}^{n} p_{ii}(k|k)$$

- Diagonálu kovariančnej matice tvoria jednotlivé rozptyly chyby odhadu stavu $e(k|k)$ ako $E\{{e_i}^2(k|k)\}$
- Stopa kovariančnej matice je potom súčet všetkých rozptylov

$$\mathrm{tr}\big(P(k|k)\big) = \sum_{i=1}^{n} E\{{e_i}^2(k|k)\}$$

- Stopa $\mathrm{tr}\big(P(k|k)\big)$ preto vyjadruje celkovú (súhrnnú) mieru chyby odhadu stavu
- Minimalizáciou $\mathrm{tr}\big(P(k|k)\big)$ vzhľadom na $K(k)$ tak získame štatisticky optimálny odhad stavu minimalizujúci rozptyly chyby odhadu stavu

Gradient stopy $P(k|k)$ podľa $K(k)$ a optimálne Kalmanovo zosilnenie

- Majme kovariančnú maticu posteriórnej chyby odhadu $P(k|k)$ ako
$$P(k|k) = (I - K(k)C)\big(AP(k-1|k-1)A^T + Q\big)\big((I - K(k)C)\big)^T + K(k)RK(k)^T$$
- Gradient stopy $P(k|k)$ podľa $K(k)$ bude
$$\nabla_{K(k)}\mathrm{tr}\big(P(k|k)\big)$$
$$= 2K(k)C\big(AP(k-1|k-1)A^T + Q\big)C^T - 2\big(AP(k-1|k-1)A^T + Q\big)C^T + 2K(k)R$$
- Keďže hľadáme extrém (minimálnu stopu), bude podmienka optimálnosti $\nabla_{K(k)}\mathrm{tr}\big(P(k|k)\big) = \mathbf{0}$ viesť na
$$2K(k)C\big(AP(k-1|k-1)A^T + Q\big)C^T - 2\big(AP(k-1|k-1)A^T + Q\big)C^T + 2K(k)R = \mathbf{0}$$
$$K(k)\big(C\big(AP(k-1|k-1)A^T + Q\big)C^T + R\big) = \big(AP(k-1|k-1)A^T + Q\big)C^T$$
- Optimálne Kalmanovo zosilnenie $K(k)$ potom bude
$$K(k) = \big(AP(k-1|k-1)A^T + Q\big)C^T\big(C\big(AP(k-1|k-1)A^T + Q\big)C^T + R\big)^{-1}$$
- Dosadíme $P(k|k-1) = AP(k-1|k-1)A^T + Q$ získame
$$K(k) = P(k|k-1)C^T\big(CP(k|k-1)C^T + R\big)^{-1}$$

Úprava $P(k|k)$ a Riccatiho rovnica

- Dosaďme teraz optimálne zosilnenie $K(k)$ do rekurzívnej rovnice pre $P(k|k)$

$$P(k|k) = (I - K(k)C)P(k|k-1)\big((I - K(k)C)\big)^T + K(k)RK(k)^T$$

- Po úprave získavame

$$P(k|k) = P(k|k-1) - P(k|k-1)C^T\big(CP(k|k-1)C^T + R\big)^{-1}CP(k|k-1)$$

- Tento výraz sa nazýva Riccatiho rovnica
- Pretože $P(k|k-1)C^T\big(CP(k|k-1)C^T + R\big)^{-1} = K(k)$ pre $P(k|k)$ potom získavame

$$P(k|k) = P(k|k-1) - K(k)CP(k|k-1)$$

Porovnanie rekurzívnych rovníc

- Pre ľubovoľné $K(k)$ použijeme

$$P(k|k) = (I - K(k)C)P(k|k-1)\big((I - K(k)C)\big)^T + K(k)RK(k)^T$$

- Pre optimálne (Kalmanovo) $K(k)$ použijeme

$$P(k|k) = P(k|k-1) - K(k)CP(k|k-1)$$

kde $K(k) = P(k|k-1)C^T\left(CP(k|k-1)C^T + R\right)^{-1}$

- Aktualizácia $P(k|k)$ a výpočet $K(k)$ vôbec nezávisia od merania $y(k)$
- $P(k|k)$ a $K(k)$ je preto možné vypočítať offline
- Počiatočná kovariančná matica $P(0|0)$ sa volí tak aby charakterizovala neistotu počiatočného odhadu stavu $\hat{x}(0|0)$



Zhrnutie algoritmu Kalmanovho filtra

- Potrebujem poznať matice systému A, B, C
- Potrebujem poznať kovariančné matice Q a R
- Definujem si počiatočnú kovariančnú maticu $P(0|0)$ a počiatočný odhad stavu $\hat{x}(0|0)$
- Rekurzívne iterujem:
  1. Predikcia

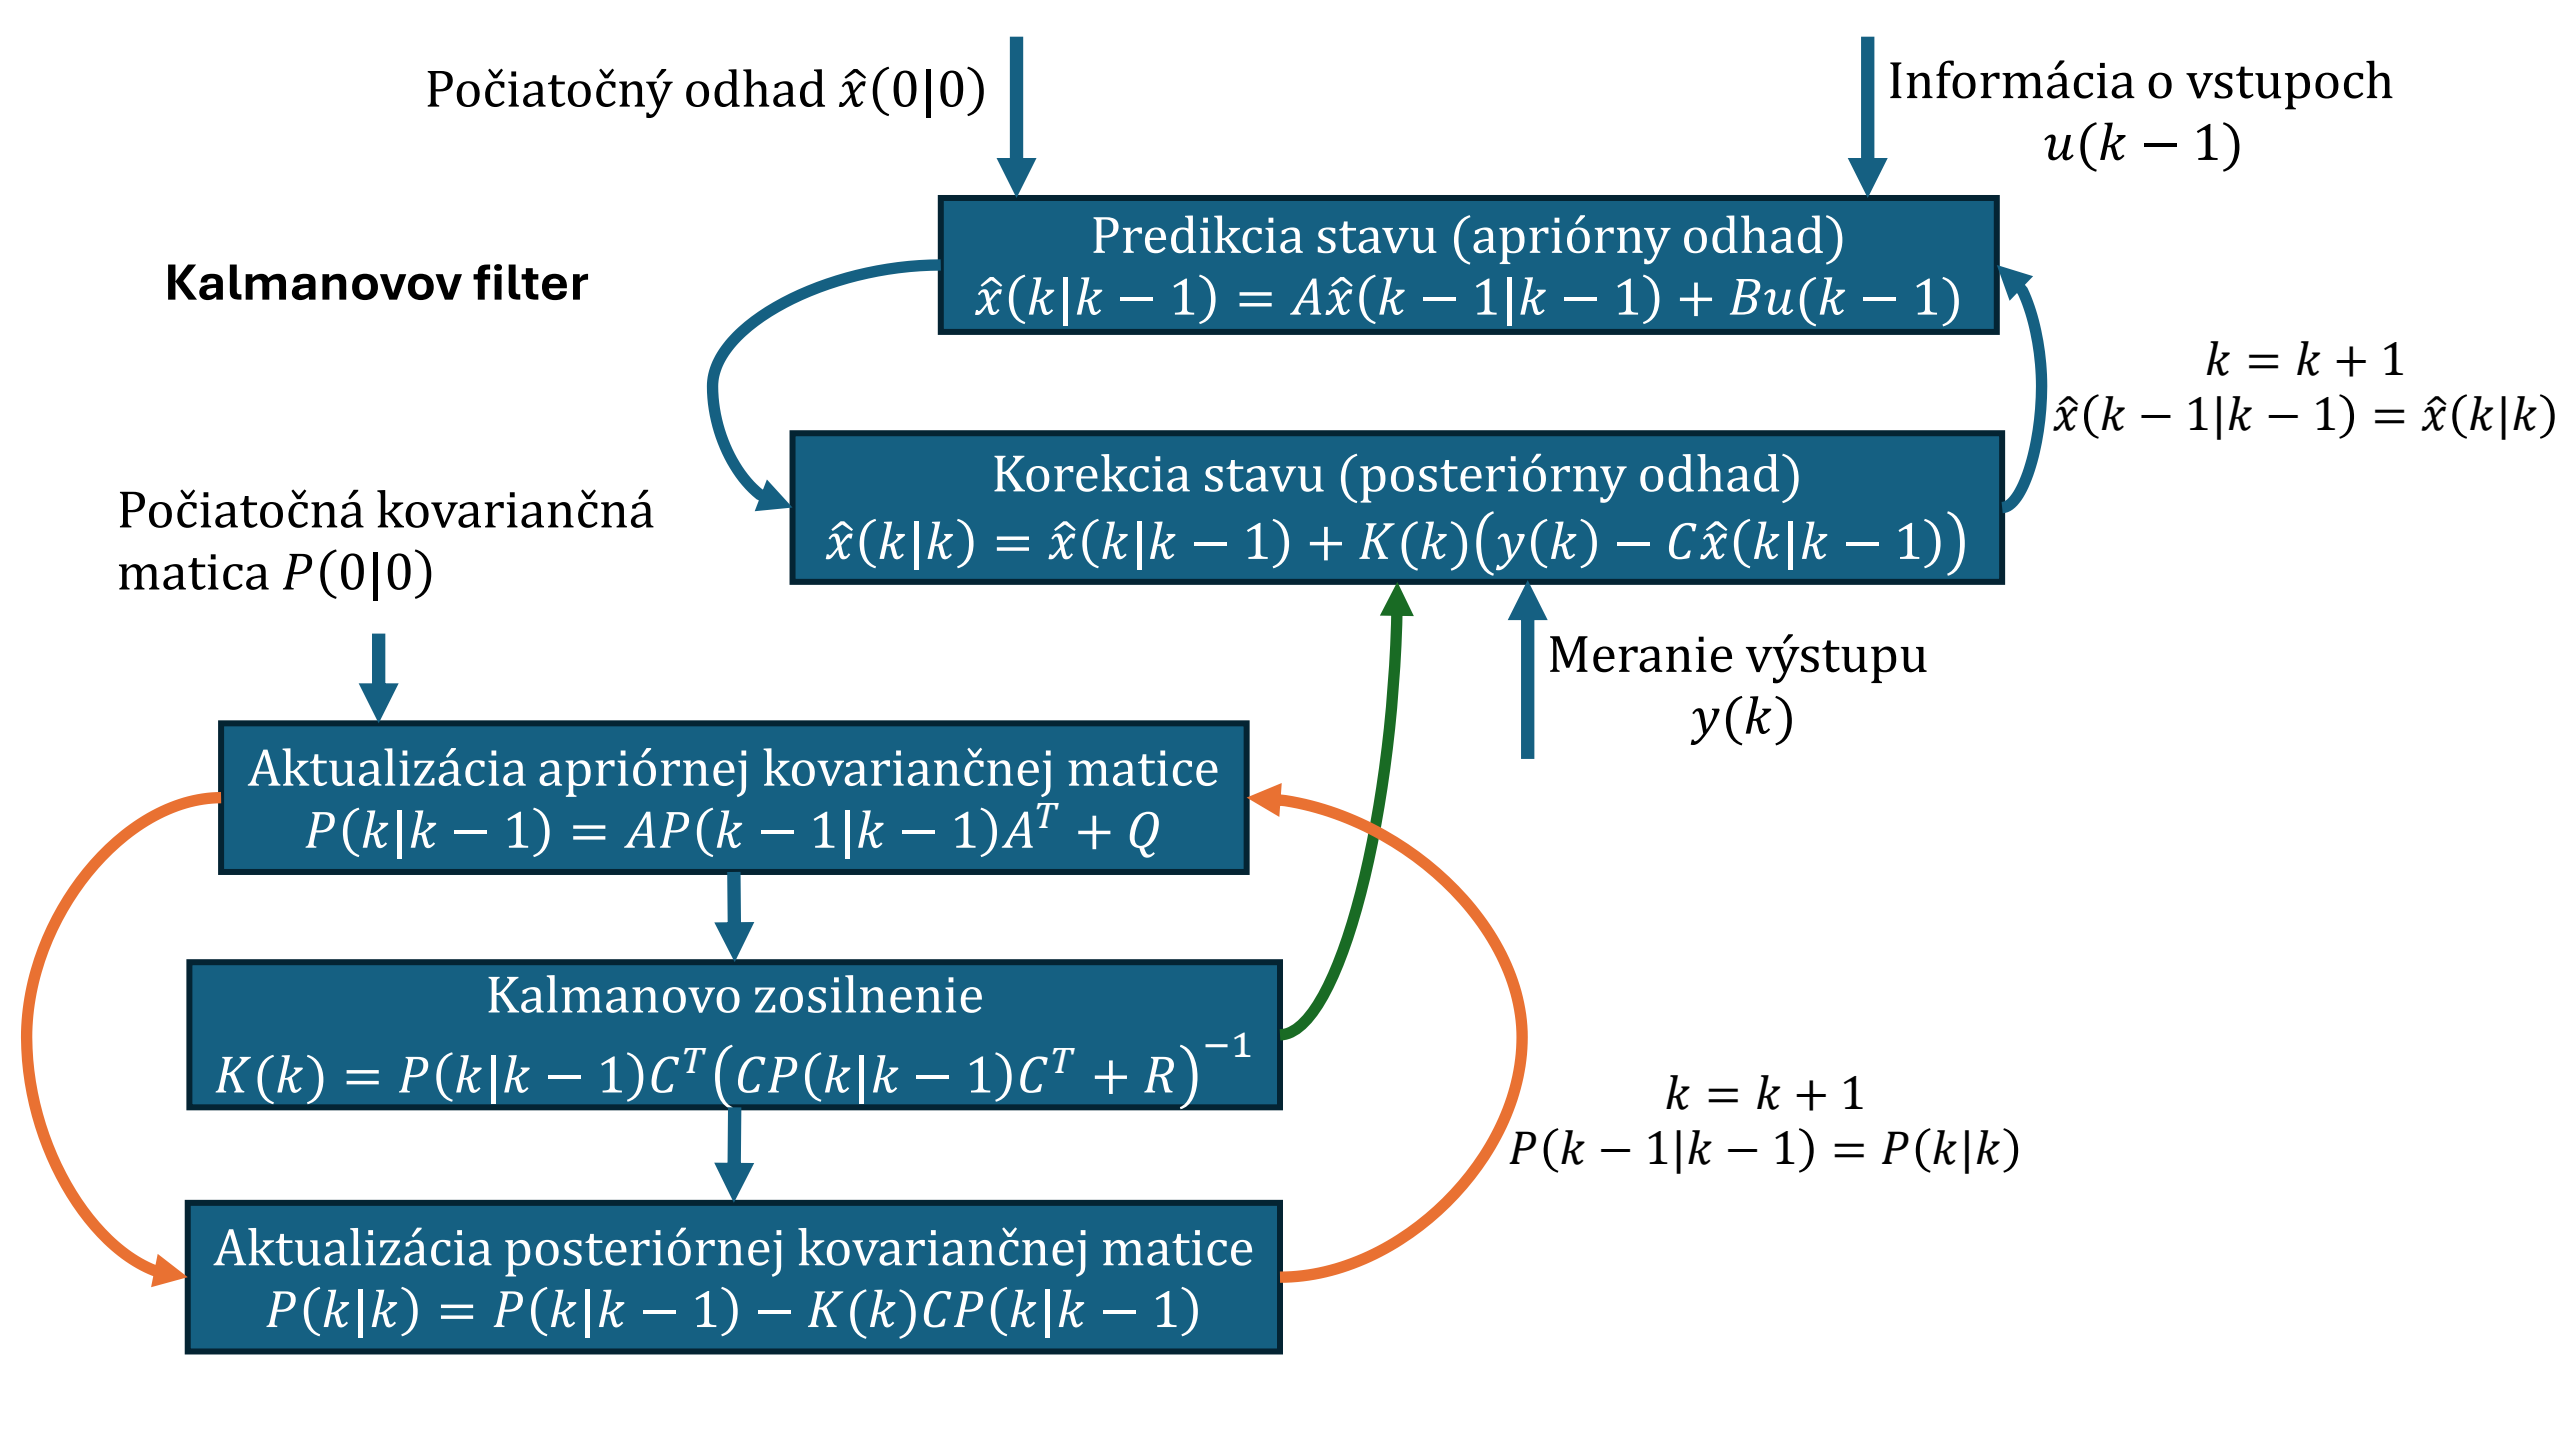
$$\hat{x}(k|k-1) = A\hat{x}(k-1|k-1) + Bu(k-1)$$
$$P(k|k-1) = AP(k-1|k-1)A^T + Q$$

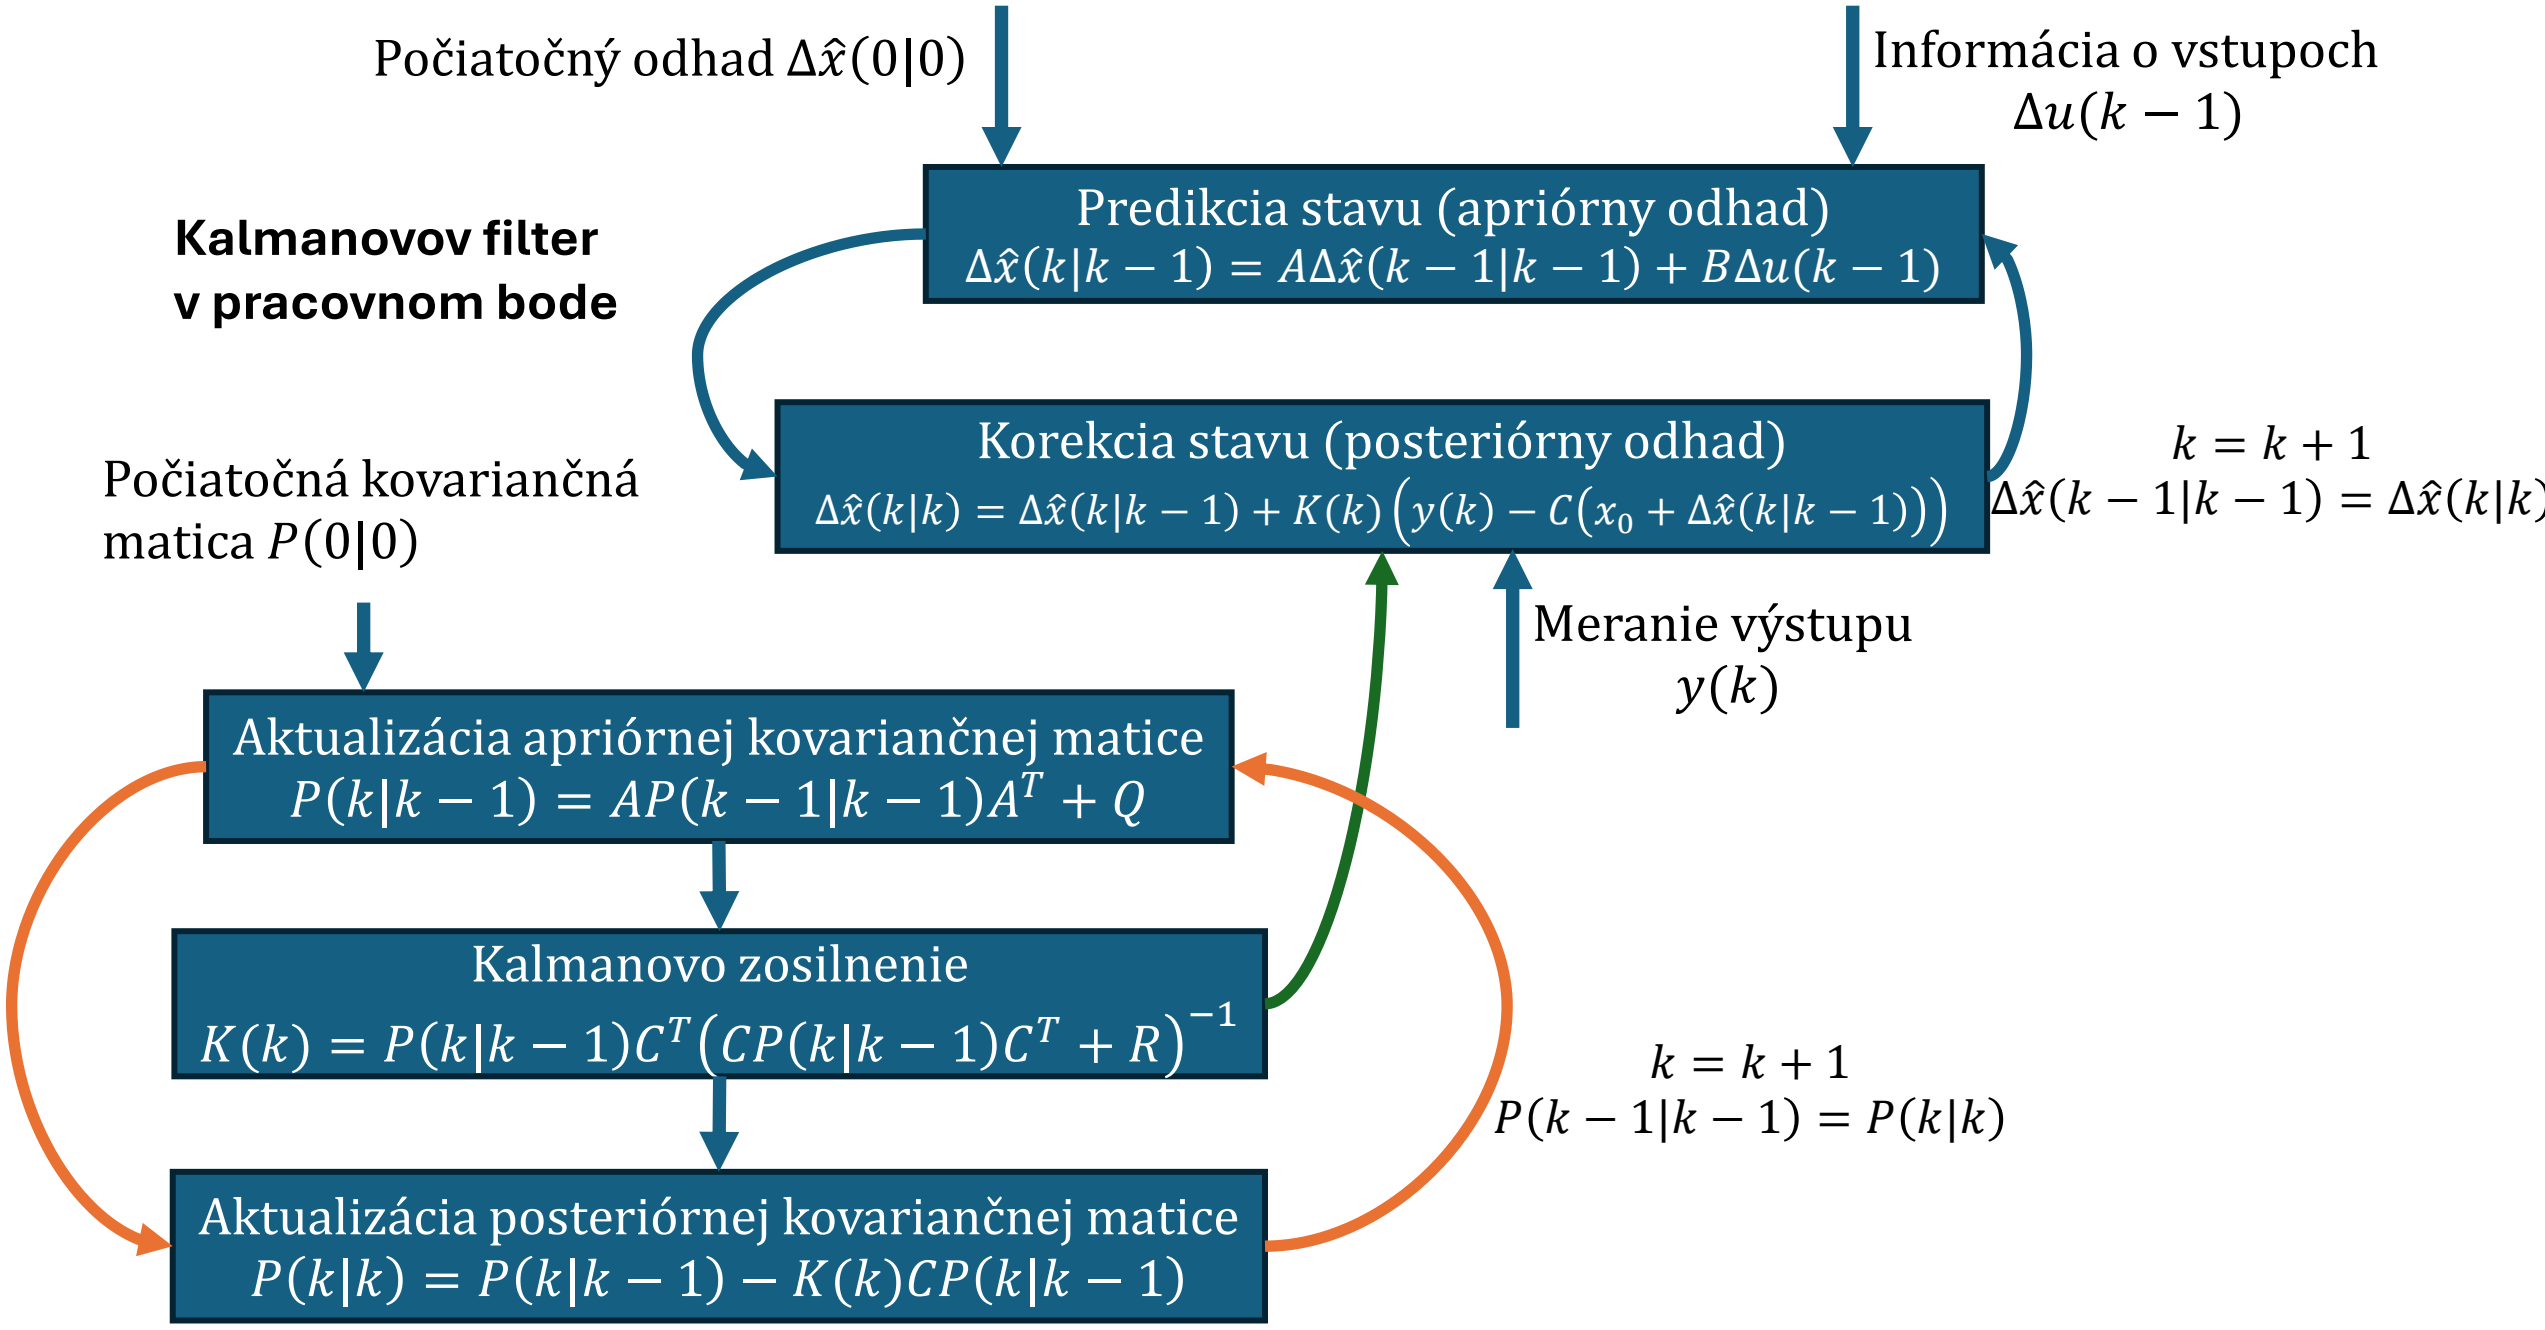
  2. Získam meranie výstupu $y(k)$
  3. Výpočet zosilnenia

$$K(k) = P(k|k-1)C^T\left(CP(k|k-1)C^T + R\right)^{-1}$$

  4. Korekcia

$$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)\left(y(k) - C\hat{x}(k|k-1)\right)$$
$$P(k|k) = P(k|k-1) - K(k)CP(k|k-1)$$


Počiatočný odhad $\hat{x}(0|0)$
Informácia o vstupoch $u(k-1)$
Kalmanovov filter
Predikcia stavu (apriórny odhad)
$\hat{x}(k|k-1) = A\hat{x}(k-1|k-1) + Bu(k-1)$
$k = k+1$
$\hat{x}(k-1|k-1) = \hat{x}(k|k)$
Korekcia stavu (posteriórny odhad)
$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)\big(y(k) - C\hat{x}(k|k-1)\big)$
Počiatočná kovariančná matica $P(0|0)$
Meranie výstupu $y(k)$
Aktualizácia apriórnej kovariančnej matice
$P(k|k-1) = AP(k-1|k-1)A^T + Q$
Kalmanovo zosilnenie
$K(k) = P(k|k-1)C^T\big(CP(k|k-1)C^T + R\big)^{-1}$
$k = k+1$
$P(k-1|k-1) = P(k|k)$
Aktualizácia posteriórnej kovariančnej matice
$P(k|k) = P(k|k-1) - K(k)CP(k|k-1)$


Počiatočný odhad $\Delta\hat{x}(0|0)$
Informácia o vstupoch $\Delta u(k-1)$
Kalmanovov filter v pracovnom bode
Predikcia stavu (apriórny odhad)
$\Delta\hat{x}(k|k-1) = A\Delta\hat{x}(k-1|k-1) + B\Delta u(k-1)$
Korekcia stavu (posteriórny odhad)
$\Delta\hat{x}(k|k) = \Delta\hat{x}(k|k-1) + K(k)\left(y(k) - C\left(x_0 + \Delta\hat{x}(k|k-1)\right)\right)$
$k = k+1$
$\Delta\hat{x}(k-1|k-1) = \Delta\hat{x}(k|k)$
Počiatočná kovariančná matica $P(0|0)$
Meranie výstupu $y(k)$
Aktualizácia apriórnej kovariančnej matice
$P(k|k-1) = AP(k-1|k-1)A^T + Q$
Kalmanovo zosilnenie
$K(k) = P(k|k-1)C^T\left(CP(k|k-1)C^T + R\right)^{-1}$
Aktualizácia posteriórnej kovariančnej matice
$P(k|k) = P(k|k-1) - K(k)CP(k|k-1)$
$k = k+1$
$P(k-1|k-1) = P(k|k)$

Asymptotická (ustálená) forma Kalmanovho filtra

- Pre počiatočnú kovariančnú maticu $P(0|0)$ by sme mohli $P(k|k)$ rekurzívne iterovať do nekonečna pričom

$$P_\infty = \lim_{k\to\infty} P(k|k)$$

- V ustálenom stave dynamiky $P(k|k)$ bude platiť

$$P(k|k) = P(k-1|k-1) = P_\infty$$

- Diferenčná Riccatiho rovnica sa tak stáva algebrickou

$$P_\infty = AP_\infty A^T + Q - K_\infty C\left(AP_\infty A^T + Q\right)$$
$$K_\infty = \left(AP_\infty A^T + Q\right)C^T\left(C\left(AP_\infty A^T + Q\right)C^T + R\right)^{-1}$$

- Potom

$$P_\infty = AP_\infty A^T + Q - \left(AP_\infty A^T + Q\right)C^T\left(C\left(AP_\infty A^T + Q\right)C^T + R\right)^{-1}C\left(AP_\infty A^T + Q\right)$$

- Asymptotický Kalmanov filter má zmysel vtedy ak môžeme zanedbať neistotu $\hat{x}(0|0)$ alebo nepoznáme $P(0|0)$
- Existuje vždy maximálne jedno pozitívne definitné riešenie $P_\infty \succ 0$ algebrickej Riccatiho rovnice

Asymptotická (ustálená) forma Kalmanovho filtra

- Máme

$$P_\infty = AP_\infty A^T + Q - \left(AP_\infty A^T + Q\right)C^T\left(C\left(AP_\infty A^T + Q\right)C^T + R\right)^{-1}C\left(AP_\infty A^T + Q\right)$$

$$K_\infty = \left(AP_\infty A^T + Q\right)C^T\left(C\left(AP_\infty A^T + Q\right)C^T + R\right)^{-1}$$

- Zavedieme substitúciu

$$\tilde{P}_\infty = AP_\infty A^T + Q$$

- Potom rovnica pre P_∞ bude

$$P_\infty = \tilde{P}_\infty - \tilde{P}_\infty C^T\left(C\tilde{P}_\infty C^T + R\right)^{-1}C\tilde{P}_\infty$$

- Kalmanovo zosilnenie bude

$$K_\infty = \tilde{P}_\infty C^T\left(C\tilde{P}_\infty C^T + R\right)^{-1}$$

- Prenásobíme P_∞ zľava A, sprava A^T a pričítame Q

$$AP_\infty A^T + Q = A\tilde{P}_\infty A^T + Q - A\tilde{P}_\infty C^T\left(C\tilde{P}_\infty C^T + R\right)^{-1}C\tilde{P}_\infty A^T$$

- Pretože $\tilde{P}_\infty = AP_\infty A^T + Q$ tento výraz je ekvivalentný k Riccatiho rovnici

$$\tilde{P}_\infty = A\tilde{P}_\infty A^T + Q - A\tilde{P}_\infty C^T\left(C\tilde{P}_\infty C^T + R\right)^{-1}C\tilde{P}_\infty A^T$$

Vplyv Q, R (štatistických vlastností šumov) na kovariančnú maticu P_∞ a Kalmanovo zosilnenie K_∞

- Uvažujme algebrickú Riccatiho rovnicu a Kalmanovo zosilnenie

$$P_\infty = AP_\infty A^T + Q - AP_\infty C^T\left(CP_\infty C^T + R\right)^{-1} CP_\infty A^T$$

$$K_\infty = P_\infty C^T\left(CP_\infty C^T + R\right)^{-1}$$

- Ak sa zväčšia rozptyly procesného šumu (diagonála Q)
  - Kovariančná matica odhadu stavu P_∞ narastie. Tým, že sa zvýšil vplyv náhodných zložiek na stav zvýšila sa aj celková neurčitosť odhadu.
  - Kalmanovo zosilnenie K_∞ narastie. Tým, že sa zvýšil vplyv náhodných zložiek na stav zvýšila sa aj potreba agresívnejšie korigovať odhad stavu na základe merania.
- Ak sa zväčšia rozptyly šumu merania (diagonála R)
  - Kovariančná matica odhadu stavu P_∞ narastie (člen $AP_\infty C^T\left(CP_\infty C^T + R\right)^{-1} CP_\infty A^T$ klesá a je pred ním mínus). Tým, že narástla veľkosť šumu merania zvýšila sa aj celková neurčitosť odhadu
  - Kalmanovo zosilnenie K_∞ klesne (člen $\left(CP_\infty C^T + R\right)^{-1}$ sa zmenší). Tým že narástla veľkosť šumu merania, sú merania výstupu menej spoľahlivé a je potreba menej agresívne korigovať odhad stavu na základe merania



- **Výhody**
- Rekurzívny charakter výpočtov
- Výpočtovo nenáročný
- Poskytuje štatisticky optimálny odhad stavu
- Pri asymptotickej forme sa návrh realizuje offline
- Umožňuje efektívnu fúziu informácii zo snímačov
- Dobrá interpretovateľnosť výsledkov (poznáme neurčitosť odhadu)
- Intuitívne ladenie

- **Nevýhody**
- Funguje za predpokladu že procesný šum a šum merania majú nulové stredné hodnoty
- Funguje za predpokladu že procesný šum a šum merania sú nekorelované v čase (biely šum)
- Funguje za predpokladu že systém je lineárny
- Odhad stavu je štatisticky optimálny iba ak presne poznáme kovariančné matice (model) procesného šumu a šumu merania

Pozorovateľnosť

- Pozorovateľnosť (observability) odpovedá na veľmi konkrétnu otázku:
  - Dokážeme zo známych vstupov a z meraných výstupov jednoznačne zrekonštruovať celý stav systému?
- Uvažujme deterministický diskrétny systém

$$x(k+1) = Ax(k) + Bu(k)$$
$$y(k) = Cx(k)$$

- Pozorovateľnosť teda hovorí, či dostupné merania $y(k)$ obsahujú dostatok informácie na rekonštrukciu všetkých stavov.
- V čase k teda vidíme iba $y(k) = Cx(k)$
  - O jeden krok neskôr $y(k+1) = CAx(k) + CBu(k)$
  - O dva kroky: $y(k+2) = CA^2x(k) + CABu(k) + CBu(k+1)$
- Ak poznáme vstupy $u(k), u(k+1)$, ..., môžeme ich príspevok od výstupu odčítať.
- Potom dostávame informáciu o stave:

$$y(k) = Cx(k)$$
$$y(k+1) - CBu(k) = CAx(k)$$
$$y(k+2) - CABu(k) - CBu(k+1) = CA^2x(k)$$

- Tieto informácie môžeme zapísať do jednej matice.

$$\mathcal{O} = \begin{bmatrix} C \\ CA \\ CA^2 \\ \vdots \\ CA^{n-1} \end{bmatrix}, \mathcal{O} \in \mathbb{R}^{mn \times n}.$$

- Systém je úplne pozorovateľný, ak hodnosť matice $\mathcal{O}$ je rovná počtu stavov

$$\mathrm{rank}(\mathcal{O}) = n$$

  - Z meraní musíme získať n nezávislých informácií o týchto neznámych

Hodnosť matice

- Hodnosť (rank) matice hovorí, koľko navzájom nezávislých riadkov alebo stĺpcov matica obsahuje
- Napríklad

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

  - Druhý riadok je iba $2 \times (1, 2) = (2, 4)$, teda nie je nezávislý od prvého. Preto $\mathrm{rank}(A) = 1$.
- Naopak,

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

má dva nezávislé riadky, takže $\mathrm{rank}(A) = 2$

Navigácia auta pomocou GPS

- Auto ide priemernou doprednou rýchlosťou 3 m/s
- Auto je vybavené GPS lokalizáciou, ktorá poskytuje merania $y(k)$ polohy $x(k)$
  - Tieto merania však bývajú zaťažené **šumom** (nepresnosťou) cca ± 5 m
- Chceme presne odhadnúť polohu x a rýchlosť s auta počas jazdy
- Merania prichádzajú v diskrétnych časových krokoch Δt
- Kalmanov filter umožňuje kombinovať tieto nepresné merania s modelom pohybu vozidla a poskytuje tak presnejší odhad polohy aj rýchlosti
- Model systému

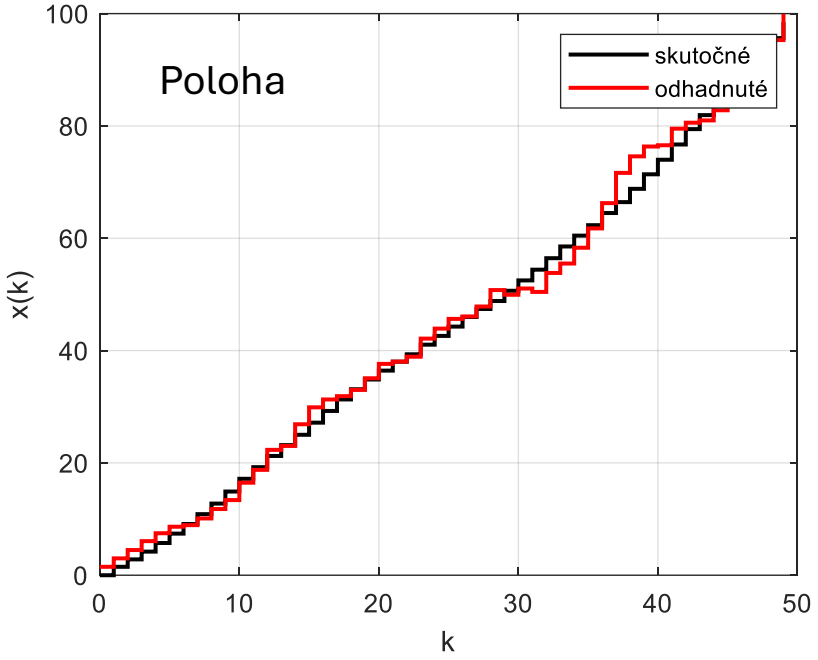
$$\begin{pmatrix} x(k+1) \\ s(k+1) \end{pmatrix} = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x(k) \\ s(k) \end{pmatrix} + \begin{pmatrix} 0 \\ w_s(k) \end{pmatrix}$$

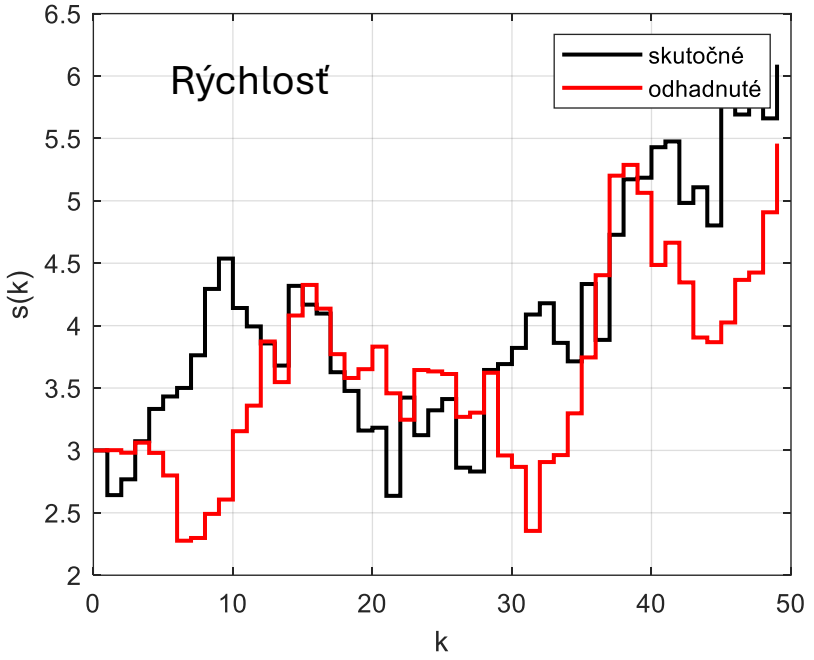
$$y(k) = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} x(k) \\ s(k) \end{pmatrix} + v(k)$$

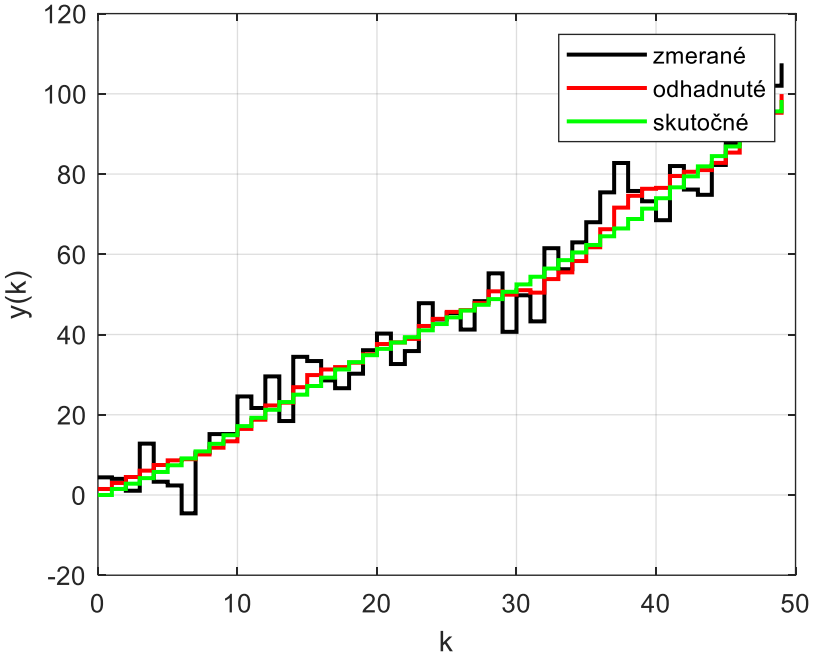
  - $\Delta t = 0.5$ s označuje časový rozdiel medzi dvoma po sebe idúcimi meraniami
  - $w_s(k)$ predstavuje malé náhodné zrýchlenia a brzdenia auta spôsobené terénnou nerovnosťou
  - priamy vplyv procesného šumu na polohu $x(k)$ neuvažujme
- Kovariančné matice zvolíme ako (iba rýchlosť podlieha náhodným fluktuáciám):

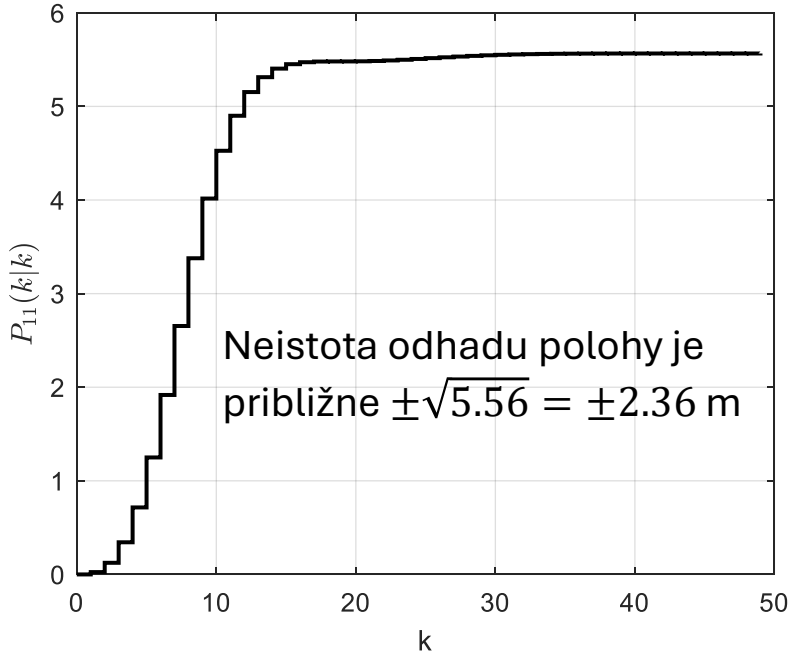
$$Q = \begin{pmatrix} 0 & 0 \\ 0 & 0.1 \end{pmatrix}, R = 25$$

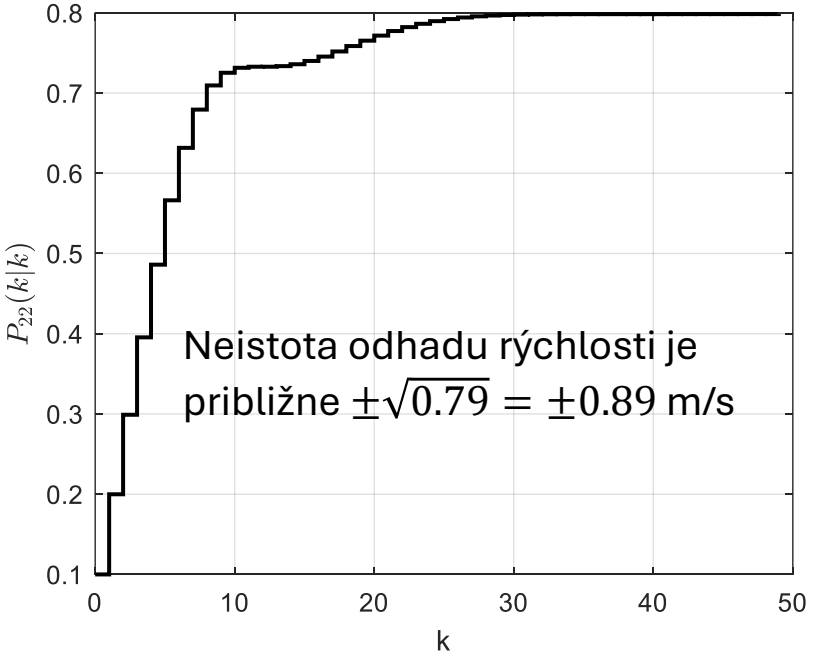
- Počiatočný stav nech poznáme presne ako $x(0) = 0, s(0) = 3$ a teda $P(0) = \mathbf{0}$

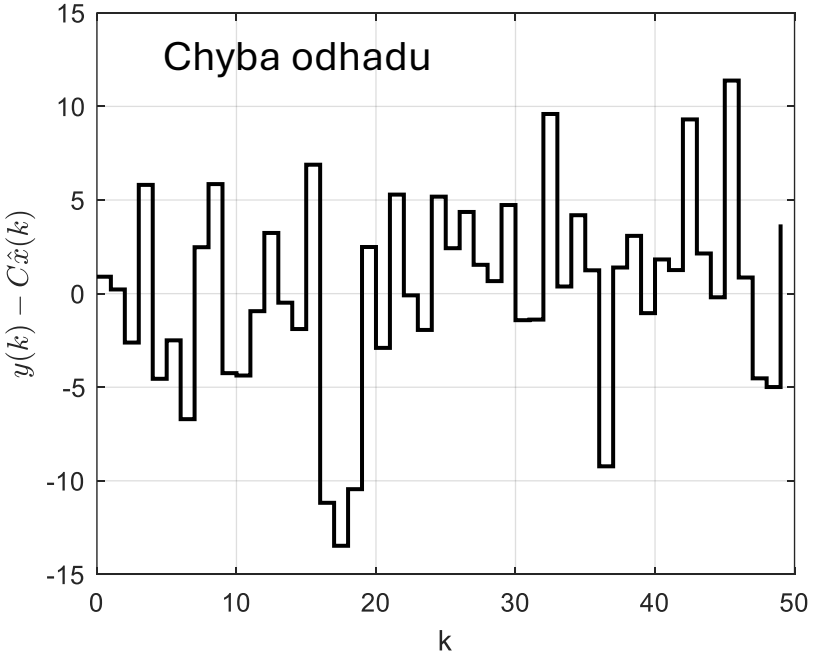

Poloha
skutočné
odhadnuté
x(k)
k


Rýchlosť
skutočné
odhadnuté
s(k)
k


zmerané
odhadnuté
skutočné
y(k)
k


$P_{11}(k|k)$
Neistota odhadu polohy je približne $\pm\sqrt{5.56} = \pm 2.36$ m
k


$P_{22}(k|k)$
Neistota odhadu rýchlosti je približne $\pm\sqrt{0.79} = \pm 0.89$ m/s
k


Chyba odhadu
$y(k) - C\hat{x}(k)$
k

Lokalizácia mobilného robota

- Robot sa pohybuje v 2D priestore a pomocou senzorov zisťuje svoju polohu a rýchlosť
  - Odometria (rotačné enkódre) – rýchlosť
  - GPS – poloha
- Tieto senzory sú však zaťažené šumom merania (neistotami)
- Cieľom je čo najpresnejšie odhadnúť pozíciu p_X, p_Y a rýchlosť robota s_X, s_Y
- Merania prichádzajú v diskrétnych časových krokoch Δt
- Budeme uvažovať model systému v tvare

$$\begin{pmatrix} p_X(k+1) \\ p_Y(k+1) \\ s_X(k+1) \\ s_Y(k+1) \end{pmatrix} = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} p_X(k) \\ p_Y(k) \\ s_X(k) \\ s_Y(k) \end{pmatrix} + \begin{pmatrix} w_{pX}(k) \\ w_{pY}(k) \\ w_{sX}(k) \\ w_{sY}(k) \end{pmatrix}$$

- Model merania bude

Odometria poskytuje meranie rýchlosti

$$\begin{pmatrix} y_{X_{ODO}}(k) \\ y_{Y_{ODO}}(k) \\ y_{X_{GPS}}(k) \\ y_{Y_{GPS}}(k) \end{pmatrix} = \begin{pmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} p_X(k) \\ p_Y(k) \\ s_X(k) \\ s_Y(k) \end{pmatrix} + \begin{pmatrix} v_{X_{ODO}}(k) \\ v_{Y_{ODO}}(k) \\ v_{X_{GPS}}(k) \\ v_{Y_{GPS}}(k) \end{pmatrix}$$

GPS poskytuje meranie polohy

- Štatistické vlastnosti procesného šumu a šumu merania

$$Q = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0.3 & 0 \\ 0 & 0 & 0 & 0.3 \end{pmatrix}, \qquad R = \begin{pmatrix} 0.09 & 0 & 0 & 0 \\ 0 & 0.09 & 0 & 0 \\ 0 & 0 & 25 & 0 \\ 0 & 0 & 0 & 25 \end{pmatrix}$$

Rýchlosť podlieha náhodným vplyvom (terénna nerovnosť)

Neistota odometrie ± 0.3 m/s

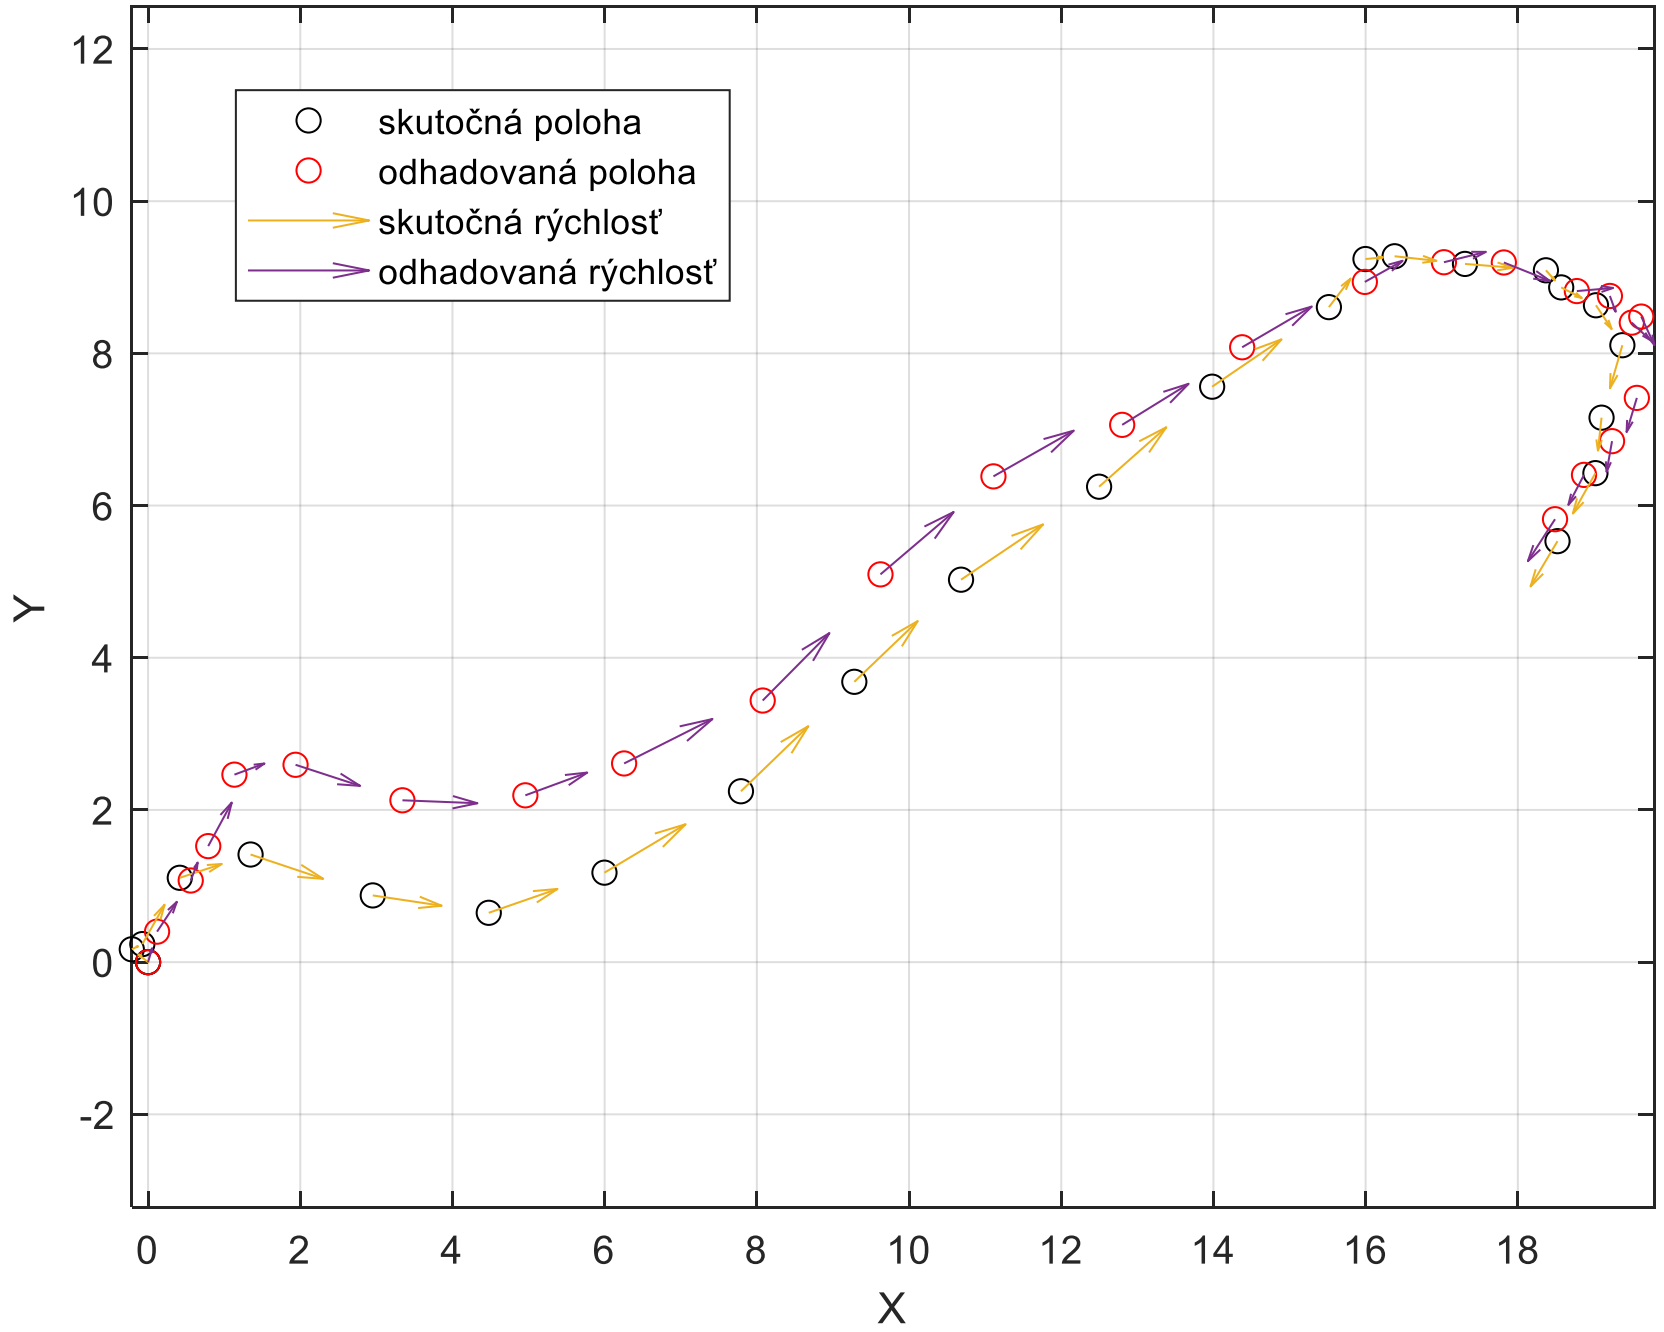
Neistota GPS ± 5 m

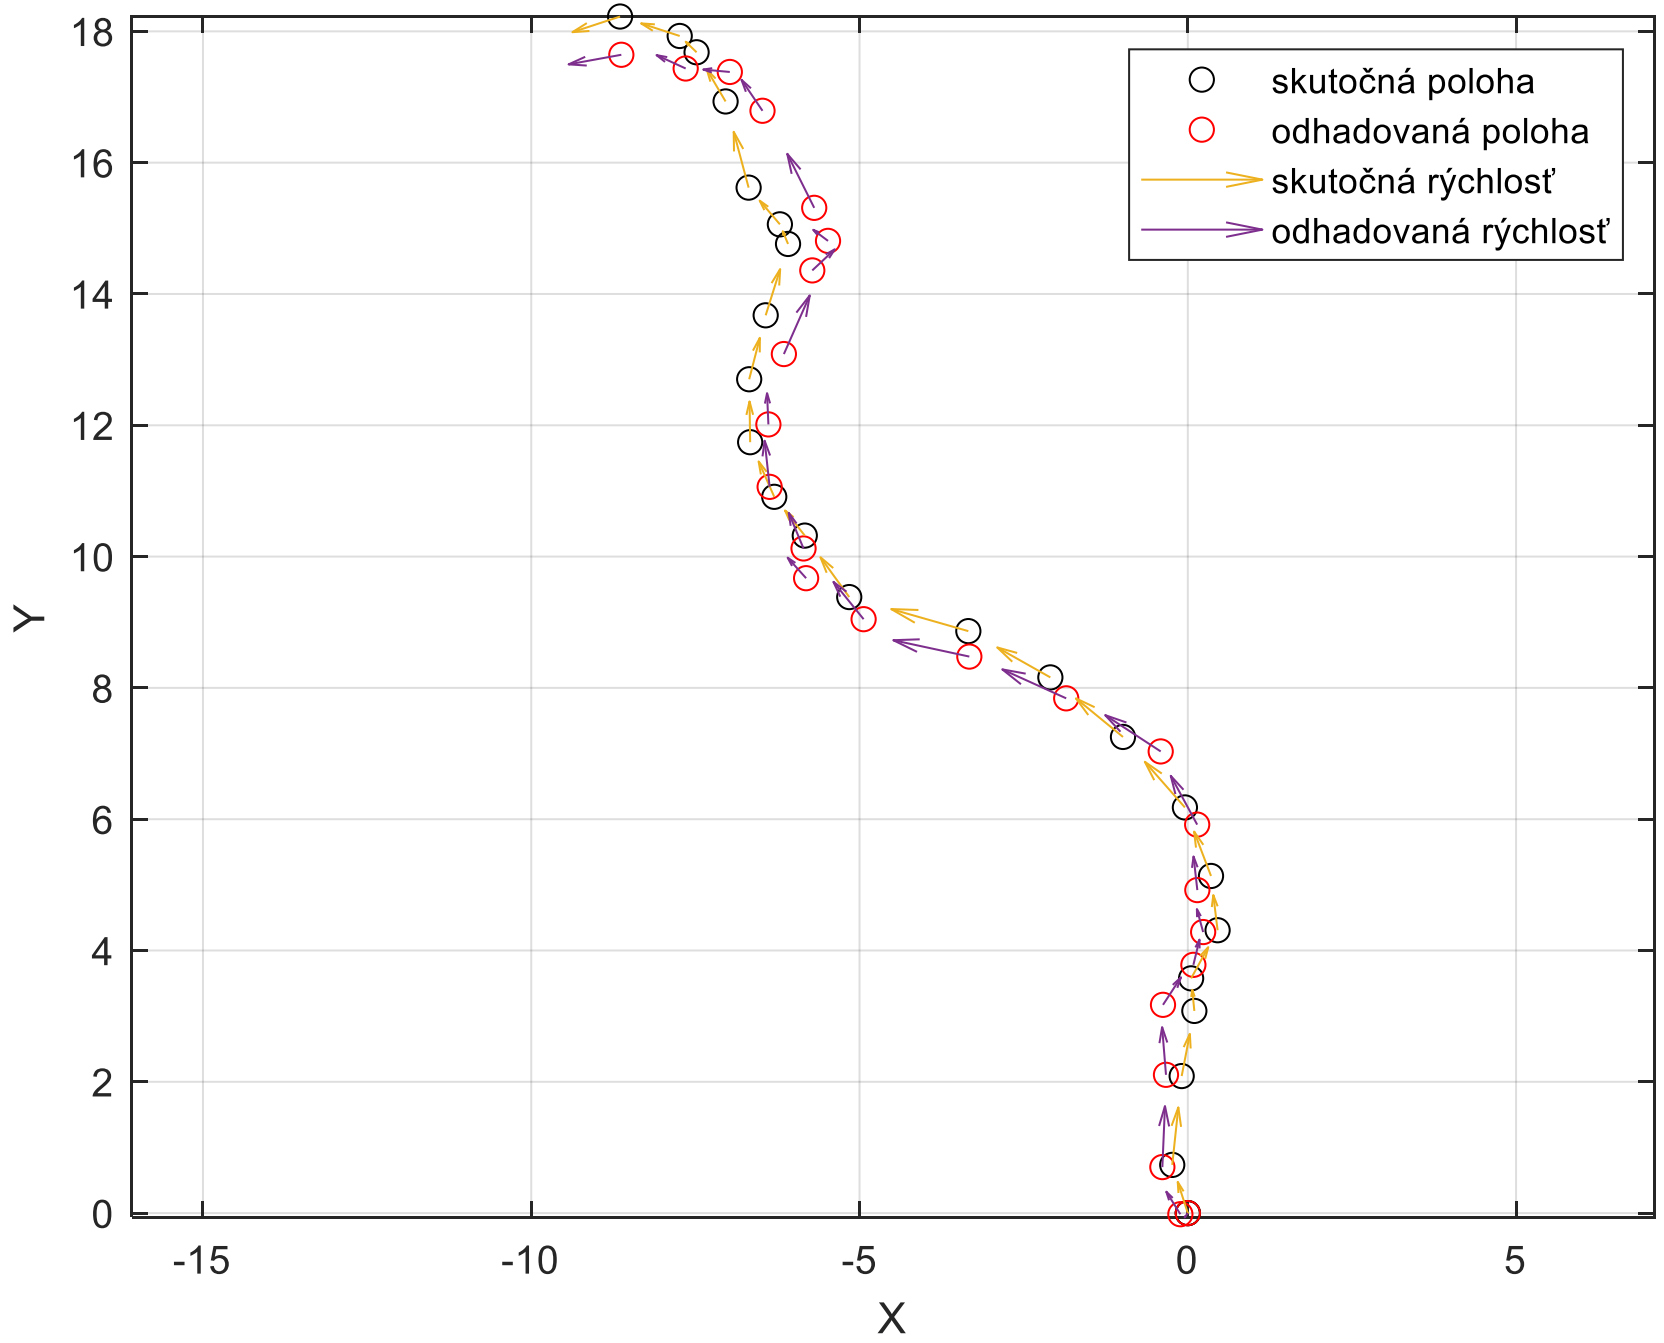
- Štatistické vlastnosti odhadu stavu

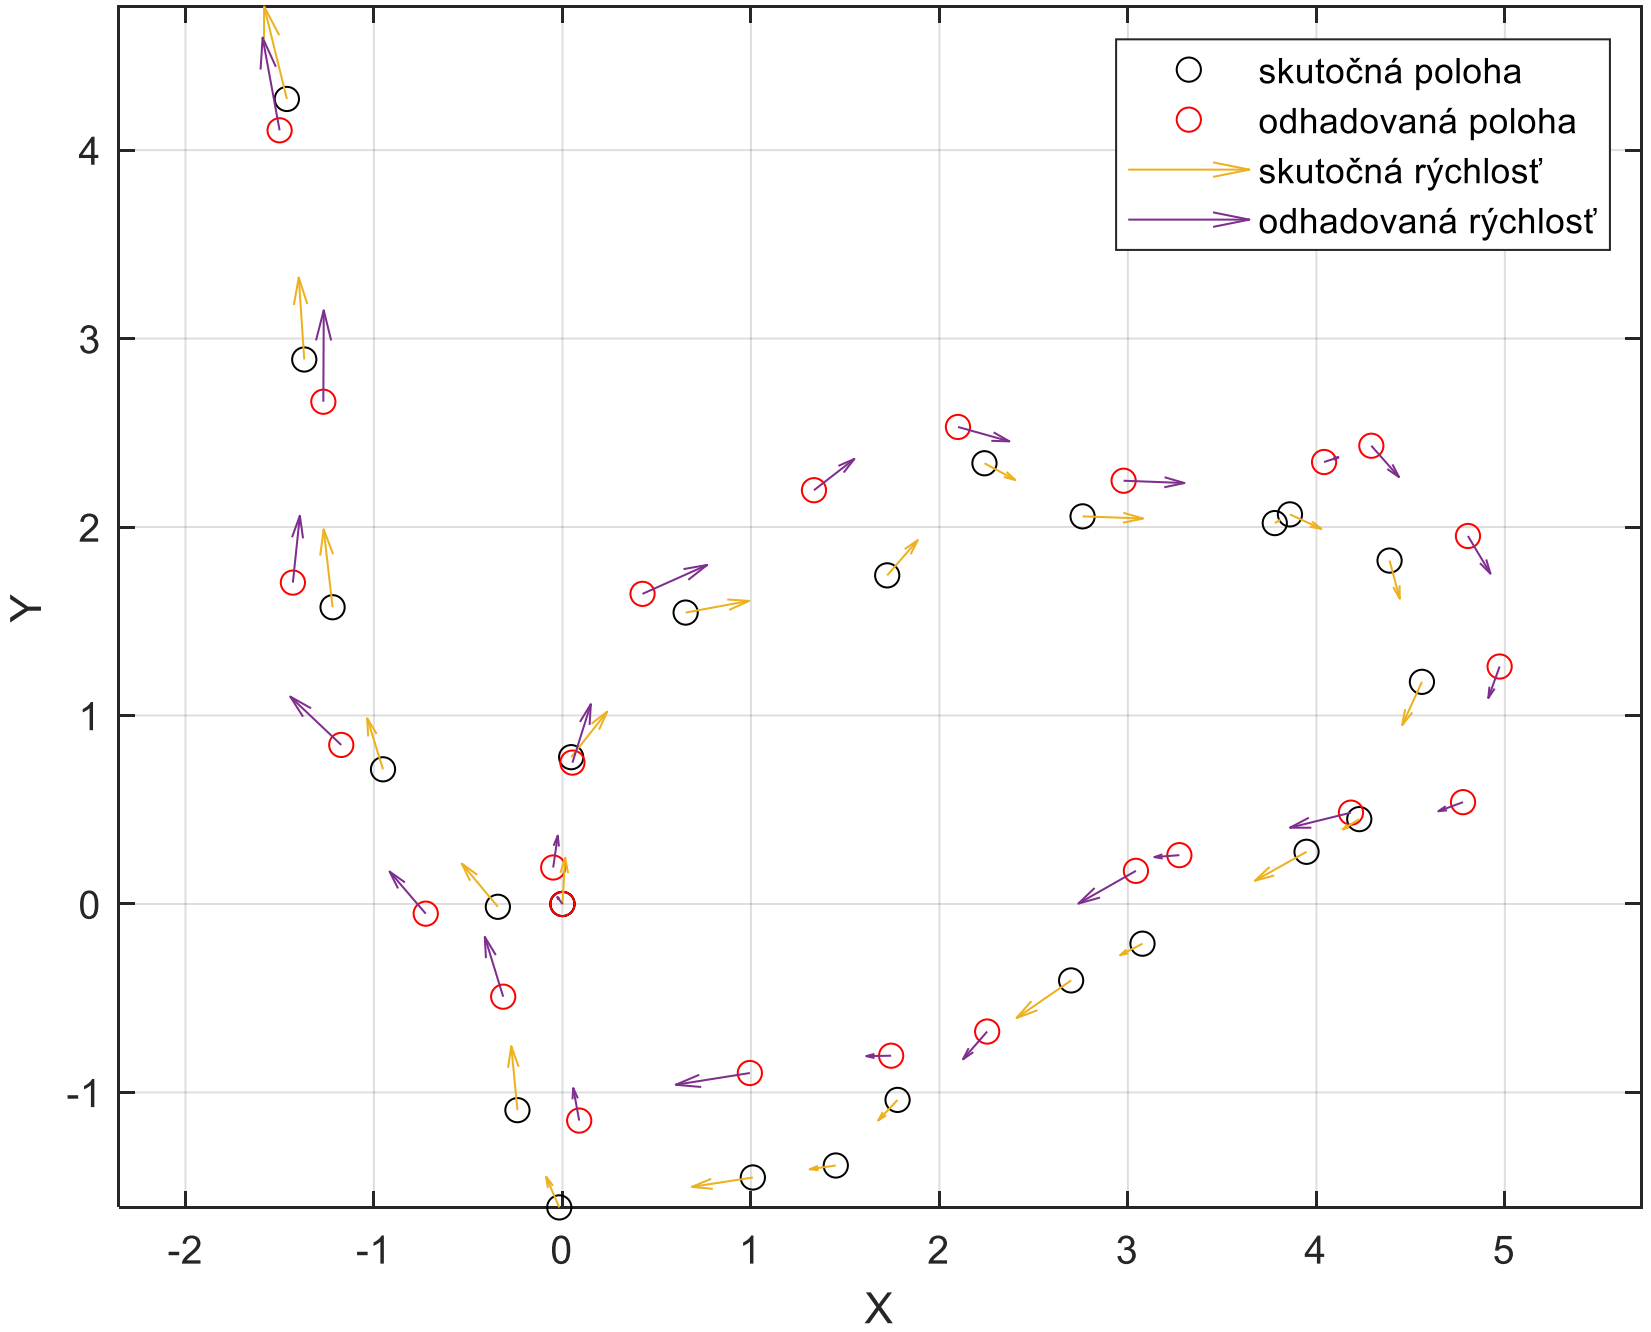
$$P_\infty = \begin{pmatrix} 0.4258 & 0 & 0.0052 & 0 \\ 0 & 0.4258 & 0 & 0.0052 \\ 0.0052 & 0 & 0.0436 & 0 \\ 0 & 0.0052 & 0 & 0.0436 \end{pmatrix}$$

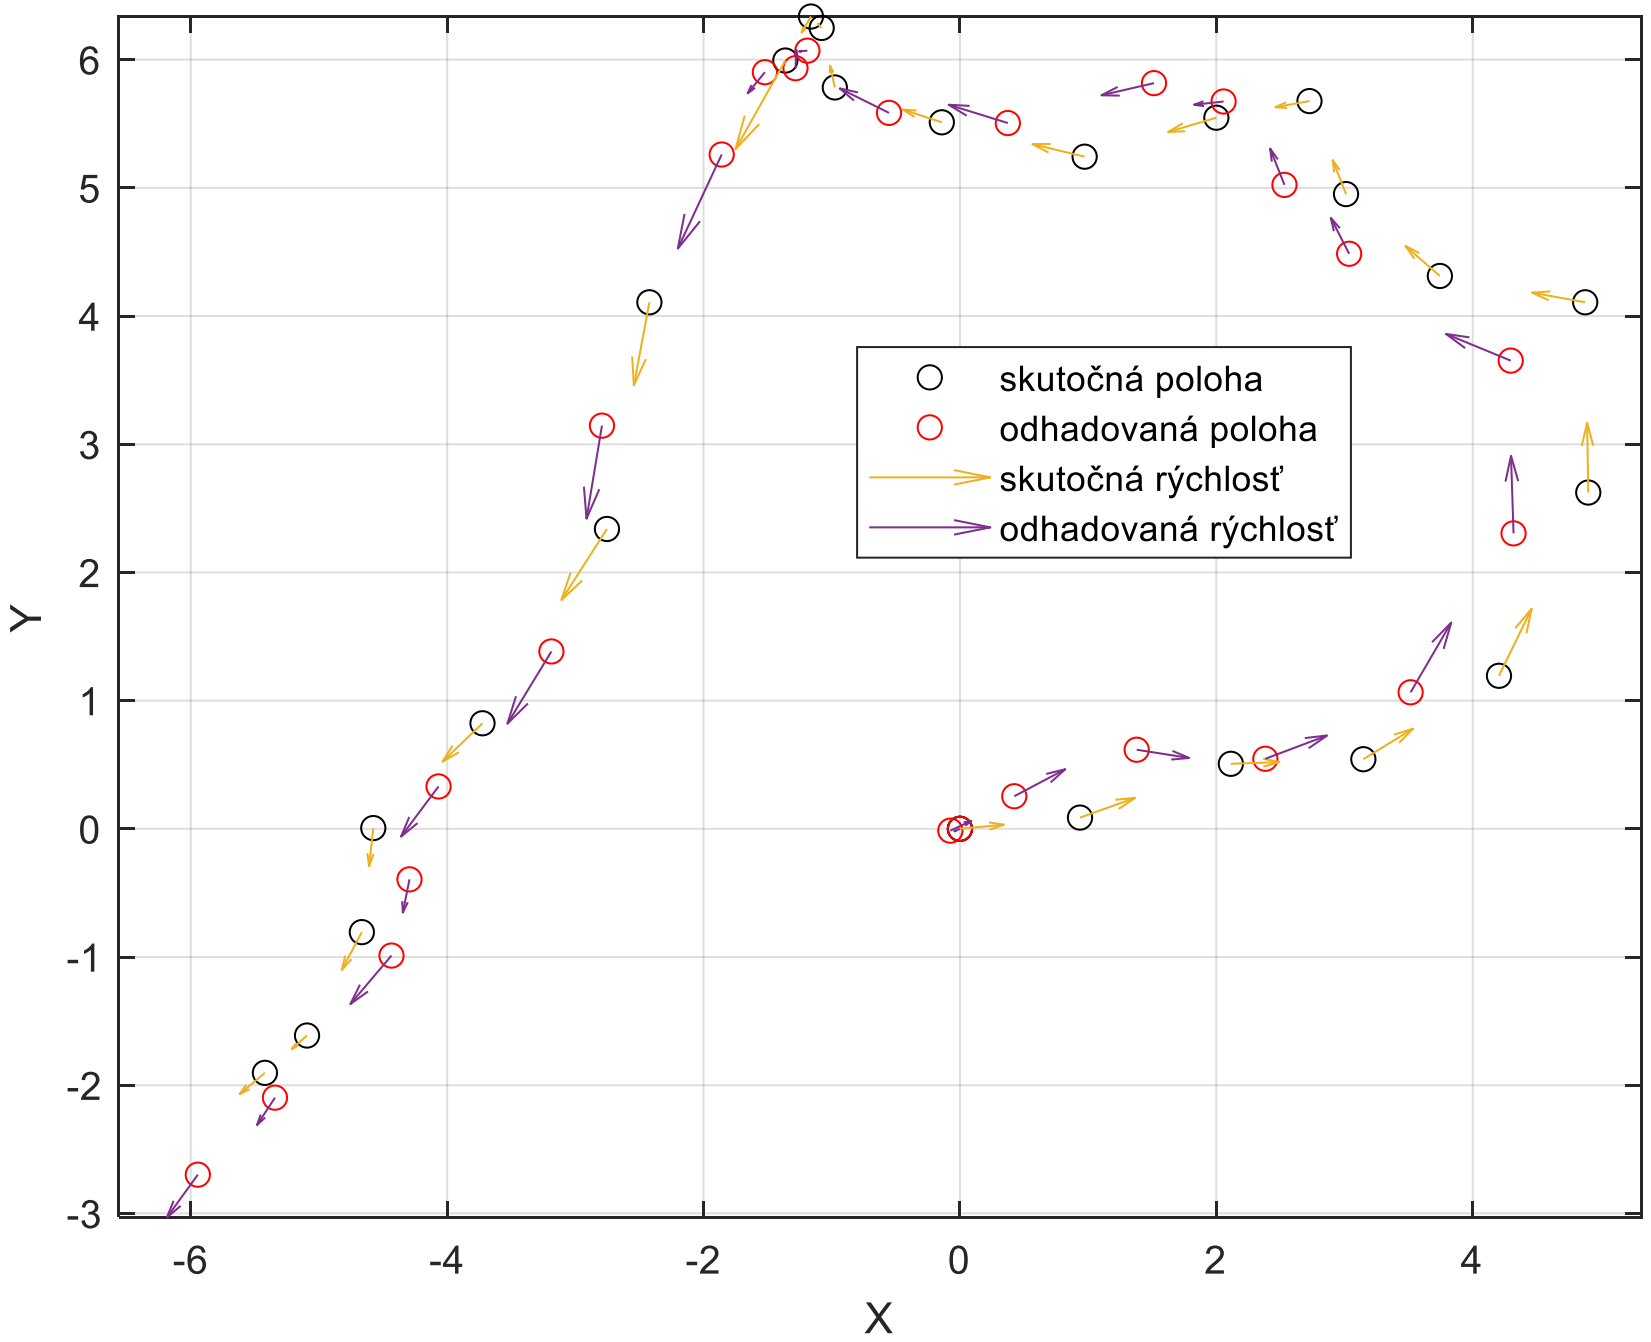
Neistota odhadu polohy ± 0.6525 m

Neistota odhadu rýchlosti ± 0.2088 m/s


skutočná poloha
odhadovaná poloha
skutočná rýchlosť
odhadovaná rýchlosť
Y
X
12
10
8
6
4
2
0
-2
0
2
4
6
8
10
12
14
16
18


skutočná poloha
odhadovaná poloha
skutočná rýchlosť
odhadovaná rýchlosť
Y
X
18
16
14
12
10
8
6
4
2
0
-15
-10
-5
0
5


skutočná poloha
odhadovaná poloha
skutočná rýchlosť
odhadovaná rýchlosť
Y
X
4
3
2
1
0
-1
-2
-1
0
1
2
3
4
5


skutočná poloha
odhadovaná poloha
skutočná rýchlosť
odhadovaná rýchlosť
X
Y
6
5
4
3
2
1
0
-1
-2
-3
-6
-4
-2
0
2
4

Rozšírený Kalmanov filter

- Klasický Kalmanov filter sa dá použiť len pre lineárne systémy
- Rozšírený Kalmanov filter - Extended Kalman filter (EKF)
  - Zovšeobecnenie Kalmanovho filtra pre nelineárne systémy
- EKF linearizuje nelineárny model v okolí aktuálneho odhadu stavu
- Uvažujme nelineárny model systému v tvare diferenčnej rovnice stavu a rovnice merania

$$x(k+1) = f\big(x(k), u(k)\big) + w(k)$$
$$y(k) = h\big(x(k)\big) + v(k)$$

$x(k) \in \mathbb{R}^n, u(k) \in \mathbb{R}^r, y(k) \in \mathbb{R}^m$

$f\big(x(k), u(k)\big)$: $\mathbb{R}^{n+r} \to \mathbb{R}^n$ je prechodová funkcia

$h\big(x(k)\big)$: $\mathbb{R}^n \to \mathbb{R}^m$ je funkcia merania

- Budeme potrebovať Jakobián prechodovej funkcie $f\big(x(k), u(k)\big)$

$$A(k) = \frac{\partial f\big(x(k), u(k)\big)}{\partial x(k)}_{x(k)=\hat{x}(k|k)}$$

a Jakobián funkcie merania $h\big(x(k)\big)$

$$C(k) = \frac{\partial h\big(x(k)\big)}{\partial x(k)}_{x(k)=\hat{x}(k|k-1)}$$

kde $A(k) \in \mathbb{R}^{n\times n}, C(k) \in \mathbb{R}^{m\times n}$

Rozšírený Kalmanov filter

- Rekurzívne iterujem:

1. Predikcia stavu

$$\hat{x}(k|k-1) = f\big(\hat{x}(k-1|k-1), u(k-1)\big)$$

2. Výpočet Jakobiánu prechodovej funkcie

$$A(k-1) = \frac{\partial f\big(x(k-1), u(k-1)\big)}{\partial x(k-1)}_{x(k-1)=\hat{x}(k-1|k-1)}$$

3. Aktualizácia apriórnej kovariančnej matice

$$P(k|k-1) = A(k-1)P(k-1|k-1)A(k-1)^T + Q$$

4. Meranie $y(k)$

5. Výpočet Jakobiánu funkcie merania

$$C(k) = \frac{\partial h\big(x(k)\big)}{\partial x(k)}_{x(k)=\hat{x}(k|k-1)}$$

6. Výpočet zosilnenia

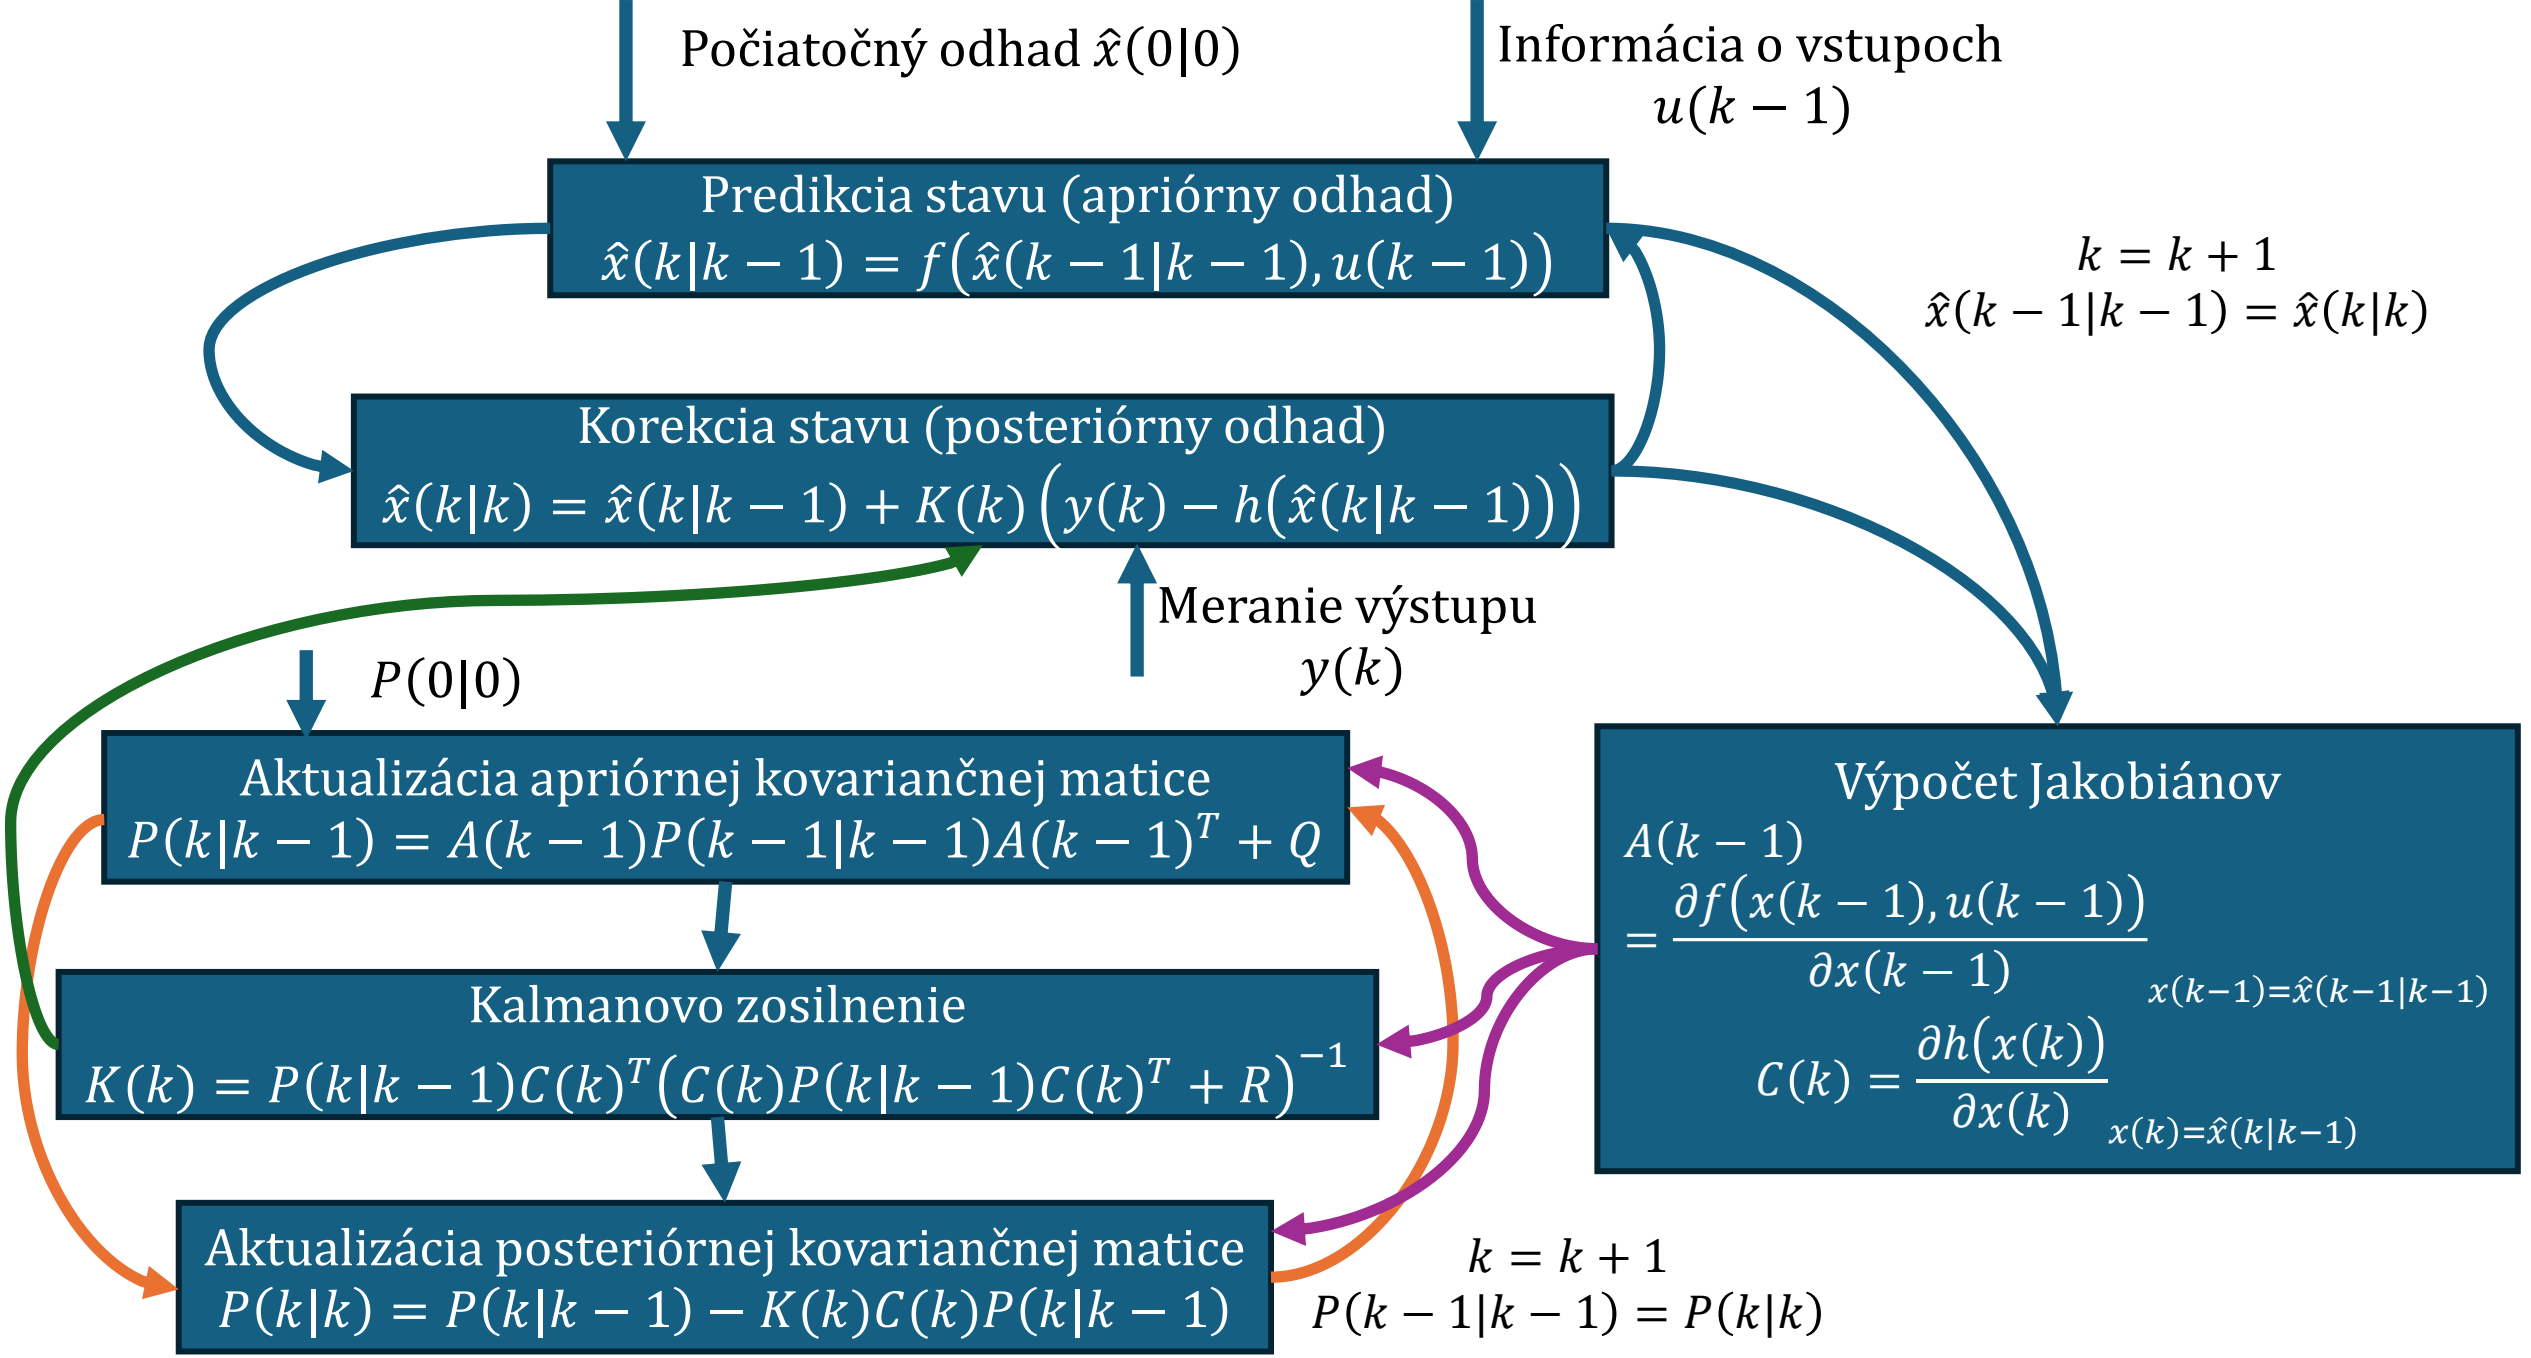
$$K(k) = P(k|k-1)C(k)^T\big(C(k)P(k|k-1)C(k)^T + R\big)^{-1}$$

7. Korekcia stavu

$$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)\Big(y(k) - h\big(\hat{x}(k|k-1)\big)\Big)$$

8. Aktualizácia posteriórnej kovariančnej matice

$$P(k|k) = P(k|k-1) - K(k)C(k)P(k|k-1)$$


Počiatočný odhad $\hat{x}(0|0)$
Informácia o vstupoch $u(k-1)$
Predikcia stavu (apriórny odhad)
$\hat{x}(k|k-1) = f\left(\hat{x}(k-1|k-1), u(k-1)\right)$
$k = k+1$
$\hat{x}(k-1|k-1) = \hat{x}(k|k)$
Korekcia stavu (posteriórny odhad)
$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)\left(y(k) - h\left(\hat{x}(k|k-1)\right)\right)$
Meranie výstupu $y(k)$
$P(0|0)$
Aktualizácia apriórnej kovariančnej matice
$P(k|k-1) = A(k-1)P(k-1|k-1)A(k-1)^T + Q$
Výpočet Jakobiánov
$A(k-1) = \frac{\partial f\left(x(k-1), u(k-1)\right)}{\partial x(k-1)}$ $x(k-1)=\hat{x}(k-1|k-1)$
$C(k) = \frac{\partial h\left(x(k)\right)}{\partial x(k)}$ $x(k)=\hat{x}(k|k-1)$
Kalmanovo zosilnenie
$K(k) = P(k|k-1)C(k)^T\left(C(k)P(k|k-1)C(k)^T + R\right)^{-1}$
Aktualizácia posteriórnej kovariančnej matice
$P(k|k) = P(k|k-1) - K(k)C(k)P(k|k-1)$
$k = k+1$
$P(k-1|k-1) = P(k|k)$

Lokalizácia robota pomocou EKF

- Robot s diferenciálnym podvozkom sa pohybuje v 2D priestore
- Budeme uvažovať model systému v tvare

$$\begin{pmatrix} x_r(k+1) \\ y_r(k+1) \\ \theta_r(k+1) \end{pmatrix} = \begin{pmatrix} x_r(k) + v_r(k)\Delta t \cos(\theta_r(k)) \\ y_r(k) + v_r(k)\Delta t \sin(\theta_r(k)) \\ \theta_r(k) + \omega(k)\Delta t \end{pmatrix} + \begin{pmatrix} w_1(k) \\ w_2(k) \\ w_3(k) \end{pmatrix}$$

  - x_r, y_r sú súradnice robota, θ_r je jeho orientácia (natočenie)
  - v_r je dopredná rýchlosť pohybu, ω je uhlová rýchlosť pohybu (rýchlosť otáčania)
  - Δt je diskrétny časový krok
- Vektor vstupov bude

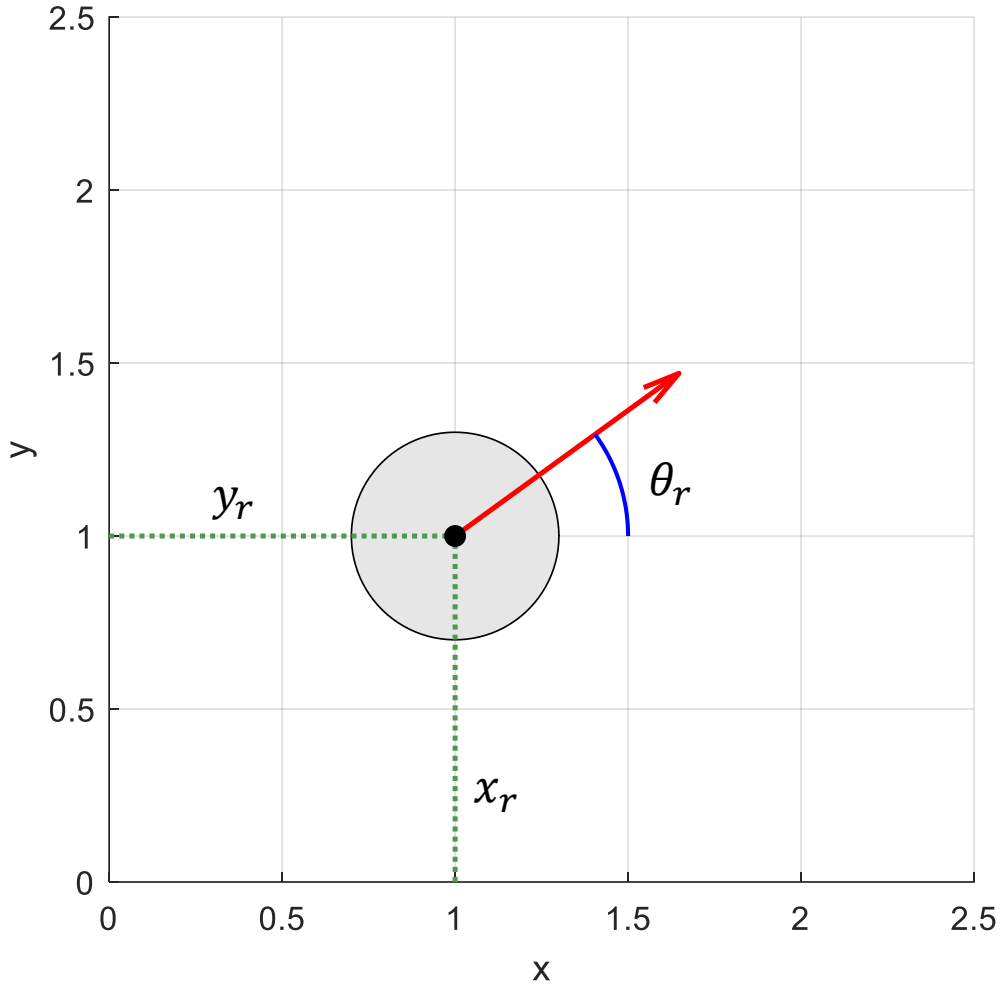
$$u(k) = \begin{pmatrix} v_r(k) \\ \omega(k) \end{pmatrix}$$

- Vektor stavov bude

$$x(k) = \begin{pmatrix} x_r(k) \\ y_r(k) \\ \theta_r(k) \end{pmatrix}$$

- Cieľom je odhadnúť pozíciu $x_r(k), y_r(k)$ a natočenie robota $\theta_r(k)$
- Prechodová funkcia $f\big(x(k), u(k)\big)$ potom bude

$$f\big(x(k), u(k)\big) = \begin{pmatrix} x_r(k) + v_r(k)\Delta t \cos(\theta_r(k)) \\ y_r(k) + v_r(k)\Delta t \sin(\theta_r(k)) \\ \theta_r(k) + \omega(k)\Delta t \end{pmatrix}$$



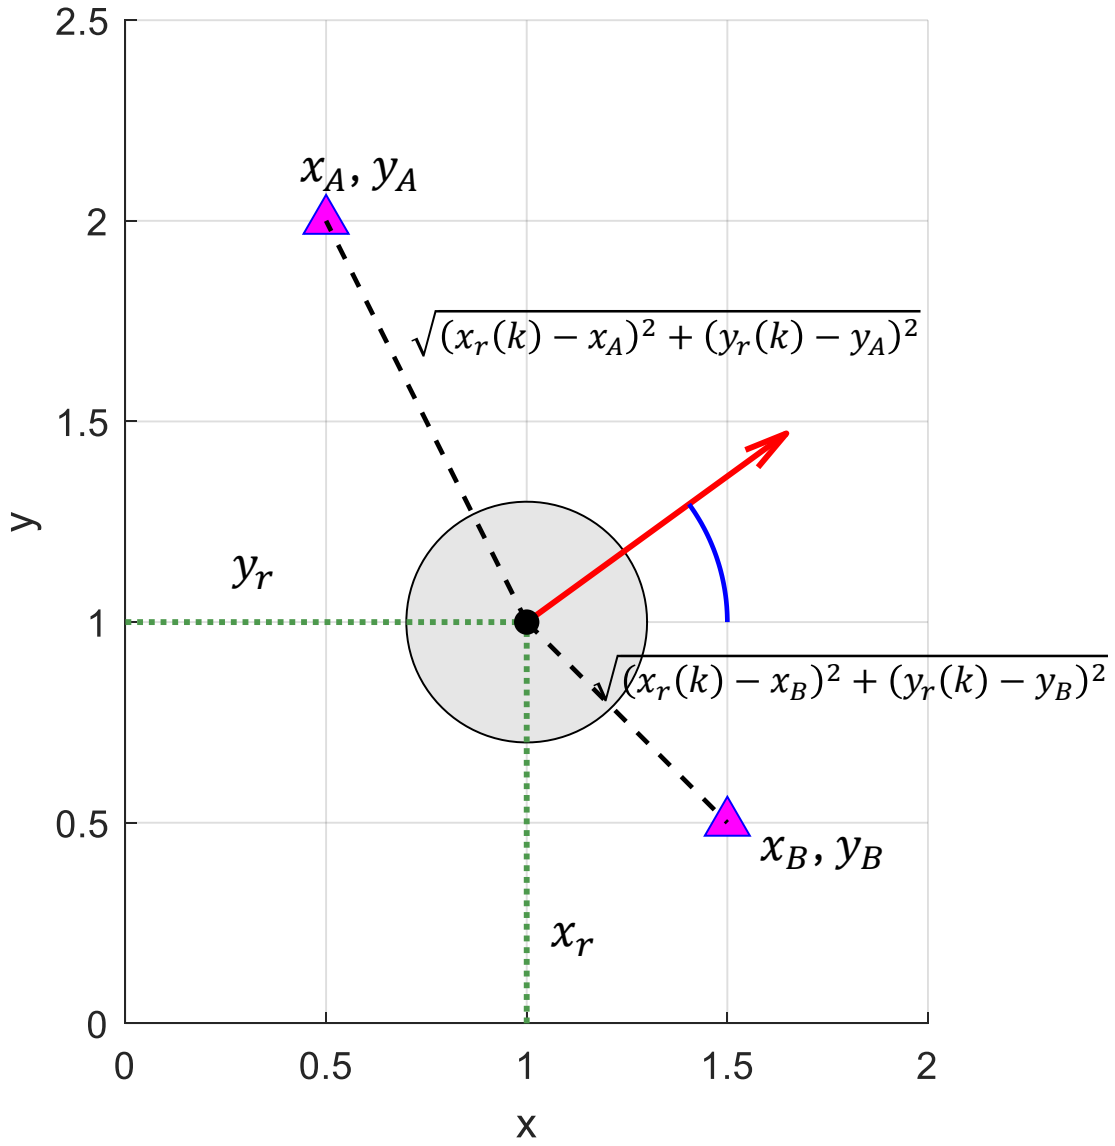
Lokalizácia robota pomocou EKF

- Majme dva statické majáky na známych pozíciách
  - Maják A x_A, y_A
  - Maják B x_B, y_B
- Robot meria druhú mocninu vzdialenosti od týchto majákov

$$y(k) = h\big(x(k)\big) + \begin{pmatrix} v_A(k) \\ v_B(k) \end{pmatrix}$$

$$= \begin{pmatrix} (x_r(k) - x_A)^2 + (y_r(k) - y_A)^2 \\ (x_r(k) - x_B)^2 + (y_r(k) - y_B)^2 \end{pmatrix} + \begin{pmatrix} v_A(k) \\ v_B(k) \end{pmatrix}$$

- Tieto merania sú zaťažené šumom s kovariančnou maticou R



Jakobiány modelu

- Potrebujeme určiť Jakobiány prechodovej funkcie $\frac{\partial f(x(k),u(k))}{\partial x(k)}$ a funkcie merania $\frac{\partial h(x(k))}{\partial x(k)}$
- Pre $f(x(k),u(k))$

$$f(x(k),u(k)) = \begin{pmatrix} x_r(k) + v_r(k)\Delta t \cos(\theta_r(k)) \\ y_r(k) + v_r(k)\Delta t \sin(\theta_r(k)) \\ \theta_r(k) + \omega(k)\Delta t \end{pmatrix}$$

- Jakobián bude

$$\frac{\partial f(x(k),u(k))}{\partial x(k)} = \begin{pmatrix} 1 & 0 & -v_r(k)\Delta t \sin(\theta_r(k)) \\ 0 & 1 & +v_r(k)\Delta t \cos(\theta_r(k)) \\ 0 & 0 & 1 \end{pmatrix}$$

- Pre $h(x(k))$

$$h(x(k)) = \begin{pmatrix} (x_r(k) - x_A)^2 + (y_r(k) - y_A)^2 \\ (x_r(k) - x_B)^2 + (y_r(k) - y_B)^2 \end{pmatrix}$$

- Jakobián bude

$$\frac{\partial h(x(k))}{\partial x(k)} = \begin{pmatrix} 2(x_r(k) - x_A) & 2(y_r(k) - y_A) & 0 \\ 2(x_r(k) - x_B) & 2(y_r(k) - y_B) & 0 \end{pmatrix}$$

$$Q = \begin{pmatrix} 0.25 & 0 & 0 \\ 0 & 0.25 & 0 \\ 0 & 0 & 0.015 \end{pmatrix}$$

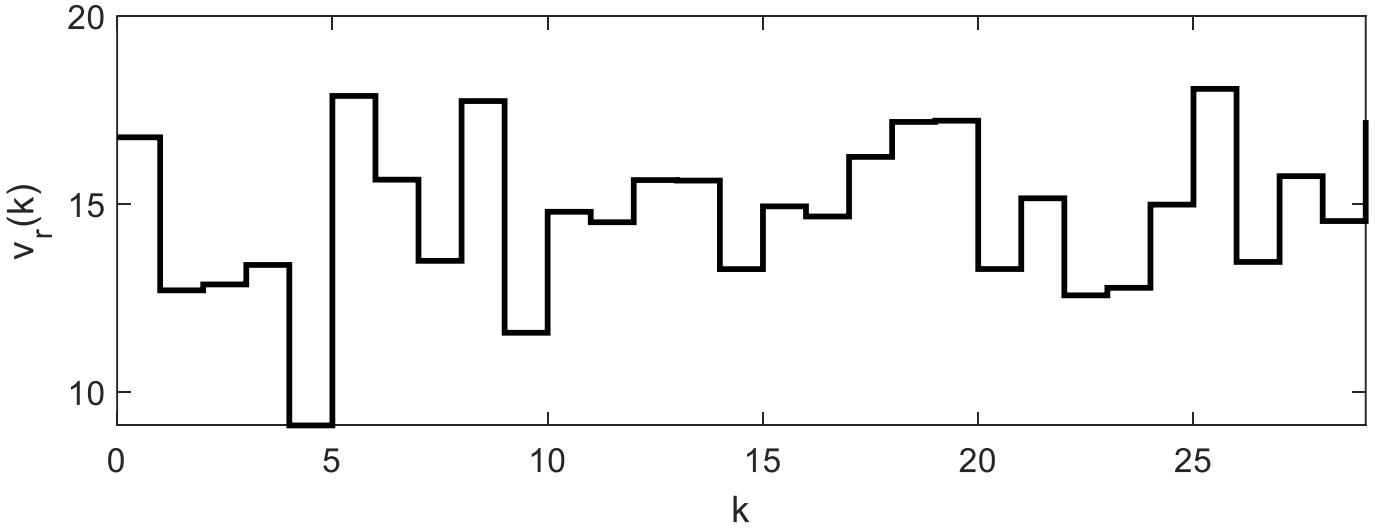
$$R = \begin{pmatrix} 30 & 0 \\ 0 & 30 \end{pmatrix}$$

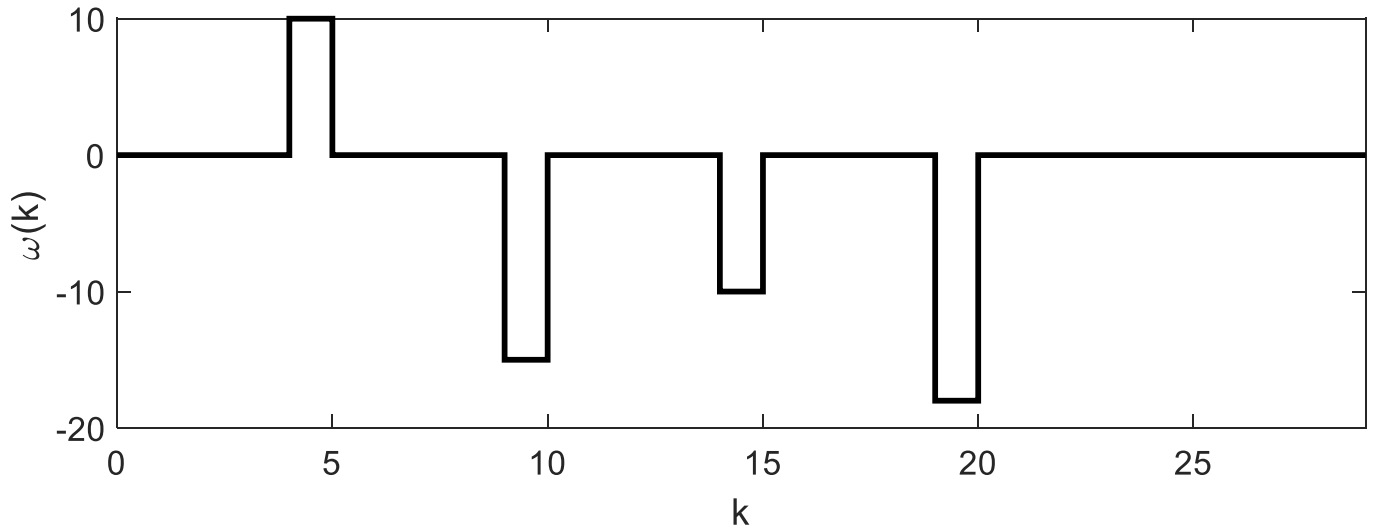
$$x_A = 4, \qquad y_A = 8$$
$$x_B = 10, \qquad y_B = 0$$

$$\Delta t = 0.1$$

$$x(0) = \begin{pmatrix} 5 \\ 2 \\ \frac{\pi}{4} \end{pmatrix}$$

$$P(0|0) = \begin{pmatrix} 20 & 0 & 0 \\ 0 & 20 & 0 \\ 0 & 0 & \frac{\pi}{4} \end{pmatrix}$$



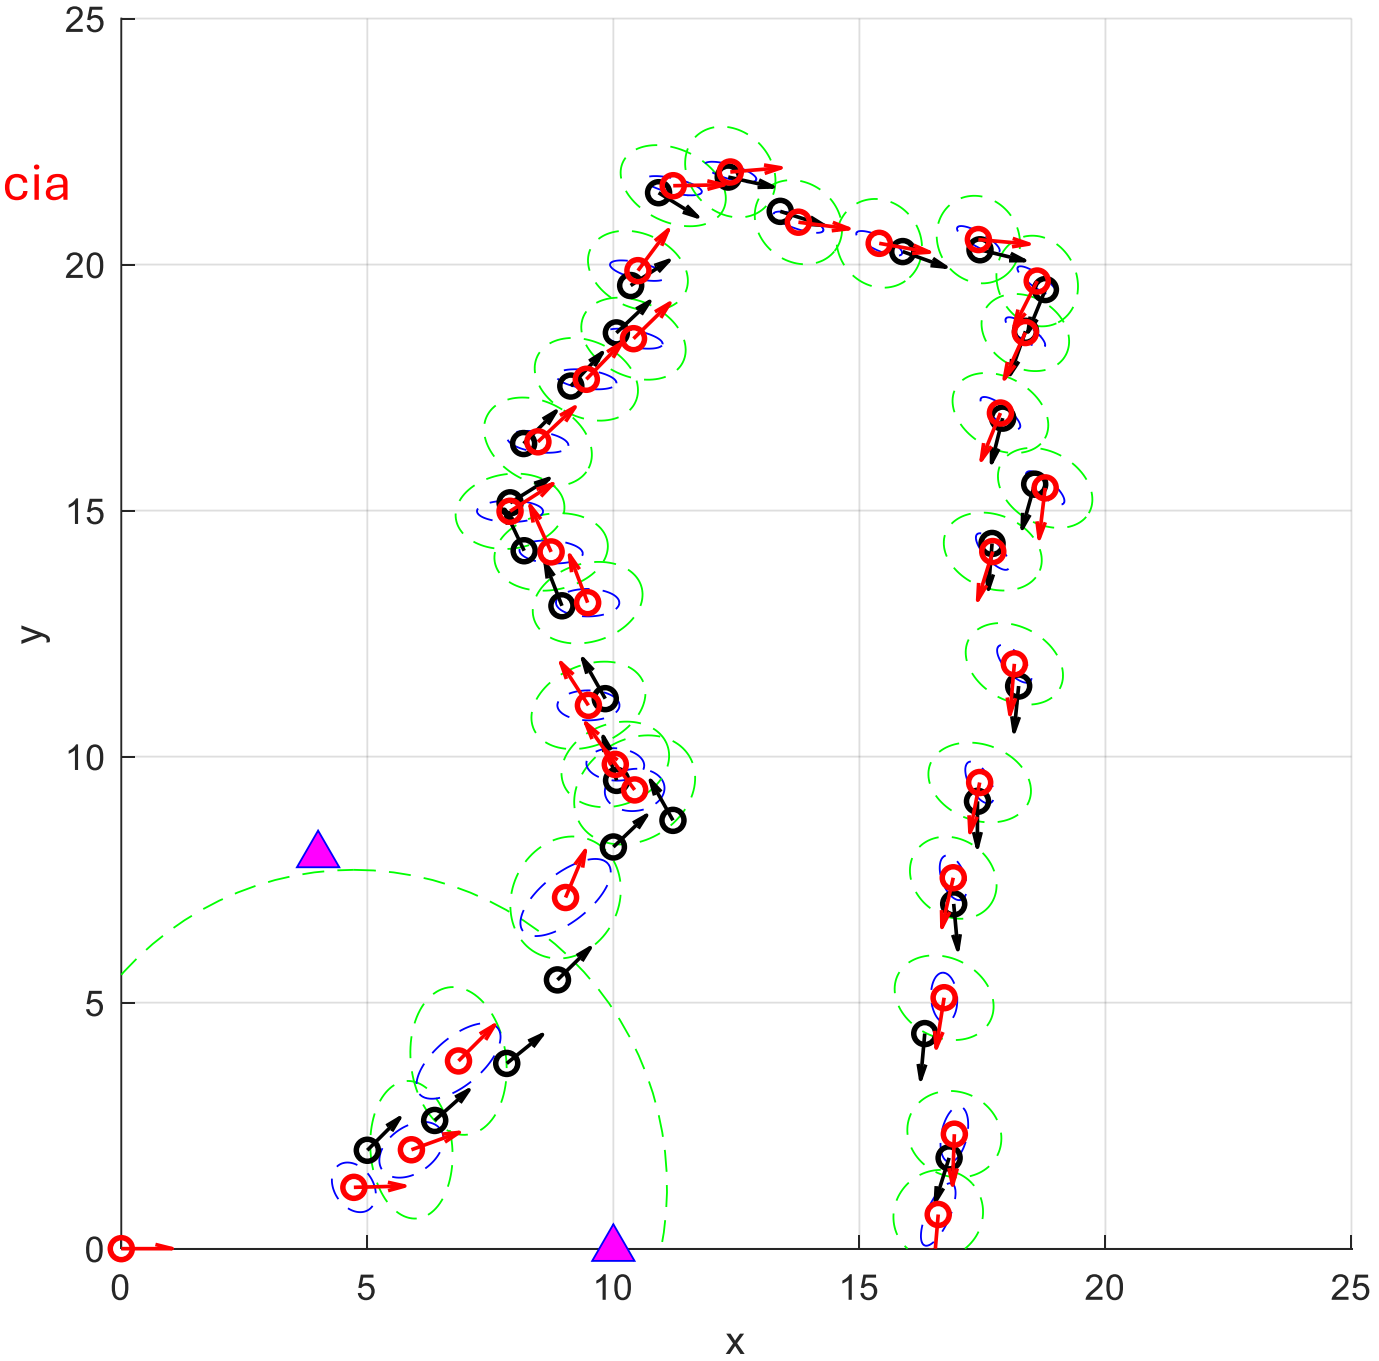


Skutočná poloha a orientácia

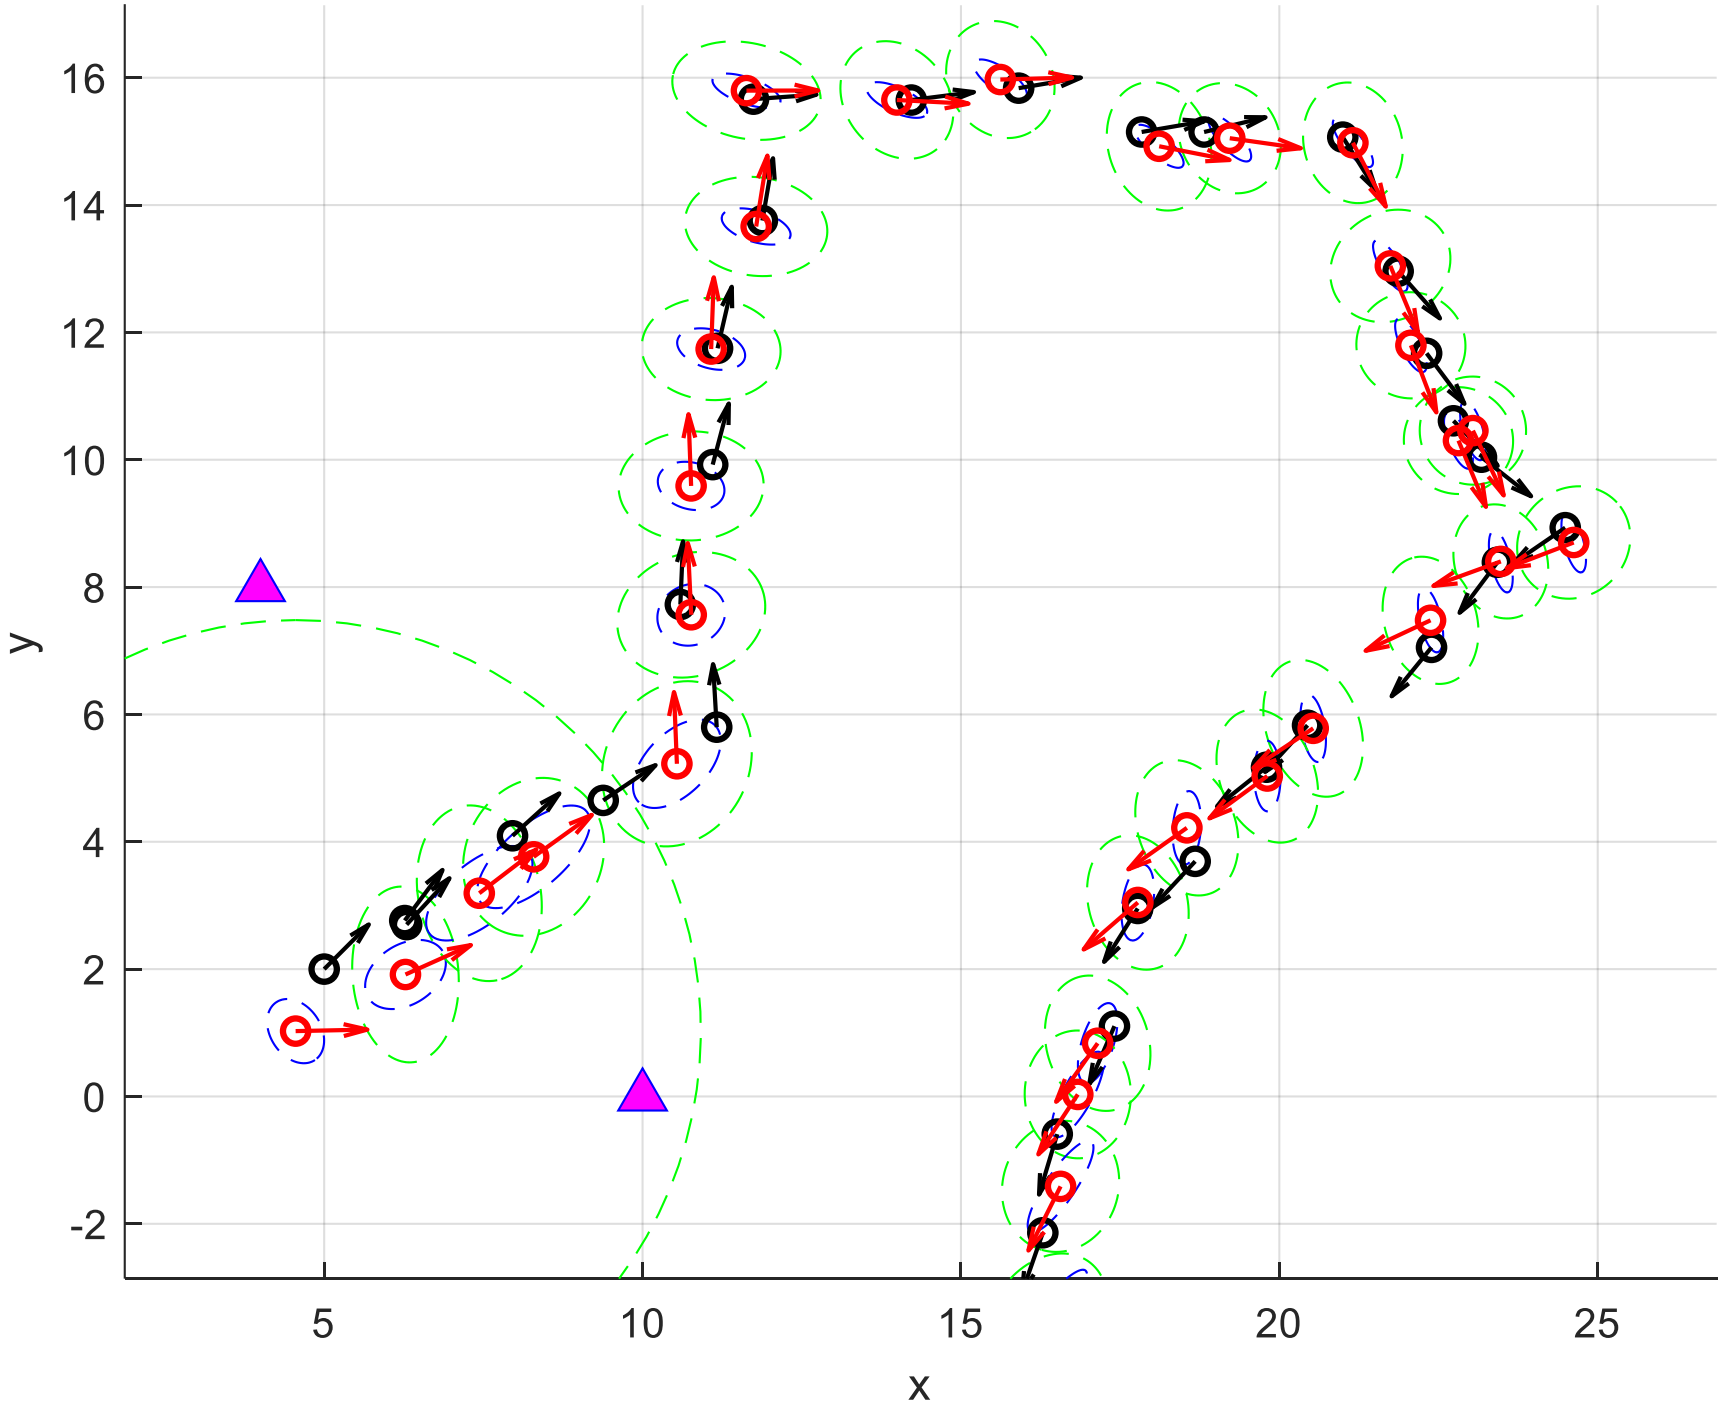
Odhadovaná poloha a orientácia

Apriórna neistota odhadu

Posteriórna neistota odhadu



Skutočná poloha a orientácia
Odhadovaná poloha a orientácia
Apriórna neistota odhadu
Posteriórna neistota odhadu



Odstránenie driftu snímačov

- Drift je pomalá, systematická chybová zmena výstupu snímača v čase, ktorá nie je spôsobená zmenou meranej veličiny
- Je to typ chyby merania, ktorá sa postupne hromadí
- Drift je časovo závislý – vzniká počas dlhodobého merania
- Na rozdiel od náhodného šumu s nulovou strednou hodnotou, drift má nenulovú strednú hodnotu
- Inerciálne systémy (gyroskop, akcelerometer) - integračný drift
- Pri integrácii signálu (napr. z akcelerometra na výpočet polohy) môže drift spôsobiť veľké chyby za krátky čas

Rozšírený stochastický stavový model

- Diferenčná (state-transition) rovnica systému je

$$x(k+1) = Ax(k) + Bu(k) + w(k)$$

kde $x(k) \in \mathbb{R}^n$, $w(k) \in \mathbb{R}^n$, $A \in \mathbb{R}^{n\times n}$, $B \in \mathbb{R}^{n\times r}$, $u(k) \in \mathbb{R}^r$

- Zavedieme si poruchový vektor $d(k) \in \mathbb{R}^m$, ktorý predstavuje drift snímačov (meraní výstupu)
- Drift budeme modelovať ako integrovaný biely šum

$$d(k+1) = d(k) + w_d(k)$$

- Rovnica merania výstupu (observation) potom bude

$$y(k) = Cx(k) + d(k) + v(k)$$

kde $y(k) \in \mathbb{R}^m$, $C \in \mathbb{R}^{m\times n}$

- Pre návrh Kalmanovho filtra budeme používať rozšírený stavový model v tvare

$$\begin{pmatrix} x(k+1) \\ d(k+1) \end{pmatrix} = \begin{pmatrix} A & \mathbf{0} \\ \mathbf{0} & I \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix} + \begin{pmatrix} I \\ \mathbf{0} \end{pmatrix} u(k) + \begin{pmatrix} w(k) \\ w_d(k) \end{pmatrix}$$

$$\tilde{x}(k+1) = \tilde{A}\tilde{x}(k) + \tilde{B}u(k) + \tilde{w}(k)$$

kde $\tilde{x}(k) \in \mathbb{R}^{n+m}$, $\tilde{w}(k) \in \mathbb{R}^{n+m}$, $\tilde{A} \in \mathbb{R}^{n+m\times n+m}$, $\tilde{B} \in \mathbb{R}^{n+m\times r}$, $u(k) \in \mathbb{R}^r$

- Model merania (výstupu) potom môžeme napísať ako

$$y(k) = \begin{pmatrix} C & I \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix} + v(k)$$

$$y(k) = \tilde{C}\tilde{x}(k) + v(k)$$

kde $\tilde{C} \in \mathbb{R}^{m\times n+m}$

Kovariančná matica spojeného procesného šumu

- Uvažujeme procesný šum pre stav $w(k)$ a procesný šum pre drift $w_d(k)$
- Spojený vektor procesného šumu preto bude

$$\tilde{w}(k) = \begin{pmatrix} w(k) \\ w_d(k) \end{pmatrix}$$

- Kovariančná matica spojeného procesného šumu $\tilde{w}(k)$ potom bude blokovo diagonálna

$$\tilde{Q} = \mathrm{cov}\big(\tilde{w}(k), \tilde{w}(k)\big) = \begin{pmatrix} Q & \mathbf{0} \\ \mathbf{0} & Q_d \end{pmatrix}$$

kde $\tilde{Q} \in \mathbb{R}^{m+n \times m+n}$ je celková kovariančná matica a kovariančná matica $Q_d \in \mathbb{R}^{m \times m}$ predstavuje mieru driftu snímačov