Ohraničená optimalizácia

Význam ohraničenej optimalizácie

- Väčšina reálnych optimalizačných úloh je viazaná rôznymi obmedzeniami – technickými, fyzikálnymi alebo ekonomickými.
- Ohraničená optimalizácia hľadá najlepšie riešenie, ktoré zároveň rešpektuje tieto limity.
- Cieľom je dosiahnuť kompromis medzi optimálnosťou riešenia a splnením všetkých podmienok.
- Umožňuje modelovať reálne situácie, kde nie je možné zvoliť premenné bez ohľadu na ich hranice.
- Spája teoretické princípy optimalizácie s praktickými požiadavkami.

Príklady ohraničenej optimalizácie

- Návrh trasy robota s minimálnou spotrebou energie pri vyhýbaní sa prekážkam.
- Optimalizácia tvaru konštrukcie pri zachovaní pevnosti a hmotnostných limitov.
- Určenie výrobného plánu s maximálnym ziskom pri obmedzených zdrojoch surovín.
- Rozdelenie investícií do portfólia pri obmedzenom riziku.
- Určenie optimálnej rýchlosti vozidla pre minimálnu spotrebu paliva a dodržanie rýchlostných limitov.
- Návrh dávkovania lieku pre maximálny účinok bez prekročenia toxickej hladiny.
- Optimalizácia riadenia pre zabezpečenie optimálnej odozvy pri ohraničení akčného zásahu.

Ohraničenia rovnicami

- Uvažujme, že vektor optimalizovaných premenných $x \in \mathbb{R}^n$ musí spĺňať sústavu p rovníc definujúcich ohraničenia ako

$$h(x) = \mathbf{0}$$

  $h(x)$: $\mathbb{R}^n \to \mathbb{R}^p$ je vektorová funkcia ohraničení

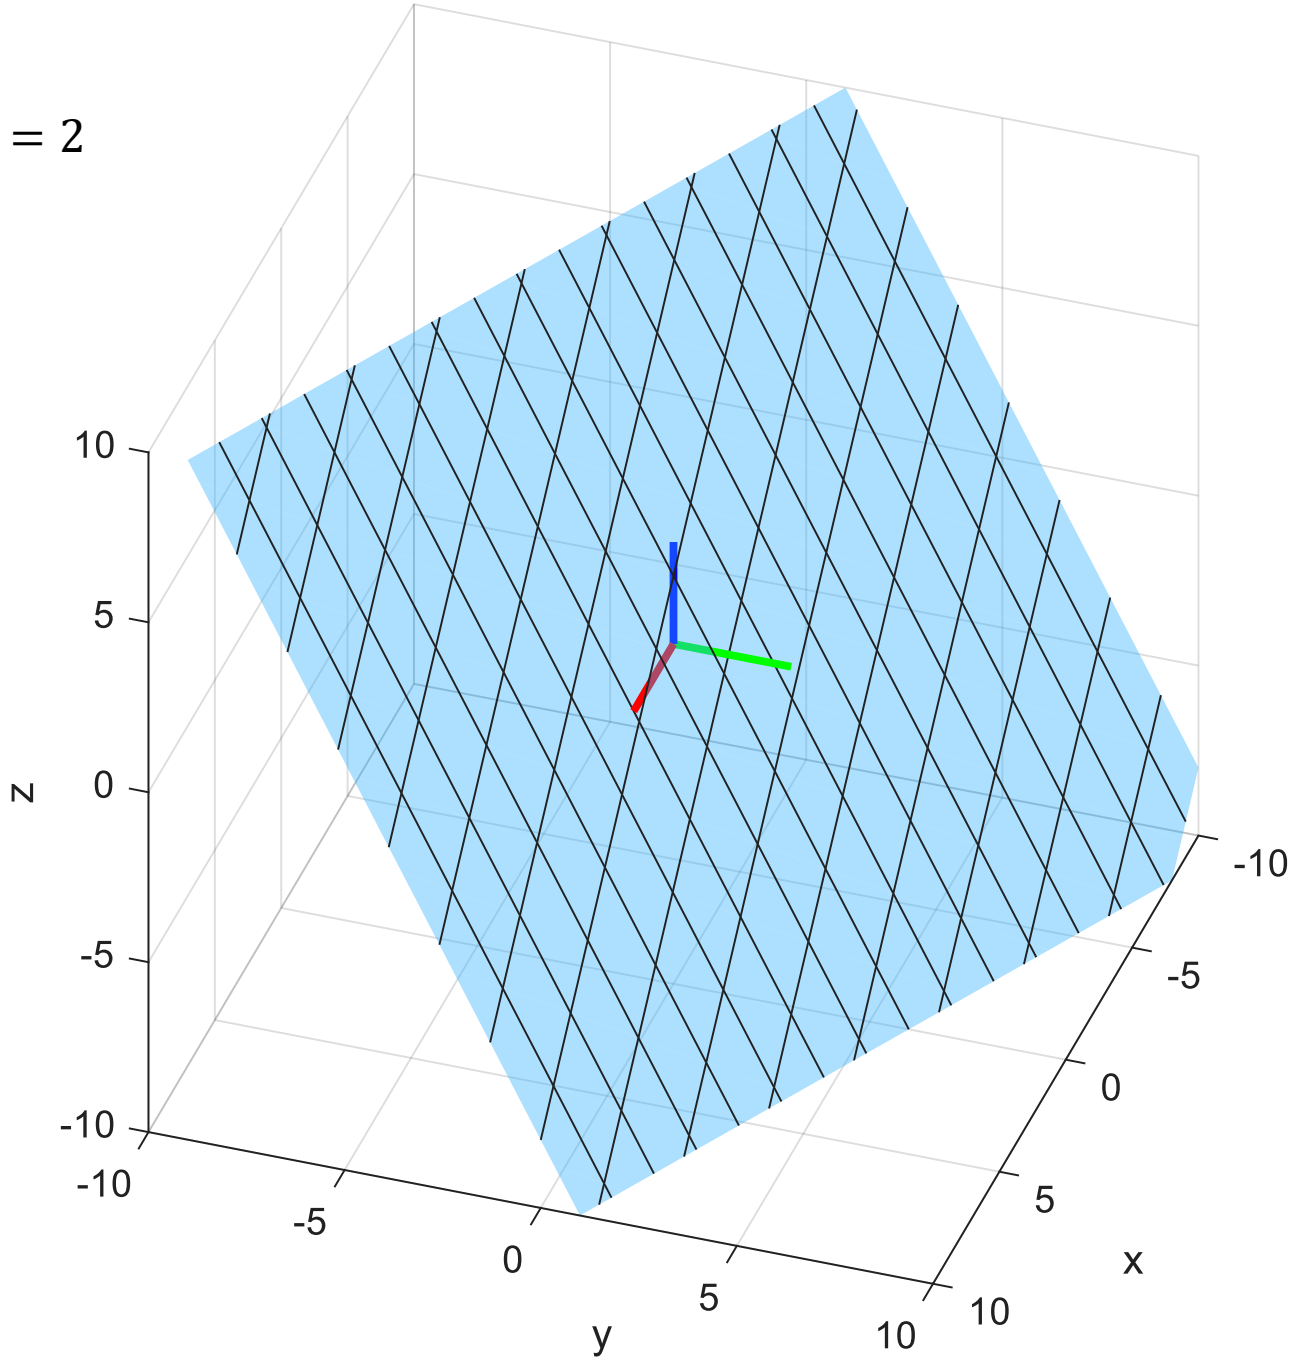
- Každý prvok (funkcia) $h_i(x)$ preto predstavuje jednu podmienku (rovnicu)

$$\begin{pmatrix} h_1(x) \\ h_2(x) \\ \vdots \\ h_p(x) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

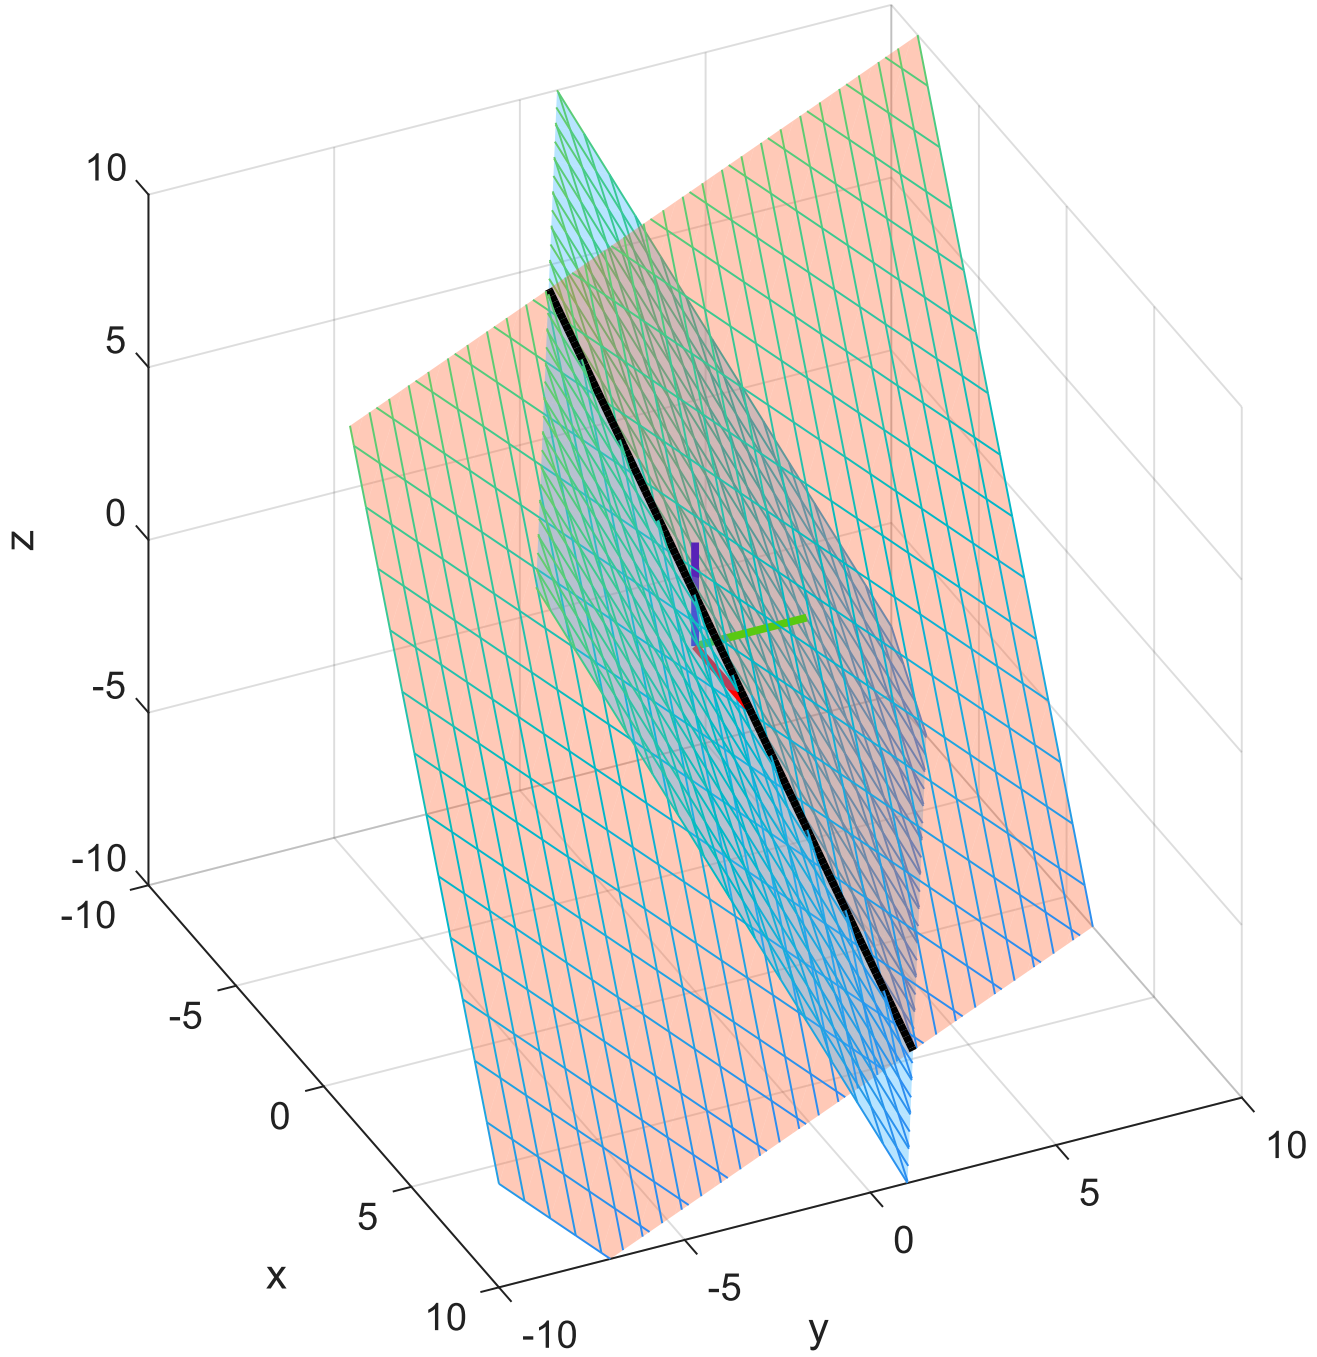
- Riešenia x ktoré vyhovujú všetkým rovniciam $h(x) = \mathbf{0}$ nazývame prípustné riešenia
- V podstate tým obmedzujeme definičný obor funkcie len na také hodnoty, ktoré spĺňajú dané podmienky
- Každé nezávislé ohraničenie rovnicou odoberá jednu voľnosť pohybu (jeden stupeň voľnosti)
- Môže nastať situácia, že ohraničeniam nevyhovuje žiadne riešenie a teda rovnicu $h(x) = \mathbf{0}$ nie je možné splniť
- Ohraničenie lineárnou rovnicou $a^T x = b$ predstavuje v $\mathbb{R}^2$ priamku v $\mathbb{R}^3$ rovinu
- Výraz $\nabla h(x)$: $\mathbb{R}^n \to \mathbb{R}^{p \times n}$ predstavuje Jakobián funkcie ohraničení $h(x)$

$$\nabla h(x) = \begin{pmatrix} \frac{\partial h_1(x)}{\partial x_1} & \frac{\partial h_1(x)}{\partial x_2} & \cdots & \frac{\partial h_1(x)}{\partial x_n} \\ \frac{\partial h_2(x)}{\partial x_1} & \frac{\partial h_2(x)}{\partial x_2} & \cdots & \frac{\partial h_2(x)}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial h_p(x)}{\partial x_1} & \frac{\partial h_p(x)}{\partial x_2} & \cdots & \frac{\partial h_p(x)}{\partial x_n} \end{pmatrix}$$

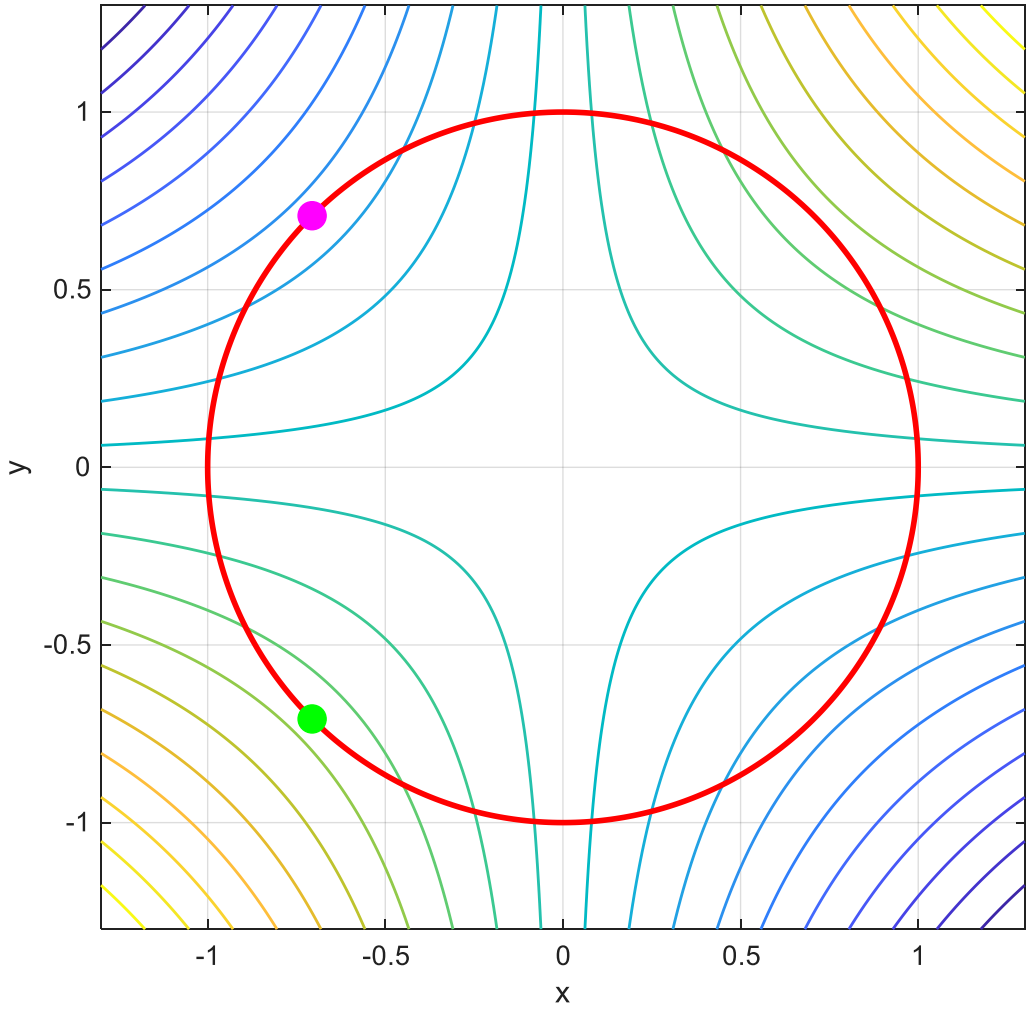
$$(1 \quad 2 \quad 1)^T \begin{pmatrix} x \\ y \\ z \end{pmatrix} = 2$$

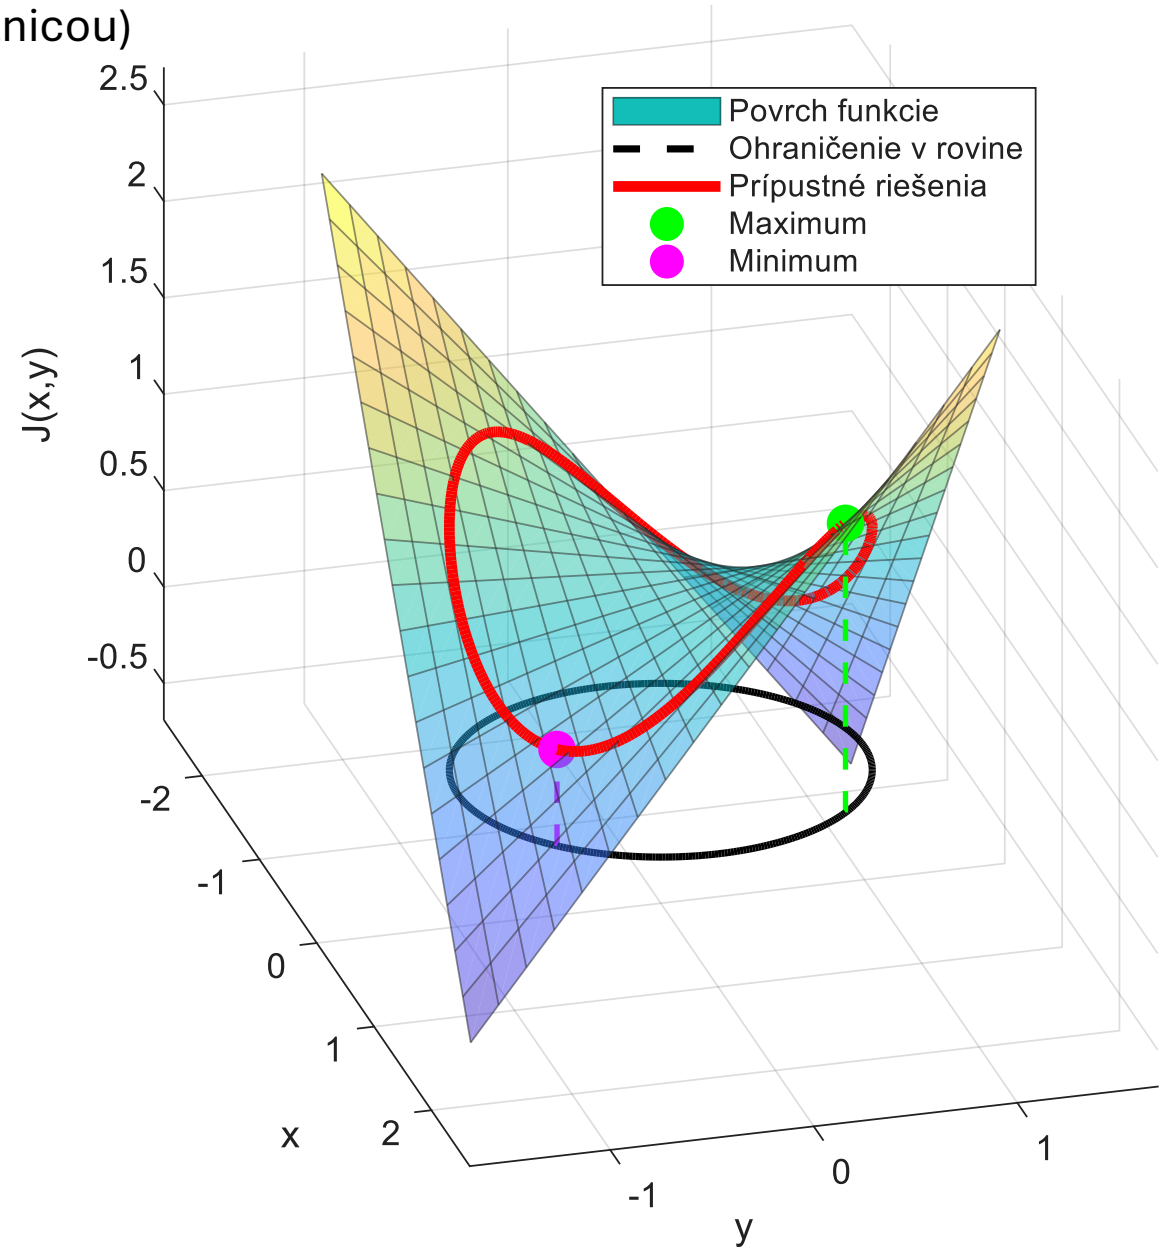


$$\begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 1 \end{pmatrix}^T \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$



$J(x, y) = xy + 1$ (kvadratická účelová funkcia so sedlom)
$h(x, y) = x^2 + y^2 - 1$ (ohraničenia jednotkovou kružnicou)

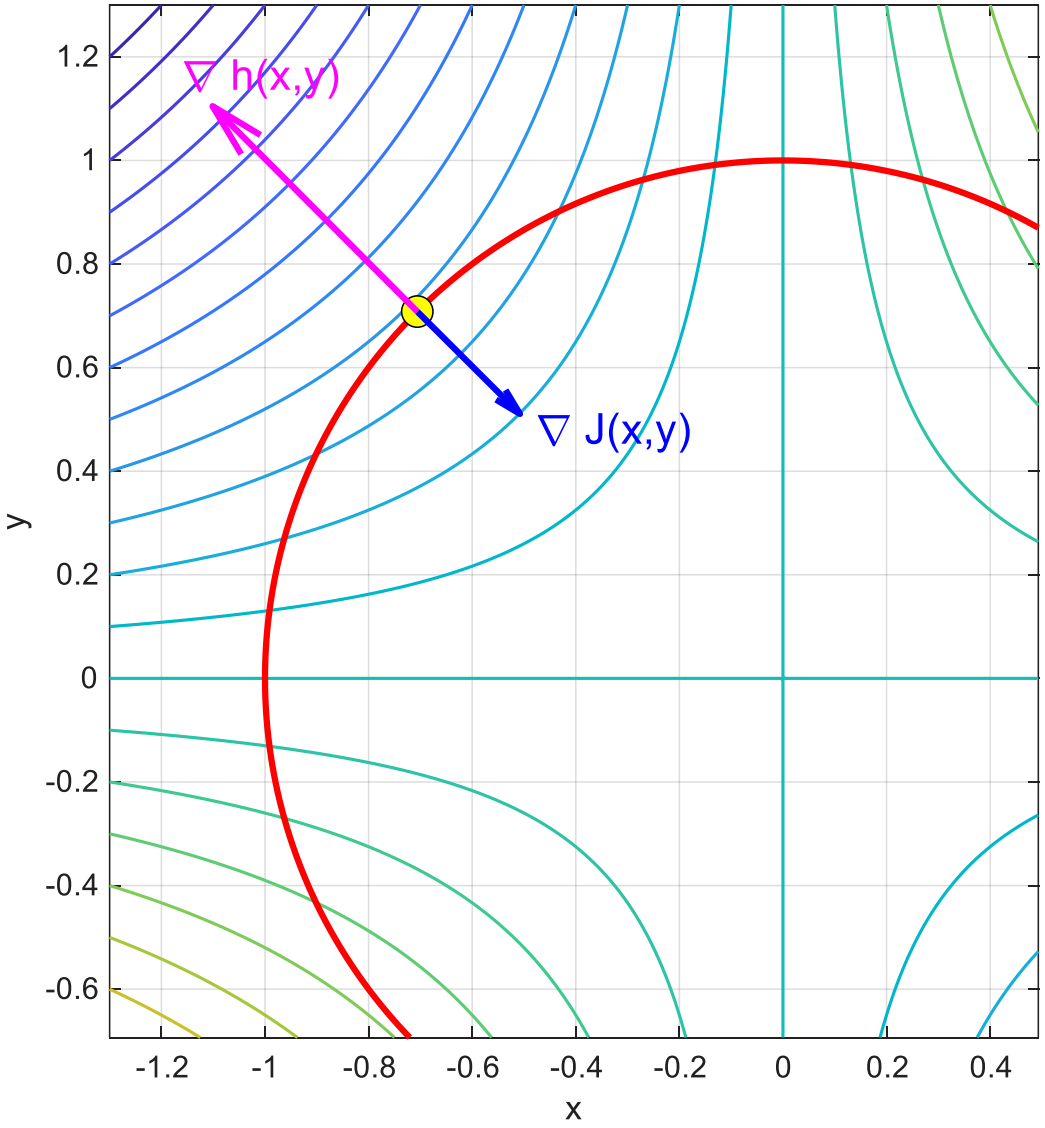




Podmienka ohraničeného extrému (jedno ohraničenie)

- Gradient $\nabla J(x,y)$ je kolmý na vrstevnicu účelovej funkcie
- Jakobián $\nabla h(x,y)$ je kolmý na ohraničenie
- V ohraničenom extréme je gradient účelovej funkcie $\nabla J(x,y)$ rovný skalárnemu násobku Jakobiánu ohraničenia $\nabla h(x,y)$
- $\nabla J(x,y)$ a $\nabla h(x,y)$ sú rovnobežné a môžu mať inú veľkosť
- Musia platiť súbežne tieto dve rovnice:

$$\nabla J(x,y) = \lambda \nabla h(x,y)$$
$$h(x,y) = 0$$



Lagrangeova funkcia pri rovnostiach

Uvažujme účelovú funkciu $J(x)$ a rovnostné ohraničenia $h(x) = 0$.

$$L(x, \lambda) = J(x) + \lambda^{\mathrm{T}} h(x),$$
$$\lambda \in \mathbb{R}^{\mathrm{p}}$$

- Multiplikátory λ hľadáme spolu s optimalizovanými premennými x.
- Pri rovnostiach môžu byť kladné aj záporné.
- Ak $h(x) = 0$, príspevok $\lambda^{\mathrm{T}} h(x)$ je nulový pre ľubovoľné λ.
- Prípustné riešenie môže mať nenulové multiplikátory.
- Pri vhodných podmienkach optimálne multiplikátory spĺňajú stacionaritu L a súvisia s citlivosťou optimálnej hodnoty na zmenu ohraničení.

$$\nabla_{\mathrm{x}} L(x^*, \lambda^*) = \nabla J(x^*) + \nabla h(x^*)^{\mathrm{T}} \lambda^* = 0$$

Podmienka ohraničeného extrému (stacionarita)

- Máme Lagrangeovu funkciu $L(x, \lambda)$: $\mathbb{R}^{n+p} \rightarrow \mathbb{R}$

$$L(x, \lambda) = J(x) + \lambda^T h(x)$$

- Nájdem gradient Lagrangeovej funkcie podľa λ a položím ho rovný nulovému vektoru

$$\nabla_\lambda L(x, \lambda) = h(x) = \mathbf{0}$$

  - Získal som tak pôvodné ohraničenia rovnicami (prípustnosť)

- Nájdem gradient Lagrangeovej funkcie podľa x a položím ho rovný nulovému vektoru

$$\nabla_x L(x, \lambda) = \nabla_x J(x) + \left(\nabla_x h(x)\right)^T \lambda = \mathbf{0}$$

  - Z tejto rovnosti vyplýva:

$$\nabla_x J(x) = -\left(\nabla_x h(x)\right)^T \lambda$$

- V extréme je gradient účelovej funkcie $\nabla_x J(x)$ rovný lineárnej kombinácii prvkov Jakobiánu ohraničenia $\nabla_x h(x)$

Ohraničenia nerovnicami

- Uvažujme, že vektor optimalizovaných premenných $x \in \mathbb{R}^n$ musí spĺňať sústavu q nerovníc definujúcich ohraničenia ako

$$g(x) \leq \mathbf{0}$$

  $g(x)$: $\mathbb{R}^n \rightarrow \mathbb{R}^q$ je vektorová funkcia ohraničení

- Každý prvok (funkcia) $g_i(x)$ preto predstavuje jednu podmienku (nerovnicu)

$$\begin{pmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_q(x) \end{pmatrix} \leq \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

- Podmienku opačného typu $g(x) \geq \mathbf{0}$ vieme previesť na požadovaný tvar ako $-g(x) \leq \mathbf{0}$
- Riešenia x ktoré vyhovujú všetkým nerovniciam $g(x) \leq \mathbf{0}$ nazývame prípustné riešenia
- Výraz $\nabla g(x)$: $\mathbb{R}^n \rightarrow \mathbb{R}^{q \times n}$ predstavuje Jakobián funkcie ohraničení $g(x)$

$$\nabla g(x) = \begin{pmatrix} \frac{\partial g_1(x)}{\partial x_1} & \frac{\partial g_1(x)}{\partial x_2} & \cdots & \frac{\partial g_1(x)}{\partial x_n} \\ \frac{\partial g_2(x)}{\partial x_1} & \frac{\partial g_2(x)}{\partial x_2} & \cdots & \frac{\partial g_2(x)}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_q(x)}{\partial x_1} & \frac{\partial g_q(x)}{\partial x_2} & \cdots & \frac{\partial g_q(x)}{\partial x_n} \end{pmatrix}$$

Ohraničenia lineárnymi nerovnicami



- Najbežnejším typom ohraničení sú ohraničenia q lineárnymi nerovnicami v tvare

$$A_c x \leq b_c$$

kde $A_c \in \mathbb{R}^{q \times n}$ (obdĺžniková matica), $b_c \in \mathbb{R}^q$ (vektor)

- Potom pre ekvivalentnú funkciu ohraničení môžeme napísať:

$$g(x) = A_c x - b_c \leq \mathbf{0}$$

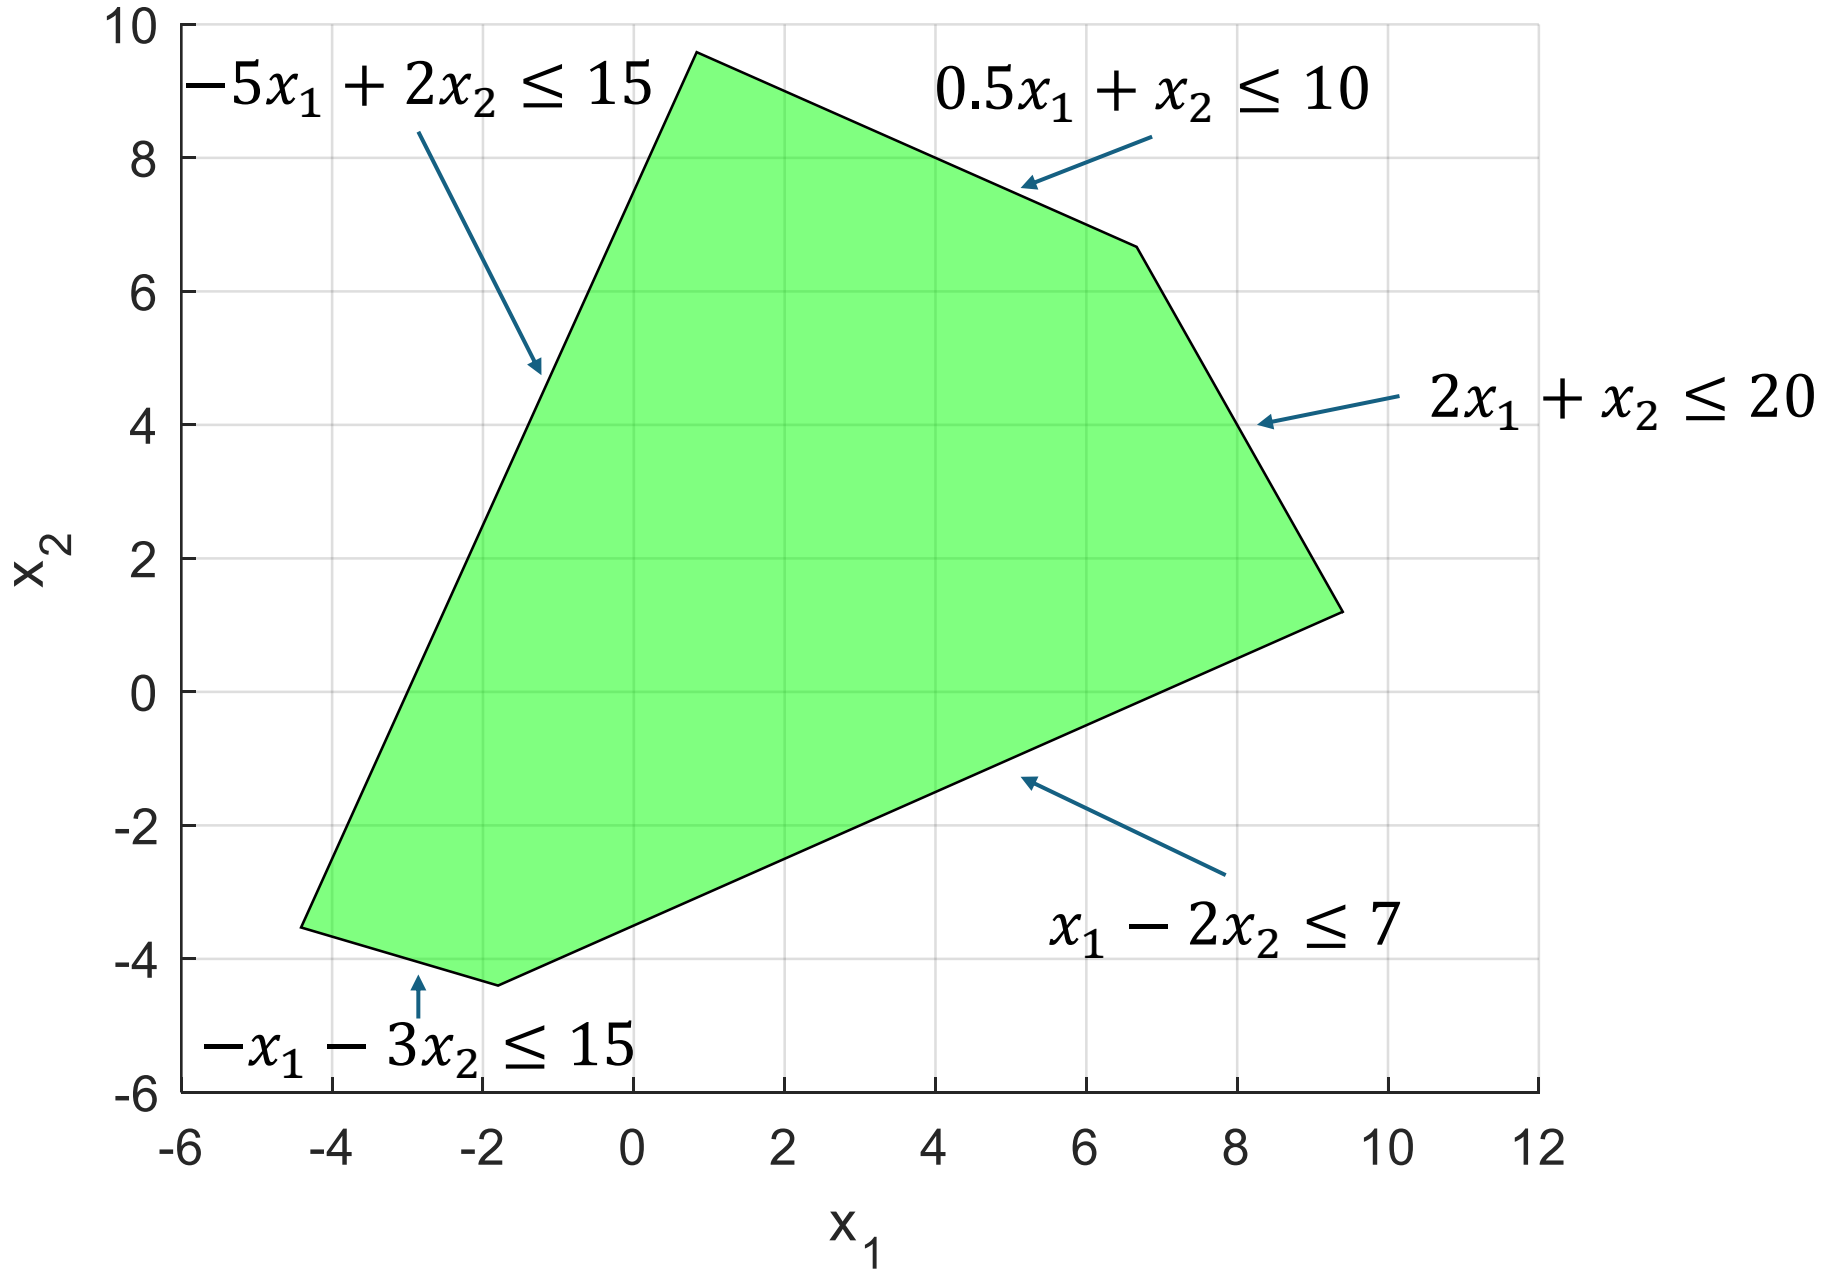
- Jakobián ohraničení $g(x) = A_c x - b_c$ bude jednoducho

$$\nabla g(x) = A_c$$

- Každá z q podmienok predstavuje rozdelenie priestoru $\mathbb{R}^n$ jednou polrovinou
- Súčasným splnením všetkých q podmienok vzniká teleso - konvexný q - uholník (mnohosten)
- Toto teleso definuje priestor prípustných riešení optimalizačnej úlohy

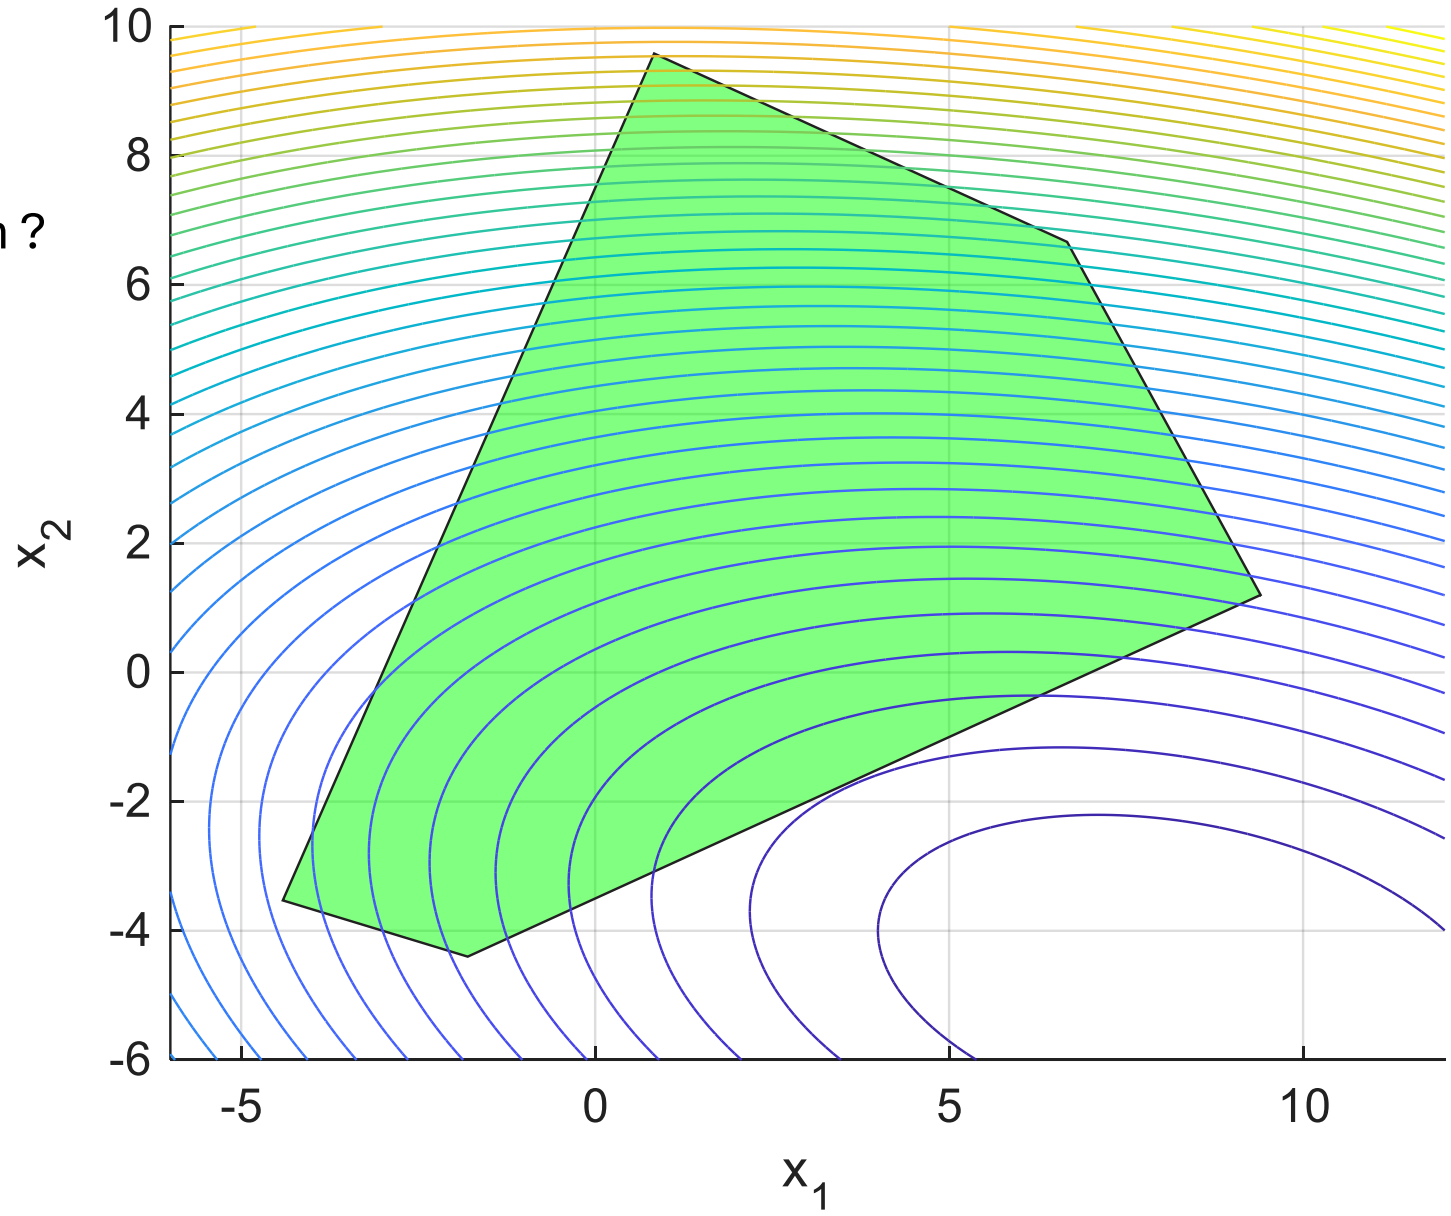
$$A_c = \begin{pmatrix} 1 & -2 \\ -5 & 2 \\ 2 & 1 \\ 0.5 & 1 \\ -1 & -3 \end{pmatrix}$$

$$b_c = \begin{pmatrix} 7 \\ 15 \\ 20 \\ 10 \\ 15 \end{pmatrix}$$



$$J(x) = \frac{1}{2}x^T Ax + b^T x + c, \qquad A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 3 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$

Kde sa nachádza ohraničené minimum ?



Zavedenie penalizačnej funkcie

- Aby sme sa zbavili obmedzení, zaveďme nasledovnú pokutovú funkciu (death penalty):

$$C(x) = \begin{cases} J(x), & \text{ak } g_i \leq 0 \ \forall i \\ \infty, & \text{inak} \end{cases}$$

$$C(x) = J(x) + \sum_i I[g_i(x)]$$

kde $I[u]$ je funkcia s nekonečným skokom:

$$I[u] = \begin{cases} 0, & \text{ak } u \leq 0 \\ \infty, & \text{inak} \end{cases}$$

- Funkcia $C(x) = J(x) + \sum_i I[g_i(x)]$ nie je spojitá, čo je nepraktické

Lineárna penalizácia porušenia ohraničení

- Preto zaveďme namiesto $I[u]$ lineárnu funkciu:

$$L(x, \lambda) = J(x) + \sum_i \lambda_i g_i(x), \lambda_i \geq 0$$

- Ak nesplníme obmedzenia $g_i(x) > 0$, tak penalizujeme a ak splníme $g_i(x) < 0$ odmeňujeme, čo je nežiadúce
- Čo ale môžeme spraviť, je maximalizovať pokutu a tým zabrániť odmeňovaniu

$$C(x) = J(x) + \max_{\lambda_i \geq 0} \sum_i \lambda_i g_i(x)$$

- A keďže funkcia $J(x)$ nie je závislá na λ, môžeme operátor *max* vytiahnuť pred celý výraz

$$C(x) = \max_{\lambda_i \geq 0} (J(x) + \sum_i \lambda_i g_i(x))$$

- Potom
  - Ak $g_i(x) > 0$ (nesplnené ohraničenie) tak $\max_{\lambda_i \geq 0} \lambda_i g_i(x) = \infty$ pri $\lambda_i = \infty$
  - Ak $g_i(x) \leq 0$ (splnené ohraničenie) tak $\max_{\lambda_i \geq 0} \lambda_i g_i(x) = 0$ pri $\lambda_i = 0$
- Takže naozaj platí

$$\max_{\lambda_i \geq 0} L(x, \lambda) = C(x) = J(x) + \sum_i I[g_i(x)]$$

- Maximalizácia podľa λ automaticky „odstráni“ všetky neprípustné body: prípustným bodom ponechá hodnotu $J(x)$, zatiaľ čo neprípustné body dostanú nekonečný trest.
- Našou úlohou bude teraz vyriešiť nasledovný primálny problém:

$$\min_x \max_{\lambda_i \geq 0} L(x, \lambda)$$

teda najprv maximalizovať podľa λ a potom minimalizovať podľa x

Lagrangeova funkcia pri nerovnostiach

$$L(x, \lambda) = J(x) + \lambda^{\mathrm{T}} g(x)$$
$$\lambda \geq 0$$

- Pre každý prípustný bod $g(x) \leq \mathbf{0}$ platí

$$\lambda^{\mathrm{T}} g(x) \leq 0$$
$$L(x, \lambda) \leq J(x)$$

- Pri pevnom λ minimalizujeme $L(x, \lambda)$ podľa x na celej doméne. Pôvodné nerovnosti už pri tomto vnútornom kroku nevnucujeme.
- Výsledkom je dolný odhad primálnej optimálnej hodnoty $\min_{x} \max_{\lambda_i \geq 0} L(x, \lambda)$.
- Duálny problém potom vyberá λ tak, aby tento dolný odhad bol čo najvyšší.

Dualita

- Primálny (pôvodný) problém

$$p^* = \min_x \max_{\lambda_i \geq 0} L(x, \lambda)$$

  - Najprv maximalizujme podľa λ pre $\lambda \geq 0$

$$r(x) = \max_{\lambda_i \geq 0} L(x, \lambda)$$

  - Potom minimalizujme podľa x pre $g(x) \leq \mathbf{0}$

$$p^* = \min_x r(x)$$

- Duálny (alternatívny) problém

$$d^* = \max_{\lambda_i \geq 0} \min_x L(x, \lambda)$$

  - Najprv minimalizujme podľa x pre ľubovoľné λ

$$q(\lambda) = \min_x L(x, \lambda)$$

  - Potom maximalizujme podľa λ pre $\lambda \geq 0$

$$d^* = \max_{\lambda_i \geq 0} q(\lambda)$$

- Všeobecne potom platí slabá dualita (duálny problém je menší alebo rovný)

$$\min_x \max_{\lambda_i \geq 0} L(x, \lambda) \geq \max_{\lambda_i \geq 0} \min_x L(x, \lambda)$$

$$d^* \leq p^*$$

- Pre konvexný problém ale platí silná dualita:

$$\min_x \max_{\lambda_i \geq 0} L(x, \lambda) = \max_{\lambda_i \geq 0} \min_x L(x, \lambda)$$

Podmienky ohraničenej optimálnosti



- Nazývajú sa Karush–Kuhn–Tuckerove (KKT) podmienky
- Ak x^* je ohraničené optimum, potom existujú Lagrangeove multiplikátory $\lambda^* \geq \mathbf{0}$, také že platia nasledujúce podmienky
- Stacionarita Lagrangeovej funkcie (nulový gradient vzhľadom na x)

$$\nabla_x L(x^*, \lambda^*) = \nabla J(x^*) + \left(\nabla g(x^*)\right)^T \lambda^* = \mathbf{0}$$

- Splnenie definovaných ohraničení (prípustnosť)

$$g(x^*) \leq \mathbf{0}$$
$$\lambda^* \geq \mathbf{0}$$

- Komplementarita

$$g_i(x^*)\lambda_i{}^* = 0$$

  po prvkoch nulové súčiny – buď $g_i(x^*) = 0$ (aktívne ohraničenie) alebo $\lambda_i{}^* = 0$

- Pre každú z nerovností môžu preto nastať dva prípady
  - Ak $g_i(x^*) = 0$ (ohraničenie je aktívne) a $\lambda_i{}^* > 0$
  - Ak $g_i(x^*) < 0$ (ohraničenie je neaktívne) a $\lambda_i{}^* = 0$
- Z komplementarity vyplýva že

$$\lambda^{*T} g(x^*) = 0$$

- Lagrangeova funkcia je preto v ohraničenom optime rovná priamo účelovej funkcii

$$L(x^*, \lambda^*) = J(x^*) + \lambda^{*T} g(x^*) = J(x^*)$$

- V prípade ak všetky $\lambda_i{}^* = 0$ a teda $\lambda^* = \mathbf{0}$ tak potom je extrém ekvivalentný extrému bez ohraničení a platí štandardná podmienka optimálnosti (nulový gradient)

$$\nabla J(x^*) = \mathbf{0}$$

Význam podmienky stacionarity

- Podmienka stacionarity Lagrangeovej funkcie je daná ako

$$\nabla_x L(x^*, \lambda^*) = \nabla J(x^*) + \left(\nabla g(x^*)\right)^T \lambda^* = \mathbf{0}$$

- Hypotéza: Môže existovať prípustný smer $s \in \mathbb{R}^n$ pre ktorý platí, že derivácia účelovej funkcie v tomto smere je záporná (funkcia môže ešte klesať) ?

$$s^T \nabla J(x^*) < 0$$

- V stacionárnom bode Lagrangeovej funkcie platí že gradient účelovej funkcie $\nabla J(x^*)$ je lineárnou kombináciou Jakobiánu ohraničení $\nabla g(x^*)$

$$\nabla J(x^*) = -\left(\nabla g(x^*)\right)^T \lambda^*$$

- Derivácia účelovej funkcie v smere s bude (skalárny súčin s gradientom)

$$s^T \nabla J(x^*) = -s^T \left(\nabla g(x^*)\right)^T \lambda^* = -(\nabla g(x^*) s)^T \lambda^*$$

- Keďže v bode x^* platí $g(x^*) \leq \mathbf{0}$, prípustný smer s nesmie narušiť ohraničenia (derivácie ohraničení v smere s sú záporné) a teda

$$\nabla g(x^*) s \leq \mathbf{0}$$

- Keďže $\nabla g(x^*) s \leq \mathbf{0}$ a $\lambda^* \geq \mathbf{0}$ potom $-(\nabla g(x^*) s)^T \lambda^*$ je skalárny súčin dvoch kladných vektorov a teda derivácia účelovej funkcie v prípustnom smere s je vždy kladná

$$s^T \nabla J(x^*) = (\nabla g(x^*) s)^T \lambda^* \geq 0$$

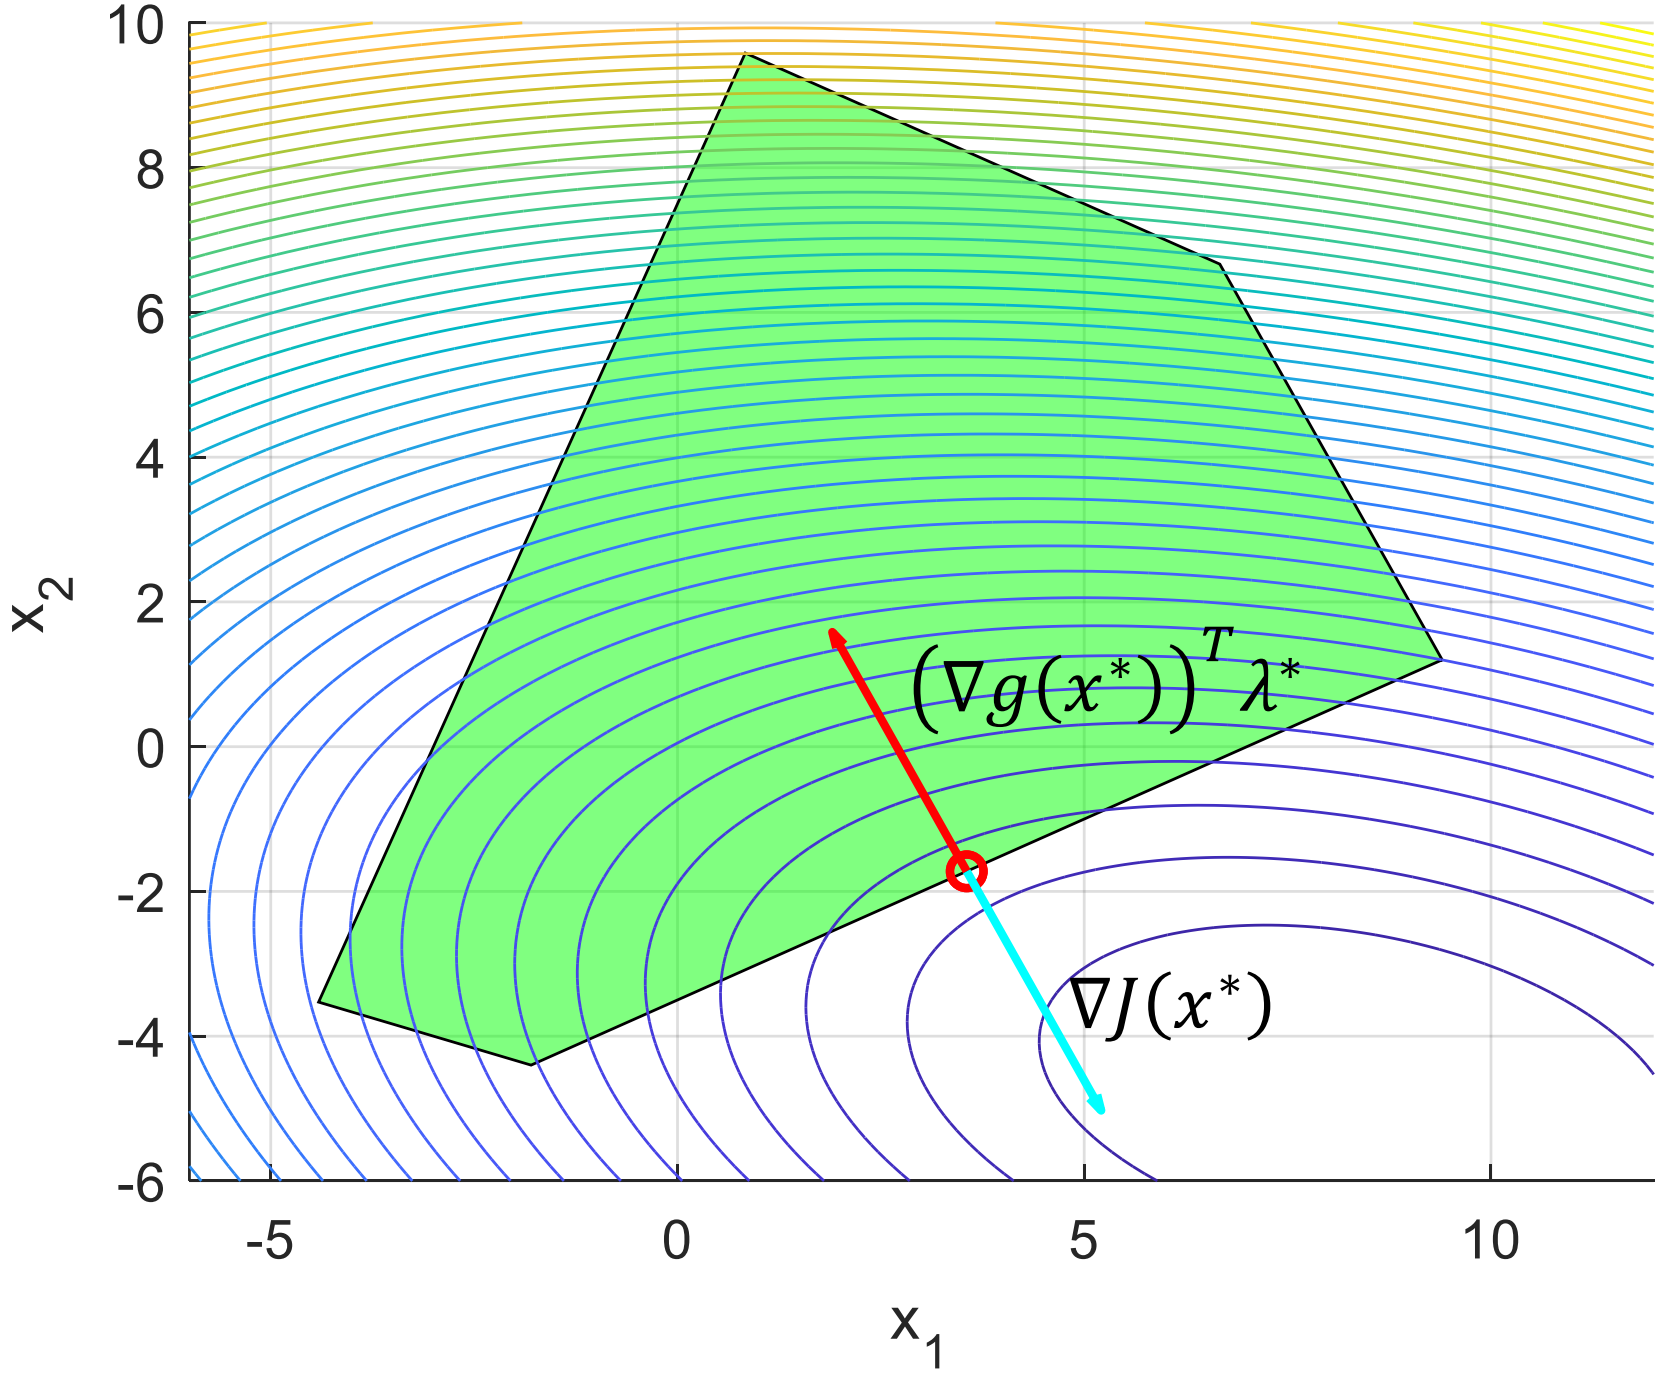
- Záver: Neexistuje prípustný smer s v ktorom by účelová funkcia klesala v bode x^*

$$\nabla J(x^*) + \left(\nabla g(x^*)\right)^T \lambda^* = \mathbf{0}$$

$$\nabla J(x^*) = -\left(\nabla g(x^*)\right)^T$$

$$\lambda^* = \begin{pmatrix} 3.3055 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$$g(x^*) = \begin{pmatrix} 0 \\ -36.2226 \\ -14.6109 \\ -9.9443 \\ -13.3892 \end{pmatrix}$$



Ako inak zapísať podmienku komplementarity ?

- Podmienka komplementarity je daná ako

$$g_i(x)\lambda_i = 0$$

  - Súčiny vektorov $g(x)$, λ po prvkoch sú nulové
- Túto podmienku vieme zapísať ekvivalentne ako

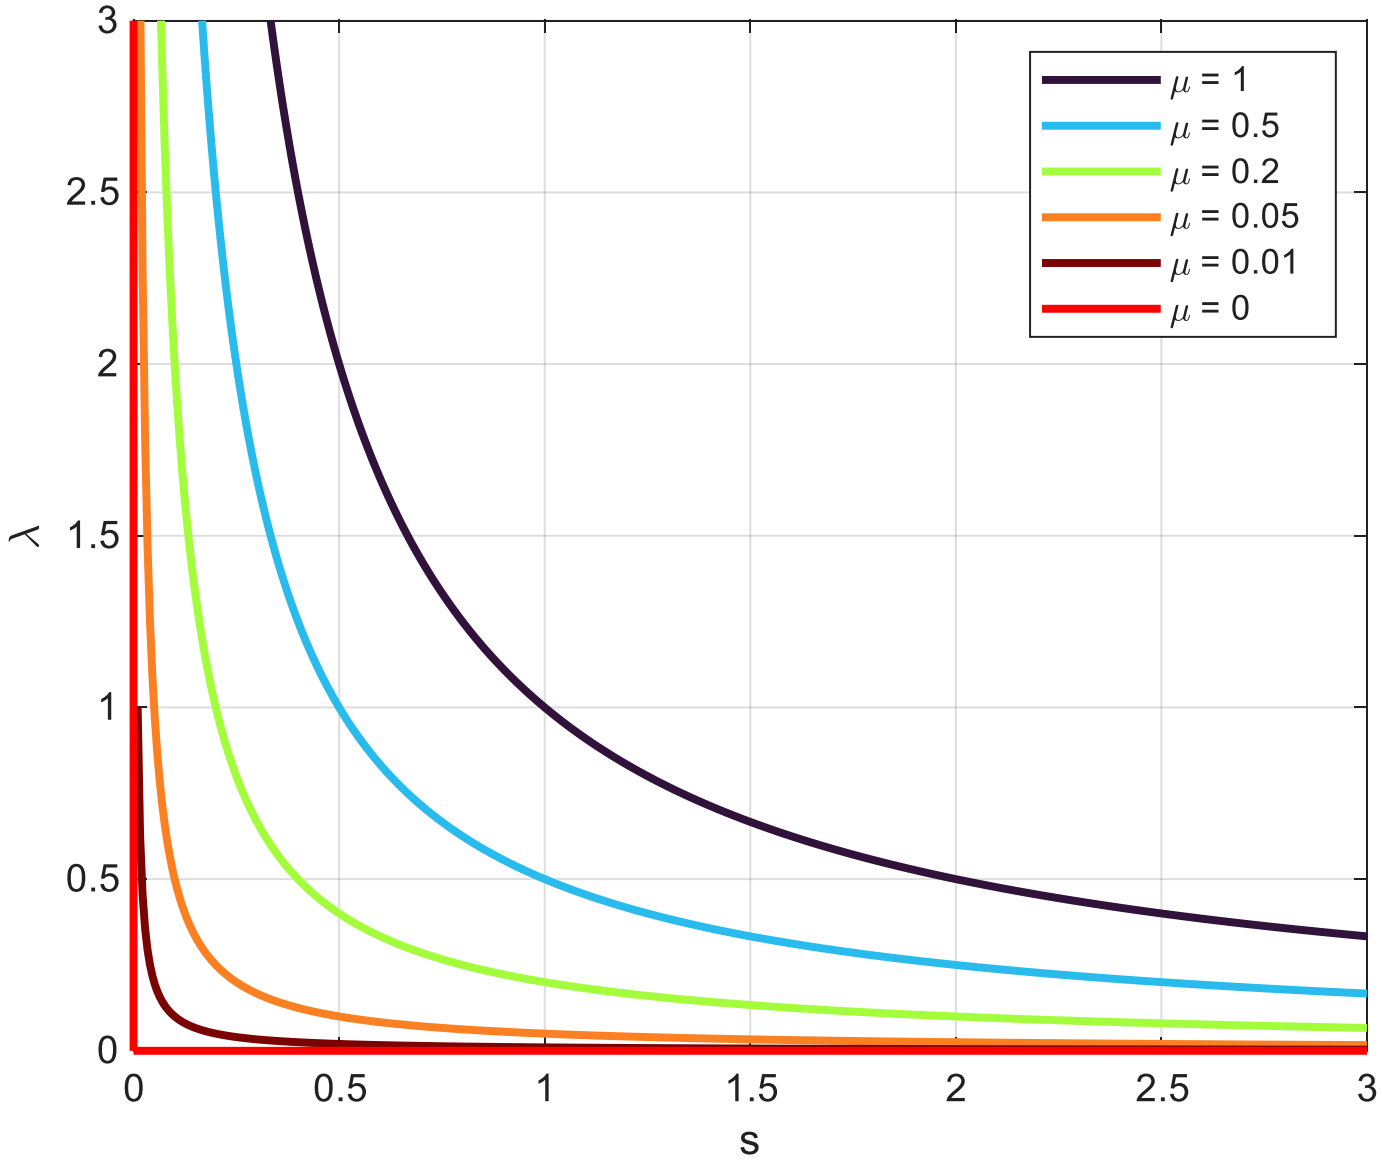
$$\mathrm{diag}\big(g(x)\big)\lambda = \mathrm{diag}(\lambda)g(x) = \mathbf{0}$$

$$\mathrm{diag}\big(g(x)\big)\lambda = \begin{pmatrix} g_1(x) & 0 & \cdots & 0 \\ 0 & g_2(x) & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & g_p(x) \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_p \end{pmatrix} = \begin{pmatrix} \lambda_1 g_1(x) \\ \lambda_2 g_2(x) \\ \vdots \\ \lambda_p g_p(x) \end{pmatrix} = \mathbf{0}$$

$$\mathrm{diag}(\lambda)g(x) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix} \begin{pmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_p(x) \end{pmatrix} = \begin{pmatrix} \lambda_1 g_1(x) \\ \lambda_2 g_2(x) \\ \vdots \\ \lambda_p g_p(x) \end{pmatrix} = \mathbf{0}$$

Myšlienka vnútorného bodu (interior point)

- Komplementárnosť znamená
$$\lambda_i s_i = 0.$$
- Teda pre každé ohraničenie platí
  - buď $s_i = 0$,
  - alebo $\lambda_i = 0$
- Výsledkom je množina riešení tvorená osami súradnicového systému (ostrý nespojitý roh)
  - Zlá podmienenosť, degenerované riešenie
- Myšlienka interior-point:
  - Namiesto $\lambda_i s_i = 0$ rieši uvoľnenú podmienku
$$\lambda_i s_i = \mu$$
kde pre $\mu > 0$ táto rovnica predstavuje hyperbolu
- Hyperbola nikdy nepretína osi, takže
$$\lambda > 0, s > 0$$
- Pohybujeme sa tak vo vnútri prípustnej oblasti (hladkou centrálnou cestou), nie po jej hranici
- Ako $\mu \to 0$, hyperbola sa približuje k osiam a dostávame pôvodnú podmienku
$$\lambda_i s_i \to 0,$$


3
2.5
2
1.5
1
0.5
0
λ
0
0.5
1
1.5
2
2.5
3
s
μ = 1
μ = 0.5
μ = 0.2
μ = 0.05
μ = 0.01
μ = 0

Úloha kvadratického programovania



- Kvadratické programovanie označuje minimalizáciu kvadratickej formy pri uvažovaní ohraničení lineárnymi nerovnicami
- Majme kvadratickú formu n premenných

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c$$

kde $x \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$, $c \in \mathbb{R}$

- Premenné x budú podliehať q lineárnym nerovniciam

$$A_c x \leq b_c$$

kde $A_c \in \mathbb{R}^{q \times n}$, $b_c \in \mathbb{R}^q$

- Potom teda funkcia ohraničení bude

$$g(x) = A_c x - b_c$$

- Lagrangeova funkcia pre problém kvadratického programovania získa tvar

$$L(x, \lambda) = J(x) + \lambda^T g(x)$$

$$L(x, \lambda) = \frac{1}{2}x^T Ax + b^T x + c + \lambda^T (A_c x - b_c)$$

Podmienky ohraničeného optima v kvadratickom programovaní

- Stacionarita

$$\nabla_x L(x^*, \lambda^*) = \nabla J(x^*) + \left(\nabla g(x^*)\right)^T \lambda^* = Ax^* + b + {A_c}^T \lambda^* = \mathbf{0}$$

- Prípustnosť

$$g(x^*) = A_c x^* - b_c \leq \mathbf{0}$$
$$\lambda^* \geq \mathbf{0}$$

- Komplementarita

$$\mathrm{diag}(\lambda^*) g(x^*) = \mathrm{diag}(\lambda^*)(A_c x^* - b_c) = \mathbf{0}$$

- Ako ale naraz splniť všetky tieto podmienky a nájsť ohraničené optimum x^* a multiplikátory λ^* ?
- Odpoveďou je numerické riešenie

Reziduá (chyby) podmienok optimálnosti

- Zavedieme si nový pomocný vektor $s \in \mathbb{R}^q$ (slack premenné), ktorý bude predstavovať splnenie podmienok nerovníc $A_c x - b_c \leq \mathbf{0}$ ako

$$A_c x - b_c = -s$$
$$A_c x - b_c + s = \mathbf{0}$$
$$s \geq \mathbf{0}$$

- Definujeme si reziduálne funkcie predstavujúce nesplnenie (chyby) podmienok ohraničenej optimálnosti
  - Reziduum stacionárnosti $r_1 \in \mathbb{R}^n$

$$r_1(x, \lambda) = Ax + b + {A_c}^T \lambda$$

  - Reziduum pre nerovnice $r_2 \in \mathbb{R}^q$

$$r_2(x, s) = A_c x - b_c + s$$

  - Reziduum komplementárnosti $r_3 \in \mathbb{R}^q$

$$r_3(s, \lambda, \mu) = \mathrm{diag}(\lambda) s$$

  - Cieľom je nájsť vektory x, $s \geq \mathbf{0}$, $\lambda \geq \mathbf{0}$ také že všetky reziduá budú nulové

$$r_1(x, \lambda) = \mathbf{0}, r_2(x, s) = \mathbf{0}, r_3(s, \lambda, \mu) = \mathbf{0}$$

Reziduá (chyby) podmienok optimálnosti (interior point modifikácia)

- Definujeme si reziduálne funkcie predstavujúce nesplnenie (chyby) podmienok ohraničenej optimálnosti
  - Reziduum stacionárnosti $r_1 \in \mathbb{R}^n$

$$r_1(x, \lambda) = Ax + b + {A_c}^T \lambda$$

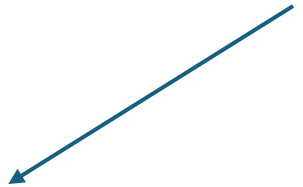
  - Reziduum pre nerovnice $r_2 \in \mathbb{R}^q$

$$r_2(x, s) = A_c x - b_c + s$$

  - Reziduum komplementárnosti $r_3 \in \mathbb{R}^q$

$$r_3(s, \lambda, \mu) = \mathrm{diag}(\lambda)s - \mu \mathbf{1}$$

Modifikácia



  - Cieľom je nájsť vektory x, $s \geq \mathbf{0}$, $\lambda \geq \mathbf{0}$ také že všetky reziduá budú nulové

$$r_1(x, \lambda) = \mathbf{0}, r_2(x, s) = \mathbf{0}, r_3(s, \lambda, \mu) = \mathbf{0}$$

Reziduá podmienok optimálnosti a ich Jakobián

- Spojený vektor hľadaných premenných $\theta \in \mathbb{R}^{n+q+q}$ bude

$$\theta = \begin{bmatrix} x \\ \lambda \\ s \end{bmatrix}$$

- Spojená funkcia reziduí bude $r(\theta) \in \mathbb{R}^{n+q+q}$

$$r(\theta) = \begin{bmatrix} r_1(\theta) \\ r_2(\theta) \\ r_3(\theta) \end{bmatrix} = \begin{bmatrix} Ax + b + {A_c}^T\lambda \\ A_c x - b_c + s \\ \mathrm{diag}(\lambda)s - \mu\mathbf{1} \end{bmatrix}$$

- Nájdime teraz Jakobián reziduí $\nabla r(\theta) \in \mathbb{R}^{n+q+q \times n+q+q}$ ako

$$\nabla r(\theta) = \begin{pmatrix} \nabla_x r_1(\theta) & \nabla_\lambda r_1(\theta) & \nabla_s r_1(\theta) \\ \nabla_x r_2(\theta) & \nabla_\lambda r_2(\theta) & \nabla_s r_2(\theta) \\ \nabla_x r_3(\theta) & \nabla_\lambda r_3(\theta) & \nabla_s r_3(\theta) \end{pmatrix} = \begin{pmatrix} A & {A_c}^T & \mathbf{0} \\ A_c & \mathbf{0} & I \\ \mathbf{0} & \mathrm{diag}(s) & \mathrm{diag}(\lambda) \end{pmatrix}$$

Hľadanie riešenia v zmysle Newtonovej metódy

- Cieľom je nájsť také θ^* že $r(\theta^*) = \mathbf{0}$ a teda všetky reziduá budú nulové
- Môžeme použiť iteratívny algoritmus – Newtonovu metódu
  - Newtonova metóda hľadá nulové body $r(\theta)$ s využitím Jakobiánu
- Krok $\Delta\theta_{k+1}$ nech spĺňa sústavu lineárnych rovníc

$$\nabla r(\theta_k)\Delta\theta_{k+1} = -r(\theta_k)$$

$$\begin{pmatrix} A & A_c{}^T & \mathbf{0} \\ A_c & \mathbf{0} & I \\ \mathbf{0} & \mathrm{diag}(s_k) & \mathrm{diag}(\lambda_k) \end{pmatrix} \begin{bmatrix} \Delta x_{k+1} \\ \Delta\lambda_{k+1} \\ \Delta s_{k+1} \end{bmatrix} = - \begin{bmatrix} Ax_k + b + A_c{}^T\lambda_k \\ A_c x_k - b_c + s_k \\ \mathrm{diag}(\lambda_k)s_k - \mu\mathbf{1} \end{bmatrix}$$

- Nová aproximácia optima však musí spĺňať podmienky $\lambda_{k+1} \geq \mathbf{0}$, $s_{k+1} \geq \mathbf{0}$
- Definujme si preto skalár (tlmenie) $0 \leq \gamma \leq 1$ tak aby sme zabezpečili

$$\begin{pmatrix} \lambda_k + \gamma\Delta\lambda_{k+1} \\ s_k + \gamma\Delta s_{k+1} \end{pmatrix} \geq \mathbf{0}$$

- Odhad θ_{k+1} potom aktualizujeme ako

$$\theta_{k+1} = \theta_k + \gamma\Delta\theta_{k+1}$$

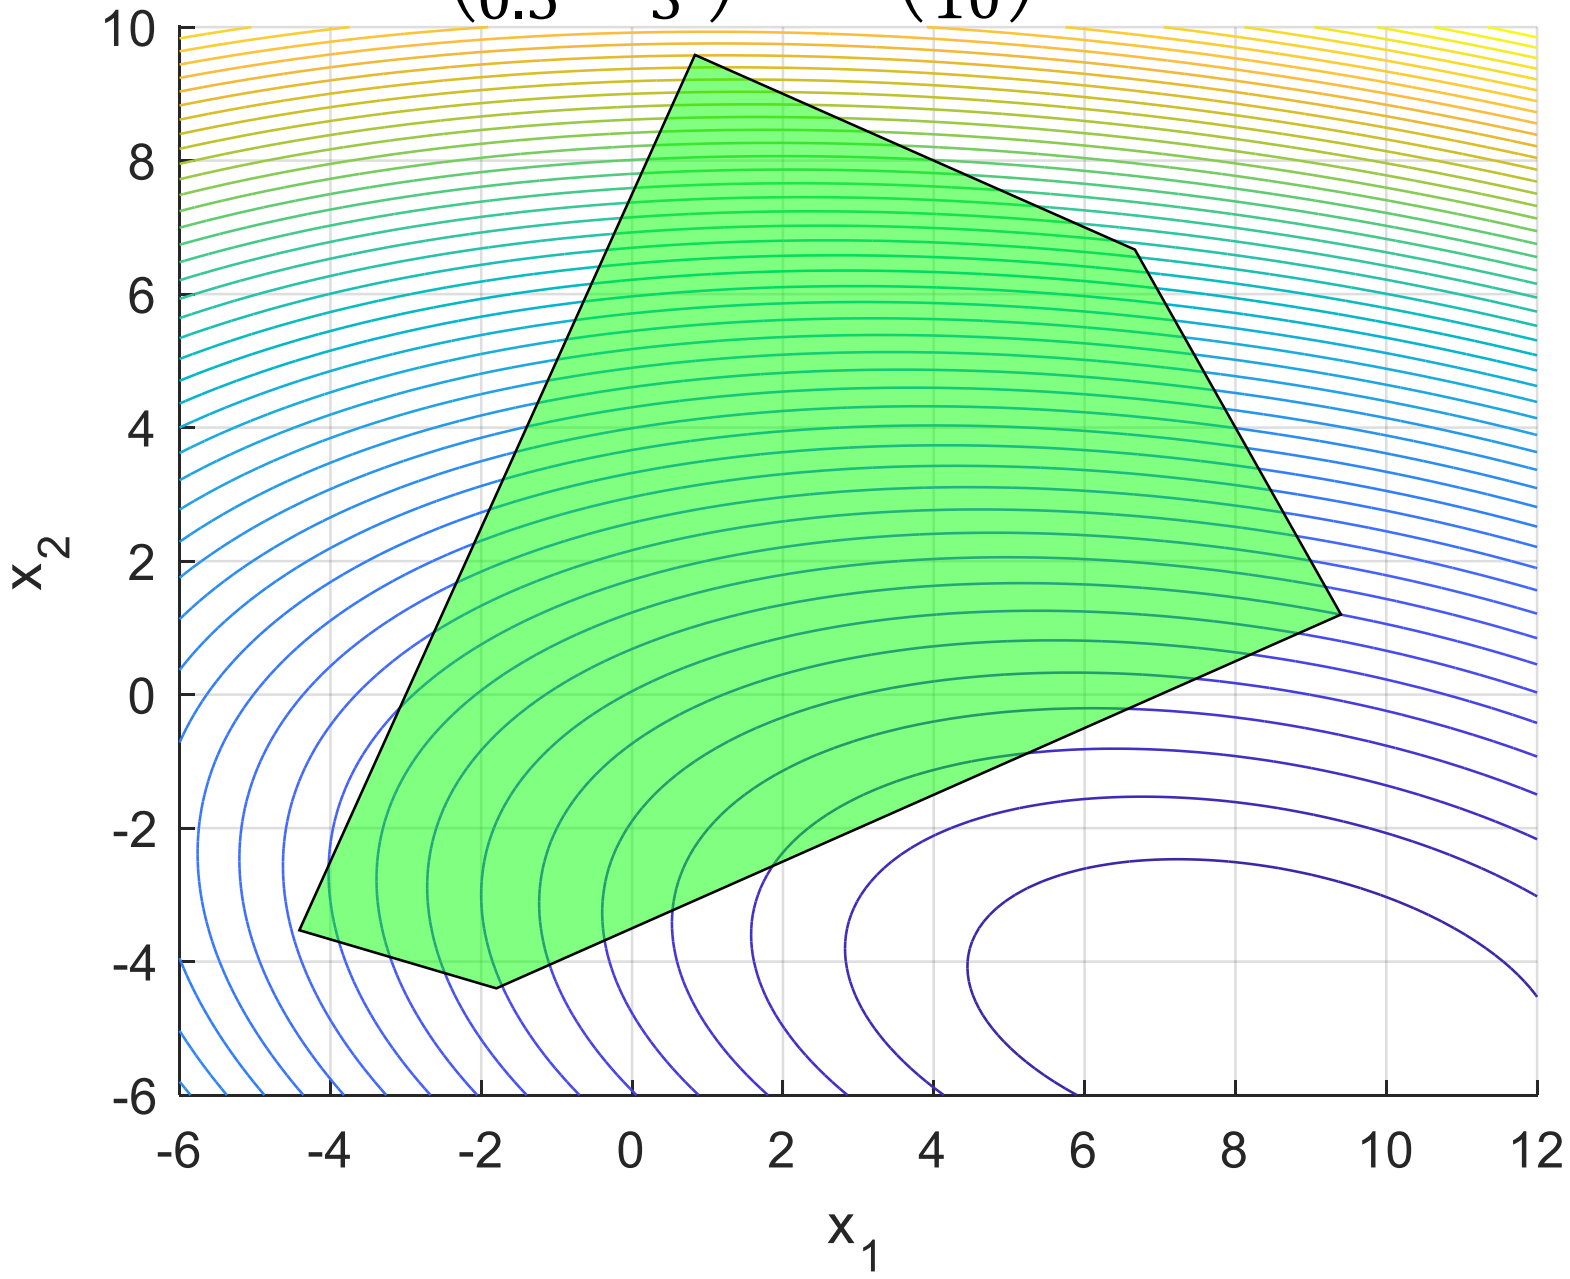
- Pokračujeme s novým KKT systémom až do splnenia podmienky (veľkosť rezidua) $\left(r(\theta_k)\right)^T r(\theta_k) < \epsilon$
- Faktor μ môžeme zvoliť ako:

$$\mu = \frac{\lambda^T s}{2q}$$

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c, \qquad A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 3 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$

$$A_c = \begin{pmatrix} 1 & -2 \\ -5 & 2 \\ 2 & 1 \\ 0.5 & 1 \\ -1 & -3 \end{pmatrix}$$

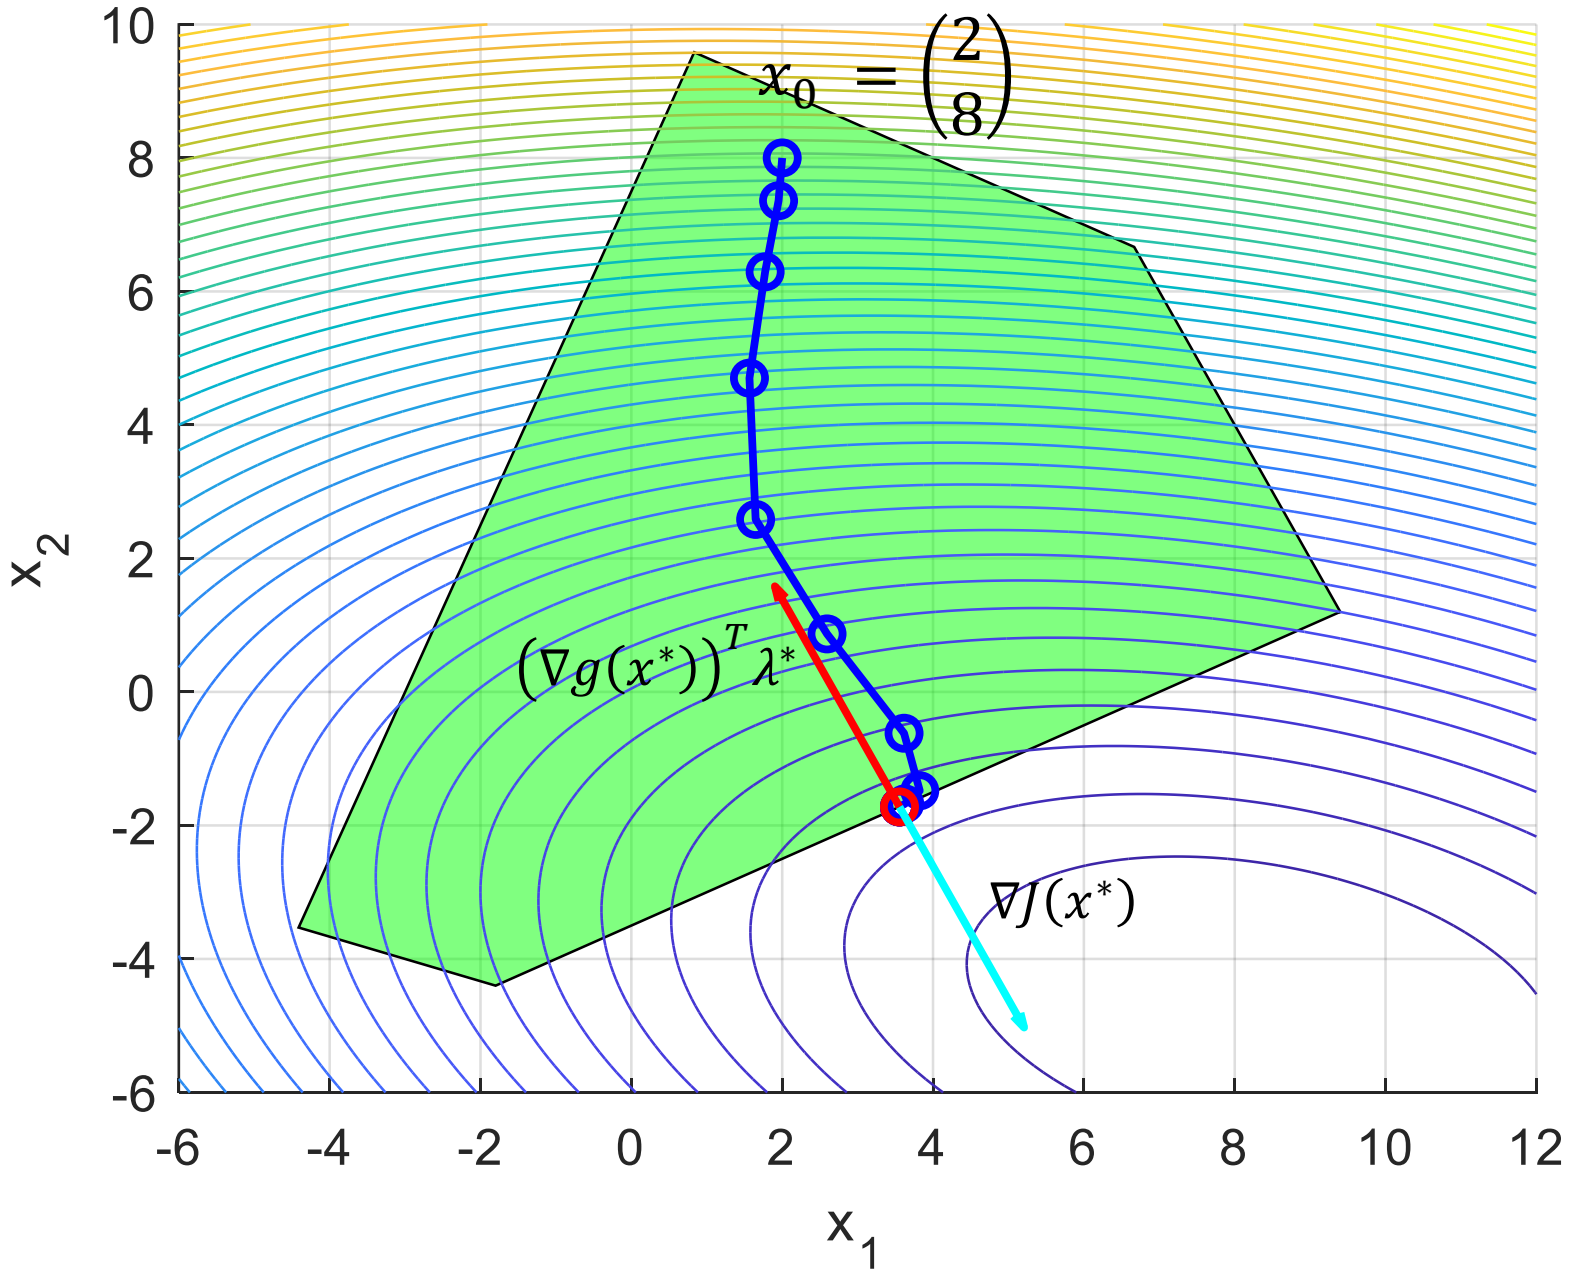
$$b_c = \begin{pmatrix} 7 \\ 15 \\ 20 \\ 10 \\ 15 \end{pmatrix}$$

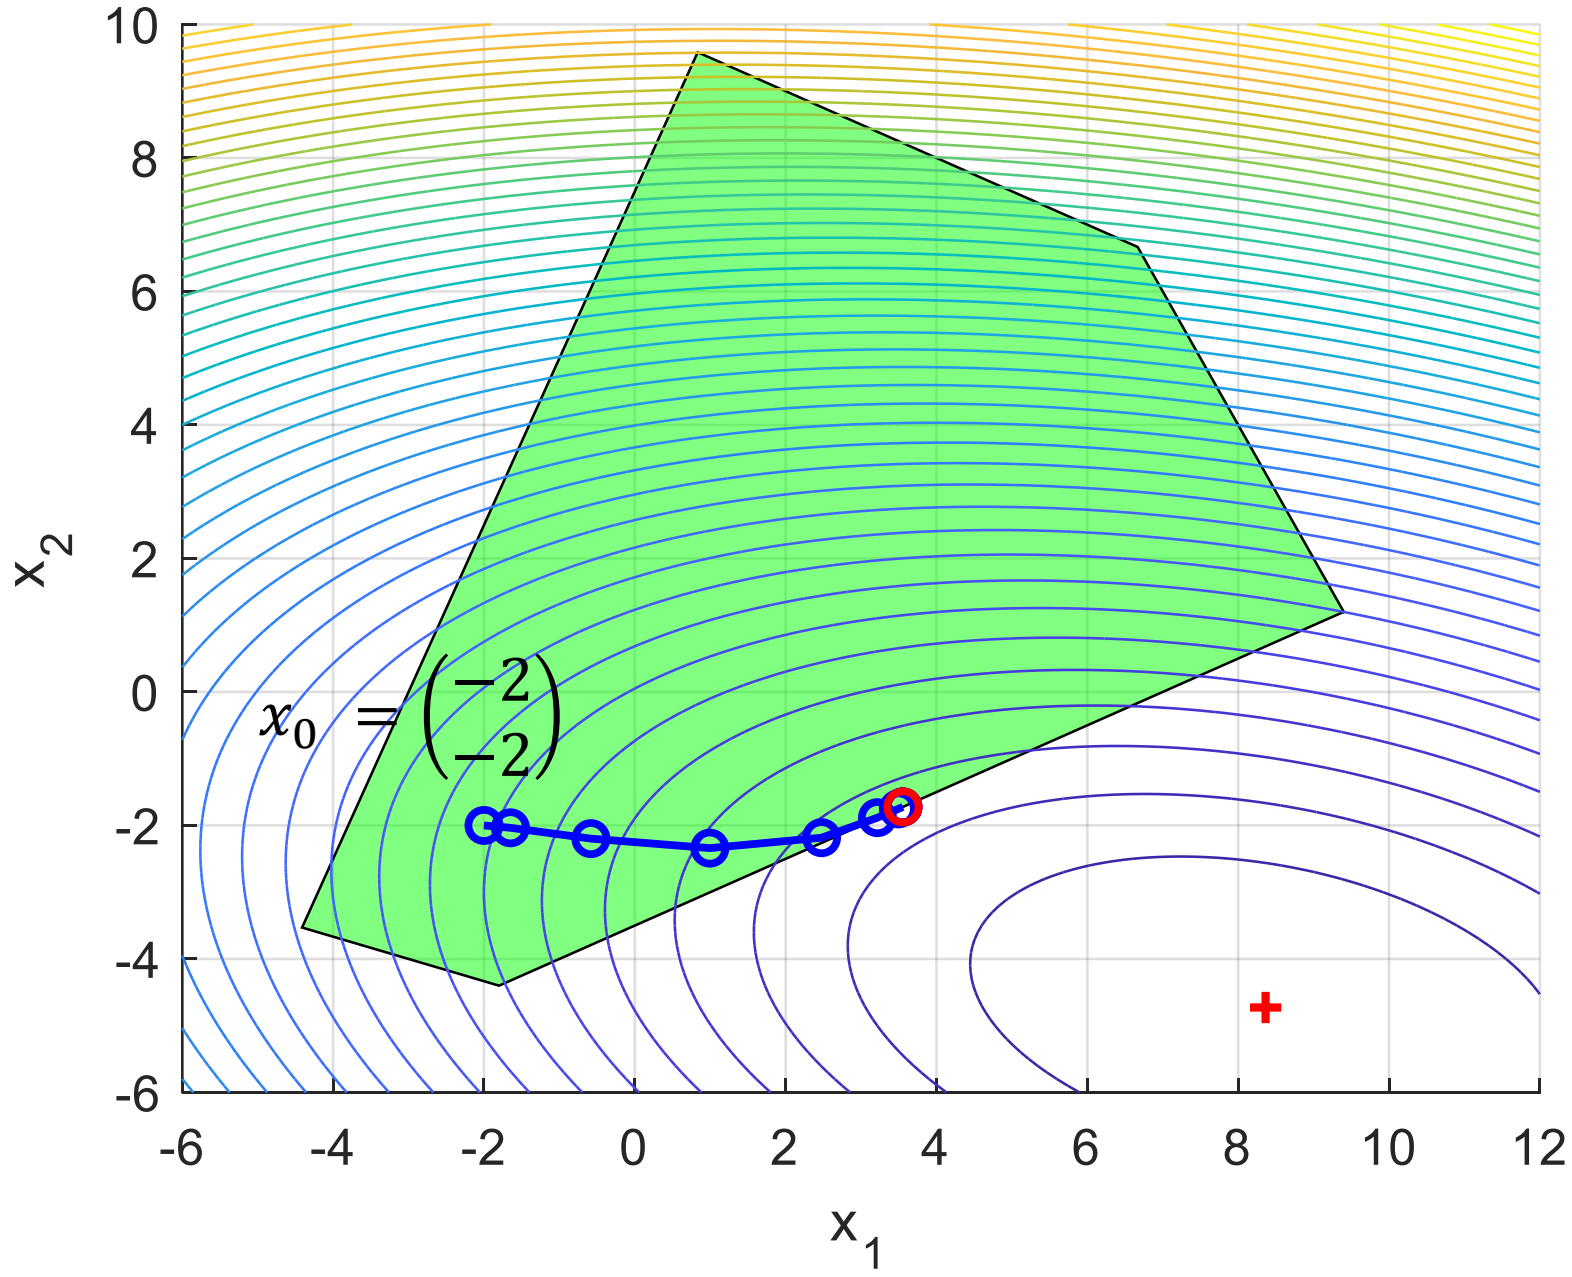


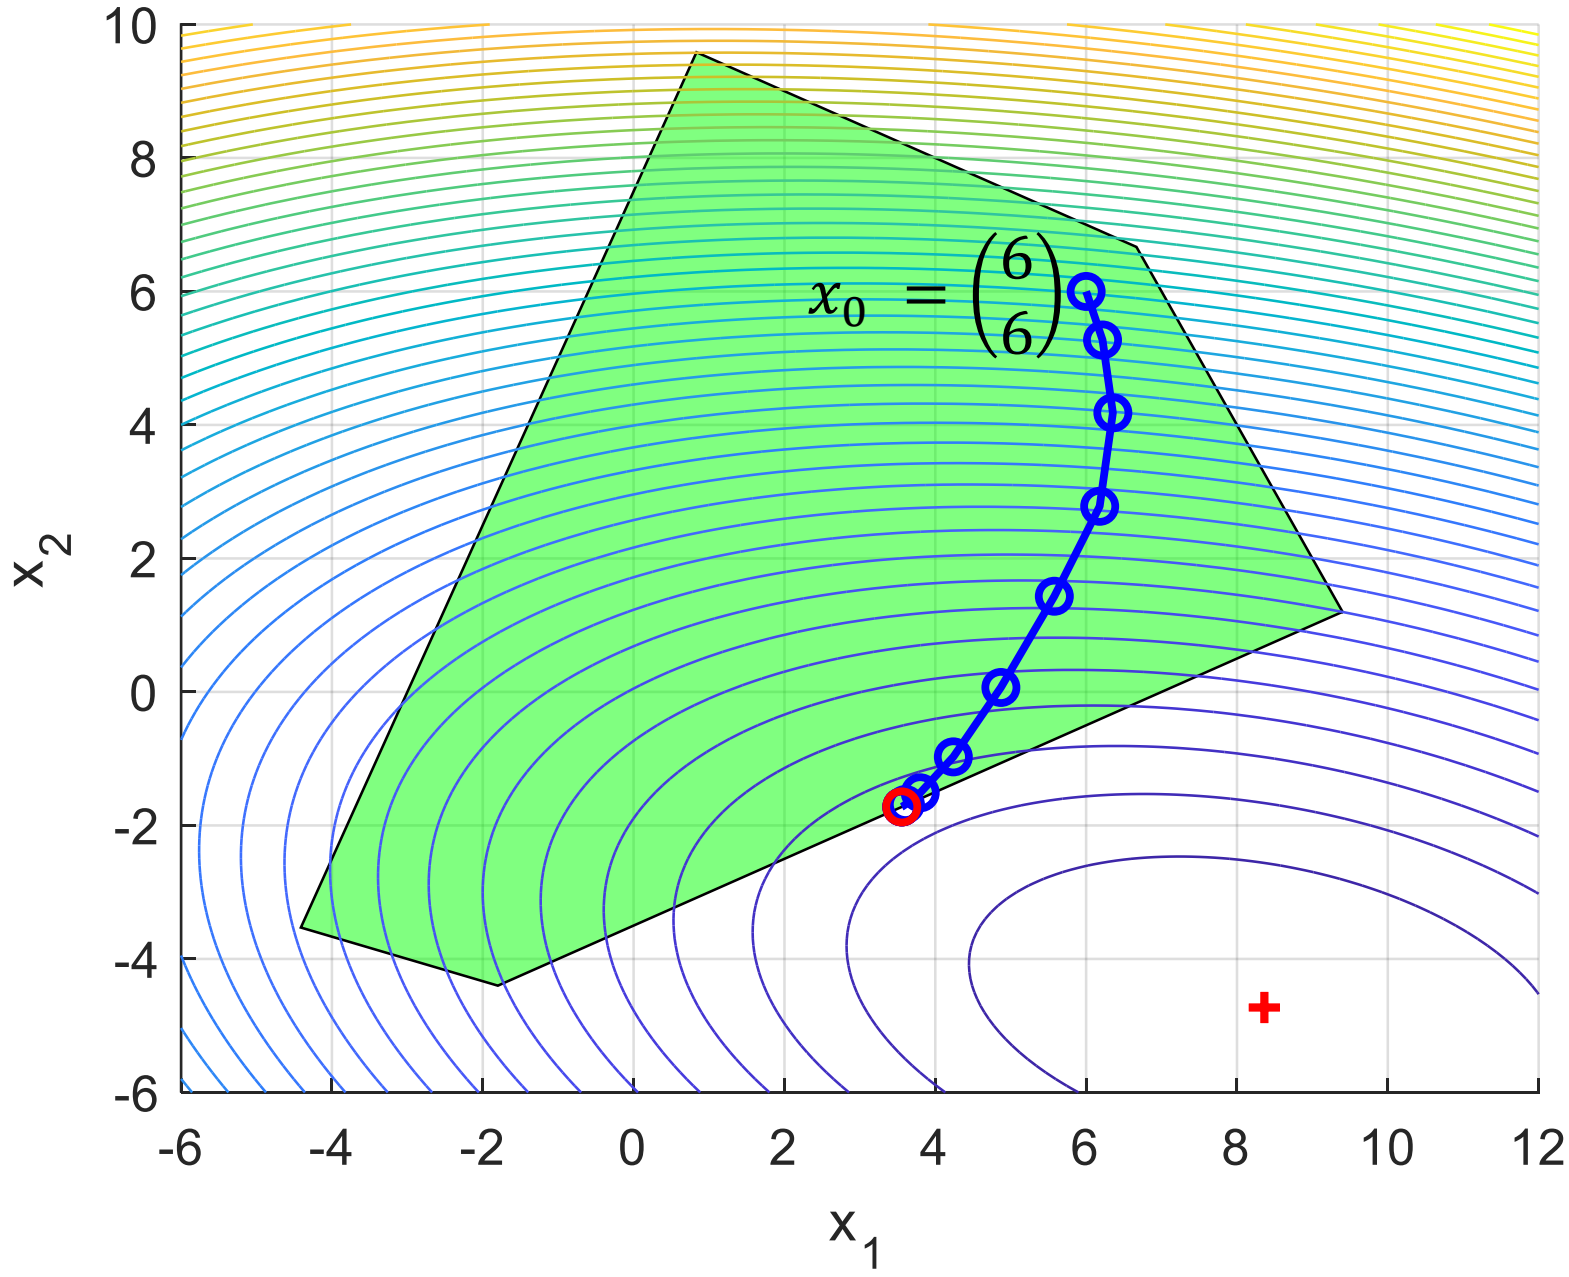
$$x^* = \begin{pmatrix} 3.5556 \\ -1.7222 \end{pmatrix}$$

$$\lambda^* = \begin{pmatrix} 3.3055 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$$g(x^*) = \begin{pmatrix} 0 \\ -36.2226 \\ -14.6109 \\ -9.9443 \\ -13.3892 \end{pmatrix}$$



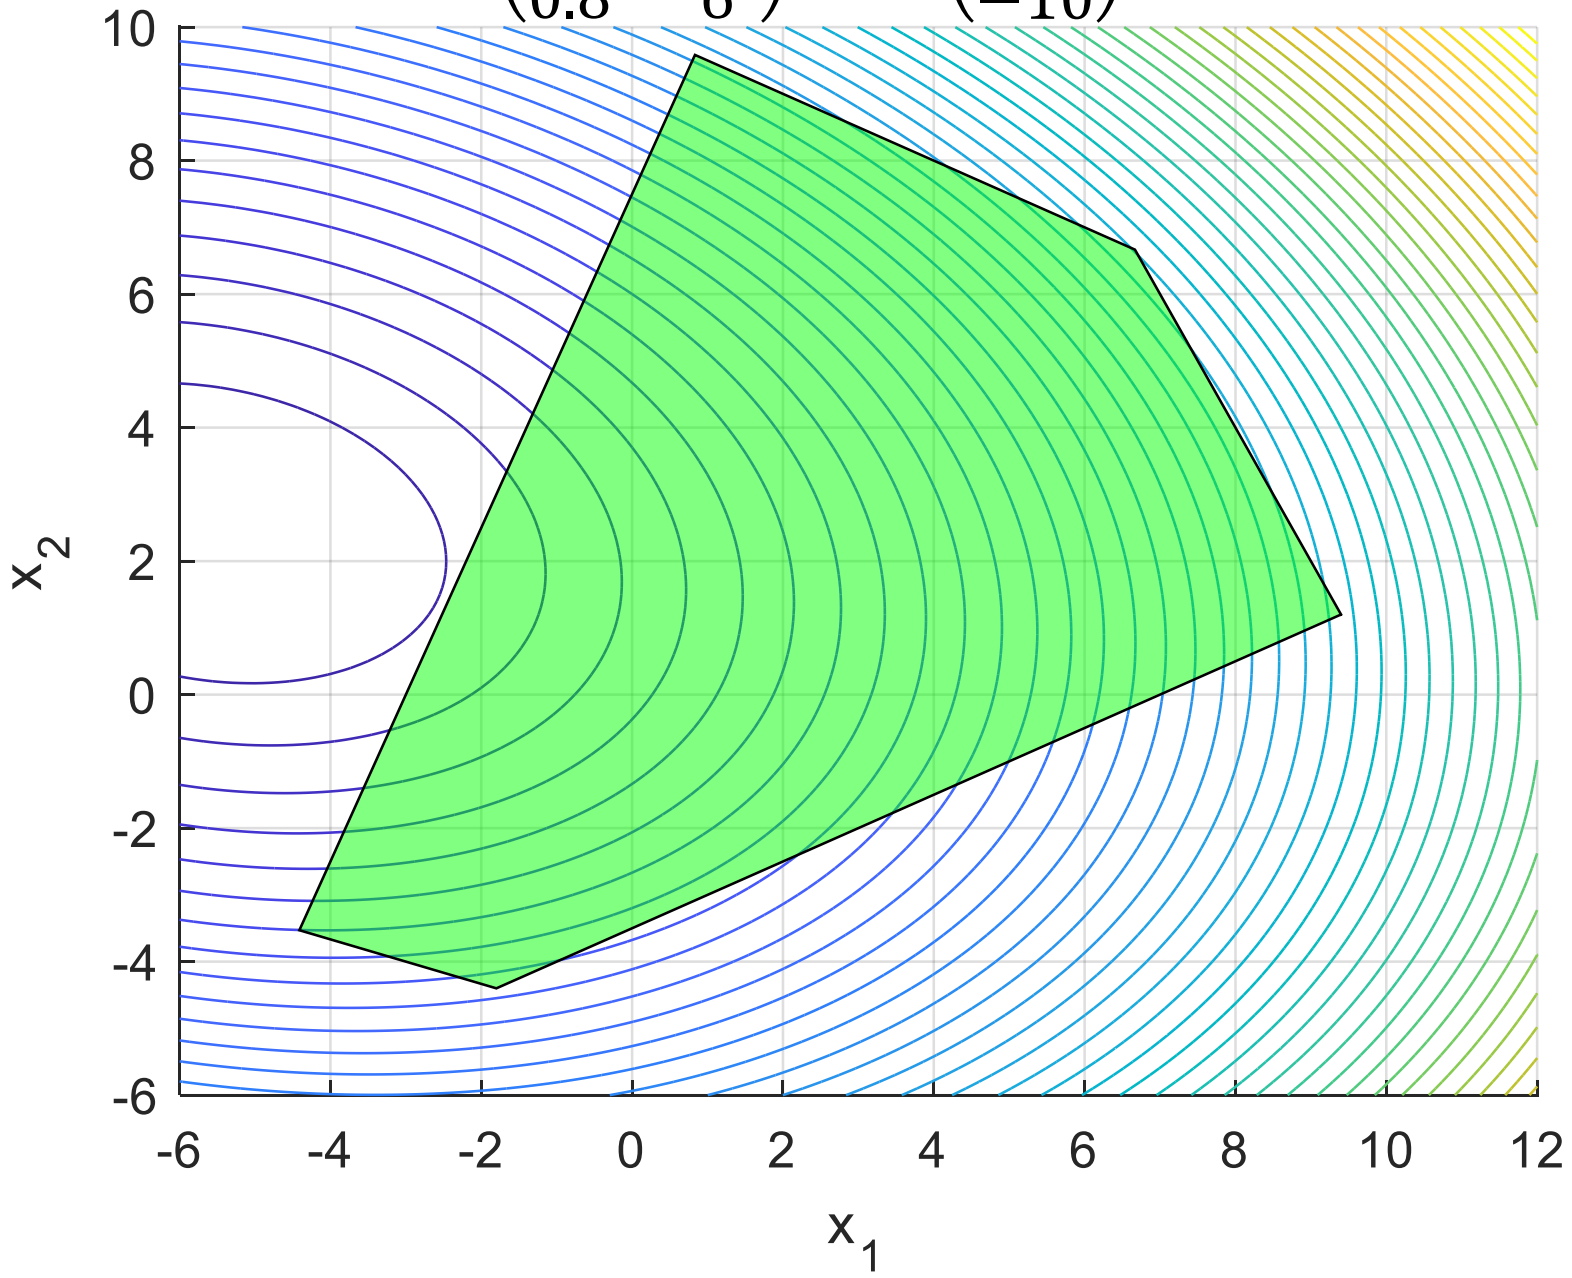

10
8
6
4
2
0
-2
-4
-6
-6
-4
-2
0
2
4
6
8
10
12
x2
x1
$x_0 = \begin{pmatrix} -2 \\ -2 \end{pmatrix}$


$x_0 = \begin{pmatrix} 6 \\ 6 \end{pmatrix}$
10
8
6
4
2
0
-2
-4
-6
-6
-4
-2
0
2
4
6
8
10
12
x_2
x_1

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c, \qquad A = \begin{pmatrix} 3 & 0.8 \\ 0.8 & 6 \end{pmatrix}, b = \begin{pmatrix} 15 \\ -10 \end{pmatrix}, c = 10$$

$$A_c = \begin{pmatrix} 1 & -2 \\ -5 & 2 \\ 2 & 1 \\ 0.5 & 1 \\ -1 & -3 \end{pmatrix}$$

$$b_c = \begin{pmatrix} 7 \\ 15 \\ 20 \\ 10 \\ 15 \end{pmatrix}$$



$$x^* = \begin{pmatrix} -2.4382 \\ 1.4045 \end{pmatrix}$$

$$\lambda^* = \begin{pmatrix} 0 \\ 1.7618 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$$g(x^*) = \begin{pmatrix} -12.2472 \\ 0 \\ -23.4719 \\ -9.8146 \\ -16.7753 \end{pmatrix}$$

