Prediktívne riadenie

Čo je prediktívne riadenie ?



- Prediktívne riadenie s modelom - Model Predictive Control (MPC)
- Moderná metóda riadenia, ktorá využíva matematický model riadeného systému na predikciu a optimalizáciu jeho budúceho správania
- Predikcia znamená predpovedanie (odhad) budúceho vývoja stavu
- Využíva diskrétny stavový model
- Riadiaci algoritmus optimalizuje akčné zásahy na základe predikcie
- Cieľom je dosiahnuť čo najlepšiu kvalitu riadenia pri dodržaní praktických obmedzení
- Výhody MPC:
  - Vysoká kvalita a optimálnosť riadenia na konečnom horizonte
  - Intuitívne ladenie parametrov
  - Priamočiara práca s obmedzeniami (ohraničeniami)

Diskrétny lineárny model v stavovom opise

- Uvažujme systém s n stavmi a r vstupmi
- Prechodová (diferenčná) rovnica systému je

$$x(k+1) = Ax(k) + Bu(k)$$

- Stavový vektor $x(k) \in \mathbb{R}^n$, matica $A \in \mathbb{R}^{n \times n}$, matica $B \in \mathbb{R}^{n \times r}$, vektor vstupov $u \in \mathbb{R}^r$ sú dané ako:

$$x(k) = \begin{pmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_n(k) \end{pmatrix}, A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix},$$

$$u(k) = \begin{pmatrix} u_1(k) \\ u_2(k) \\ \vdots \\ u_r(k) \end{pmatrix}, B = \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1r} \\ b_{21} & b_{22} & \cdots & b_{2r} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nr} \end{pmatrix},$$

Predikcia stavu o viac krokov dopredu



- Predikujme stav systému o i krokov dopredu
  - Pre $i = 1$

$$x(k+1) = Ax(k) + Bu(k)$$

  - Pre $i = 2$

$$x(k+2) = Ax(k+1) + Bu(k+1)$$

  - Dosadíme $x(k+1)$ z predchádzajúceho kroku

$$x(k+2) = A(Ax(k) + Bu(k)) + Bu(k+1)$$
$$x(k+2) = A^2x(k) + ABu(k) + Bu(k+1)$$

  - Pre $i = 3$

$$x(k+3) = Ax(k+2) + Bu(k+2)$$

  - Dosadíme $x(k+2)$ z predchádzajúceho kroku

$$x(k+3) = A\left(A^2x(k) + ABu(k) + Bu(k+1)\right) + Bu(k+2)$$
$$x(k+3) = A^3x(k) + A^2Bu(k) + ABu(k+1) + Bu(k+2)$$

Predikcia stavu o viac krokov dopredu

- Predikovaný stav o i krokov dopredu bude

$$x(k+i) = A^i x(k) + A^{i-1}Bu(k) + A^{i-2}Bu(k+1) \ldots + Bu(k+i-1)$$

- Predikciu vieme zapísať ako

$$x(k+i) = A^i x(k) + \sum_{j=1}^{i} A^{i-j} B\, u(k+j-1)$$

- Zložku $A^i x(k)$ nazývame voľná odozva
  - Závisí iba od stavu $x(k)$
  - Nevieme ju ovplyvniť
- Zložku $\sum_{j=1}^{i} A^{i-j} B\, u(k+j-1)$ nazývame vynútená odozva
  - Závisí iba od budúcich hodnôt akčného zásahu $u(k+j-1)$
  - Vieme ju ovplyvniť

Horizont predikcie

- Budeme predikovať p krokov dopredu - predikčný horizont p
- Zadefinujme rozšírený (predikovaný) stavový vektor $X(k) \in \mathbb{R}^{pn}$ ako

$$X(k) = \begin{pmatrix} x(k+1) \\ x(k+2) \\ x(k+3) \\ \vdots \\ x(k+p-1) \\ x(k+p) \end{pmatrix}$$

- Zadefinujme rozšírený (predikovaný) vektor vstupov $U(k) \in \mathbb{R}^{pr}$ ako

$$U(k) = \begin{pmatrix} u(k) \\ u(k+1) \\ u(k+2) \\ \vdots \\ u(k+p-2) \\ u(k+p-1) \end{pmatrix}$$

Prediktívna rovnica v lineárnom tvare



- Ukázali sme že viackroková predikcia stavu je

$$x(k+i) = A^i x(k) + \sum_{j=1}^{i} A^{i-j} B u(k+j-1)$$

- Túto rovnicu vieme napísať s využitím vektora $X(k)$ a vektora $U(k)$ lineárne ako

$$\begin{pmatrix} x(k+1) \\ x(k+2) \\ x(k+3) \\ \vdots \\ x(k+p-1) \\ x(k+p) \end{pmatrix} = \begin{pmatrix} A \\ A^2 \\ A^3 \\ \vdots \\ A^{p-1} \\ A^p \end{pmatrix} x(k) + \begin{pmatrix} B & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ AB & B & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ A^2B & AB & B & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ A^{p-2}B & A^{p-3}B & A^{p-4}B & \cdots & B & \mathbf{0} \\ A^{p-1}B & A^{p-2}B & A^{p-3}B & \cdots & AB & B \end{pmatrix} \begin{pmatrix} u(k) \\ u(k+1) \\ u(k+2) \\ \vdots \\ u(k+p-2) \\ u(k+p-1) \end{pmatrix}$$

$$X(k) = Mx(k) + NU(k)$$

$M \in \mathbb{R}^{np \times n}$ je predikčná matica voľnej odozvy
$N \in \mathbb{R}^{np \times rp}$ je predikčná matica vynútenej odozvy



Účelová funkcia prediktívneho riadenia

- Prediktívne riadenie definuje účelovú funkciu $J(U(k))$ v kroku k ako funkciu vektora budúcich akčných zásahov $U(k)$ na konečnom predikčnom horizonte p ako

$$J(U(k)) = \sum_{i=1}^{p} x(k+i)^T Q x(k+i) + u(k+i-1)^T R u(k+i-1)$$

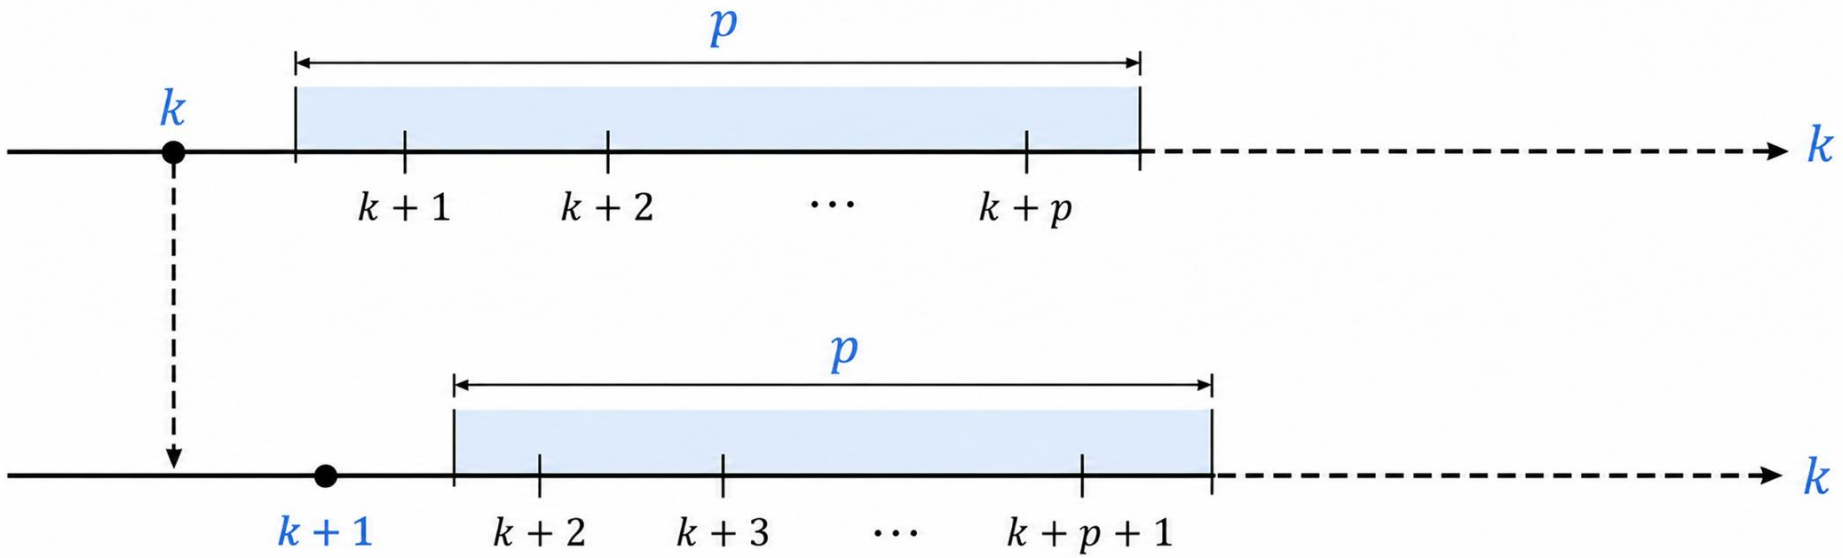
$Q \in \mathbb{R}^{n \times n}, Q = Q^T, Q \succ 0$ je váhovacia matica penalizácie stavov

$R \in \mathbb{R}^{r \times r}, R = R^T, R \succ 0$ je váhovacia matica penalizácie vstupov

  - Matice Q a R predstavujú ladiace parametre
- Účelová funkcia penalizuje:
  - stavy cez člen $x(k+i)^T Q x(k+i) \geq 0$
  - vstupy cez člen $u(k+i-1)^T R u(k+i-1) \geq 0$

Ustupujúci horizont

- V kroku k sa neaplikuje všetkých p vypočítaných zásahov, ale použije sa iba prvý.
- V novom kroku sa posunieme ďalej ako $k \leftarrow k + 1$ čo sa nazýva ustupujúci horizont.
- MPC problém sa v novom kroku vyrieši znova.
- Preto sa nazýva ustupujúci horizont (*receding horizon*): neustále sa pozeráme rovnakú vzdialenosť do budúcnosti, ale začiatok horizontu sa posúva dopredu.
- Prečo sa nepoužije celá optimálna sekvencia?
  - Dôvod je jednoduchý: predikcie sa môžu mýliť. Medzitým môže systém reagovať trochu inak, môže vzniknúť porucha, alebo môže byť stav odhadnutý inak, než sme predpokladali.



Rozšírené váhovacie matice

- Účelovú funkciu možno napísať v maticovo-vektorovom tvare (bez sumácie) ako

$$J(U(k)) = X(k)^T \mathbf{Q} X(k) + U(k)^T \mathbf{R} U(k)$$

- Matica $\mathbf{Q} \in \mathbb{R}^{pn \times pn}$ bude blokovo diagonálna

$$\mathbf{Q} = \begin{pmatrix} Q & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & Q & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & Q \end{pmatrix}$$

- Matica $\mathbf{R} \in \mathbb{R}^{pr \times pr}$ bude blokovo diagonálna

$$\mathbf{R} = \begin{pmatrix} R & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & R & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & R \end{pmatrix}$$

Ekvivalencia účelových funkcii

$$J(U(k)) = X(k)^T \mathbf{Q} X(k) + U(k)^T \mathbf{R} U(k)$$

$$= \begin{pmatrix} x(k+1)^T & x(k+2)^T & \cdots & x(k+p)^T \end{pmatrix} \begin{pmatrix} Q & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & Q & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & Q \end{pmatrix} \begin{pmatrix} x(k+1) \\ x(k+2) \\ \vdots \\ x(k+p) \end{pmatrix}$$

$$+ \begin{pmatrix} u(k)^T & u(k+1)^T & \cdots & u(k+p-1)^T \end{pmatrix} \begin{pmatrix} R & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & R & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & R \end{pmatrix} \begin{pmatrix} u(k) \\ u(k+1) \\ \vdots \\ u(k+p-1) \end{pmatrix}$$

$$= \sum_{i=1}^{p} x\left(k+i\right)^T Q x\left(k+i\right) + u\left(k+i-1\right)^T R u(k+i-1)$$

Kvadratická forma účelovej funkcie

- Máme účelovú funkciu v kompaktnom (maticovo-vektorovom) tvare

$$J(U(k)) = X(k)^T \mathbf{Q} X(k) + U(k)^T \mathbf{R} U(k)$$

- Za $X(k)$ teraz dosadíme prediktívnu rovnicu $X(k) = Mx(k) + NU(k)$

$$J(U(k)) = (Mx(k) + NU(k))^T \mathbf{Q}(Mx(k) + NU(k)) + U(k)^T \mathbf{R} U(k)$$

- Účelovú funkciu roznásobíme a upravíme

$$J(U(k)) = U(k)^T \left(N^T \mathbf{Q} N + \mathbf{R}\right) U(k) + 2x(k)^T M^T \mathbf{Q} N U(k) + x(k)^T M^T \mathbf{Q} M x(k)$$

- Zavedieme si nasledovné substitúcie pre zjednodušenie označovania:

$$\mathbf{H} = \left(N^T \mathbf{Q} N + \mathbf{R}\right), \quad \mathbf{b}^T(k) = x(k)^T M^T \mathbf{Q} N, \quad \mathbf{c}(k) = x(k)^T M^T \mathbf{Q} M x(k)$$

- Účelová funkcia potom bude

$$J(U(k)) = U(k)^T \mathbf{H} U(k) + 2\mathbf{b}^T(k) U(k) + \mathbf{c}(k)$$

- Získali sme tak kvadratickú formu účelovej funkcie vzhľadom na $U(k)$

Analytické optimum účelovej funkcie

- Pre účelovú funkciu v kvadratickej forme vieme nájsť analytické optimum
- Gradient $J(U(k))$ je rovný
$$\nabla J(U(k)) = \nabla\left(U(k)^T \mathbf{H} U(k) + 2\mathbf{b}^T(k)U(k) + \mathbf{c}(k)\right) = 2\mathbf{H}U(k) + 2\mathbf{b}(k)$$
- Podmienka optima bez ohraničení (stacionárny bod) $\nabla J(U(k)) = \mathbf{0}$ vedie na
$$\mathbf{H}U(k) + \mathbf{b}(k) = \mathbf{0}$$
- To nám dáva riešenie pre optimálny vektor $U^*(k)$ ako
$$U^*(k) = -\mathbf{H}^{-1}\mathbf{b}(k)$$
- Dosadíme naspäť $\mathbf{H} = \left(N^T\mathbf{Q}N + \mathbf{R}\right),\ \ \mathbf{b}(k) = N^T\mathbf{Q}Mx(k)$ a získame
$$U^*(k) = -\left(N^T\mathbf{Q}N + \mathbf{R}\right)^{-1} N^T\mathbf{Q}Mx(k)$$
- Hesseho matica problému bude
$$\nabla^2 J(U(k)) = 2\left(N^T\mathbf{Q}N + \mathbf{R}\right) \succ 0$$
  - Nájdený stacionárny bod je preto globálnym minimom

Lineárny spätnoväzobný zákon riadenia



- Sekvencia budúcich akčných zásahov $U^*(k)$ sa neaplikuje celá naraz
- Ak z vektora $U^*(k)$ vyberieme len prvých r riadkov, získame akčný zásah v aktuálnom kroku

$$u^*(k) = (I \quad \mathbf{0} \quad \cdots \quad \mathbf{0})U^*(k)$$

- Optimálny akčný zásah $u^*(k)$ je lineárny voči stavu $x(k)$

$$u^*(k) = -(I \quad \mathbf{0} \quad \cdots \quad \mathbf{0})\left(N^T\mathbf{Q}N + \mathbf{R}\right)^{-1}N^T\mathbf{Q}Mx(k)$$

- Získavame tak lineárny späznoväzobný zákon riadenia v tvare

$$u^*(k) = Kx(k)$$

  - Matica zosilnenia $K \in \mathbb{R}^{r\times n}$ stavovej spätnej väzby potom bude

$$K = -(I \quad \mathbf{0} \quad \cdots \quad \mathbf{0})\left(N^T\mathbf{Q}N + \mathbf{R}\right)^{-1}N^T\mathbf{Q}M$$

- Platí to však iba v prípade bez ohraničení

Zhrnutie postupu návrhu prediktívneho regulátora bez ohraničení



- Potrebujem poznať matice systému A a B a teda aj rozmery n a r
- Zvolím si horizont predikcie p
- Zvolím si matice Q a R ako symetrické a kladne definitné a naplním si matice $\mathbf{Q}$ a $\mathbf{R}$ ako blokovo diagonálne
- Naplním si matice M a N ako

$$M = \begin{pmatrix} A \\ A^2 \\ \vdots \\ A^p \end{pmatrix}, \qquad N = \begin{pmatrix} B & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ AB & B & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ A^{p-1}B & A^{p-2}B & \cdots & AB & B \end{pmatrix}$$

- Vypočítam zosilnenie spätnej väzby lineárneho stavového regulátora

$$K = -(I \quad \mathbf{0} \quad \cdots \quad \mathbf{0})\left(N^T\mathbf{Q}N + \mathbf{R}\right)^{-1}N^T\mathbf{Q}M$$

- Akčný zásah ďalej počítam v každom kroku ako $u(k) = Kx(k)$

Stabilita diskrétnych systémov

- Stabilita vyjadruje ako sa systém správa v čase po vychýlení zo svojho rovnovážneho stavu
- Definuje schopnosť systému vrátiť sa alebo zostať blízko rovnovážneho stavu $x^* \in \mathbb{R}^n$
- Na analýzu stability sa používa Lyapunovova teória
- Uvažujme Lyapunovovu funkciu $V(x(k))$ ktorá je skalárnou funkciou stavu
- Lyapunovova funkcia $V(x(k))$ musí byť definovaná tak aby spĺňala
  - $V\big(x(k)\big) \geq 0$ (vždy kladná)
  - $V(x^*) = 0$ (má minimum v rovnovážnom stave x^*)
- Lyapunovova funkcia $V(x(k))$ je metrika vyjadrujúca geometrickú vzdialenosť stavu $x(k)$ od rovnovážneho stavu x^*

Kvadratická Lyapunovova funkcia

- Najčastejšie sa stretávame s Lyapunovovou funkciou v kvadratickom tvare (kvadratická forma) ako

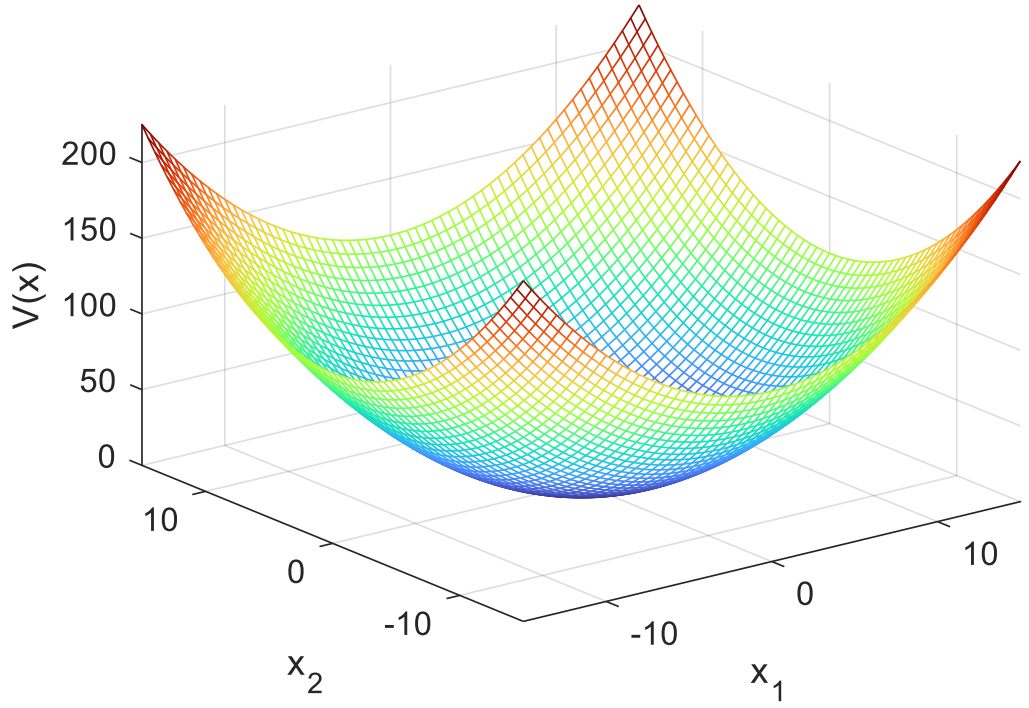
$$V\big(x(k)\big) = (x(k) - x^*)^T P(x(k) - x^*)$$

kde $P \in \mathbb{R}^{n \times n}$ je symetrická ($P = P^T$) a kladne definitná matica ($P \succ 0$)

- Pre takúto Lyapunovovu funkciu platia podmienky

$V\big(x(k)\big) = (x(k) - x^*)^T P(x(k) - x^*) \geq 0$ (vždy kladná)

$V(x^*) = (x^* - x^*)^T P(x^* - x^*) = 0$ (má minimum v x^*, ktoré je rovné 0)



$$x^* = \mathbf{0}$$
$$P = I$$

Podmienka stability diskrétnych systémov

- Ak je systém stabilný, malo by platiť, že $V\big(x(\infty)\big) = V(x^*) = 0$ a teda stav systému konverguje do ustáleného stavu
- Na to aby bola zabezpečená stabilita (konvergencia $V(x(k))$ do nuly), musí hodnota $V(x(k))$ klesať v čase (vzhľadom na k)
- Definujeme preto podmienku stability s využitím diferencie ako:

$$V\big(x(k+1)\big) - V\big(x(k)\big) < 0$$

- Táto podmienka znamená, že zmena Lyapunovovej funkcie musí byť záporná pre ľubovoľné $x(k)$

Stabilita diskrétnych lineárnych systémov

- Uvažujme systém bez riadenia $u(k) = \mathbf{0}$ čomu zodpovedá ustálený stav $x^* = \mathbf{0}$
- Kvadratická Lyapunovova funkcia potom bude

$$V\big(x(k)\big) = \big(x(k)\big)^T P x(k)$$

- Majme podmienku stability

$$V\big(x(k+1)\big) - V\big(x(k)\big) < 0$$

- Za $x(k+1)$ dosadíme diferenčnú rovnicu $x(k+1) = Ax(k)$ a získame

$$\big(Ax(k)\big)^T PAx(k) - \big(x(k)\big)^T Px(k) < 0$$
$$\big(x(k)\big)^T \big(A^T PA - P\big)x(k) < 0$$

- To vieme previesť zo skalárnej podmienky na podmienku definitnosti

$$A^T PA - P \prec 0$$

Overenie stability MPC

- V našom MPC optimalizujeme iba konečný počet krokov. Problém je, že regulátor vidí systém iba po čas $k + p$. Čo sa stane so systémom za týmto bodom, účelová funkcia vôbec nehodnotí.
- Stabilita MPC nie je automaticky zaručená len tým, že v každom kroku minimalizujeme účelovú funkciu.
- Stabilitu vieme aspoň overiť
  - Odvodili sme spätnoväzobný lineárny stavový zákon riadenia

$$K_{\mathrm{MPC}} = -(I \quad \mathbf{0} \quad \cdots \quad \mathbf{0})\left(N^T \mathbf{Q} N + \mathbf{R}\right)^{-1} N^T \mathbf{Q} M$$

  - Po dosadení do diferenčnej rovnice riadeného systému dostávame uzavretú slučku

$$x(k+1) = Ax(k) + Bu(k)$$
$$x(k+1) = Ax(k) + BKx(k)$$
$$x(k+1) = (A + BK)x(k)$$

  - Podmienka stability diskrétnych lineárnych systémov potom vedie na

$$(A + BK)^T (A + BK) - I \prec 0$$

  - Táto podmienka je splnená ak sú všetky vlastné čísla matice$(A + BK)$ v jednotkovej kružnici (ich veľkosť v komplexnej rovine je < 1)

Zabezpečenie stability MPC

- Riešením je povedať MPC regulátoru:
  - „Na konci predikčného horizontu nechceme iba malý stav. Chceme, aby bol systém v stave, z ktorého vieme pokračovať stabilným spôsobom.“
- Preto k účelovej funkcii pridáme takzvanú terminálnu (koncovú) penalizáciu:

$$V_f\big(x(k+p)\big) = x^T(k+p)Px(k+p)$$

kde $P \in \mathbb{R}^{n\times n}$, $P = P^T$, $P \succ 0$ je váhovacia matica koncovej penalizácie.

- Účelová funkcia potom bude

$$J_{\text{MPC}} = \sum_{i=0}^{p-1} [x^T(k+i)Qx(k+i) + u^T(k+i)Ru(k+i)] + x^T(k+p)Px(k+p)$$

- Predstavme si, že na konci horizontu už nepoužívame MPC, ale lineárny stabilizujúci regulátor

$$u(k+p) = Kx(k+p)$$

- Pri lineárnom systéme môžeme ako K použiť LQ regulátor.
- LQ regulátor minimalizuje účelovú funkciu na nekonečnom horizonte

$$J_{\text{LQ}} = \sum_{i=p}^{\infty} x(k+i)^T Qx(k+i) + u(k+i)^T Ru(k+i)$$

- Pričom zosilnenie sa určí na základe riešenia Riccatiho rovnice

$$P = A^T PA + Q - A^T PB\big(B^T PB + R\big)^{-1} B^T PA$$

$$K = -\big(B^T PB + R\big)^{-1} B^T PA$$

- Takto získané P potom použijeme ako váhovaciu maticu koncovej penalizácie pri MPC

Prečo práve Riccatiho matica P?

- Lineárny zákon riadenia je $u(k+p) = Kx(k+p)$
- Po skončení horizontu predikcie sa systém bude správať ako

$$x(k+p+1) = Ax(k+p) + Bu(k+p)$$
$$x(k+p+1) = Ax(k+p) + BKx(k+p)$$
$$x(k+p+1) = (A+BK)x(k+p)$$

- Máme koncovú penalizáciu

$$V_f\big(x(k+p)\big) = x^T(k+p)Px(k+p)$$

- Túto funkciu teraz považujme za Lyapunovovu funkciu
- Podmienka stability hovorí, že Lyapunovova funkcia musí klesať

$$V_f\left(x(k+p+1)\right) - V_f\big(x(k+p)\big) = x^T(k+p+1)Px(k+p+1) - x^T(k+p)Px(k+p) < 0$$

- Dosadíme teraz $x(k+p+1) = (A+BK)x(k+p)$

$$V_f\left(x(k+1)\right) - V_f\big(x(k)\big) = x^T(k+p)\big((A+BK)^T(A+BK) - P\big)x(k+p)$$

- Pre riešenie Riccatiho rovnice platí

$$P = (A+BK)^T P(A+BK) + Q + K^T RK$$

- Potom $(A+BK)^T P(A+BK) - P = -Q - K^T RK \prec 0$ bude

$$(A+BK)^T P(A+BK) - P = -Q - K^T RK$$

- Diferencia Lyapunovovej funkcie potom bude

$$V_f\left(x(k+1)\right) - V_f\big(x(k)\big) = -x^T(k+p)\big(Q + K^T RK\big)x(k+p)$$

- Pretože Q a $K^T RK$ sú kladne definitné matice, tak $V_f\left(x(k+1)\right) - V_f\big(x(k)\big) < 0$, čím získavame stabilné riadenie
- Terminálny regulátor teda zabezpečuje, že od konca horizontu bude systém stabilný

Ako sa to prenesie na celé MPC?

- Účelová funkcia MPC s koncovou penalizáciou je

$$J_{\mathrm{MPC}} = \sum_{i=0}^{p-1} [x^T(k+i)Qx(k+i) + u^T(k+i)Ru(k+i)] + x^T(k+p)Px(k+p)$$

- Z teórie LQ riadenia vieme, že účelovú funkciu na nekonečnom horizonte môžeme vyjadriť ako

$$J_{\mathrm{LQ}} = \sum_{i=p}^{\infty} x(k+i)^T Qx(k+i) + u(k+i)^T Ru(k+i) \; = x^T(k+p)Px(k+p)$$

- Účelová funkcia MPC s koncovou penalizáciou sa potom stane

$$J_{\mathrm{MPC}} = \sum_{i=0}^{p-1} x^T(k+i)Qx(k+i) + u^T(k+i)Ru(k+i) + \sum_{i=p}^{\infty} x(k+i)^T Qx(k+i) + u(k+i)^T Ru(k+i)$$

$$= \sum_{i=0}^{\infty} x(k+i)^T Qx(k+i) + u(k+i)^T Ru(k+i)$$

- Ak zvolíme koncovú penalizáciu P ako riešenie LQ problému, potom koncová penalizácia reprezentuje optimálnu cenu pokračovania riadenia za koncom predikčného horizontu.
- Účelovú funkciu MPC preto môžeme interpretovať ako LQ účelovú funkciu na nekonečnom horizonte rozdelenú na konečnú časť optimalizovanú pomocou MPC a nekonečné pokračovanie reprezentované koncovou penalizáciou.
- Celý MPC problém sa tak dá interpretovať ako

MPC na konečnom horizonte + optimálne LQ pokračovanie za horizont = LQ riadenie na nekonečnom horizonte

Kedy teda MPC nie je iba LQ ?

- MPC získava svoju hlavnú výhodu vtedy, keď pridáme **obmedzenia**
- Potrebujeme zabezpečiť, aby posledný stav $x(k+p)$ ležal v oblasti, z ktorej vieme pokračovať stabilne a neporušiť ohraničenia.
- Táto oblasť sa nazýva terminálna množina $\mathcal{X}_f$
- Na konci predikčného horizontu preto pridáme podmienku

$$x(k+p) \in \mathcal{X}_f$$

- Potom pre $u(k+p+i) = Kx(k+p+i)$

$$x(k+p+1) = (A+BK)x(k+p)$$

- Terminálna množina musí spĺňať podmienku

$$x \in \mathcal{X}_f \;\Rightarrow\; (A+BK)x \in \mathcal{X}_f$$

- Táto vlastnosť sa nazýva pozitívna invariantnosť
- Musí byť zároveň zabezpečené, že terminálny regulátor neporuší obmedzenia (vstupné a stavové):

$$x \in \mathcal{X}_f \;\Rightarrow\; Kx \in \mathcal{U}$$
$$x \in \mathcal{X}_f \;\Rightarrow\; x \in \mathcal{X}$$

- MPC dovedie systém do oblasti, o ktorej vieme, že z nej ho dokážeme stabilne riadiť bez porušenia obmedzení

Inkrementálna forma pre riadenie výstupu na želanú hodnotu

- Uvažujme inkrementálny akčný zásah kde $u(k)$ sa počíta rekurzívne ako

$$u(k) = \Delta u(k) + u(k-1)$$

  - Člen $\Delta u(k) = u(k) - u(k-1)$ nazývame inkrement (zmena) akčného zásahu
  - Pridávame tak vlastne diskrétny integrátor na vstup do systému/ na výstup regulátora
- Pre budúce akčné zásahy $U(k)$ bude platiť

$$U(k) = \begin{pmatrix} u(k) \\ u(k+1) \\ u(k+2) \\ \vdots \\ u(k+p-2) \\ u(k+p-1) \end{pmatrix} = \begin{pmatrix} I & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ I & I & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ I & I & I & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ I & I & I & \cdots & I & \mathbf{0} \\ I & I & I & \cdots & I & I \end{pmatrix} \begin{pmatrix} \Delta u(k) \\ \Delta u(k+1) \\ \Delta u(k+2) \\ \vdots \\ \Delta u(k+p-2) \\ \Delta u(k+p-1) \end{pmatrix} + \begin{pmatrix} I \\ I \\ I \\ \vdots \\ I \\ I \end{pmatrix} u(k-1)$$

- Tento vzťah budeme zapisovať skrátene ako

$$U(k) = \Gamma \Delta U(k) + \mathbf{1} u(k-1)$$

kde $\Delta U(k) \in \mathbb{R}^{rp}$, $\Gamma \in \mathbb{R}^{rp \times rp}$ (je takzvaná kumulatívna sumačná matica)

- Inkrementálna forma riadenia má zmysel pri:
  - penalizácii zmien akčného zásahu
  - sledovaní žiadanej hodnoty výstupu (integračný charakter)

Výstup lineárneho modelu v stavovom opise

- Uvažujme systém s m výstupmi
- Rovnica pre výstup systému $y(k) \in \mathbb{R}^m$ bude

$$y(k) = Cx(k)$$

- Matica $C \in \mathbb{R}^{m \times n}$ je daná ako:

$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mn} \end{pmatrix}$$

- Zadefinujme rozšírený predikovaný výstupný vektor $Y(k) \in \mathbb{R}^{pm}$ ako

$$Y(k) = \begin{pmatrix} y(k+1) \\ y(k+2) \\ y(k+3) \\ \vdots \\ y(k+p-1) \\ y(k+p) \end{pmatrix} = \begin{pmatrix} Cx(k+1) \\ Cx(k+2) \\ Cx(k+3) \\ \vdots \\ Cx(k+p-1) \\ Cx(k+p) \end{pmatrix}$$

Prediktívna rovnica pre výstup

- Viackroková predikcia výstupu potom bude

$$y(k+i) = CA^i x(k) + \sum_{j=1}^{i} CA^{i-j} B u(k+j-1)$$

- Túto rovnicu vieme napísať s využitím rozšíreného výstupného vektora $Y(k)$ a vstupného vektora $U(k)$ ako

$$\begin{pmatrix} y(k+1) \\ y(k+2) \\ y(k+3) \\ \vdots \\ y(k+p-1) \\ y(k+p) \end{pmatrix} = \begin{pmatrix} CA \\ CA^2 \\ CA^3 \\ \vdots \\ CA^{p-1} \\ CA^p \end{pmatrix} x(k) + \begin{pmatrix} CB & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ CAB & CB & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ CA^2B & CAB & CB & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ CA^{p-2}B & CA^{p-3}B & CA^{p-4}B & \cdots & CB & \mathbf{0} \\ CA^{p-1}B & CA^{p-2}B & CA^{p-3}B & \cdots & CAB & CB \end{pmatrix} \begin{pmatrix} u(k) \\ u(k+1) \\ u(k+2) \\ \vdots \\ u(k+p-2) \\ u(k+p-1) \end{pmatrix}$$

$$Y(k) = Mx(k) + NU(k)$$

- $M \in \mathbb{R}^{mp \times n}$ je predikčná matica voľnej odozvy
- $N \in \mathbb{R}^{mp \times rp}$ je predikčná matica vynútenej odozvy

Účelová funkcia prediktívneho riadenia na referenčnú hodnotu výstupu s penalizáciou zmien akčného zásahu



- Prediktívne riadenie definuje účelovú funkciu $J(\Delta U(k))$ v kroku k ako funkciu vektora budúcich zmien akčných zásahov $\Delta U(k)$ na konečnom predikčnom horizonte p vzhľadom na žiadanú hodnotu výstupu $\tilde{y}$ ako

$$J(\Delta U(k)) = \sum_{i=1}^{p} \big(y(k+i) - \tilde{y}(k+i)\big)^T Q\big(y(k+i) - \tilde{y}(k+i)\big) + \Delta u(k+i-1)^T R \Delta u(k+i-1)$$

  $\tilde{y}(k+i) \in \mathbb{R}^m$ je referenčná (žiadaná) hodnota výstupu

  $Q \in \mathbb{R}^{m \times m}, Q = Q^T, Q \succ 0$ je váhovacia matica penalizácie odchýlky výstupu od referenčnej hodnoty

  $R \in \mathbb{R}^{r \times r}, R = R^T, R \succ 0$ je váhovacia matica penalizácie zmien vstupov

- Účelová funkcia penalizuje:
  - odchýlky výstupu od referenčnej hodnoty cez člen $\big(y(k+i) - \tilde{y}(k+i)\big)^T Q\big(y(k+i) - \tilde{y}(k+i)\big)$
  - zmeny vstupov cez člen $\Delta u(k+i-1)^T R \Delta u(k+i-1)$

Rozšírené váhovacie matice a referenčný vektor výstupu

- Účelovú funkciu možno napísať v maticovo-vektorovom tvare (bez sumácie) ako

$$J(\Delta U(k)) = \left(Y(k) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Y(k) - \tilde{Y}(k)\right) + \Delta U(k)^T \mathbf{R}\, \Delta U(k)$$

- Matica $\mathbf{Q} \in \mathbb{R}^{pm \times pm}$ bude blokovo diagonálna

$$\mathbf{Q} = \begin{pmatrix} Q & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & Q & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & Q \end{pmatrix}$$

- Matica $\mathbf{R} \in \mathbb{R}^{pr \times pr}$ bude blokovo diagonálna

$$\mathbf{R} = \begin{pmatrix} R & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & R & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & R \end{pmatrix}$$

- Rozšírený vektor $\tilde{Y}(k) \in \mathbb{R}^{pm}$ žiadanej (referenčnej) hodnoty výstupu bude

$$\tilde{Y}(k) = \begin{pmatrix} \tilde{y}(k+1) \\ \tilde{y}(k+2) \\ \vdots \\ \tilde{y}(k+p-1) \\ \tilde{y}(k+p) \end{pmatrix}$$

Kvadratická forma účelovej funkcie

- Máme účelovú funkciu v kompaktnom (maticovo-vektorovom) tvare

$$J(\Delta U(k)) = \left(Y(k) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Y(k) - \tilde{Y}(k)\right) + \Delta U(k)^T \mathbf{R}\, \Delta U(k)$$

- Za $Y(k)$ dosadíme prediktívnu rovnicu $Y(k) = Mx(k) + NU(k)$ a

$$J(\Delta U(k)) = \left(Mx(k) + NU(k) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Mx(k) + NU(k) - \tilde{Y}(k)\right) + \Delta U(k)^T \mathbf{R} \Delta U(k)$$

- Za $U(k)$ dosadíme inkrementálnu formu $U(k) = \Gamma \Delta U(k) + \mathbf{1} u(k-1)$

$$J(\Delta U(k))$$
$$= \left(Mx(k) + N\left(\Gamma \Delta U(k) + \mathbf{1} u(k-1)\right) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Mx(k) + N\left(\Gamma \Delta U(k) + \mathbf{1} u(k-1)\right) - \tilde{Y}(k)\right)$$
$$+ \Delta U(k)^T \mathbf{R} \Delta U(k)$$

- Účelovú funkciu roznásobíme a upravíme

$$J(\Delta U(k))$$
$$= \Delta U(k)^T \left(\Gamma^T N^T \mathbf{Q} N \Gamma + \mathbf{R}\right) \Delta U(k) + 2 \left(Mx(k) + N\mathbf{1} u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} N \Gamma \Delta U(k)$$
$$+ \left(Mx(k) + N\mathbf{1} u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Mx(k) + N\mathbf{1} u(k-1) - \tilde{Y}(k)\right)$$

Kvadratická forma účelovej funkcie

- Máme účelovú funkciu
$J(\Delta U(k))$
$= \Delta U(k)^T \left(\Gamma^T N^T \mathbf{Q} N \Gamma + \mathbf{R}\right) \Delta U(k) + 2 \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} N \Gamma \Delta U(k)$
$+ \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)$
- Zavedieme si nasledovné substitúcie pre zjednodušenie označovania:

$$\mathbf{H} = \left(\Gamma^T N^T \mathbf{Q} N \Gamma + \mathbf{R}\right),$$

$$\mathbf{b}^T(k) = \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} N \Gamma,$$

$$\mathbf{c}(k) = \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)$$

- Získali sme tak kvadratickú formu účelovej funkcie vzhľadom na vektor $\Delta U(k)$

$$J(\Delta U(k)) = \Delta U(k)^T \mathbf{H} \Delta U(k) + 2\mathbf{b}^T(k) \Delta U(k) + \mathbf{c}(k)$$

- Optimálny vektor $\Delta U^*(k)$ potom bude

$$\Delta U^*(k) = -\mathbf{H}^{-1}\mathbf{b}(k)$$

Ohraničenia akčného zásahu

- Uvažujme horné a dolné ohraničenie akčného zásahu

$$\underline{u} \leq u(k) \leq \overline{u}$$

- Zavedieme vektory $\underline{U} \in \mathbb{R}^{pr}$, $\overline{U} \in \mathbb{R}^{pr}$ ako

$$\underline{U} = \begin{pmatrix} \underline{u} \\ \vdots \\ \underline{u} \end{pmatrix}, \qquad \overline{U} = \begin{pmatrix} \overline{u} \\ \vdots \\ \overline{u} \end{pmatrix}$$

- Pre $U(k)$ potom musí platiť

$$\underline{U} \leq U(k) \leq \overline{U}$$

- Pre neinkrementálnu formu riadenia získavame sústavu lineárnych nerovníc

$$\begin{pmatrix} I \\ -I \end{pmatrix} U(k) \leq \begin{pmatrix} \overline{U} \\ -\underline{U} \end{pmatrix}$$

Ohraničenia akčného zásahu (inkrementálna forma)

- Uvažujme horné a dolné ohraničenie akčného zásahu

$$\underline{u} \leq u(k) \leq \overline{u}$$

- Zavedieme vektory $\underline{U} \in \mathbb{R}^{pr}$, $\overline{U} \in \mathbb{R}^{pr}$ ako

$$\underline{U} = \begin{pmatrix} \underline{u} \\ \vdots \\ \underline{u} \end{pmatrix}, \qquad \overline{U} = \begin{pmatrix} \overline{u} \\ \vdots \\ \overline{u} \end{pmatrix}$$

- Pre $U(k)$ musí platiť

$$\underline{U} \leq U(k) \leq \overline{U}$$

- Pre inkrementálnu formu riadenia potom bude platiť

$$U(k) = \Gamma \Delta U(k) + \mathbf{1} u(k-1)$$
$$\underline{U} \leq \Gamma \Delta U(k) + \mathbf{1} u(k-1) \leq \overline{U}$$

- Nájdeme nerovnice pre $\Delta U(k)$

$$\underline{U} - \mathbf{1} u(k-1) \leq \Gamma \Delta U(k) \leq \overline{U} - \mathbf{1} u(k-1)$$

- Príslušná sústava lineárnych nerovníc bude

$$\begin{pmatrix} \Gamma \\ -\Gamma \end{pmatrix} \Delta U(k) \leq \begin{pmatrix} \overline{U} - \mathbf{1} u(k-1) \\ -\underline{U} + \mathbf{1} u(k-1) \end{pmatrix}$$

Ohraničenia stavu

- Uvažujme horné a dolné ohraničenie stavového vektora

$$\underline{x} \leq x(k) \leq \overline{x}$$

- Zavedieme vektory $\underline{X} \in \mathbb{R}^{pn}$, $\overline{X} \in \mathbb{R}^{pn}$ ako

$$\underline{X} = \begin{pmatrix} \underline{x} \\ \vdots \\ \underline{x} \end{pmatrix}, \qquad \overline{X} = \begin{pmatrix} \overline{x} \\ \vdots \\ \overline{x} \end{pmatrix}$$

- Pre $X(k)$ potom bude platiť

$$\underline{X} \leq X(k) \leq \overline{X}$$

- Uvažujme prediktívnu rovnicu pre $X(k)$

$$X(k) = Mx(k) + NU(k)$$

- Nájdeme nerovnice pre $\Delta U(k)$

$$\underline{X} \leq Mx(k) + NU(k) \leq \overline{X}$$
$$\underline{X} - Mx(k) \leq NU(k) \leq \overline{X} - Mx(k)$$

- Príslušná sústava lineárnych nerovníc bude

$$\begin{pmatrix} N \\ -N \end{pmatrix} U(k) \leq \begin{pmatrix} \overline{X} - Mx(k) \\ -\underline{X} + Mx(k) \end{pmatrix}$$

Ohraničenia výstupu (inkrementálna forma)

- Uvažujme horné a dolné ohraničenie výstupného vektora

$$\underline{y} \leq y(k) \leq \overline{y}$$

- Zavedieme vektory $\underline{Y} \in \mathbb{R}^{pm}$, $\overline{Y} \in \mathbb{R}^{pm}$ ako

$$\underline{Y} = \begin{pmatrix} \underline{y} \\ \vdots \\ \underline{y} \end{pmatrix}, \qquad \overline{Y} = \begin{pmatrix} \overline{y} \\ \vdots \\ \overline{y} \end{pmatrix}$$

- Pre $Y(k)$ potom bude platiť

$$\underline{Y} \leq Y(k) \leq \overline{Y}$$

- Uvažujme prediktívnu rovnicu pre $Y(k)$ a inkrementálnu formu riadenia

$$Y(k) = Mx(k) + N\left(\Gamma \Delta U(k) + \mathbf{1}u(k-1)\right)$$

- Nájdeme nerovnice pre $\Delta U(k)$

$$\underline{Y} \leq Mx(k) + N\left(\Gamma \Delta U(k) + \mathbf{1}u(k-1)\right) \leq \overline{Y}$$

$$\underline{Y} - Mx(k) - N\mathbf{1}u(k-1) \leq N\Gamma \Delta U(k) \leq \overline{Y} - Mx(k) - N\mathbf{1}u(k-1)$$

- Príslušná sústava lineárnych nerovníc bude

$$\begin{pmatrix} N\Gamma \\ -N\Gamma \end{pmatrix} \Delta U(k) \leq \begin{pmatrix} \overline{Y} - Mx(k) - N\mathbf{1}u(k-1) \\ -\underline{Y} + Mx(k) + N\mathbf{1}u(k-1) \end{pmatrix}$$

Zhrnutie postupu návrhu stavového prediktívneho riadenia s ohraničeniami



- Potrebujem poznať matice systému A a B a teda aj rozmery n a r
- Zvolím si horizont predikcie p
- Špecifikujem ohraničenia akčného zásahu $\underline{u} \leq u(k) \leq \overline{u}$ a vektory $\underline{U} = \begin{pmatrix} \underline{u} \\ \vdots \\ \underline{u} \end{pmatrix}$, $\overline{U} = \begin{pmatrix} \overline{u} \\ \vdots \\ \overline{u} \end{pmatrix}$
- Špecifikujem ohraničenia stavov $\underline{x} \leq x(k) \leq \overline{x}$ a vektory $\underline{X} = \begin{pmatrix} \underline{x} \\ \vdots \\ \underline{x} \end{pmatrix}$, $\overline{X} = \begin{pmatrix} \overline{x} \\ \vdots \\ \overline{x} \end{pmatrix}$
- Naplním si matice M a N ako

$$M = \begin{pmatrix} A \\ A^2 \\ \vdots \\ A^p \end{pmatrix}, \quad N = \begin{pmatrix} B & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ AB & B & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ A^{p-1}B & A^{p-2}B & \cdots & AB & B \end{pmatrix}$$

- Definujem sústavu lineárnych nerovníc

$$\begin{pmatrix} I \\ -I \\ N \\ -N \end{pmatrix} U(k) \leq \begin{pmatrix} \overline{U} \\ -\underline{U} \\ \overline{X} - Mx(k) \\ -\underline{X} + Mx(k) \end{pmatrix}$$

- Zvolím si matice Q a R ako symetrické a kladne definitné a naplním si matice $\mathbf{Q}$ a $\mathbf{R}$ ako blokovo diagonálne
- Určím maticu $\mathbf{H}$ a vektor $\mathbf{b}$ kvadratickej formy $J(U(k)) = U(k)^T \mathbf{H} U(k) + 2\mathbf{b}^T(k) U(k)$ ako

$$\mathbf{H} = \left(N^T \mathbf{Q} N + \mathbf{R}\right), \mathbf{b}(k) = N^T \mathbf{Q} M x(k)$$

- V každom kroku riešim problém kvadratického programovania pre získanie $U^*(k)$
- Akčný zásah v aktuálnom kroku aplikujem ako

$$u^*(k) = (I \quad \mathbf{0} \quad \cdots \quad \mathbf{0}) U^*(k)$$

Zhrnutie postupu návrhu výstupného prediktívneho riadenia s ohraničeniami



- Potrebujem poznať matice systému A, B, C a teda aj rozmery n, r, m
- Zvolím si horizont predikcie p
- Špecifikujem referenčný vektor výstupu $\tilde{Y}(k) = \begin{pmatrix} \tilde{y}(k+1) \\ \vdots \\ \tilde{y}(k+p) \end{pmatrix}$
- Špecifikujem ohraničenia akčného zásahu $\underline{u} \leq u(k) \leq \overline{u}$ a vektory $\underline{U} = \begin{pmatrix} \underline{u} \\ \vdots \\ \underline{u} \end{pmatrix}$, $\overline{U} = \begin{pmatrix} \overline{u} \\ \vdots \\ \overline{u} \end{pmatrix}$
- Špecifikujem ohraničenia výstupu $\underline{y} \leq y(k) \leq \overline{y}$ a vektory $\underline{Y} = \begin{pmatrix} \underline{y} \\ \vdots \\ \underline{y} \end{pmatrix}, \overline{Y} = \begin{pmatrix} \overline{y} \\ \vdots \\ \overline{y} \end{pmatrix}$
- Naplním si matice M, N, Γ ako

$$M = \begin{pmatrix} CA \\ CA^2 \\ \vdots \\ CA^p \end{pmatrix}, \quad N = \begin{pmatrix} CB & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ CAB & CB & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ CA^{p-1}B & CA^{p-2}B & \cdots & CAB & CB \end{pmatrix}, \quad \Gamma = \begin{pmatrix} I & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ I & I & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ I & I & I & \cdots & I & I \end{pmatrix}$$

- Definujem sústavu lineárnych nerovníc

$$\begin{pmatrix} \Gamma \\ -\Gamma \\ N\Gamma \\ -N\Gamma \end{pmatrix} \Delta U(k) \leq \begin{pmatrix} \overline{U} - \mathbf{1}u(k-1) \\ -\underline{U} + \mathbf{1}u(k-1) \\ \overline{Y} - Mx(k) - N\mathbf{1}u(k-1) \\ -\underline{Y} + Mx(k) + N\mathbf{1}u(k-1) \end{pmatrix}$$

- Zvolím si matice Q a R ako symetrické a kladne definitné a naplním si matice $\mathbf{Q}$ a $\mathbf{R}$ ako blokovo diagonálne
- Určím maticu $\mathbf{H}$ a vektor $\mathbf{b}$ kvadratickej formy $J(\Delta U(k)) = \Delta U(k)^T \mathbf{H} \Delta U(k) + 2\mathbf{b}^T(k)\Delta U(k)$ ako

$$\mathbf{H} = \left(\Gamma^T N^T \mathbf{Q} N\Gamma + \mathbf{R}\right) \qquad \mathbf{b}^T(k) = \left(Mx(k) + N\mathbf{1}u(k-1) - \tilde{Y}(k)\right)^T \mathbf{Q} N\Gamma$$

- V každom kroku riešim problém kvadratického programovania pre získanie $\Delta U^*(k)$
- Akčný zásah v aktuálnom kroku aplikujem ako

$$u^*(k) = (I \quad \mathbf{0} \quad \cdots \quad \mathbf{0})\Delta U^*(k) + u^*(k-1)$$



Prediktívne riadenie

- Kvadratická účelová funkcia
- Konečný horizont optimalizácie
- Lineárny model v stavovom priestore
- Lineárny zákon riadenia (bez ohraničení)
- Analytické riešenie v zmysle minimalizácie kvadratickej formy (inverzia Hessiánu alebo kvadratické programovanie)
- Stabilita nie je explicitne garantovaná
- Možno zahrnúť ohraničenia

Lineárny kvadratický regulátor

- Kvadratická účelová funkcia
- Nekonečný horizont optimalizácie
- Lineárny model v stavovom priestore
- Lineárny zákon riadenia
- Riešenie v zmysle algebrickej Riccatiho rovnice
- Stabilita je explicitne garantovaná
- Nemožno zahrnúť ohraničenia



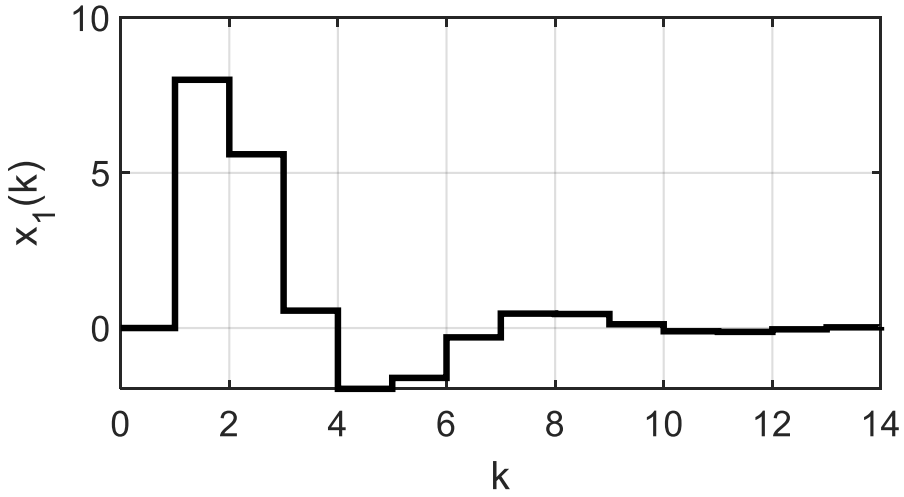
- **Výhody**
- Zabezpečuje minimálnu hodnotu kvadratického kritéria na konečnom horizonte
- Pre prípad bez ohraničení vedie na analytické riešenie a lineárny stavový zákon riadenia
- Umožňuje zahrnúť ohraničenia akčného zásahu a stavových premenných
- Pre prípad s ohraničeniami vedie na problém kvadratického programovania
- Intuitívne ladenie parametrov a správania regulačného obvodu
- Kombinovateľnosť s Kalmanovým filtrom pre odhad stavu
- Možnosť riadiť viacvstupové a viacvýstupové (MIMO) systémy

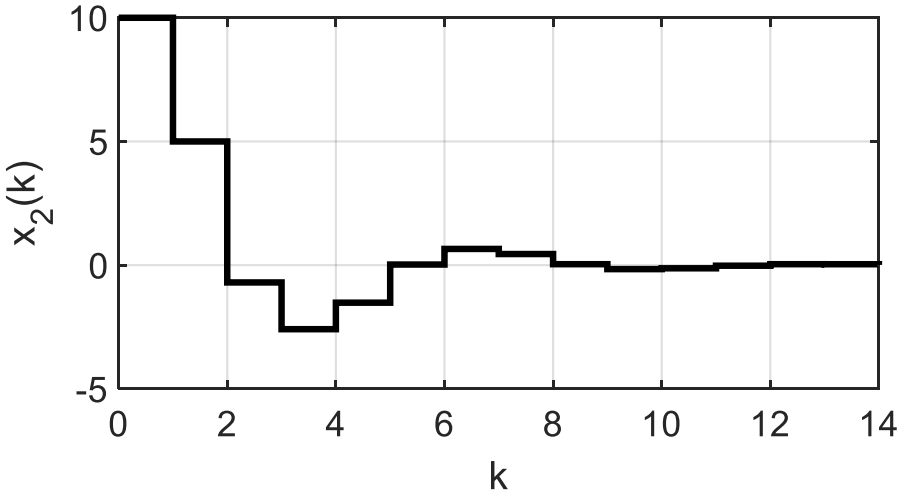
- **Nevýhody**
- Obmedzenie iba na lineárne systémy
- Explicitne nezabezpečuje stabilitu riadenia
- Vyžaduje merať alebo odhadnúť úplný stavový vektor
- Pre prípad s ohraničeniami vyžaduje riešenie optimalizačnej úlohy v reálnom čase
- Citlivý na rozdiely medzi modelom a skutočným systémom
- Nie je robustný voči parametrickým neurčitostiam

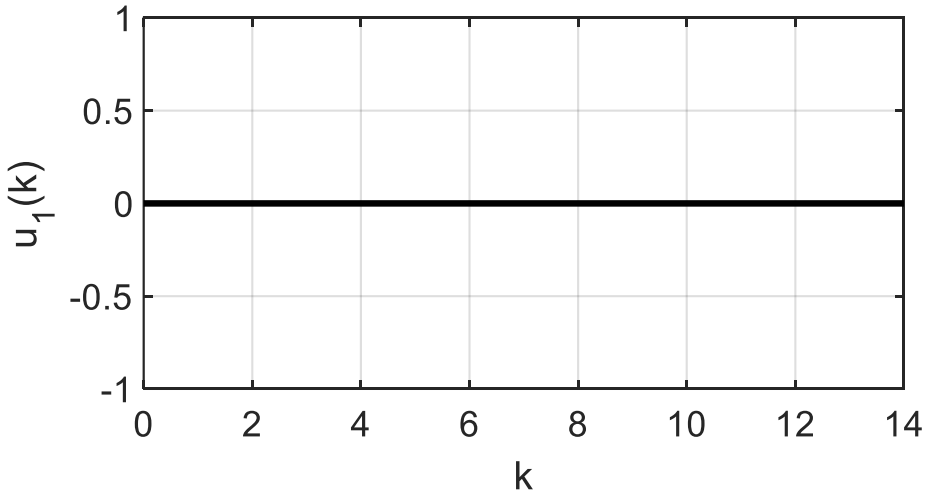
Odozva systému
(bez riadenia)

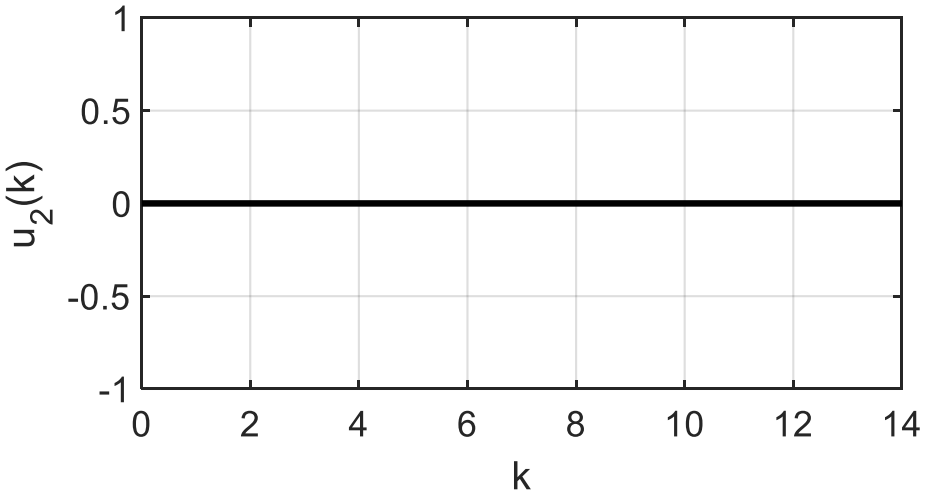
$$A = \begin{pmatrix} 0.2 & 0.8 \\ -0.4 & 0.5 \end{pmatrix}, B = \begin{pmatrix} 2 & 0.5 \\ 0 & 1 \end{pmatrix}$$

$$x(0) = \begin{pmatrix} 0 \\ 10 \end{pmatrix}$$









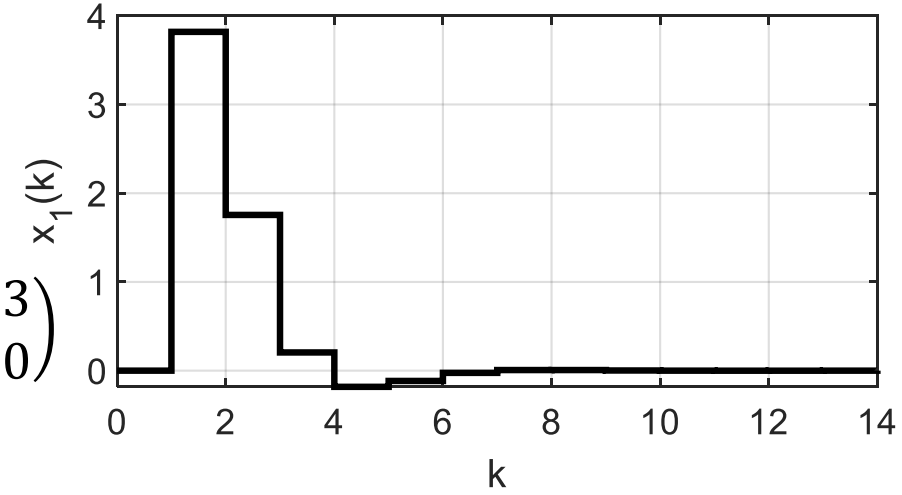
Prediktívne riadenie bez ohraničení

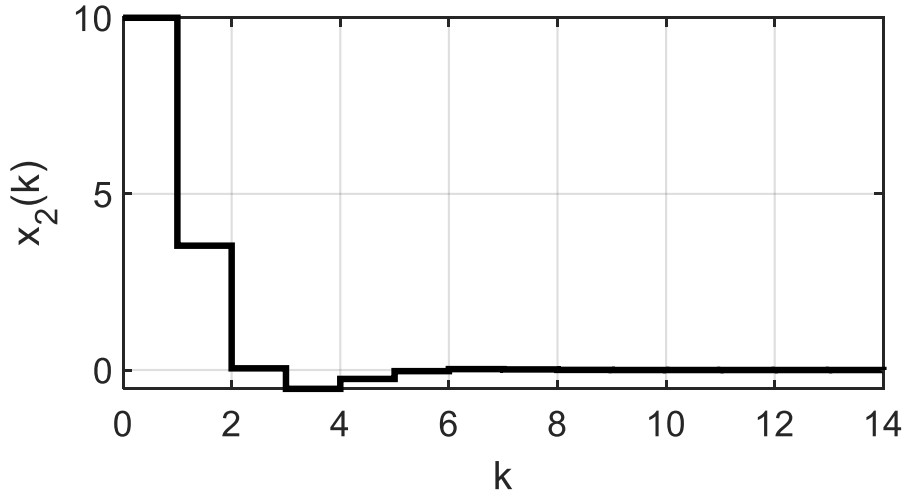
$$Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, R = \begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix}$$

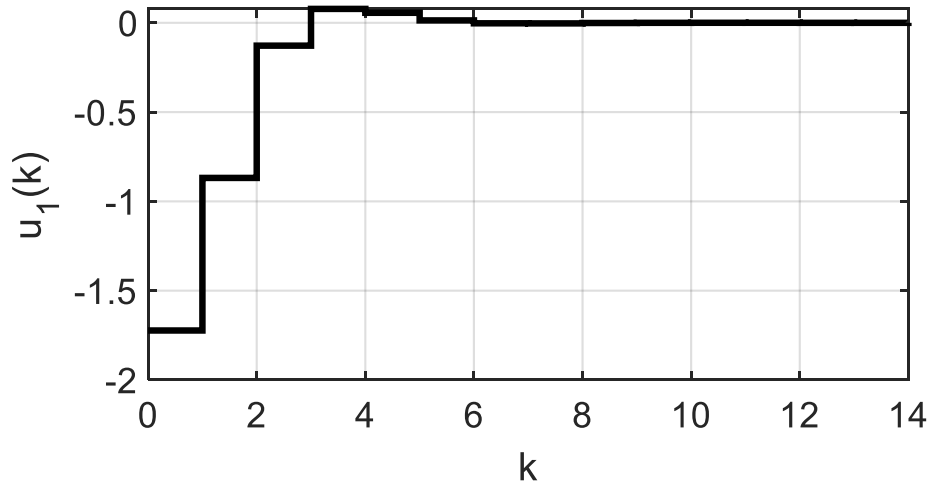
$$p = 5$$

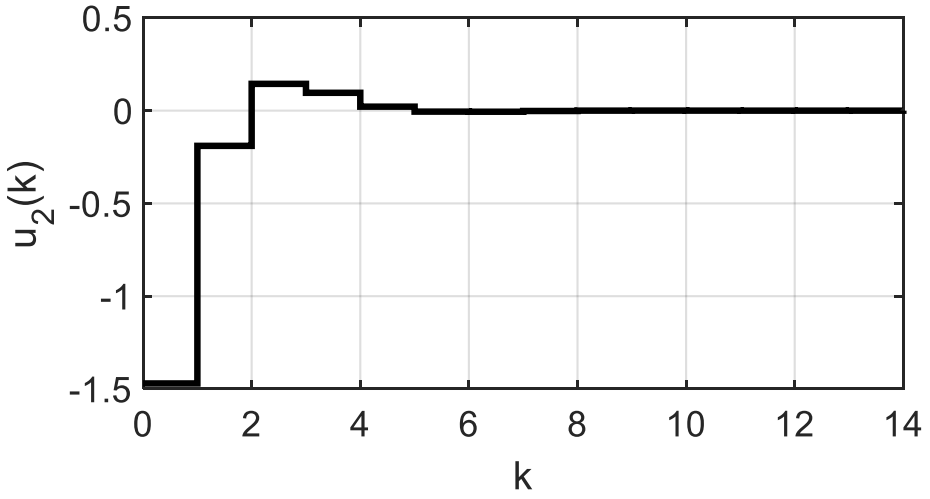
$$K = \begin{pmatrix} -0.0682 & -0.1723 \\ 0.0862 & -0.1470 \end{pmatrix}$$

$$x(0) = \begin{pmatrix} 0 \\ 10 \end{pmatrix}$$









Prediktívne riadenie s ohraničeniami

$Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, R = \begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix}$

$p = 5$

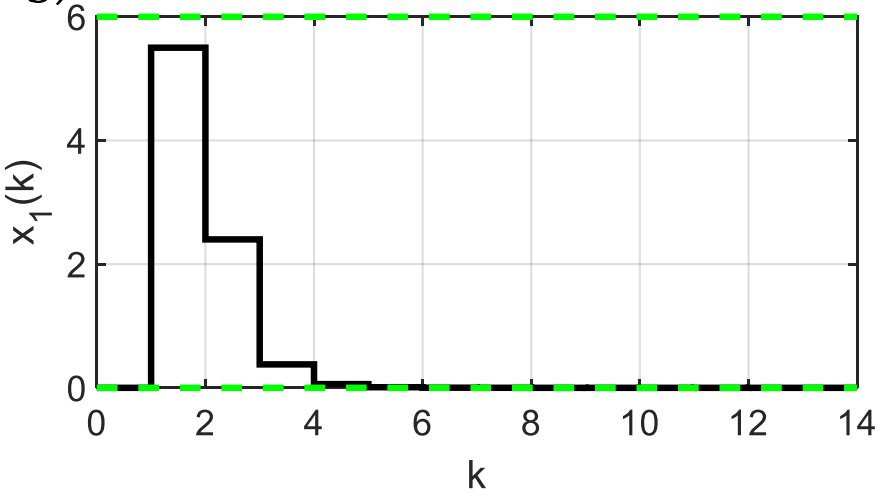
$x(0) = \begin{pmatrix} 0 \\ 10 \end{pmatrix}$

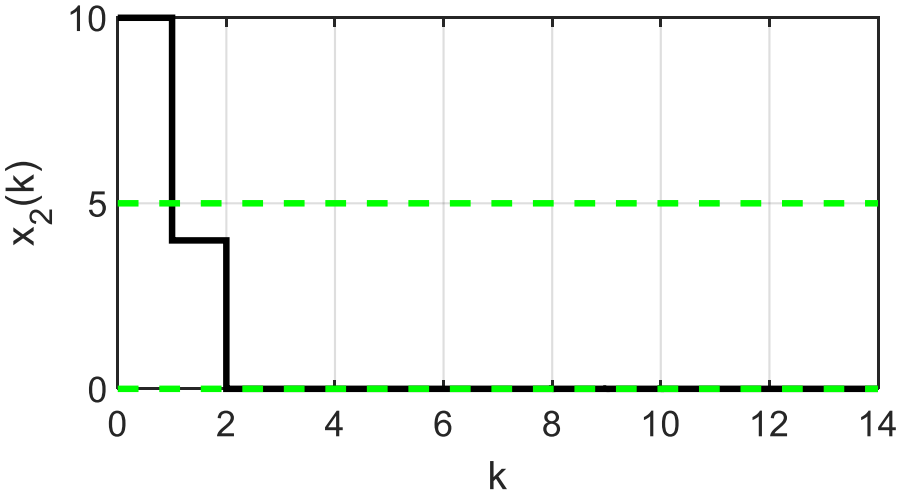
$\underline{u} = \begin{pmatrix} -1 \\ -1 \end{pmatrix}$

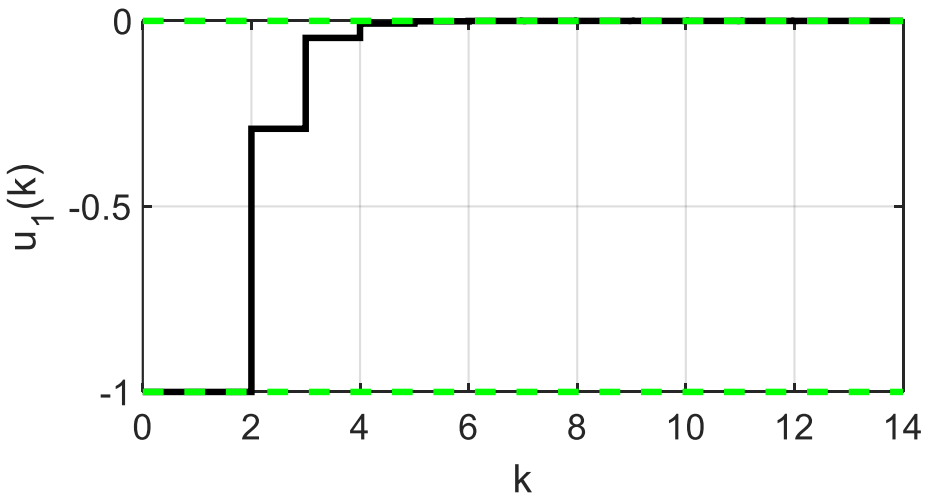
$\overline{u} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

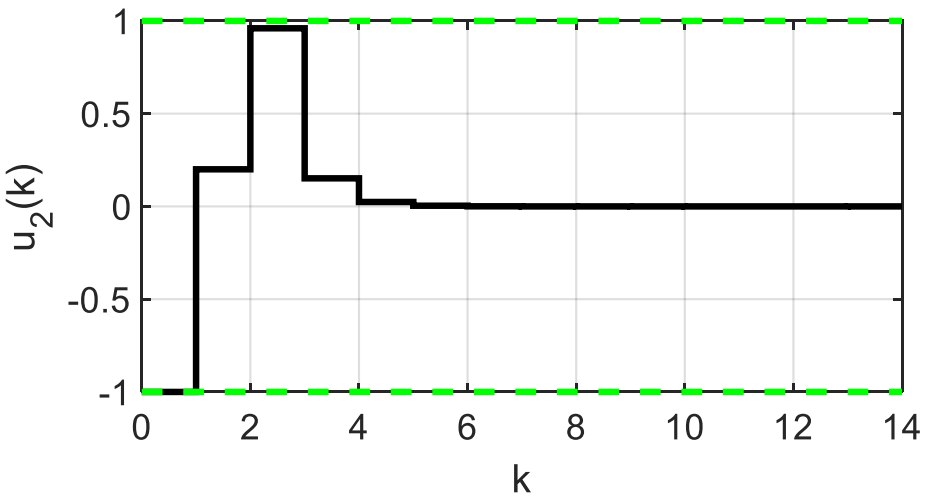
$\underline{x} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

$\overline{x} = \begin{pmatrix} 6 \\ 5 \end{pmatrix}$









Prediktívne riadenie na referenčnú hodnotu výstupu, v inkrementálnej forme a bez ohraničení

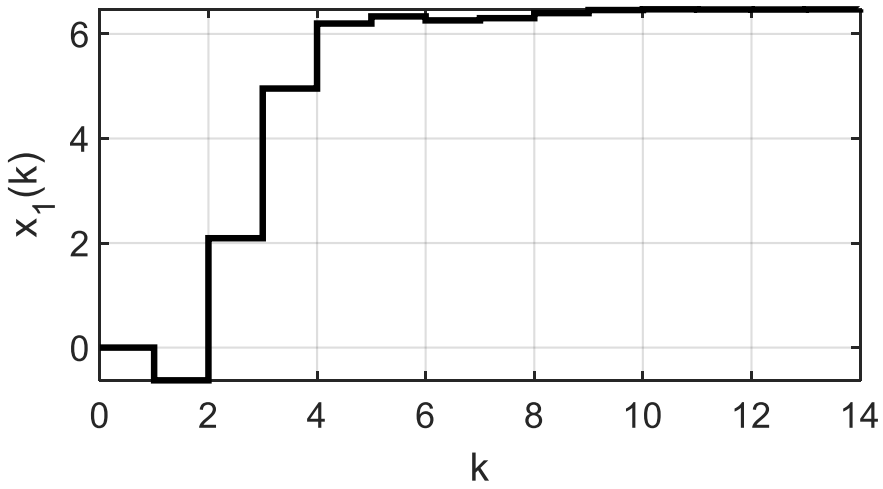
$$A = \begin{pmatrix} 0.2 & 0.8 \\ -0.4 & 0.5 \end{pmatrix}, B = \begin{pmatrix} 2 & 0.5 \\ 0 & 1 \end{pmatrix}, C = (0 \quad 1)$$

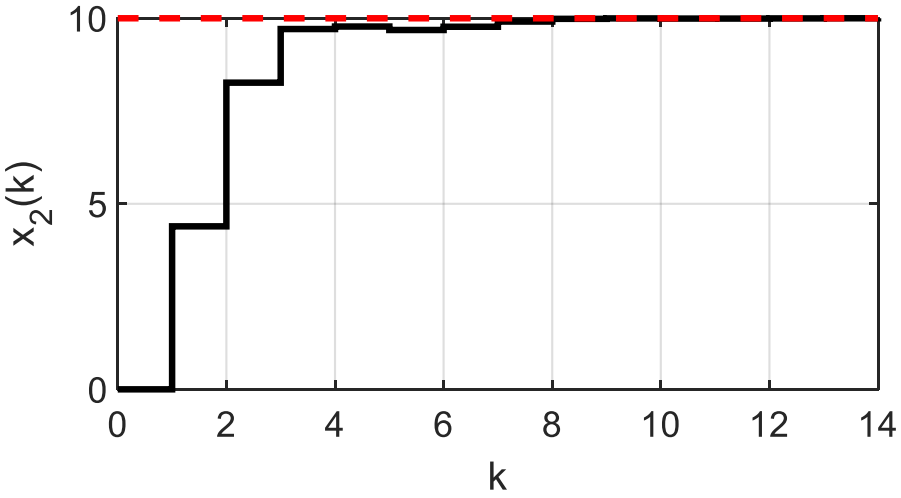
$$Q = 1, R = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

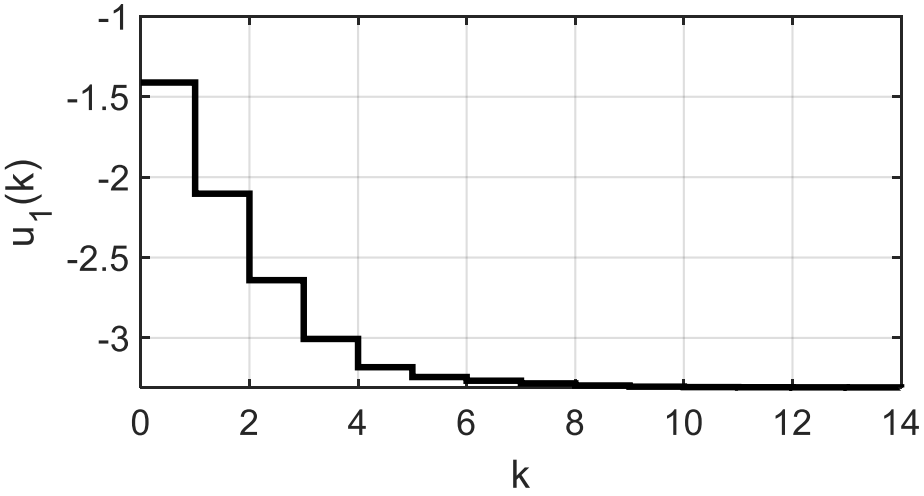
$$p = 5$$

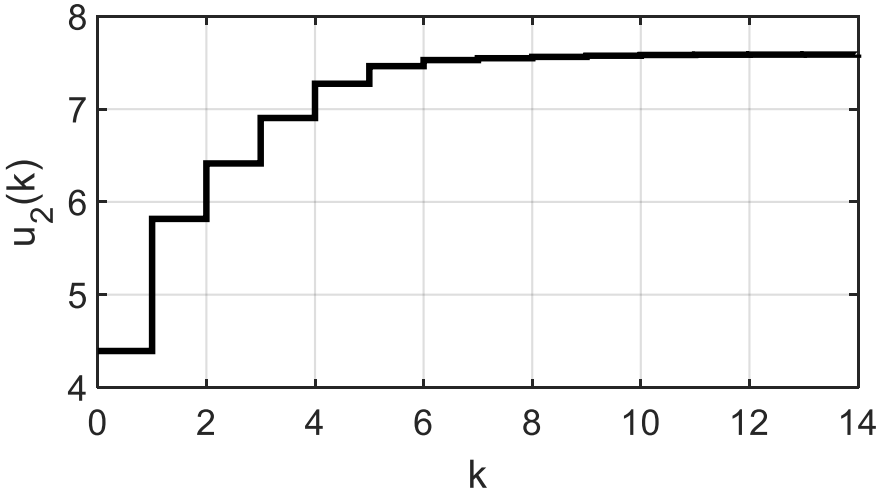
$$x(0) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\tilde{y} = 10$$









Prediktívne riadenie na referenčnú hodnotu výstupu, v inkrementálnej forme a s ohraničeniami

$$A = \begin{pmatrix} 0.2 & 0.8 \\ -0.4 & 0.5 \end{pmatrix}, B = \begin{pmatrix} 2 & 0.5 \\ 0 & 1 \end{pmatrix}, C = \begin{pmatrix} 0 & 1 \end{pmatrix}$$

$$Q = 1, R = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$$p = 5$$

$$x(0) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

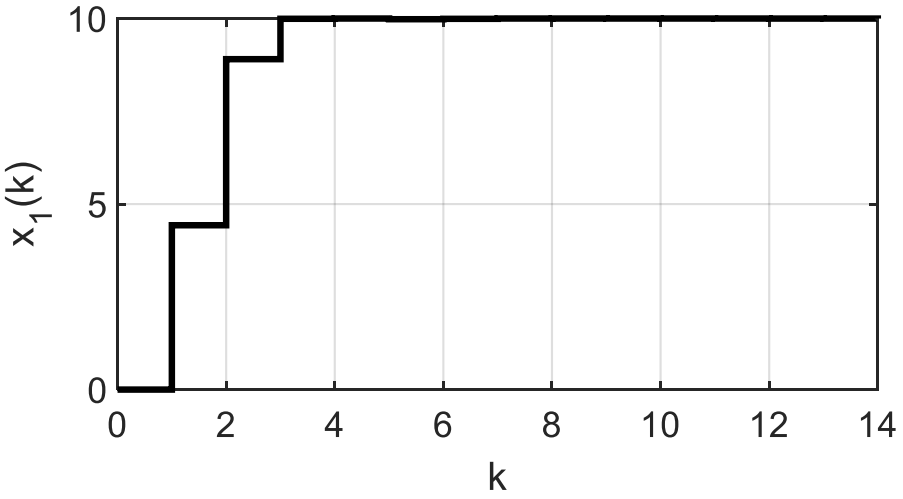
$$\tilde{y} = 10$$

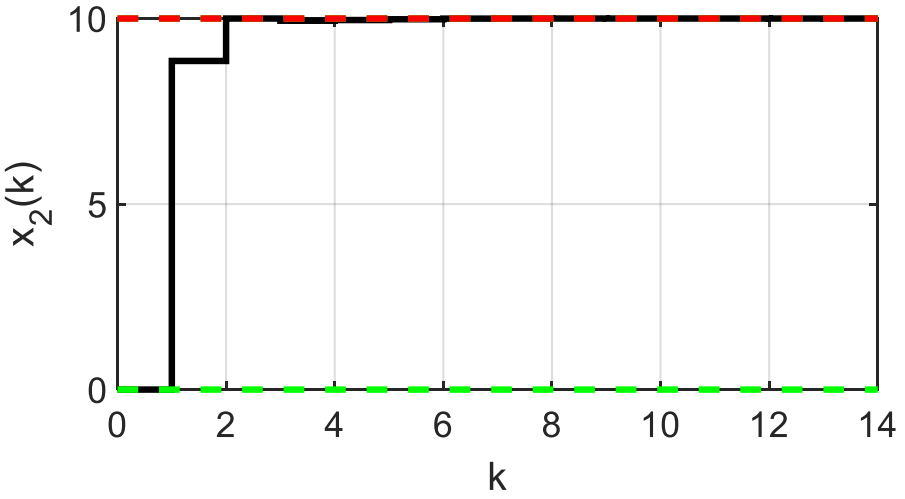
$$\underline{u} = \begin{pmatrix} -3 \\ 0 \end{pmatrix}$$

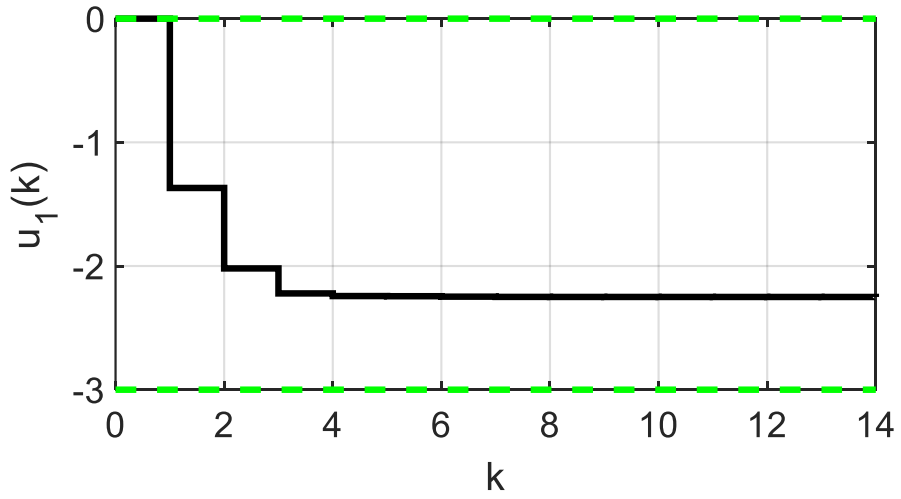
$$\overline{u} = \begin{pmatrix} 0 \\ 9 \end{pmatrix}$$

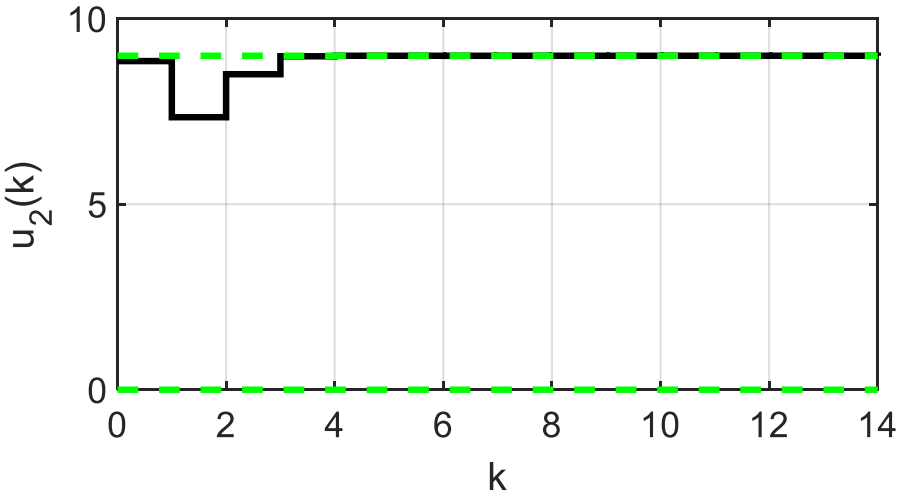
$$\underline{y} = 0$$

$$\overline{y} = 10$$





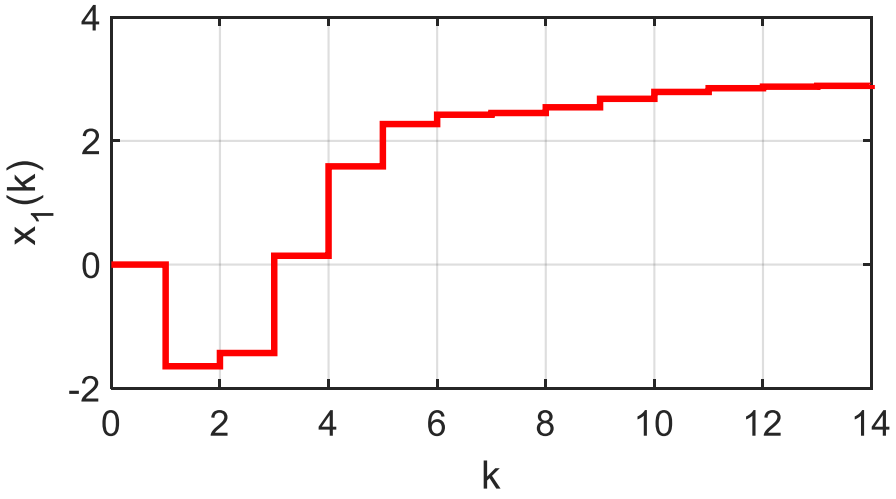


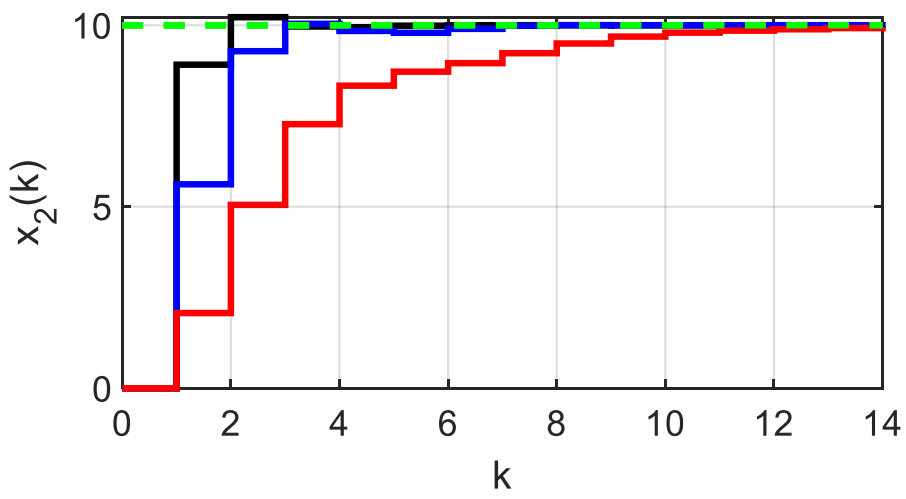


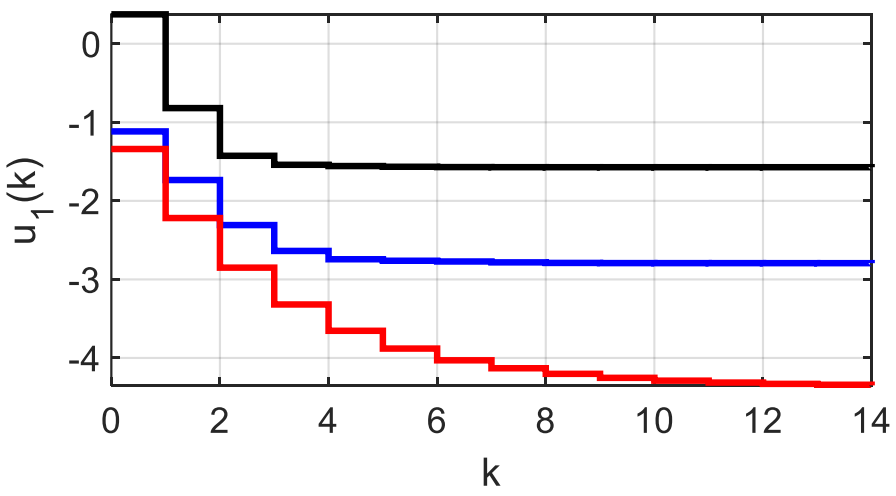
$Q = 1$

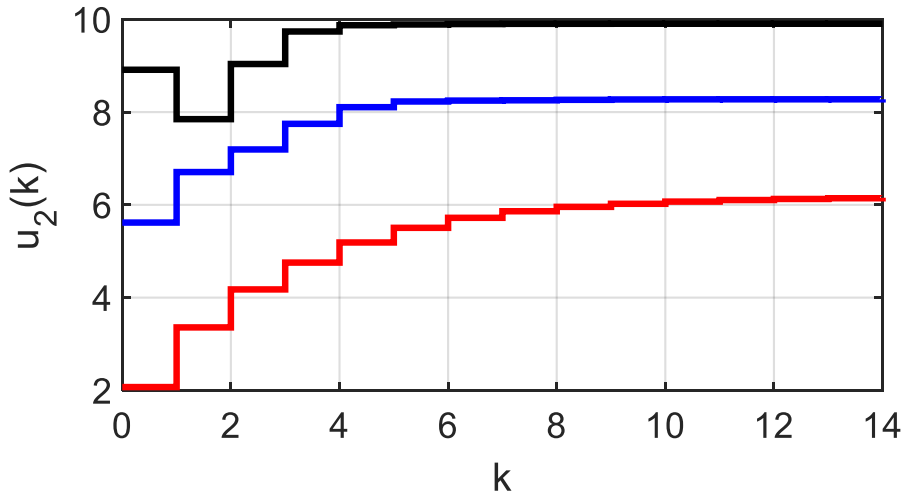
$Q = 1/10$

$Q = 1/100$









Riadenie bez trvalej regulačnej odchýlky

- Vstupno-výstupné prediktívne riadenie zabezpečuje nulovú trvalú regulačnú odchýlku len za ideálnych podmienok
- Problém však nastáva ak model použitý pri návrhu riadenia presne nezodpovedá realite (nemodelovaná dynamika, plant-model mismatch, nelinearita)
- Ďalším zdrojom trvalej regulačnej odchýlky sú konštantné nemerateľné poruchy ovplyvňujúce stav alebo výstup
- Ak prediktívnym riadením vypočítame optimálny akčný zásah tak žiadanú hodnotu výstupu nedosiahneme a vzniká trvalá regulačná odchýlka
- Túto odchýlku je potrebné kompenzovať

Model s poruchou na výstupe

- Uvažujme lineárny stavový model
$$x(k+1) = Ax(k) + Bu(k)$$
- Systém má m výstupov ktoré chceme riadiť na referenčnú hodnotu bez trvalej regulačnej odchýlky
- Výstup systému však podlieha neznámej poruche $d(k) \in \mathbb{R}^m$
- Rovnica pre výstup systému $y(k) \in \mathbb{R}^m$ bude
$$y(k) = Cx(k) + d(k)$$
- Predikcia poruchy bude rovná jej aktuálnej hodnote
$$d(k+i) = d(k)$$
- Poruchu $d(k)$ musíme odhadnúť z dostupných meraní výstupu Kalmanovým filtrom

Rozšírený model s poruchou na výstupe

- Predikčný model s poruchou na výstupe môžeme zapísať vo forme rozšíreného stavového modelu

$$\begin{pmatrix} x(k+1) \\ d(k+1) \end{pmatrix} = \begin{pmatrix} A & \mathbf{0} \\ \mathbf{0} & I \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix} + \begin{pmatrix} B \\ \mathbf{0} \end{pmatrix} u(k)$$

$$y(k) = \begin{pmatrix} C & I \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix}$$

- Tento model sa tak stane novým modelom riadeného systému použitým pri návrhu prediktívneho riadenia

$$\tilde{x}(k+1) = \tilde{A}\tilde{x}(k) + \tilde{B}u(k)$$

$$y(k) = \tilde{C}\tilde{x}(k)$$

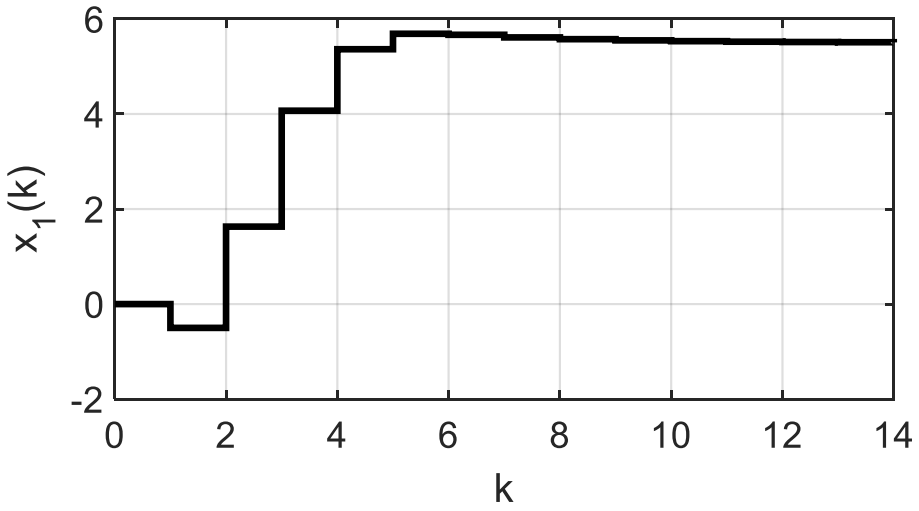
kde $\tilde{x}(k) \in \mathbb{R}^{n+m}$, matica $\tilde{A} \in \mathbb{R}^{n+m \times n+m}$, matica $\tilde{B} \in \mathbb{R}^{n+m \times r}$, matica $\tilde{C} \in \mathbb{R}^{m \times n+m}$

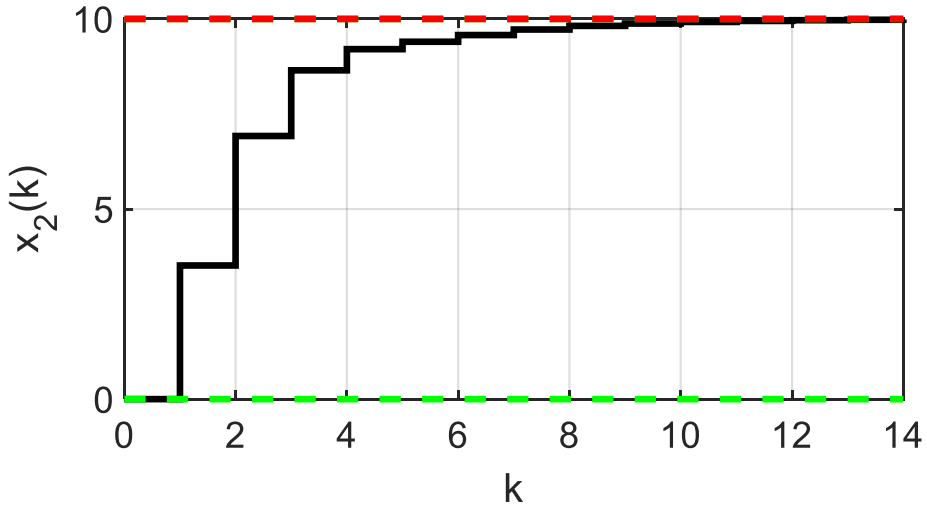
- V každom kroku tak Kalmanovým filtrom odhadneme rozšírený stavový vektor

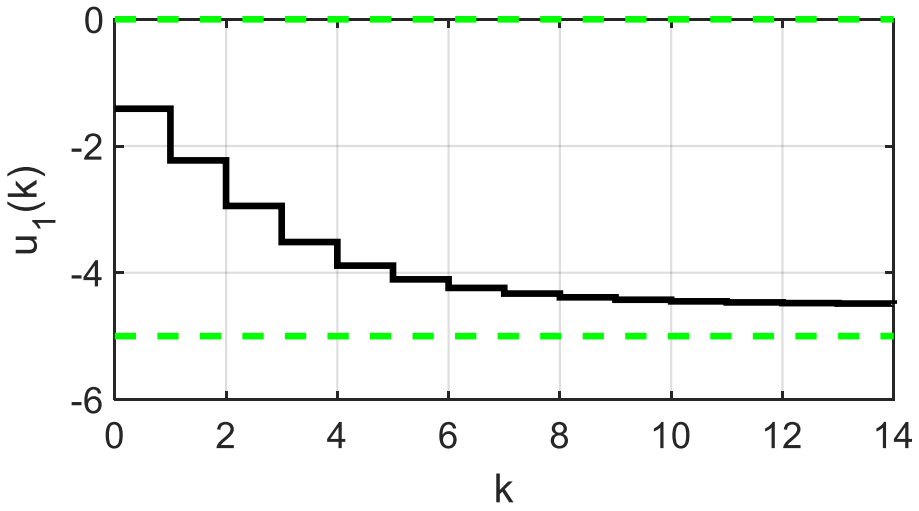
$$\tilde{x}(k) = \begin{pmatrix} x(k) \\ d(k) \end{pmatrix}$$

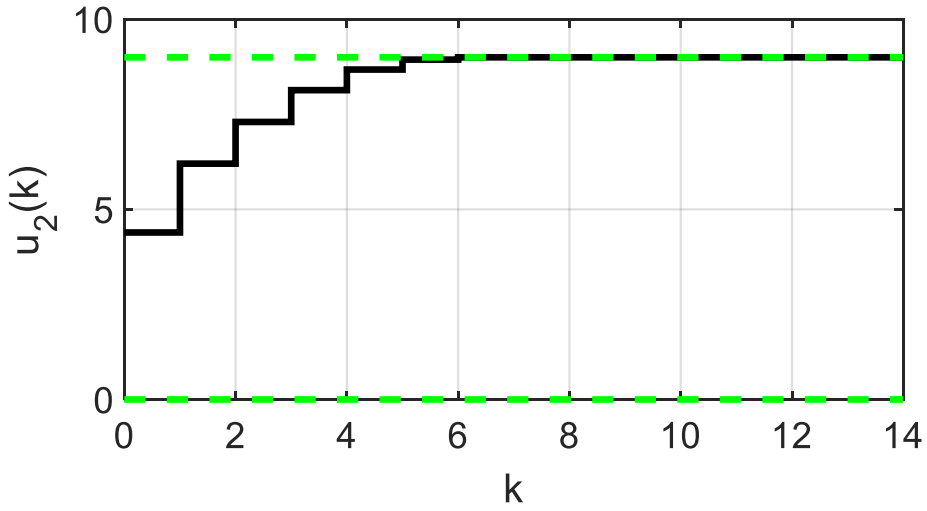
Prediktívne riadenie na referenčnú hodnotu výstupu s nulovou trvalou regulačnou odchýlkou.
Uvažujme nepresný model systém, pričom riadený systém sa v skutočnosti správa ako
$x(k+1) = Ax(k) + 0.8\,Bu(k)$

$A = \begin{pmatrix} 0.2 & 0.8 \\ -0.4 & 0.5 \end{pmatrix}$,
$B = \begin{pmatrix} 2 & 0.5 \\ 0 & 1 \end{pmatrix}$,
$C = (0 \quad 1)$,
$Q = 1, R = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$
$p = 5$
$x(0) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$
$\tilde{y} = 10$
$\underline{u} = \begin{pmatrix} -5 \\ 0 \end{pmatrix}$
$\overline{u} = \begin{pmatrix} 0 \\ 9 \end{pmatrix}$
$\underline{y} = 0$
$\overline{y} = 10$









Model so stavovou poruchou

- Uvažujme lineárny stavový model, ktorý podlieha stavovej poruche $d(k) \in \mathbb{R}^n$

$$x(k+1) = Ax(k) + d(k) + Bu(k)$$

- Rovnica pre výstup systému $y(k) \in \mathbb{R}^m$ bude

$$y(k) = Cx(k)$$

kde $C \in \mathbb{R}^{m \times n}$

- Predikcia poruchy bude rovná jej aktuálnej hodnote

$$d(k+1) = d(k)$$

- Poruchu $d(k)$ musíme odhadnúť z dostupných meraní výstupu Kalmanovým filtrom

Rozšírený model so stavovou poruchou

- Predikčný model so stavovou poruchou môžeme zapísať vo forme rozšíreného stavového modelu

$$\begin{pmatrix} x(k+1) \\ d(k+1) \end{pmatrix} = \begin{pmatrix} A & I \\ \mathbf{0} & I \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix} + \begin{pmatrix} B \\ \mathbf{0} \end{pmatrix} u(k)$$

$$y(k) = \begin{pmatrix} C & \mathbf{0} \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix}$$

- Tento model sa tak stane novým modelom riadeného systému použitým pri návrhu prediktívneho riadenia

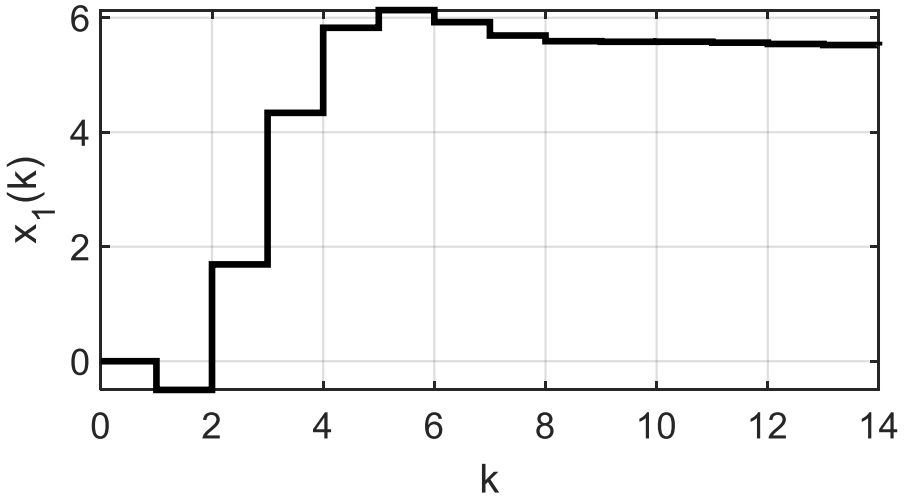
$$\tilde{x}(k+1) = \tilde{A}\tilde{x}(k) + \tilde{B}u(k)$$
$$y(k) = \tilde{C}\tilde{x}(k)$$

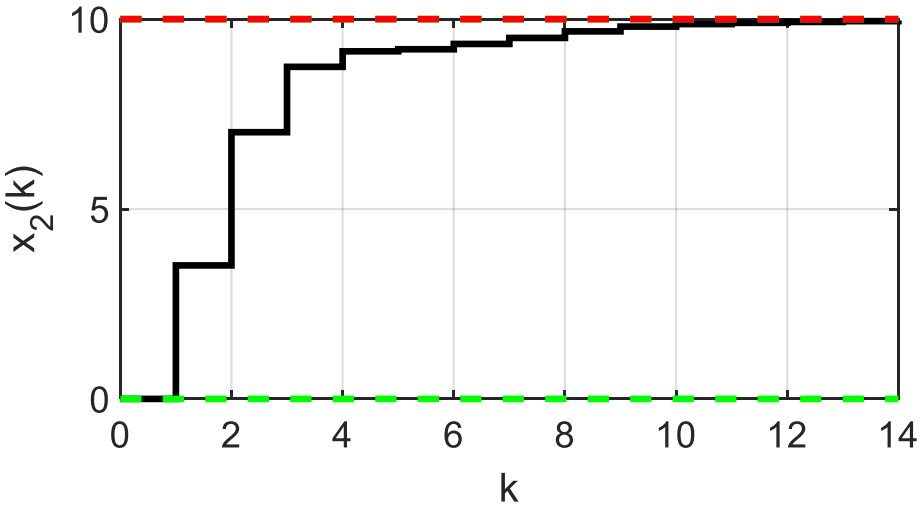
kde $\tilde{x}(k) \in \mathbb{R}^{2n}$, matica $\tilde{A} \in \mathbb{R}^{2n \times 2n}$, matica $\tilde{B} \in \mathbb{R}^{2n \times r}$, matica $\tilde{C} \in \mathbb{R}^{m \times 2n}$

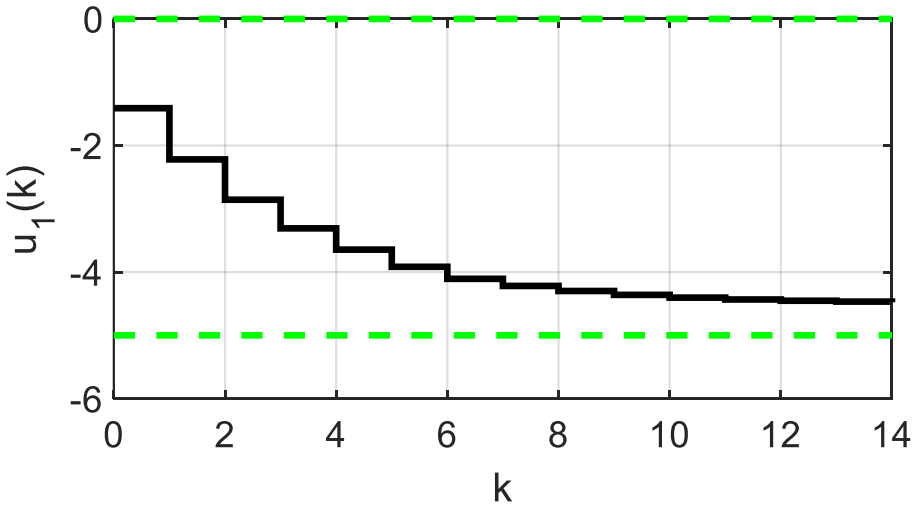
- V každom kroku tak na základe merania výstupu $y(k)$ Kalmanovým filtrom odhadneme rozšírený stavový vektor $\tilde{x}(k)$ čo nám súčasne poskytne odhad stavu $x(k)$ a odhad poruchy $d(k)$

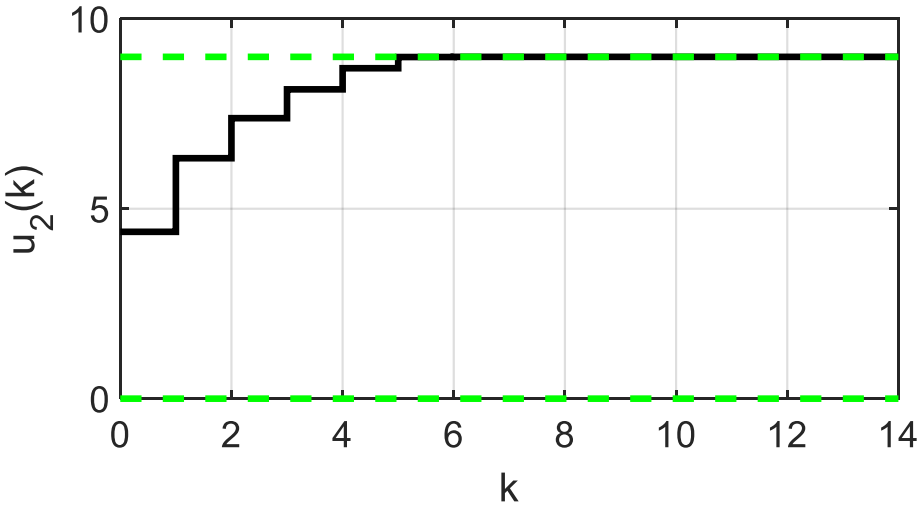
Prediktívne riadenie na referenčnú hodnotu výstupu s nulovou trvalou regulačnou odchýlkou.
Uvažujme nepresný model systém, pričom riadený systém sa v skutočnosti správa ako
$x(k+1) = Ax(k) + 0.8\,Bu(k)$

$A = \begin{pmatrix} 0.2 & 0.8 \\ -0.4 & 0.5 \end{pmatrix}$,
$B = \begin{pmatrix} 2 & 0.5 \\ 0 & 1 \end{pmatrix}$,
$C = (0 \quad 1)$,
$Q = 1, R = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$
$p = 5$
$x(0) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$
$\tilde{y} = 10$
$\underline{u} = \begin{pmatrix} -5 \\ 0 \end{pmatrix}$
$\overline{u} = \begin{pmatrix} 0 \\ 9 \end{pmatrix}$
$\underline{y} = 0$
$\overline{y} = 10$









Všeobecný model so stavovou a výstupnou poruchou

- Uvažujme všeobecnú poruchu $d(k) \in \mathbb{R}^q$
- Predikčný model so môžeme zapísať vo forme rozšíreného stavového modelu

$$\begin{pmatrix} x(k+1) \\ d(k+1) \end{pmatrix} = \begin{pmatrix} A & E \\ \mathbf{0} & A_d \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix} + \begin{pmatrix} B \\ \mathbf{0} \end{pmatrix} u(k)$$

$$y(k) = \begin{pmatrix} C & F \end{pmatrix} \begin{pmatrix} x(k) \\ d(k) \end{pmatrix}$$

Kde $A_d \in \mathbb{R}^{q \times q}$ je matica dynamiky poruchy, $E \in \mathbb{R}^{n \times q}$ je matica vplyvu poruchy na stav, $F \in \mathbb{R}^{m \times q}$ je matica vplyvu poruchy na výstup

- Nevýhoda: je potrebné poznať A_d, E a F,
- Tento model sa tak stane novým modelom riadeného systému použitým pri návrhu prediktívneho riadenia

$$\tilde{x}(k+1) = \tilde{A}\tilde{x}(k) + \tilde{B}u(k)$$
$$y(k) = \tilde{C}\tilde{x}(k)$$

kde $\tilde{x}(k) \in \mathbb{R}^{n+q}$, matica $\tilde{A} \in \mathbb{R}^{n+q \times n+q}$, matica $\tilde{B} \in \mathbb{R}^{n+q \times r}$, matica $\tilde{C} \in \mathbb{R}^{m \times n+q}$

- V každom kroku tak na základe merania výstupu $y(k)$ Kalmanovým filtrom odhadneme rozšírený stavový vektor $\tilde{x}(k)$ čo nám súčasne poskytne odhad stavu $x(k)$ a odhad poruchy $d(k)$

Explicitné MPC

- Explicitné MPC (explicit MPC) je spôsob, ako realizovať výpočet MPC s ohraničeniami offline vopred
- Počas riadenia v reálnom čase už nie je potrebné pri každom vzorkovacom kroku riešiť optimalizačnú úlohu (kvadratické programovanie)
- Myšlienka: *Čo keby sme optimalizáciu vyriešili dopredu pre všetky možné stavy systému* $x(k)$ *?*
- Namiesto toho, aby sme online riešili

$$U(k) = \arg\min_{U(k)} J(x(k), U(k)),$$

  vyriešime optimalizačný problém offline.
- Výsledkom je priamo funkcia

$$u(k) = \kappa(x(k))$$

  ktorá hovorí:
- *Keď je aktuálny stav* $x(k)$ *takýto, použi tento riadiaci vstup.*

Optimalizačný problém MPC

- Optimalizačný problém MPC môžeme zapísať ako

$$\min_{U(k)} U^T(k)HU(k) + 2b^T(k)U(k) + c(k)$$

$$\text{s.t. } GU(k) \leq W + Ex(k)$$

- Pričom podmienka $GU(k) \leq W + Ex(k)$ predstavuje abstrakciu (kombináciu) všetkých uvažovaných ohraničení
- Keďže lineárny člen je lineárny voči stavu

$$b(k) = N^T QMx(k)$$

môžeme účelovú funkciu chápať ako parametrickú optimalizačnú úlohu

$$J(U(k), x(k)) = U^T(k)HU(k) + 2x^T(k)M^T QNU(k) + c(k)$$

- Aktuálny stav $x(k)$teda vystupuje ako parameter optimalizačnej úlohy, zatiaľ čo $U(k)$ je optimalizačná premenná.

Optimalizačný problém MPC

- Optimalizačný problém MPC môžeme zapísať ako

$$\min_{U(k)} U^T(k)HU(k) + 2x^T(k)M^TQNU(k) + c(k)$$

$$GU(k) \leq W + Ex(k)$$

- Aktuálny stav $x(k)$ teda vystupuje ako parameter optimalizačnej úlohy, zatiaľ čo $U(k)$ je optimalizačná premenná.
- Riešenie problému závisí od toho, ktoré ohraničenia sú v optimálnom bode aktívne.
- Definujme aktívnu množinu $\mathcal{A}$ ako množinu ohraničení splnených s rovnosťou (sme na hrane).
- Pre danú aktívnu množinu môžeme podmienky optimality zapísať pomocou KKT podmienok.
- Výsledkom je optimálny predikčný vektor vstupov v tvare

$$U^*(k) = K_{\mathcal{A}}x(k) + g_{\mathcal{A}}$$

- Tento vzťah platí iba pre určitú množinu aktuálnych stavov $x(k)$, tzv. kritickú oblasť

$$\mathcal{R}_{\mathcal{A}} = \{x(k) \mid H_{\mathcal{A}}x(k) \leq h_{\mathcal{A}}\}$$

- Pre celý stavový priestor tak získame sústavu kritických oblastí $\mathcal{R}_1, \mathcal{R}_2, \dots, \mathcal{R}_N$ pričom v každej oblasti platí iný riadiaci zákon

$$U^*(k) = \begin{cases} K_1x(k) + g_1, & x(k) \in \mathcal{R}_1, \\ K_2x(k) + g_2, & x(k) \in \mathcal{R}_2, \\ \vdots & \\ K_Nx(k) + g_N, & x(k) \in \mathcal{R}_N. \end{cases}$$

- Online teda už neriešime optimalizačnú úlohu. Pre aktuálny stav $x(k)$ nájdeme príslušnú kritickú oblasť a vypočítame optimálny vstup.

Lagrangeova funkcia a podmienka stacionarity

- Optimalizačný problém MPC môžeme zapísať ako

$$\min_{U(k)} U^T(k)HU(k) + 2x^T(k)M^TQNU(k) + c(k)$$

$$GU(k) \leq W + Ex(k)$$

- Nerovnice vieme prepísať do štandardného tvaru

$$g(U(k)) = GU(k) - W - Ex(k) \leq \mathbf{0}$$

- Lagrangeova funkcia je

$$L(U(k), \lambda) = J(U(k)) + \lambda^T g(U(k)) = U^T(k)HU(k) + 2b(k)^T U(k) + \lambda^T\big(GU(k) - W - Ex(k)\big).$$

- Stacionarita $\nabla_{U(k)} L(U(k), \lambda) = \nabla_{U(k)} J(U(k)) + \left(\nabla_{U(k)} g(U(k))\right)^T \lambda = \mathbf{0}$ dáva

$$2HU(k) + 2b(k) + G^T\lambda = \mathbf{0}$$

- Po vydelení dvoma a vhodnej definícii multiplikátorov môžeme písať

$$HU(k) + b(k) + G^T\lambda = \mathbf{0}$$

- Pre aktívne ohraničenia platí rovnosť (sme na hrane)

$$G_{\mathcal{A}}U(k) = W_{\mathcal{A}} + E_{\mathcal{A}}x(k)$$

- Pre aktívnu množinu teda súčasne platí:

$$HU(k) + G_{\mathcal{A}}^T\lambda_{\mathcal{A}} = -b(k)$$
$$G_{\mathcal{A}}U(k) = W_{\mathcal{A}} + E_{\mathcal{A}}x(k).$$

- Spojíme ich do jednej sústavy lineárnych rovníc:

$$\begin{bmatrix} H & G_{\mathcal{A}}^T \\ G_{\mathcal{A}} & 0 \end{bmatrix} \begin{bmatrix} U(k) \\ \lambda_{\mathcal{A}} \end{bmatrix} = \begin{bmatrix} -b(k) \\ W_{\mathcal{A}} + E_{\mathcal{A}}x(k) \end{bmatrix}$$

Lagrangeova funkcia a podmienka stacionarity

- Máme sústavu lineárnych rovníc:

$$\begin{bmatrix} H & G_{\mathcal{A}}^T \\ G_{\mathcal{A}} & \mathbf{0} \end{bmatrix} \begin{bmatrix} U(k) \\ \lambda_{\mathcal{A}} \end{bmatrix} = \begin{bmatrix} -b(k) \\ W_{\mathcal{A}} + E_{\mathcal{A}} x(k) \end{bmatrix}$$

- Vieme, že $b(k) = N^T Q M x(k)$, potom

$$\begin{bmatrix} H & G_{\mathcal{A}}^T \\ G_{\mathcal{A}} & \mathbf{0} \end{bmatrix} \begin{bmatrix} U(k) \\ \lambda_{\mathcal{A}} \end{bmatrix} = \begin{bmatrix} -N^T Q M x(k) \\ W_{\mathcal{A}} + E_{\mathcal{A}} x(k) \end{bmatrix}$$

  - Pravá strana teda obsahuje $x(k)$ lineárne.

$$\begin{bmatrix} H & G_{\mathcal{A}}^T \\ G_{\mathcal{A}} & \mathbf{0} \end{bmatrix} \begin{bmatrix} U(k) \\ \lambda_{\mathcal{A}} \end{bmatrix} = \begin{bmatrix} \mathbf{0} \\ W_{\mathcal{A}} \end{bmatrix} + \begin{bmatrix} -N^T Q M \\ E_{\mathcal{A}} \end{bmatrix} x(k)$$

- Riešenie má potom tvar

$$\begin{bmatrix} U(k) \\ \lambda_{\mathcal{A}} \end{bmatrix} = \begin{bmatrix} H & G_{\mathcal{A}}^T \\ G_{\mathcal{A}} & \mathbf{0} \end{bmatrix}^{-1} \left(\begin{bmatrix} \mathbf{0} \\ W_{\mathcal{A}} \end{bmatrix} + \begin{bmatrix} -N^T Q M \\ E_{\mathcal{A}} \end{bmatrix} x(k) \right)$$

- Keď vyriešime túto maticovú sústavu, dostaneme absolútne a lineárne členy

$$U(k) = K_{\mathcal{A}} x(k) + g_{\mathcal{A}}$$
$$\lambda_{\mathcal{A}}(x) = L_{\mathcal{A}} x(k) + m_{\mathcal{A}}$$

Kritický región

- Pre všetky neaktívne obmedzenia musí platiť (sme vnútri)

$$G_{\bar{\mathcal{A}}} U^*(x) < W_{\bar{\mathcal{A}}} + E_{\bar{\mathcal{A}}} x$$

a zároveň pre aktívne obmedzenia musia byť multiplikátory nezáporné:

$$\lambda_{\mathcal{A}}(x) \geq 0.$$

- Po dosadení $U^*(x) = K_{\mathcal{A}} x + g_{\mathcal{A}}$ a $\lambda_{\mathcal{A}}(x) = L_{\mathcal{A}} x + m_{\mathcal{A}}$ dostaneme iba lineárne nerovnosti v x:

$$G_{\bar{\mathcal{A}}}(K_{\mathcal{A}} - E_{\bar{\mathcal{A}}})x < W_{\bar{\mathcal{A}}} - G_{\bar{\mathcal{A}}} g_{\mathcal{A}}$$
$$L_{\mathcal{A}} x + m_{\mathcal{A}} \geq 0.$$

- Tieto dve podmienky môžeme spojiť do jednej nerovnosti

$$H_{\mathcal{A}} x \leq h_{\mathcal{A}}$$

- Táto množina stavov je kritický región:

$$\mathcal{R}_{\mathcal{A}} = \{x : H_{\mathcal{A}} x \leq h_{\mathcal{A}}\}$$

Nelineárne MPC

- Uvažujme všeobecný nelineárny spojitý dynamický systém n-tého rádu, ktorý je opísaný n diferenciálnymi rovnicami.
- Časová derivácia stavového vektora $x(t) \in \mathbb{R}^n$ je daná vektorovou diferenciálnou rovnicou

$$\frac{\partial x(t)}{\partial t} = f(x, u)$$

kde

- $u \in \mathbb{R}^r$ je vstupný vektor
- $x \in \mathbb{R}^n$ je stavový vektor
- $f(x, u)$: $\mathbb{R}^{n+r} \rightarrow \mathbb{R}^n$ je viacrozmerná vektorová funkcia

- Stavový vektor $x(t) \in \mathbb{R}^n$ je definovaný ako

$$x(t) = \begin{pmatrix} x_1(t) \\ x_2(t) \\ \vdots \\ x_n(t) \end{pmatrix}$$

Predikovaný vstup a stav

- Uvažujme periódu vzorkovania T_s
- Budeme predikovať p vzoriek dopredu - predikčný horizont p
- Uvažujme diskrétnu sekvenciu akčných zásahov takú že:

$$u(t) = u(iT_s) \text{ pre } iT_s \leq t < (i+1)T_s$$

- Zadefinujme rozšírený (predikovaný) vektor vstupov $U(k) \in \mathbb{R}^{pr}$ ako

$$U(k) = \begin{pmatrix} u(kT_s) \\ u\big((k+1)T_s\big) \\ u\big((k+2)T_s\big) \\ \vdots \\ u\big((k+p-2)T_s\big) \\ u\big((k+p-1)T_s\big) \end{pmatrix}$$

- Zadefinujme rozšírený (predikovaný) stavový vektor $X(k) \in \mathbb{R}^{pn}$ ako

$$X(k) = \begin{pmatrix} x\big((k+1)T_s\big) \\ x\big((k+2)T_s\big) \\ x\big((k+3)T_s\big) \\ \vdots \\ x\big((k+p-1)T_s\big) \\ x\big((k+p)T_s\big) \end{pmatrix}$$

Účelová funkcia prediktívneho riadenia

- Uvažujme kvadratickú účelovú funkciu prediktívneho riadenia vzhľadom na želanú trajektóriu

$$J(U(k)) = \frac{1}{2}\sum_{i=1}^{p} \left(x\big((k+i)T_s\big) - x_r\big((k+i)T_s\big)\right)^T Q \left(x\big((k+i)T_s\big) - x_r\big((k+i)T_s\big)\right) + \big(u\big((k+i-1)T_s\big) - u_0\big)^T R\big(u\big((k+i-1)T_s\big) - u_0\big)$$

  $Q \in \mathbb{R}^{n\times n}, Q = Q^T, Q \succ 0$ je váhovacia matica penalizácie stavov

  $R \in \mathbb{R}^{r\times r}, R = R^T, R \succ 0$ je váhovacia matica penalizácie vstupov

  $x_r \in \mathbb{R}^n$ je želaná stavová trajektória

  $u_0 \in \mathbb{R}^n$ je vstup v pracovnom bode

- Pozor: Model nediskretizujeme, ale kombinujeme pôvodnú spojitú dynamiku s diskrétnym charakterom akčného zásahu
- Účelovú funkciu vieme zapísať bez sumácie ako

$$J(U(k)) = \frac{1}{2}\big((X(k,U(k)) - X_r)^T \mathbf{Q}(X(k,U(k)) - X_r) + (U(k) - U_0)^T \mathbf{R}(U(k) - U_0)\big)$$

- Matica $\mathbf{Q} \in \mathbb{R}^{pn\times pn}$ bude blokovo diagonálna

$$\mathbf{Q} = \begin{pmatrix} Q & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & Q & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & Q \end{pmatrix}$$

- Matica $\mathbf{R} \in \mathbb{R}^{pr\times pr}$ bude blokovo diagonálna

$$\mathbf{R} = \begin{pmatrix} R & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & R & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \ldots & R \end{pmatrix}$$

Gradient a Hessián účelovej funkcie

- Máme účelovú funkciu

$$J(U(k)) = \frac{1}{2}\left((X(k,U(k)) - X_r)^T \mathbf{Q}(X(k,U(k)) - X_r) + (U(k) - U_0)^T \mathbf{R}(U(k) - U_0)\right)$$

- Gradient $\nabla J(U(k))$ tejto účelovej funkcie potom bude

$$\nabla J(U(k)) = \left(\nabla X(k,U(k))\right)^T \mathbf{Q}(X(k,U(k)) - X_r) + \mathbf{R}(U(k) - U_0)$$

kde $\nabla X(k,U(k)) \in \mathbb{R}^{np \times rp}$ je Jakobián predikcie stavov vzhľadom na akčné zásahy $U(k)$

- Prekciu stavu $X(k,U(k))$ získame numerickou integráciou diferenciálnych rovníc modelu $\frac{\partial x(t)}{\partial t} = f(x,u)$ s krokom integrácie rovným perióde vzorkovania $h = T_s$
- Hessián vieme aproximovať podobne ako pri nelineárnej metóde najmenších štvorcov pomocou Jakobiánu:

$$\nabla^2 J(U(k)) \approx \left(\nabla X(k,U(k))\right)^T \mathbf{Q}\, \nabla X(k,U(k)) + \mathbf{R}$$

- Optimálnu sekvenciu akčných zásahov bez ohraničení nájdeme splnením $\nabla J(U(k)) = \mathbf{0}$
- Krok Gauss-Newtonovho algoritmu potom bude

$$U(k)^{i+1} = U(k)^i - \left(\nabla^2 J\left(U(k)\right)_{U(k)=U(k)^i} + \Lambda\right)^{-1} \nabla J(U(k))_{U(k)=U(k)^i}$$

kde $\Lambda \in \mathbb{R}^{pr \times pr}$ je regularizačná matica

Jakobián predikcie

- Jakobián predikovaných stavov $X(k, U(k))$ vzhľadom na akčné zásahy $U(k)$ bude mať štruktúru :

$$\nabla X(k, U(k)) = \begin{pmatrix} \frac{\partial x((k+1)T_s)}{\partial u(kT_s)} & \frac{\partial x((k+1)T_s)}{\partial u((k+1)T_s)} & \cdots & \frac{\partial x((k+1)T_s)}{\partial u((k+p-1)T_s)} \\ \frac{\partial x((k+2)T_s)}{\partial u(kT_s)} & \frac{\partial x((k+2)T_s)}{\partial u((k+1)T_s)} & \cdots & \frac{\partial x((k+2)T_s)}{\partial u((k+p-1)T_s)} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial x((k+p)T_s)}{\partial u(kT_s)} & \frac{\partial x((k+p)T_s)}{\partial u((k+1)T_s)} & \cdots & \frac{\partial x((k+p)T_s)}{\partial u((k+p-1)T_s)} \end{pmatrix}$$

- Deriváciu stavového vektora voči i-temu akčnému zásahu označíme ako $S_i(t) \in \mathbb{R}^{n \times r}$(citlivostná funkcia)

$$\frac{\partial x(t)}{\partial u((k+i)T_s)} = S_i(t)$$

- Jakobián potom bude

$$\nabla X(k, U(k)) = \begin{pmatrix} S_0((k+1)T_s) & S_1((k+1)T_s) & \cdots & S_{p-1}((k+1)T_s) \\ S_0((k+2)T_s) & S_1((k+2)T_s) & \cdots & S_{p-1}((k+2)T_s) \\ \vdots & \vdots & \ddots & \vdots \\ S_0((k+p)T_s) & S_1((k+p)T_s) & \cdots & S_{p-1}((k+p)T_s) \end{pmatrix}$$

- Uvažujme citlivostnú funkciu $S_i(t) = \frac{\partial x(t)}{\partial u\left((k+i)T_s\right)}$ a jej časovú deriváciu ako

$$\frac{\partial S_i(t)}{\partial t} = \frac{\partial}{\partial t}\frac{\partial x(t)}{\partial u\left((k+i)T_s\right)}$$

- Po zámene poradia derivovania získame:

$$\frac{\partial S_i(t)}{\partial t} = \frac{\partial}{\partial u\left((k+i)T_s\right)}\frac{\partial x(t)}{\partial t}$$

- Po dosadení časovej derivácie $\frac{\partial x(t)}{\partial t} = f(x,u)$ a použití pravidla pre derivovanie zloženej funkcie (reťazového pravidla) pre parciálne derivácie získame

$$\frac{\partial S_i(t)}{\partial t} = \frac{\partial f(x,u)}{\partial u\left((k+i)T_s\right)} + \frac{\partial f(x,u)}{\partial x(t)}\frac{\partial x(t)}{\partial u\left((k+i)T_s\right)}$$

- Keďže $\frac{\partial f(x,u)}{\partial x(t)} = A(x,u)$ predstavuje stavový Jakobián systému a $\frac{\partial x(t)}{\partial u\left((k+i)T_s\right)} = S_i(t)$, možno napísať

$$\frac{\partial S_i(t)}{\partial t} = \frac{\partial f(x,u)}{\partial u\left((k+i)T_s\right)} + A(x,u)S_i(t)$$

kde $\frac{\partial f(x,u)}{\partial u\left((k+i)T_s\right)} \neq 0$ pre $(k+i)\,T_s \leq t < (k+i+1)T_s$ možno chápať ako vstupný Jakobián

- Akčný zásah $u\left((k+i)T_s\right)$ sa v dynamike systému $\frac{\partial x(t)}{\partial t} = f(x,u)$ vyskytuje iba vo vzorke $k+i$ teda ak

$$(k+i)\,T_s \leq t < (k+i+1)T_s$$

- Deriváciu $\frac{\partial f(x,u)}{\partial u\left((k+i)T_s\right)}$ môžeme vyjadriť aj pomocou vstupného Jakobiánu systému $B(x,u) = \frac{\partial f(x,u)}{\partial u}$ ako

$$\frac{\partial f(x,u)}{\partial u\left((k+i)T_s\right)} = \begin{matrix} B(x,u) \\ 0 \end{matrix}\begin{matrix} \text{, ak } (k+i)T_s \leq t < (k+i+1)T_s \\ \text{, inak} \end{matrix}$$

- To znamená, že pre $t < (k+j)\,T_s$ bude $S_i(t) = \mathbf{0}$ a zároveň pre $t \geq (k+i+1)T_s$ bude platiť autonómna dynamika

$$\frac{\partial S_i(t)}{\partial t} = A(x,u)S_i(t) + \begin{cases} B(x,u) & \text{, ak } (k+i)T_s \leq t < (k+i+1)T_s \\ 0 & \text{, inak} \end{cases}$$

Numerické riešenie diferenciálnych rovníc

- Metóda Rungeho–Kuttu 4. rádu (RK4, alebo ode4) slúži na riešenie obyčajných diferenciálnych rovníc (numerické integrovanie)
- Uvažujme diferenciálnu rovnicu

$$\dot{x}(t) = f(x(t), t)$$

- Naším cieľom je vypočítať približnú hodnotu stavu v ďalšom časovom okamihu

$$x(t_k + h)$$

kde h je integračný krok

- RK4 odhaduje priemernú deriváciu počas celého integračného intervalu
- Namiesto jedného výpočtu derivácie vypočíta štyri

$k_1 = f(x(t_k), t_k)$ (ide o tú istú deriváciu, ktorú používa Euler)

$k_2 = f\left(x(t_k) + \frac{h}{2}k_1, t_k + \frac{h}{2}\right)$ (predpokladáme, že polovicu kroku sa systém pohyboval podľa k_1)

$k_3 = f\left(x(t_k) + \frac{h}{2}k_2, t_k + \frac{h}{2}\right)$ (znova sa pozrieme do stredu intervalu, ale tentoraz použijeme odhad smeru k_2)

$k_4 = f(x(t_k) + hk_3, t_k + h)$ (nakoniec odhadneme deriváciu na konci kroku)

- Výsledný stav sa vypočíta ako vážený priemer

$$x(t_k + h) = x(t_k) + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4)$$

- Prečo práve váhy 1–2–2–1 ? : Derivácie v strede intervalu (k_2, k_3) sú spravidla reprezentatívnejšie pre celý priebeh riešenia než derivácie na začiatku a na konci intervalu.

Postup návrhu pre nelineárne MPC bez ohraničení

- Získam predikciu stavu $X(t, U(k))$ numerickou integráciou diferenciálnych rovníc modelu $\frac{\partial x(t)}{\partial t} = f(x, u)$ pre $U(k) = U(k)^i$ a počiatočnú podmienku $x(kT_s)$
- Získam citlivostné funkcie numerickou integráciou pre $U(k) = U(k)^i$ a počiatočnú podmienku $S_i(kT_s) = \mathbf{0}$

$$\frac{\partial S_i(t)}{\partial t} = A(x,u)S_i(t) + \begin{cases} B(x,u) & \text{, ak } (k+i)T_s \leq t < (k+i+1)T_s \\ 0 & \text{, inak} \end{cases}$$

- Naplním Jakobián $\nabla X(k, U(k))$

$$\nabla X(k, U(k)) = \begin{pmatrix} S_0\big((k+1)T_s\big) & S_1\big((k+1)T_s\big) & \cdots & S_{p-1}\big((k+1)T_s\big) \\ S_0\big((k+2)T_s\big) & S_1\big((k+2)T_s\big) & \cdots & S_{p-1}\big((k+2)T_s\big) \\ \vdots & \vdots & \ddots & \vdots \\ S_0\big((k+p)T_s\big) & S_1\big((k+p)T_s\big) & \cdots & S_{p-1}\big((k+p)T_s\big) \end{pmatrix}$$

- Vypočítam gradient pre $U(k) = U(k)^i$

$$\nabla J(U(k)) = \big(\nabla X(k, U(k))\big)^T \mathbf{Q}(X(t, U(k)) - X_r) + \mathbf{R}(U(k) - U_0)$$

- Vypočítam Hessián pre $U(k) = U(k)^i$

$$\nabla^2 J(U(k)) \approx \big(\nabla X(k, U(k))\big)^T \mathbf{Q}\, \nabla X(k, U(k)) + \mathbf{R}$$

- Aktualizujem odhad optima ako

$$U(k)^{i+1} = U(k)^i - \Big(\nabla^2 J(U(k))_{U(k)=U(k)^i} + \Lambda\Big)^{-1} \nabla J(U(k))_{U(k)=U(k)^i}$$

- Iterujem pokiaľ veľkosť gradientu nedosiahne požadovanú toleranciu

$$\nabla J(U(k))^T \nabla J(U(k)) < \epsilon$$

Ohraničenia akčného zásahu

- Uvažujme horné a dolné ohraničenie akčného zásahu

$$\underline{u} \leq u(k) \leq \overline{u}$$

- Zavedieme vektory $\underline{U} \in \mathbb{R}^{pr}$, $\overline{U} \in \mathbb{R}^{pr}$ ako

$$\underline{U} = \begin{pmatrix} \underline{u} \\ \vdots \\ \underline{u} \end{pmatrix}, \qquad \overline{U} = \begin{pmatrix} \overline{u} \\ \vdots \\ \overline{u} \end{pmatrix}$$

- Pre $U(k)$ potom musí platiť

$$\underline{U} \leq U(k) \leq \overline{U}$$

- Získavame sústavu lineárnych nerovníc

$$\begin{pmatrix} I \\ -I \end{pmatrix} U(k) \leq \begin{pmatrix} \overline{U} \\ -\underline{U} \end{pmatrix}$$

Postup návrhu pre nelineárne MPC s ohraničeniami

- Chceme minimalizovať účelovú funkciu

$$J(U(k)) = \frac{1}{2}\left((X(k,U(k)) - X_r)^T \mathbf{Q}(X(k,U(k)) - X_r) + (U(k) - U_0)^T \mathbf{R}(U(k) - U_0)\right)$$

- Gradient je

$$\nabla J(U(k)) = \left(\nabla X(k,U(k))\right)^T \mathbf{Q}(X(t,U(k)) - X_r) + \mathbf{R}(U(k) - U_0)$$

- Hessián je:

$$\nabla^2 J(U(k)) \approx \left(\nabla X(k,U(k))\right)^T \mathbf{Q}\, \nabla X(k,U(k)) + \mathbf{R}$$

- Uvažujme horné a dolné ohraničenie akčného zásahu

$$\underline{u} \le u(k) \le \overline{u}$$

- Zavedieme vektory $\underline{U} \in \mathbb{R}^{pr}$, $\overline{U} \in \mathbb{R}^{pr}$ ako

$$\underline{U} = \begin{pmatrix} \underline{u} \\ \vdots \\ \underline{u} \end{pmatrix}, \qquad \overline{U} = \begin{pmatrix} \overline{u} \\ \vdots \\ \overline{u} \end{pmatrix}$$

- Získavame sústavu lineárnych nerovníc

$$\begin{pmatrix} I \\ -I \end{pmatrix} U(k) \le \begin{pmatrix} \overline{U} \\ -\underline{U} \end{pmatrix}$$

- Riešime teda úlohu nelineárneho programovania

Úloha nelineárneho programovania s lineárnymi ohraničeniami

- Majme účelovú funkciu n premenných $J(x)$ kde $x \in \mathbb{R}^n$
- Premenné x budú podliehať q lineárnym nerovniciam

$$A_c x \leq b_c$$

  kde $A_c \in \mathbb{R}^{q \times n}$, $b_c \in \mathbb{R}^p$
- Potom teda funkcia ohraničení bude

$$g(x) = A_c x - b_c$$

- Lagrangeova funkcia pre problém nelineárneho programovania získa tvar

$$L(x, \lambda) = J(x) + \lambda^T (A_c x - b_c)$$

- Podmienky ohraničeného optima v nelineárnom programovaní sú nasledovné
  - Stacionarita

$$\nabla_x L(x^*, \lambda^*) = \nabla J(x^*) + {A_c}^T \lambda^* = \mathbf{0}$$

  - Prípustnosť

$$A_c x^* - b_c \leq \mathbf{0}$$
$$\lambda^* \geq \mathbf{0}$$

  - Komplementarita

$$\mathrm{diag}(\lambda^*) g(x^*) = \mathbf{0}$$

Reziduá (chyby) podmienok optimálnosti

- Zavedieme si nový pomocný vektor $s \in \mathbb{R}^q$ (slack premenné), ktorý bude predstavovať splnenie podmienok nerovníc $g(x) \leq \mathbf{0}$ ako

$$A_c x - b_c = -s$$
$$A_c x - b_c + s = \mathbf{0}$$
$$s \geq \mathbf{0}$$

- Definujeme si reziduálne funkcie predstavujúce nesplnenie (chyby) podmienok ohraničenej optimálnosti
  - Reziduum stacionárnosti $r_1 \in \mathbb{R}^n$

$$r_1(x, \lambda) = \nabla J(x) + {A_c}^T \lambda$$

  - Reziduum pre nerovnice $r_2 \in \mathbb{R}^q$

$$r_2(x, s) = A_c x - b_c + s$$

  - Reziduum komplementárnosti $r_3 \in \mathbb{R}^q$

$$r_3(s, \lambda, \mu) = \mathrm{diag}(\lambda) s - \mu \mathbf{1}$$

  - Cieľom je nájsť vektory x, $s \geq \mathbf{0}$, $\lambda \geq \mathbf{0}$ také že všetky reziduá budú nulové

$$r_1(x, \lambda) = \mathbf{0}, r_2(x, s) = \mathbf{0}, r_3(s, \lambda, \mu) = \mathbf{0}$$

Reziduá podmienok optimálnosti a ich Jakobián

- Spojený vektor hľadaných premenných $\theta \in \mathbb{R}^{n+q+q}$ bude

$$\theta = \begin{bmatrix} x \\ \lambda \\ s \end{bmatrix}$$

- Spojená funkcia reziduí bude $r(\theta) \in \mathbb{R}^{n+q+q}$

$$r(\theta) = \begin{bmatrix} r_1(\theta) \\ r_2(\theta) \\ r_3(\theta) \end{bmatrix} = \begin{bmatrix} \nabla J(x) + {A_c}^T \lambda \\ A_c x - b_c + s \\ \mathrm{diag}(\lambda) s - \mu \mathbf{1} \end{bmatrix}$$

- Nájdime teraz Jakobián reziduí $\nabla r(\theta) \in \mathbb{R}^{n+q+q \times n+q+q}$ ako

$$\nabla r(\theta) = \begin{pmatrix} \nabla_x r_1(\theta) & \nabla_\lambda r_1(\theta) & \nabla_s r_1(\theta) \\ \nabla_x r_2(\theta) & \nabla_\lambda r_2(\theta) & \nabla_s r_2(\theta) \\ \nabla_x r_3(\theta) & \nabla_\lambda r_3(\theta) & \nabla_s r_3(\theta) \end{pmatrix} = \begin{pmatrix} \nabla^2 J(x) & {A_c}^T & \mathbf{0} \\ A_c & \mathbf{0} & I \\ \mathbf{0} & \mathrm{diag}(s) & \mathrm{diag}(\lambda) \end{pmatrix}$$

Hľadanie riešenia v zmysle Newtonovej metódy

- Cieľom je nájsť také θ^* že $r(\theta^*) = \mathbf{0}$ a teda všetky reziduá budú nulové
- Môžeme použiť iteratívny algoritmus – Newtonovu metódu
- Krok $\Delta\theta_{k+1}$ nech spĺňa sústavu lineárnych rovníc

$$\nabla r(\theta_k)\Delta\theta_{k+1} = -r(\theta_k)$$

$$\begin{pmatrix} \nabla^2 J(x) & {A_c}^T & \mathbf{0} \\ A_c & \mathbf{0} & I \\ \mathbf{0} & \mathrm{diag}(s) & \mathrm{diag}(\lambda) \end{pmatrix}_{\substack{x=x_k,\\ \lambda=\lambda_k,\\ s=s_k,}} \begin{bmatrix} \Delta x_{k+1} \\ \Delta\lambda_{k+1} \\ \Delta s_{k+1} \end{bmatrix} = - \begin{bmatrix} \nabla J(x) + {A_c}^T\lambda \\ A_c x - b_c + s \\ \mathrm{diag}(\lambda)s - \mu\mathbf{1} \end{bmatrix}_{\substack{x=x_k,\\ \lambda=\lambda_k,\\ s=s_k,}}$$

- Nová aproximácia optima však musí spĺňať podmienky $\lambda_{k+1} \geq \mathbf{0}$, $s_{k+1} \geq \mathbf{0}$
- Definujme si preto skalár (tlmenie) $0 \leq \gamma \leq 1$ tak aby sme zabezpečili

$$\begin{pmatrix} \lambda_k + \gamma\Delta\lambda_{k+1} \\ s_k + \gamma\Delta s_{k+1} \end{pmatrix} \geq \mathbf{0}$$

- Odhad θ_{k+1} potom aktualizujeme ako

$$\theta_{k+1} = \theta_k + \gamma\Delta\theta_{k+1}$$

- Pokračujeme s novým KKT systémom až do splnenia podmienky (veľkosť rezidua)

$$\left(r(\theta_k)\right)^T r(\theta_k) < \epsilon$$

- Faktor μ môžeme zvoliť ako:

$$\mu = \frac{\lambda^T s}{2q}$$

Kinematický model mobilného robota

- Mobilný robot s diferenciálnym podvozkom sa pohybuje v 2D priestore
- Uvažujme jeho kinematický model v spojitom tvare

$$\dot{X}(t) = v(t)\cos(\theta(t))$$
$$\dot{Y}(t) = v(t)\sin(\theta(t))$$
$$\dot{\theta}(t) = \omega(t)$$

  - $X(t), Y(t)$ sú jeho súradnice v priestore
  - $\theta(t)$ je uhol natočenia (orientácia)
  - $v(t)$ je dopredná rýchlosť pohybu
  - $\omega(t)$ je uhlová rýchlosť otáčania

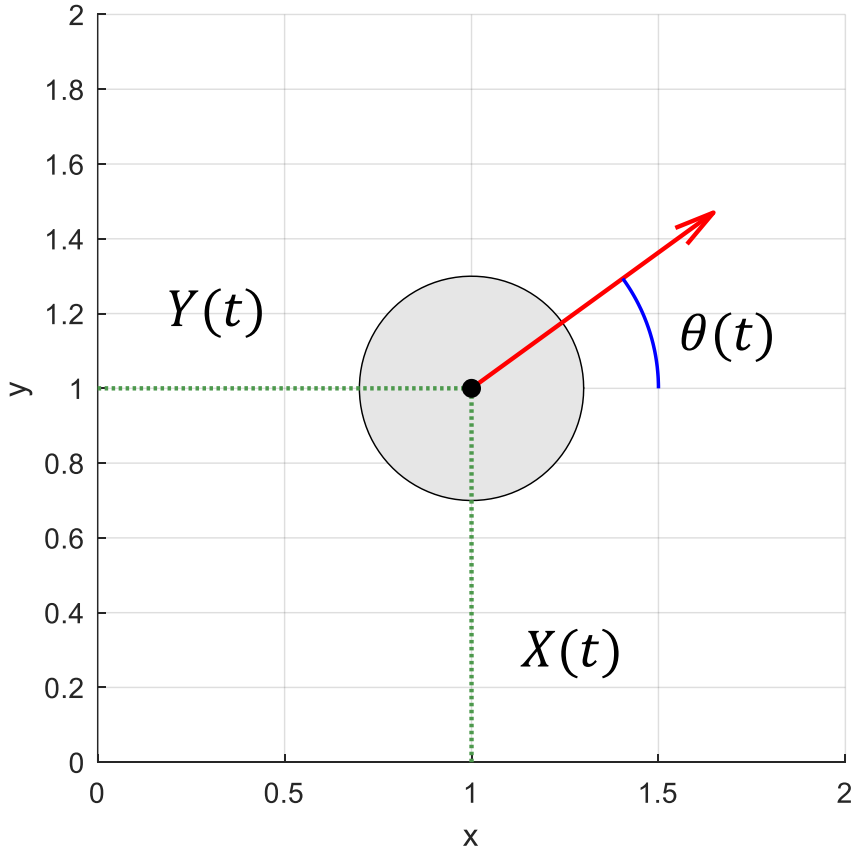
- Stavový vektor a vektor vstupov:

$$x(t) = \begin{pmatrix} X(t) \\ Y(t) \\ \theta(t) \end{pmatrix} \quad u(t) = \begin{pmatrix} v(t) \\ \omega(t) \end{pmatrix}$$

- Jakobiány modelu budú

$$\frac{\partial f(x(t),u(t))}{\partial x(t)} = \begin{pmatrix} 0 & 0 & -\sin(\theta(t))v(t) \\ 0 & 0 & \cos(\theta(t))v(t) \\ 0 & 0 & 0 \end{pmatrix}$$

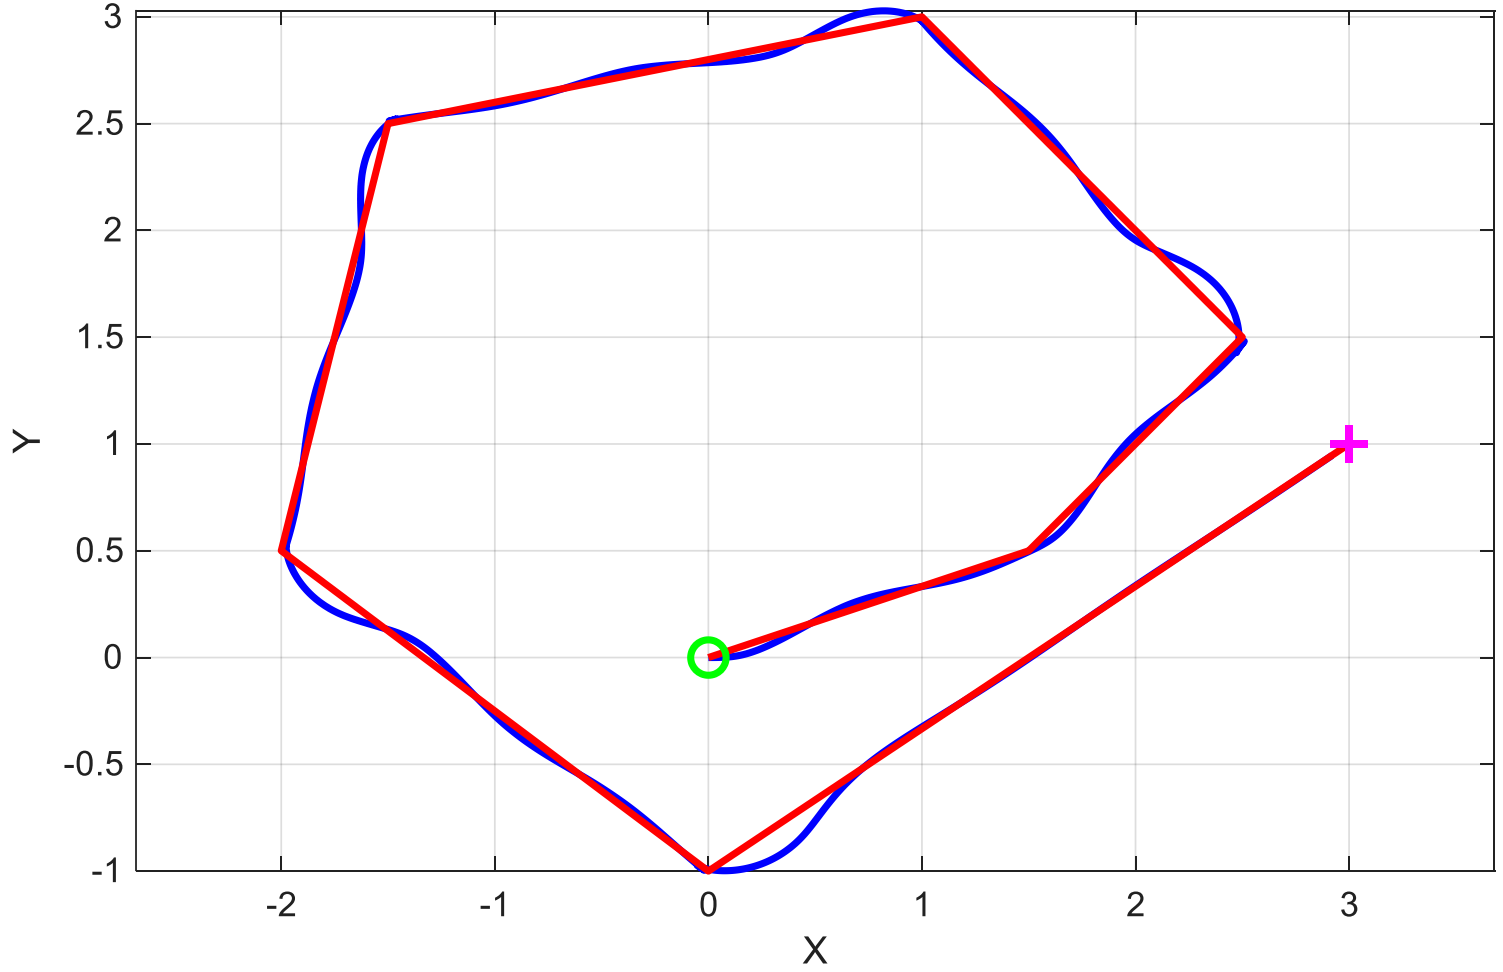
$$\frac{\partial f(x(t),u(t))}{\partial u(t)} = \begin{pmatrix} \cos(\theta(t)) & 0 \\ \sin(\theta(t)) & 0 \\ 0 & 1 \end{pmatrix}$$

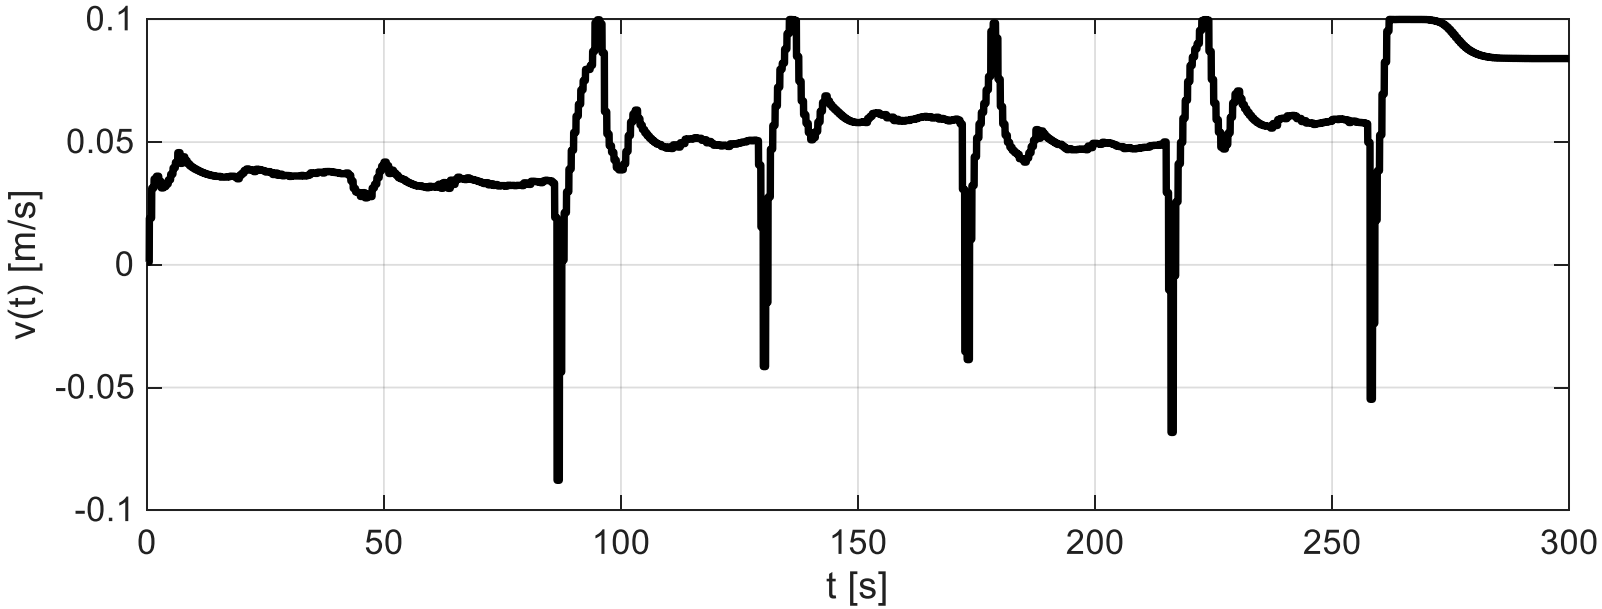


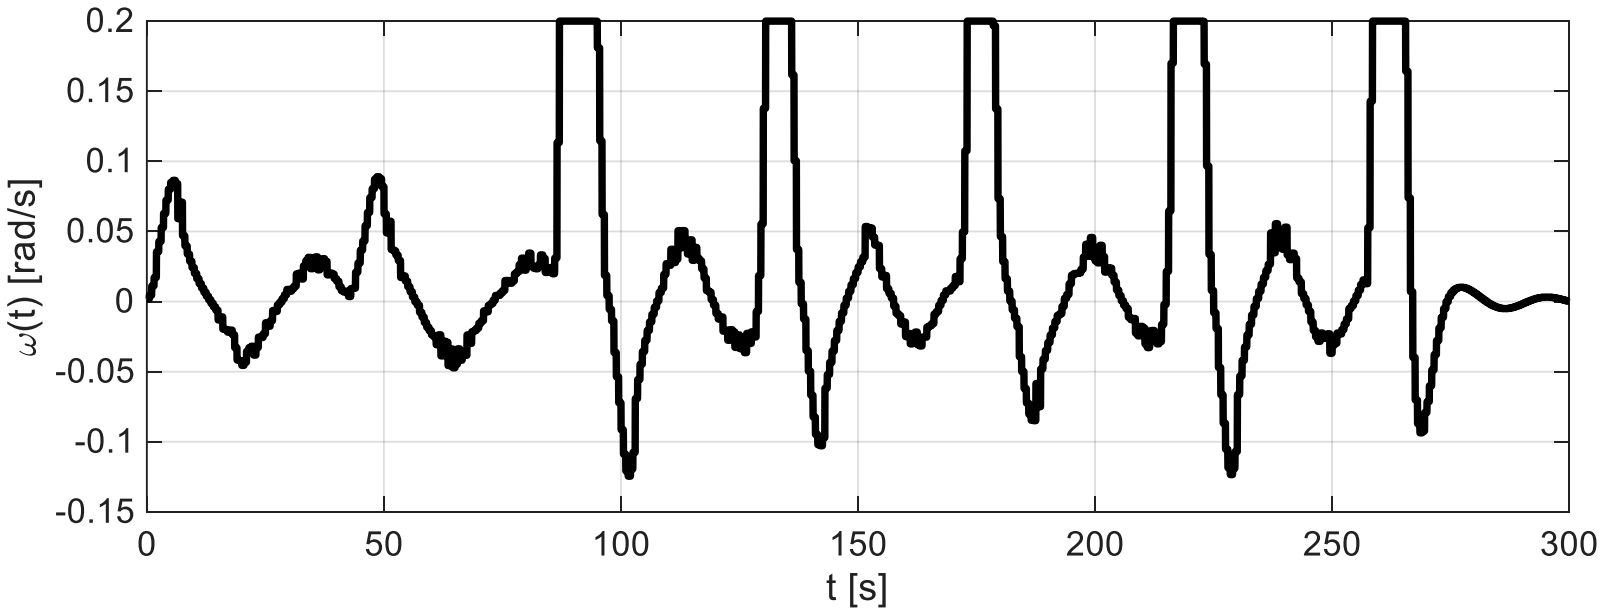
Nelineárne MPC mobilného robota

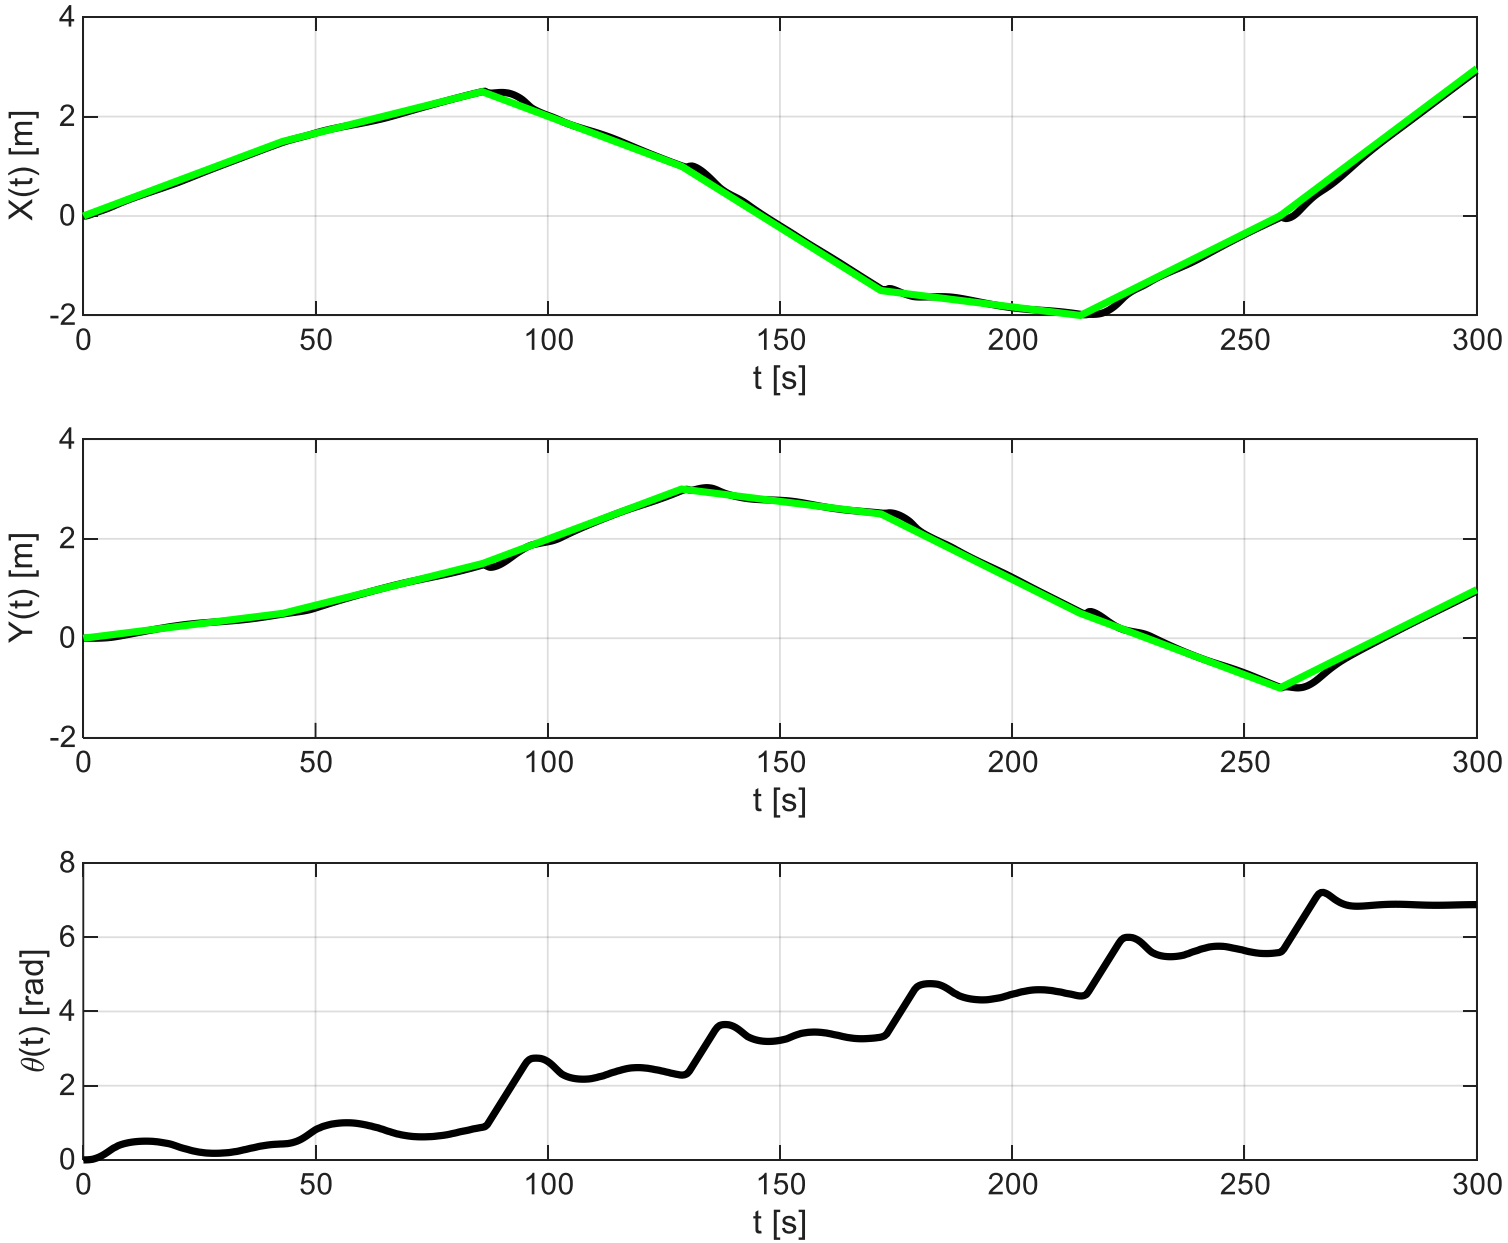
$$J(U(k)) = \frac{1}{2}\sum_{i=1}^{p}\left(x\left((k+i)T_s\right) - x_r\left((k+i)T_s\right)\right)^T Q\left(x\left((k+i)T_s\right) - x_r\left((k+i)T_s\right)\right) + \left(u\left((k+i-1)T_s\right)\right)^T R\left(u\left((k+i-1)T_s\right)\right)$$

$$Q = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \qquad R = \begin{pmatrix} 0.1 & 0 \\ 0 & 0.2 \end{pmatrix}, \qquad \begin{pmatrix} -0.2 \\ -0.3 \end{pmatrix} \leq \begin{pmatrix} v(k) \\ \omega(k) \end{pmatrix} \leq \begin{pmatrix} 0.2 \\ 0.3 \end{pmatrix}, \qquad p = 20$$




0.1
0.05
0
-0.05
-0.1
v(t) [m/s]
0
50
100
150
200
250
300
t [s]


0.2
0.15
0.1
0.05
0
-0.05
-0.1
-0.15
ω(t) [rad/s]
0
50
100
150
200
250
300
t [s]


X(t) [m]
t [s]
Y(t) [m]
t [s]
θ(t) [rad]
t [s]